Tema 5: Sistemas de recuperación de la información, RAG y Langchain

EBIS Business Techschool

Contenidos

- Fundamentos matemáticos de la recuperación de información
- Representación de la información I: Sparse vs Dense
- Representación de la información II: Métodos modernos de retrieval
- Indexación y búsqueda eficiente
- Sistemas de almacenamiento y recuperación
- Construcción y evaluación de sistemas de recuperación
- Retrieval Augmented Generation

www.ebiseducation.com

Agenda de la sesión

EBIS Business Techschool

El problema de la recuperación de información

Partiremos del problema fundamental: cómo determinar qué elementos son más relevantes o similares ante una consulta y por qué necesitamos representaciones matemáticas para hacerlo.

Vectores y espacios vectoriales

Introduciremos los vectores como representación matemática de la información, estudiando sus principales propiedades, operaciones y su interpretación geométrica.

Distancias entre vectores

Analizaremos diferentes formas de cuantificar la separación entre puntos de un espacio vectorial, incluyendo las distancias euclídea, Manhattan y Minkowski.

Similitud entre vectores

Estudiaremos medidas orientadas a determinar el grado de semejanza entre representaciones, con especial atención al producto escalar y la similitud del coseno.

De la geometría a la recuperación de información

Aplicaremos estos conceptos para ordenar elementos por relevancia y entenderemos cómo distancia y similitud constituyen la base de los sistemas modernos de recuperación

Recap & Q&A

Resumen de conceptos clave y resolución de dudas.

El problema de la recuperación de información

EBIS Business Techschool

¿Qué significa recuperar información?

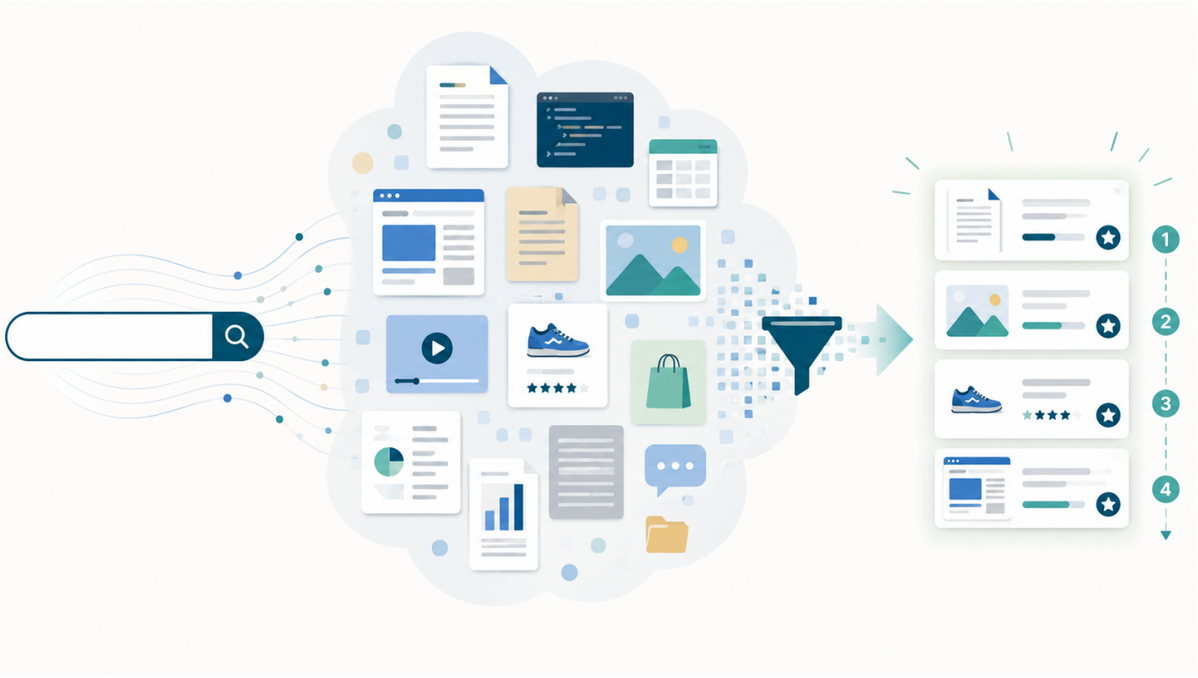

Un problema que utilizamos constantemente

Cuando realizamos una búsqueda, partimos de una **necesidad de información** expresada mediante una consulta y esperamos obtener, entre una gran colección de elementos, aquellos que mejor responden a lo que necesitamos.

Mucho más que buscar documentos

Un sistema de recuperación puede trabajar con páginas web, documentos, productos, imágenes, vídeos o cualquier otro tipo de información.

El problema siempre es similar: encontrar los elementos más relevantes para una consulta concreta

Consulta → Colección de información → Resultados relevantes

El problema de la relevancia

EBIS Business Techschool

Recuperar información no consiste simplemente en encontrar elementos que contengan las mismas palabras que aparecen en una consulta. El objetivo es determinar **qué resultados responden mejor a la necesidad del usuario**.

Cómo aumentar la autonomía de mi portátil

Reddit · r/GamingLaptops

Más de 70 comentarios · Hace 1 año

Consejos para prolongar la duración de la batería de un ordenador

Técnicas para reducir el consumo energético y aumentar el tiempo de uso entre cargas

Xataka

https://www.xataka.com > seleccion > mejores-power-b...

Las mejores baterías portátiles para viajar

5 may 2026 — En Xataka, consideramos que a día de hoy, la batería externa **Xiaomi 212w Hypercharge Power Bank 25000** es la mejor opción, sobre todo para...

Alta relevancia, aunque utiliza palabras diferentes

Baja relevancia, aunque comparte palabras con la consulta

La relevancia depende del **significado, la intención y el contexto**, no únicamente de la coincidencia literal de términos

De la información a una representación matemática

EBIS Business Techschool

Un sistema informático no puede comparar directamente el **significado** de un texto, una imagen o un producto. Para poder operar con ellos necesitamos convertir la información en una **representación matemática comparable**.

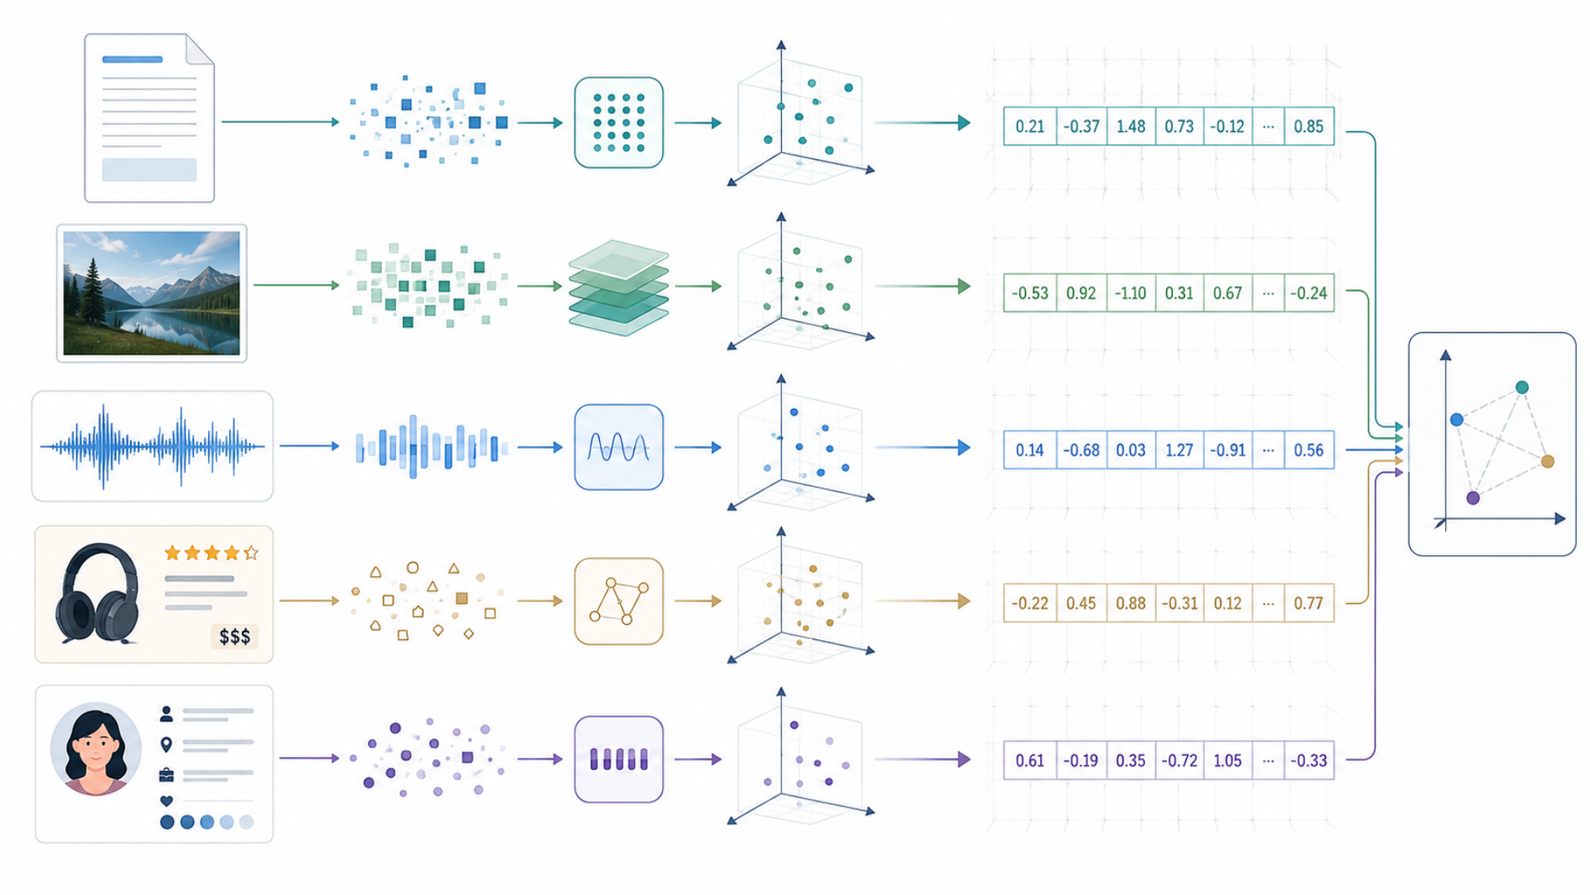

Una representación transforma un objeto complejo en un conjunto estructurado de valores sobre los que podemos realizar operaciones matemáticas.

Representar, comparar y ordenar

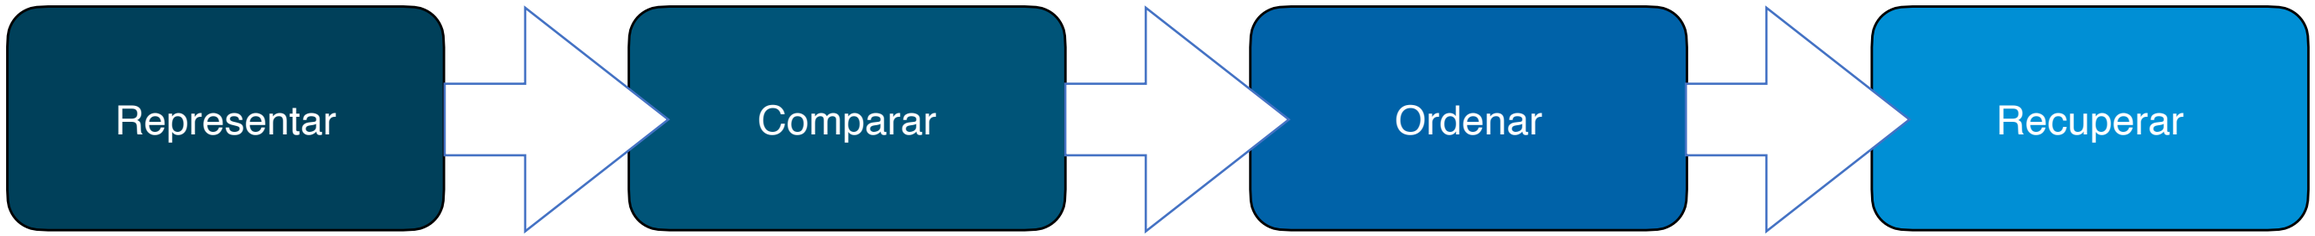

Transformar la información en una representación matemática.

Cuantificar la relación entre la consulta y cada elemento candidato.

Asignar una puntuación y priorizar los elementos más relevantes.

Devolver los mejores resultados al usuario o al sistema que realiza la consulta.

Recuperar información implica disponer de una representación y de un criterio que permita comparar y ordenar candidatos.

¿Cómo podemos comparar matemáticamente dos representaciones vectoriales?

Vectores y espacios vectoriales

EBIS Business Techschool

¿Qué es realmente un vector?

EBIS Business Techschool

Un vector es una **colección ordenada de valores numéricos** que podemos tratar como una única entidad matemática. Cada valor constituye una **componente** y ocupa una posición determinada dentro del vector.

$$\mathbf{v} = (v_1, v_2, \ldots, v_n) \in \mathbb{R}^n$$

Orden

La posición de cada componente importa.

Componentes

Un vector con *n* componentes tiene dimensión *n*.

Representación

El significado de sus valores depende de aquello que estemos representando.

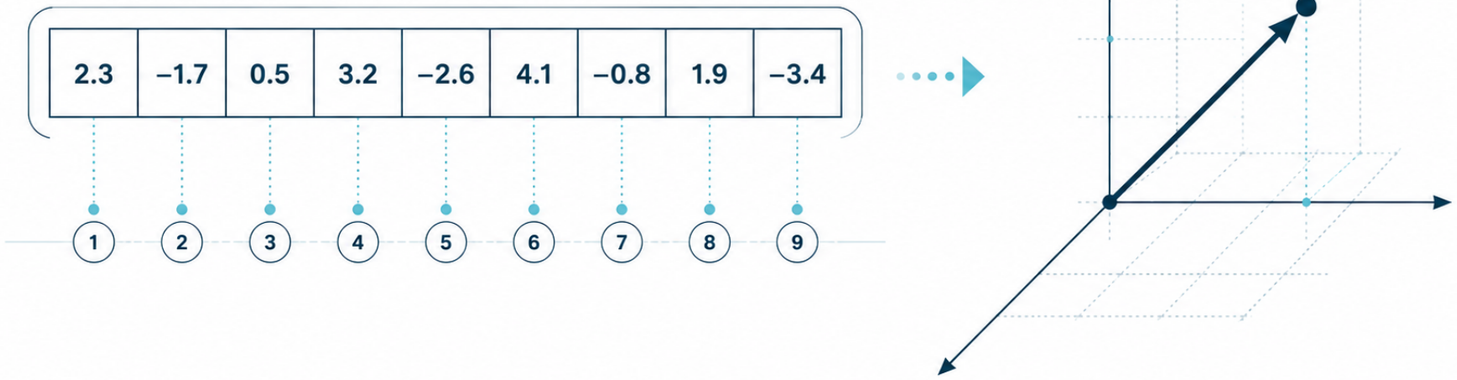

Antes de medir si dos representaciones son similares, necesitamos entender qué estamos comparando.

Componentes y dimensionalidad

La **dimensionalidad** de un vector indica cuántos valores necesitamos para describirlo. Un vector formado por *n* componentes pertenece a un espacio de *n* dimensiones.

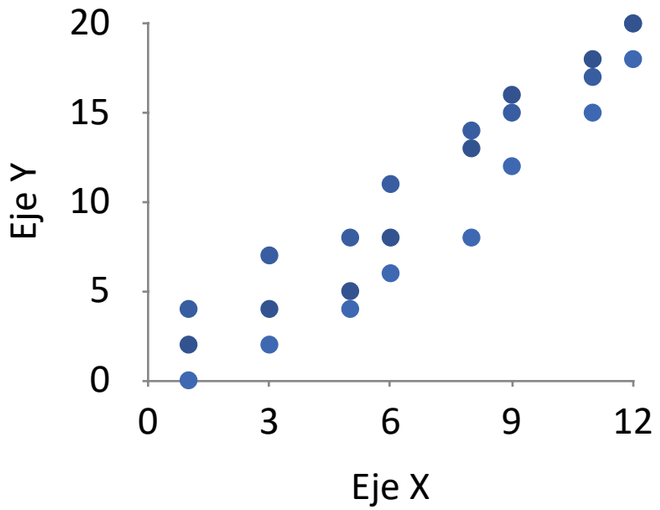

2 componentes - 2 dimensiones

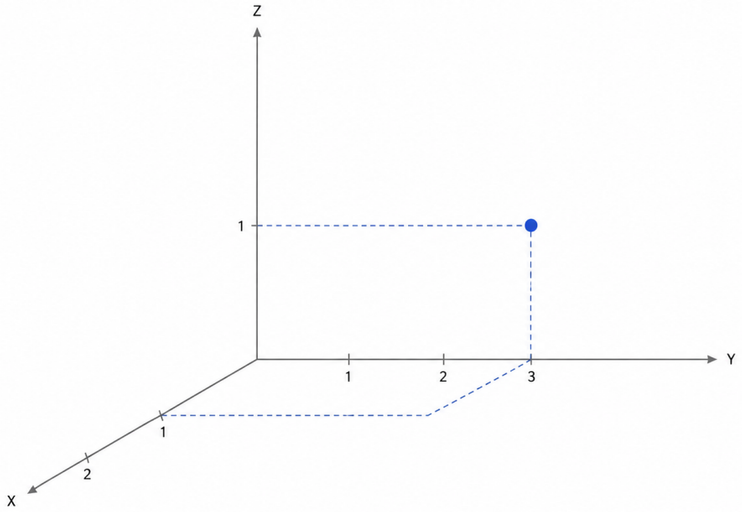

3 componentes - 3 dimensiones

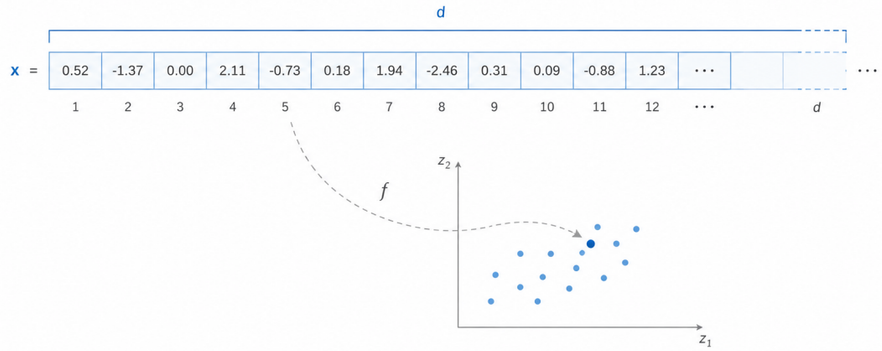

***n* componentes - *n* dimensiones**

En aplicaciones reales podemos trabajar con **cientos o miles de dimensiones**, aunque únicamente podamos visualizar directamente espacios de dos o tres dimensiones.

El significado de las componentes depende del tipo de representación: algunas son directamente interpretables y otras no

Del vector al espacio geométrico

Los valores de un vector pueden interpretarse como **coordenadas dentro de un espacio**. Geométricamente, un vector puede visualizarse como un punto o como un desplazamiento desde el origen.

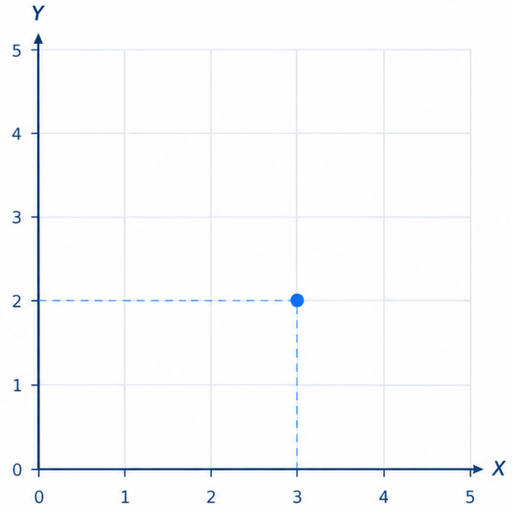

Como punto

El vector determina una posición concreta dentro del espacio.

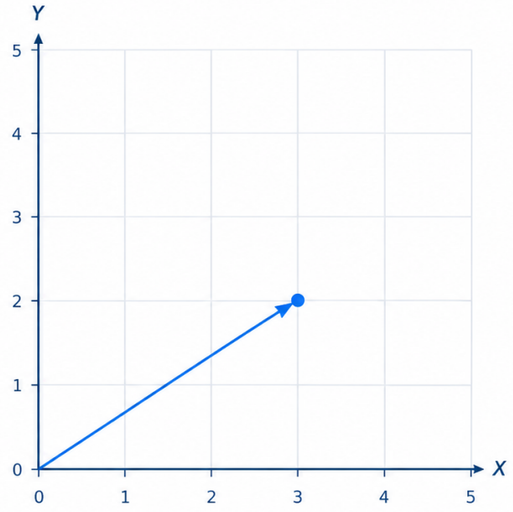

Como desplazamiento

También podemos representarlo mediante una flecha desde el origen hasta ese punto.

Posición

Dónde se encuentra el vector

Dirección

Hacia dónde apunta respecto al origen

Magnitud

Qué longitud tiene

Operaciones básicas con vectores

Los vectores pueden combinarse y transformarse mediante operaciones matemáticas. En los casos de suma y resta, los vectores deben tener la **misma dimensionalidad**.

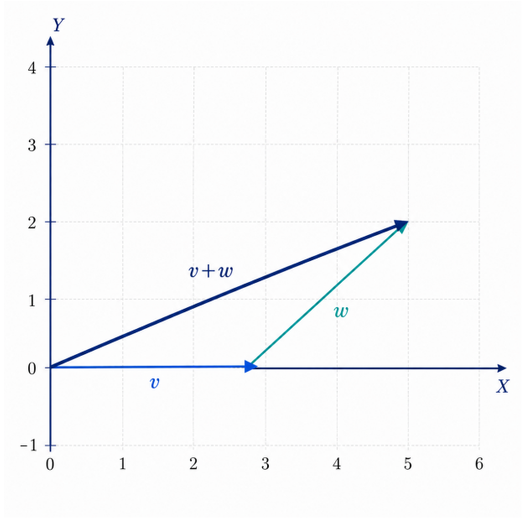

Suma

$$\mathbf{v} + \mathbf{w} = \left(v_1 + w_1, v_2 + w_2, \ldots, v_n + w_n\right)$$

Combina las componentes de ambos vectores

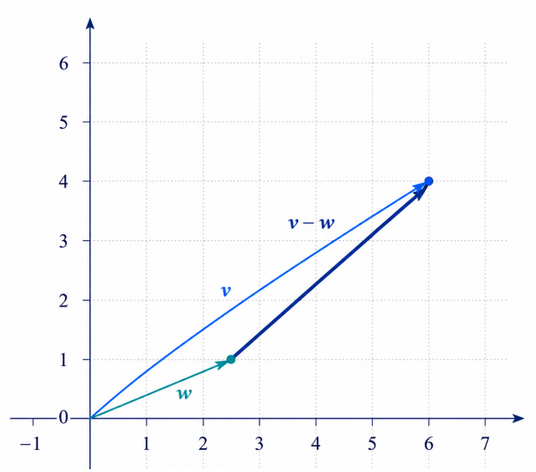

Resta

$$\mathbf{v} - \mathbf{w} = \left(v_1 - w_1, v_2 - w_2, \ldots, v_n - w_n\right)$$

Representa la diferencia o desplazamiento entre ambos

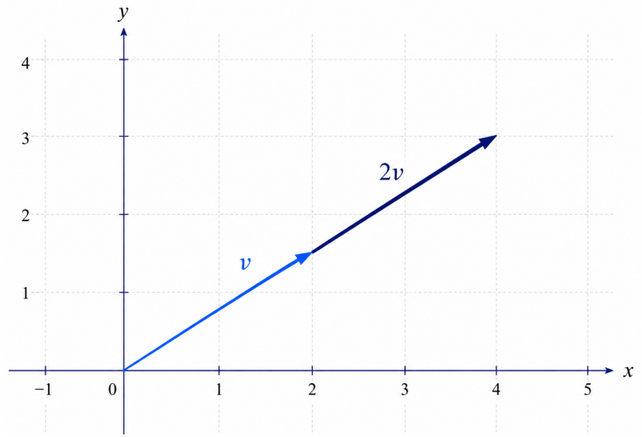

Multiplicación por un escalar

$$\lambda \cdot \mathbf{w} = \left(\lambda \cdot w_1, \lambda \cdot w_2, \ldots, \lambda \cdot w_n\right)$$

Modifica la escala del vector manteniendo su dirección si el escalar es positivo

Estas operaciones permiten construir y transformar representaciones dentro de un mismo espacio vectorial.

Magnitud y normalización

EBIS Business Techschool

Magnitud

La **norma** de un vector cuantifica la longitud de este respecto al origen. La norma euclídea o L2 se calcula como:

$$||\mathbf{v}||_2 = \sqrt{(v_1^2 + v_2^2 + \cdots + v_n^2)}$$

Ejemplo:

$$\mathbf{v} = (3,2) \in \mathbb{R}^2$$

$$||\mathbf{v}||_2 = \sqrt{3^2 + 4^2} = 5$$

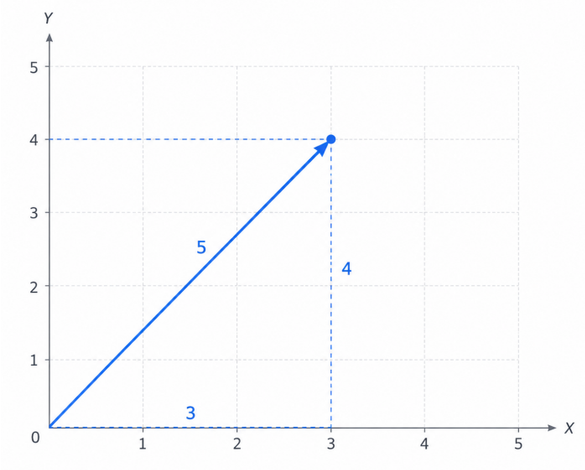

Normalización

Normalizar un vector consiste en dividir todas sus componentes por su norma:

$$\mathbf{v}' = \frac{\mathbf{v}}{||\mathbf{v}||_2}$$

Ejemplo:

$$\mathbf{v} = (3,2) \in \mathbb{R}^2$$

$$\mathbf{v}' = \left(\frac{3}{5}, \frac{2}{5}\right)$$

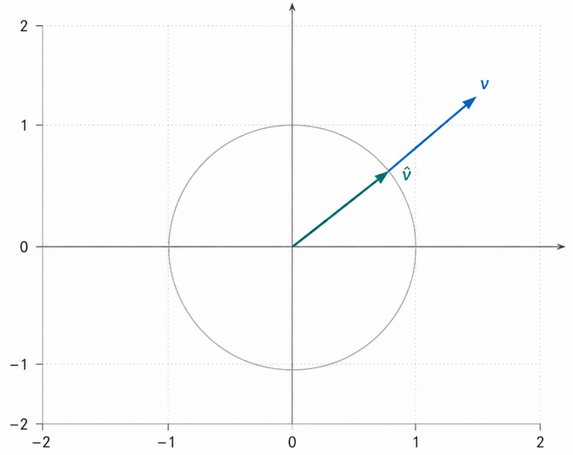

El vector resultante mantiene la **misma dirección**, pero pasa a tener magnitud 1.

Normalizar elimina la escala sin modificar la dirección del vector.

De vectores a espacios vectoriales

Un **espacio vectorial** es un conjunto de vectores sobre el que podemos realizar operaciones como la suma de vectores y la multiplicación por escalares manteniéndonos dentro del propio espacio.

Dimensión

Número de dimensiones independientes necesarias para describir el espacio.

Base

Conjunto de vectores que define las direcciones de referencia utilizadas para expresar sus coordenadas.

Combinación lineal

Los vectores del espacio pueden construirse combinando los vectores de una base mediante sumas y multiplicaciones por escalares.

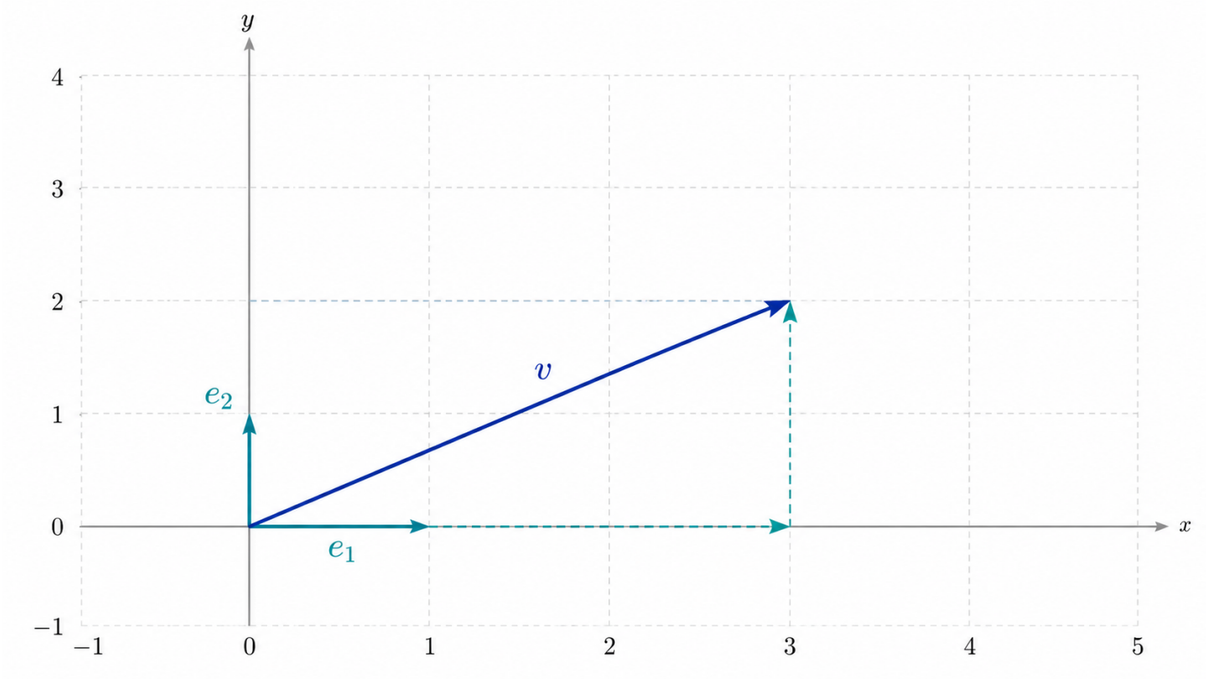

$$\mathbf{v} = \lambda_1 \cdot \mathbf{e}_1 + \lambda_2 \cdot \mathbf{e}_2 + \cdots + \lambda_n \cdot \mathbf{e}_n$$

Cuando representamos distintos elementos dentro de un **espacio común**, podemos estudiar matemáticamente las relaciones existentes entre sus vectores. Pero, **¿cómo cuantificamos la separación entre dos vectores?**

Distancias entre vectores

EBIS Business Techschool

¿Qué significa medir la distancia entre dos vectores?

EBIS Business Techschool

Una función de distancia asigna un **valor numérico a la separación existente entre dos vectores**. Cuanto menor sea ese valor, más próximos se encuentran ambos elementos según el criterio utilizado

$$d(\mathbf{v}, \mathbf{w}) = a \in \mathbb{R}^{+}$$

Cercanía

Una distancia pequeña indica que los vectores se encuentran próximos dentro del espacio.

Ranking

Podemos ordenar candidatos según su distancia respecto a una consulta.

Dependencia de la métrica

Distintas formas de medir la distancia pueden producir distintos resultados.

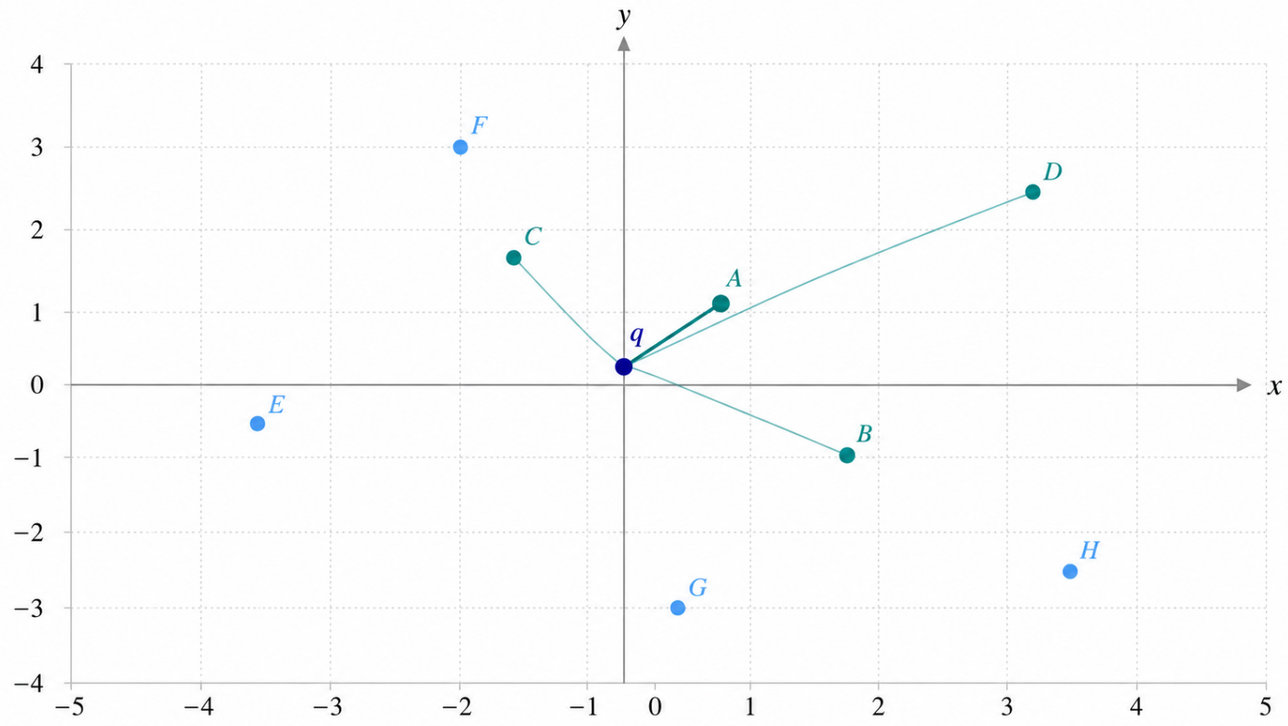

En recuperación de información, **“más cercano” no tiene significado hasta que definimos cómo vamos a medir la distancia**.

Distancia euclídea

La distancia euclídea mide la **longitud de la línea recta** que une dos puntos dentro de un espacio vectorial.

$$d_2(\mathbf{v},\mathbf{w}) = ||\mathbf{v}-\mathbf{w}||_2 = \sqrt{(v_1-w_1)^2+(v_2-w_2)^2+\cdots+(v_n-w_n)^2}$$

Ejemplo:

$$\mathbf{v} = (1,2) \in \mathbb{R}^2$$

$$\mathbf{w} = (4,6) \in \mathbb{R}^2$$

$$d_2(\mathbf{v},\mathbf{w}) = \sqrt{(1-4)^2+(2-6)^2} = 5$$

Menor distancia → Mayor proximidad

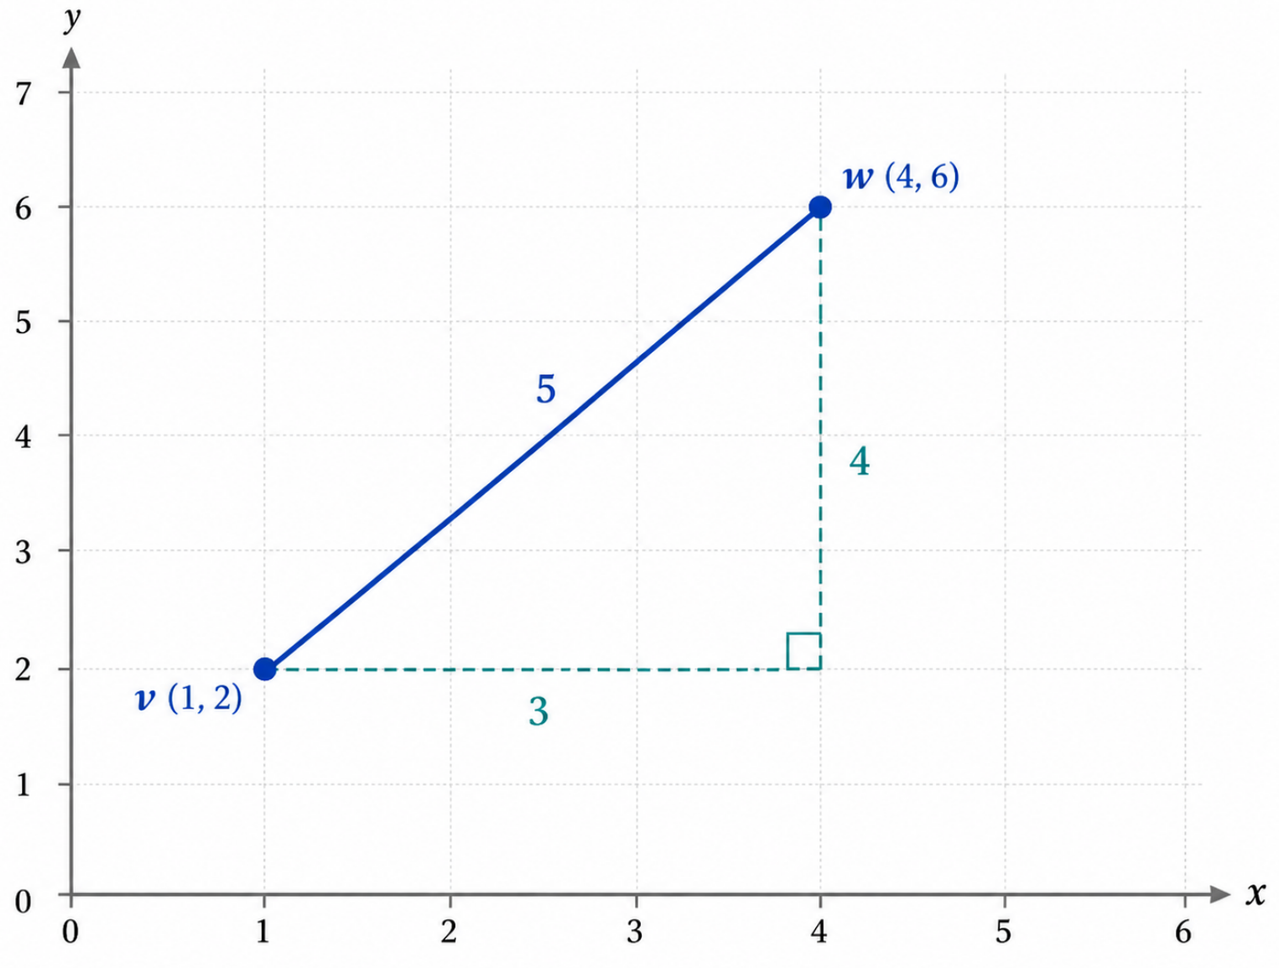

Distancia Manhattan

EBIS Business Techschool

La distancia Manhattan mide la separación entre dos vectores como la **suma de las diferencias absolutas de sus componentes**.

$$d_1(\mathbf{v},\mathbf{w}) = ||\mathbf{v}-\mathbf{w}||_1 = \left|v_1 - w_1\right| + \left|v_2 - w_2\right| + \cdots + \left|v_n - w_n\right|$$

Ejemplo:

$$\mathbf{v} = (1,2) \in \mathbb{R}^2$$

$$\mathbf{w} = (4,6) \in \mathbb{R}^2$$

$$d_1(\mathbf{v},\mathbf{w}) = \left|1-4\right| + \left|2-6\right| = 3+4 = 7$$

Menor distancia → Mayor proximidad

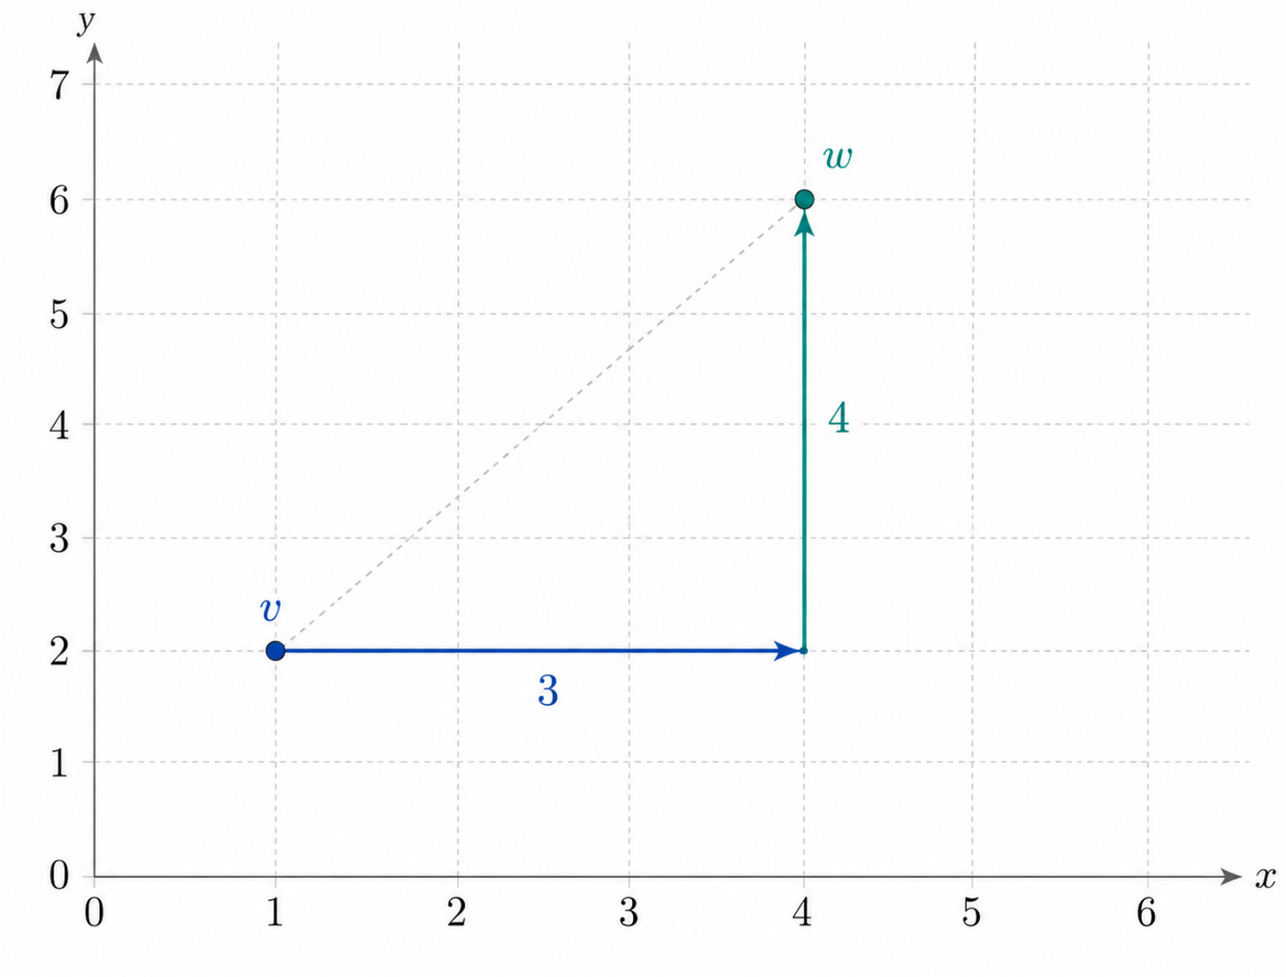

Una familia de distancias: Minkowski

La distancia de Minkowski generaliza distintas métricas mediante un único parámetro ***p***, que determina cómo se combinan las diferencias entre componentes.

$$d_p(\mathbf{v}, \mathbf{w}) = \left(\sum_{i=1}^{n} \left| v_i - w_i \right|^p \right)^{1/p}$$

p = 1 **Manhattan**

p = 2 **Euclídea**

p → ∞ **Chebyshev**

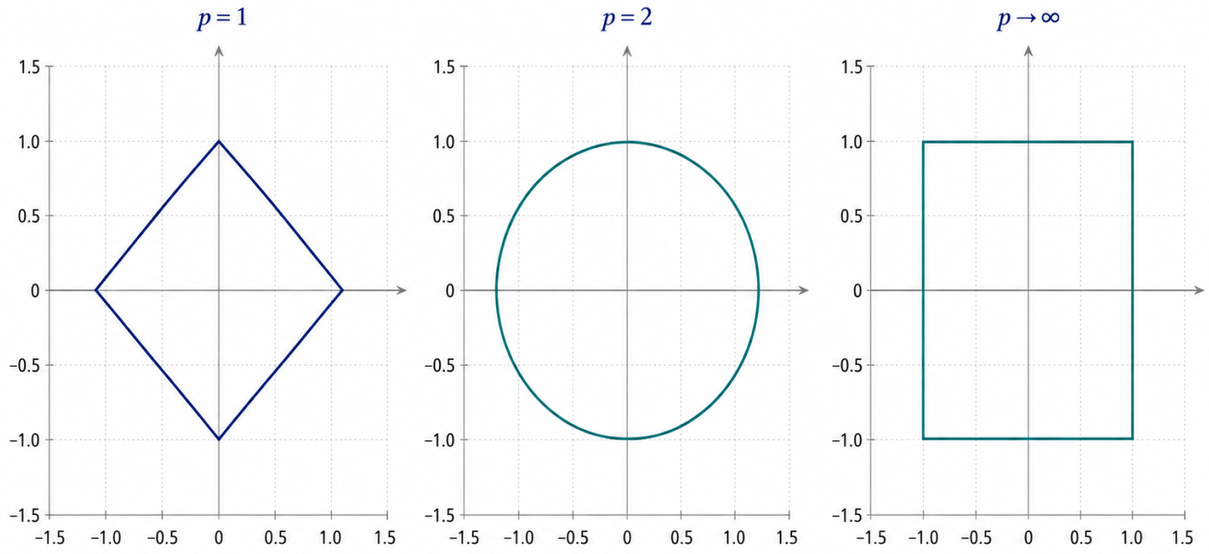

Menor distancia → Mayor proximidad

La métrica cambia quién es tu vecino

Dos candidatos pueden intercambiar su orden de proximidad dependiendo de la métrica utilizada. Por tanto, la elección de distancia puede modificar directamente el **ranking de resultados**.

En el gráfico, si queremos ver el punto más cercano a *q*, tendremos que:

Si usamos distancia **euclídea**, el punto más cercano será el **punto A**.

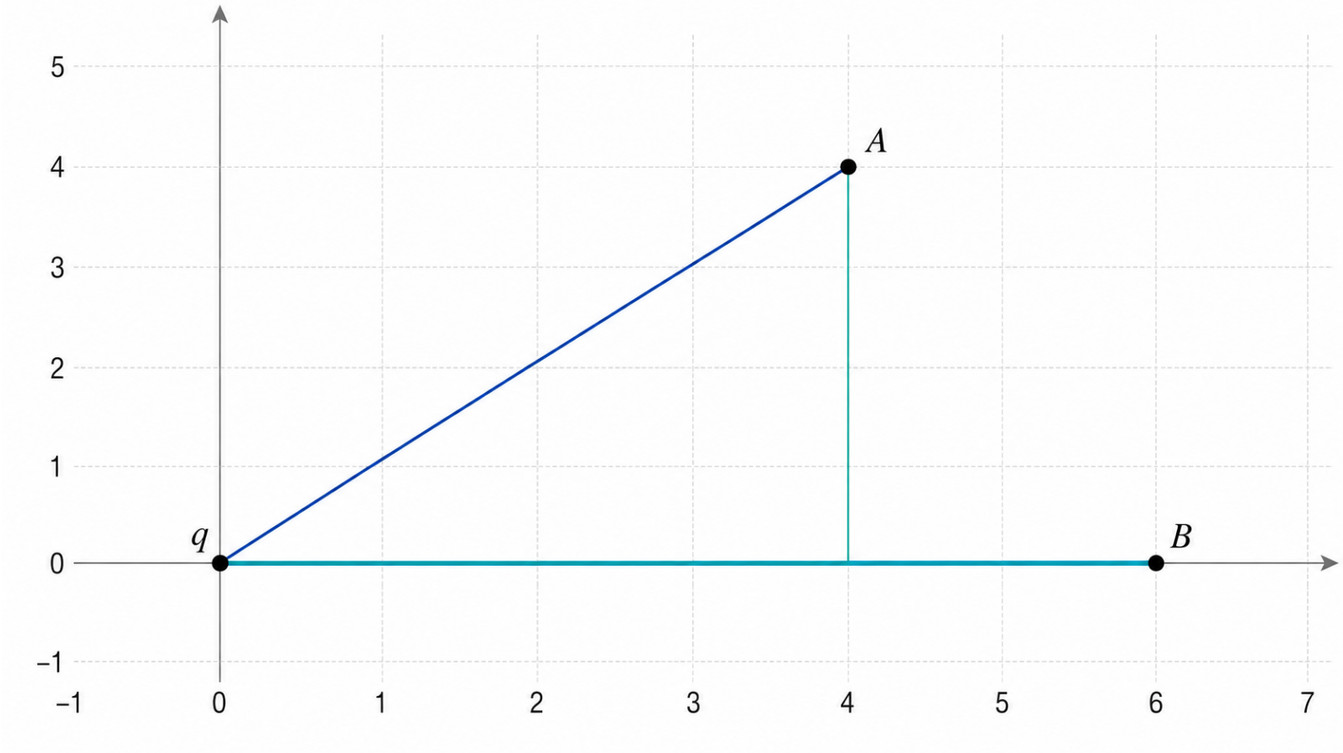

Si usamos distancia **Manhattan**, el punto más cercano será el **punto B**.

La métrica no es únicamente una decisión matemática: **forma parte del diseño del sistema de recuperación**.

La distancia también depende de la escala

EBIS Business Techschool

Cuando las componentes representan magnitudes con escalas muy diferentes, aquellas con valores numéricos mayores pueden **dominar artificialmente el cálculo de la distancia**.

Componente	Usuario A	Usuario B
Edad	25	35
Ingresos (€)	30.000	50.000

Diferencia: 10

Diferencia: 20.000

Sin un tratamiento adecuado, la distancia estará prácticamente determinada por los ingresos.

¿Qué podemos hacer al respecto?

Normalizar o escalar las variables antes de calcular distancias cuando sus magnitudes no son directamente comparables.

Una distancia solo tiene sentido si la representación sobre la que se calcula también lo tiene.

Similitud entre vectores

EBIS Business Techschool

De la distancia a la similitud

Hasta ahora hemos cuantificado cuánto se **separan** dos vectores. También podemos abordar el problema desde la perspectiva contraria: medir hasta qué punto dos representaciones son **similares**.

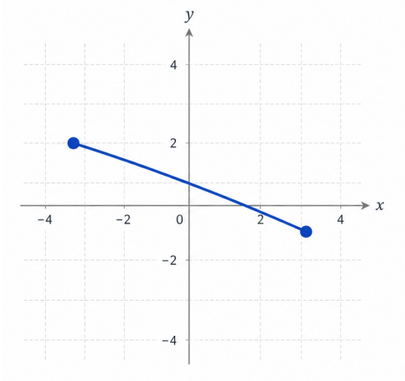

DISTANCIA

Menor valor → Mayor proximidad

Mide cuánto debemos desplazarnos de un vector a otro dentro del espacio.

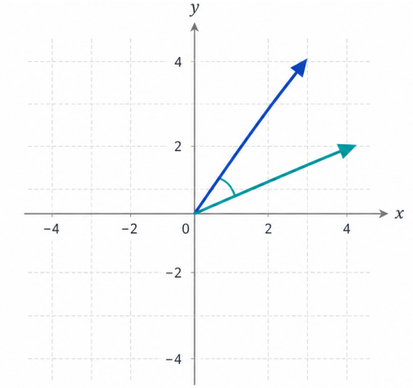

SIMILITUD

Mayor valor → Mayor semejanza

Asigna una puntuación que refleja cuánto se parecen dos vectores según un criterio determinado.

Distancia y similitud no son conceptos opuestos de forma universal: distintas funciones capturan propiedades diferentes de los vectores.

En representaciones vectoriales, una de las medidas más utilizadas es la **similitud del coseno**, basada principalmente en la dirección de los vectores.

Producto escalar

El producto escalar combina dos vectores de la misma dimensionalidad y produce un **único valor numérico** multiplicando sus componentes correspondientes y sumando los resultados.

$$\mathbf{v} \cdot \mathbf{w} = \sum_{i=1}^{n} v_i \cdot w_i = ||\mathbf{v}||_2 \cdot ||\mathbf{w}||_2 \cdot \cos\theta$$

Ejemplo:

$$\mathbf{v} = (2,1) \in \mathbb{R}^2$$

$$\mathbf{w} = (3,4) \in \mathbb{R}^2$$

$$\mathbf{v} \cdot \mathbf{w} = ||\mathbf{v}|| \cdot ||\mathbf{w}|| = 2 \cdot 3 + 1 \cdot 4 = 10$$

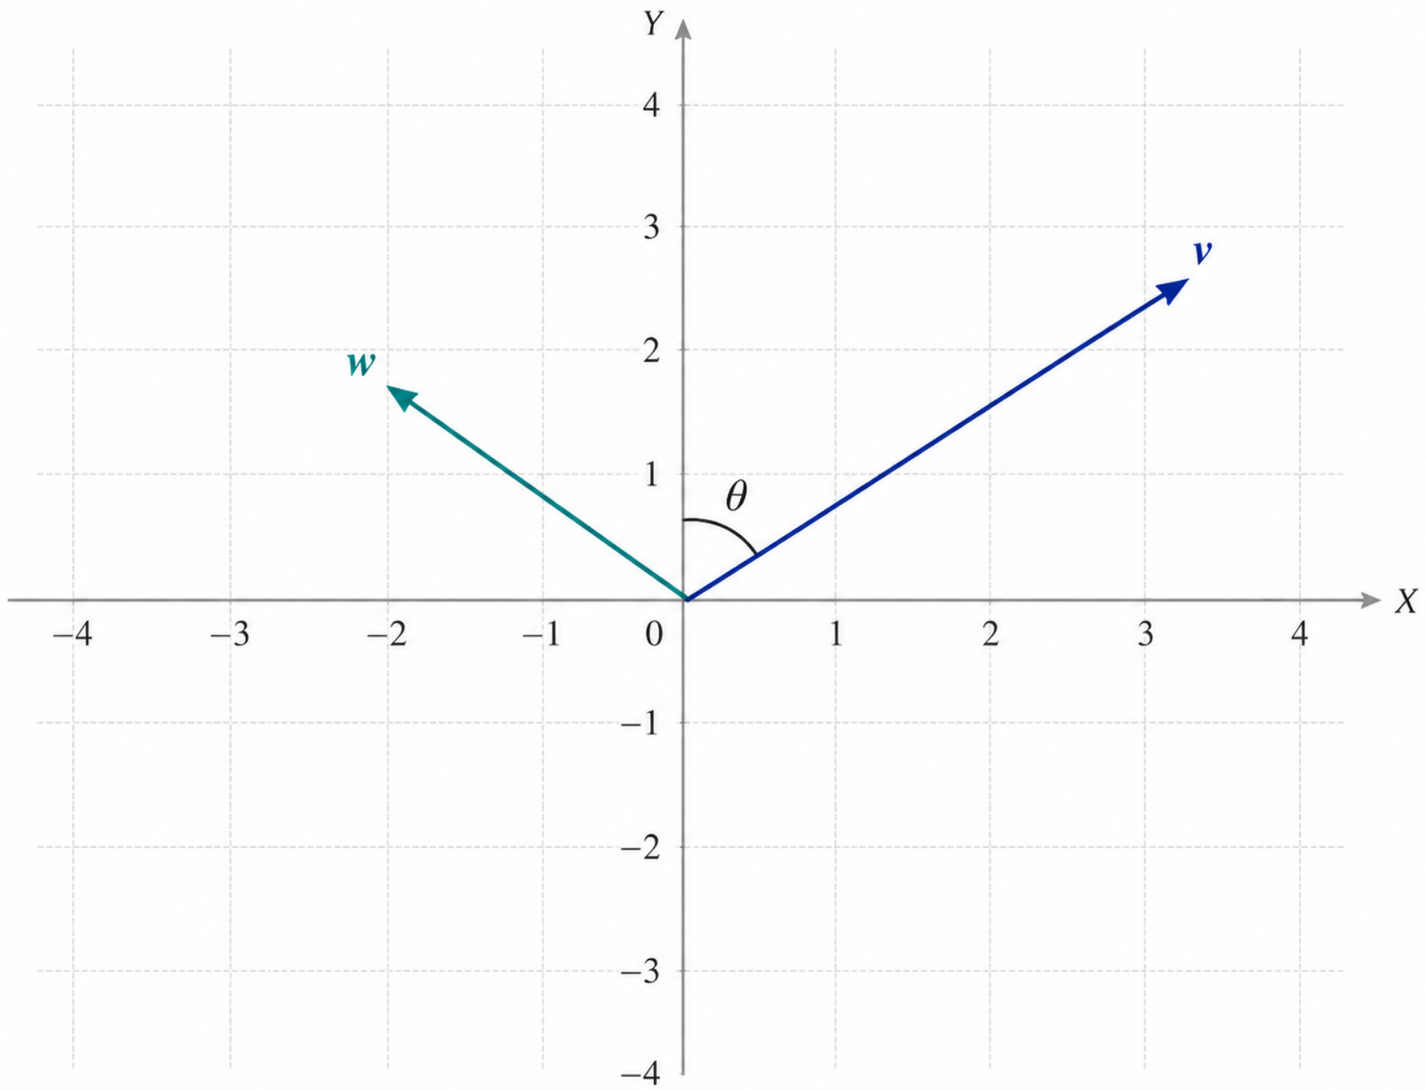

Similitud del coseno

La similitud del coseno mide el grado de alineación entre dos vectores a partir del **ángulo que forman**, reduciendo la influencia de sus magnitudes

$$\cos_{sim}(\mathbf{v}, \mathbf{w}) = \frac{v \cdot w}{||v||_2 \cdot ||w||_2}$$

Interpretación:

- 1 → Misma dirección
- 0 → Vectores ortogonales
- -1 → Direcciones opuestas

Al dividir por las magnitudes de ambos vectores, la comparación se centra fundamentalmente en su **orientación dentro del espacio**.

Dos vectores pueden encontrarse a distinta distancia del origen y, aun así, presentar una similitud del coseno elevada

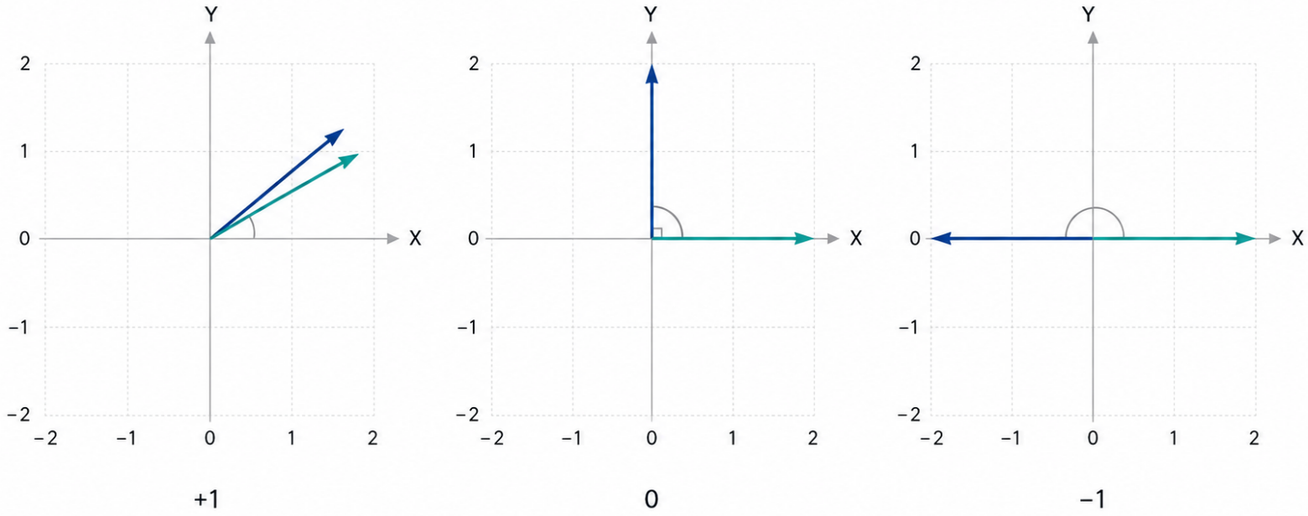

Misma dirección, diferente magnitud

Dos vectores pueden tener magnitudes muy diferentes y, sin embargo, alcanzar una **similitud del coseno máxima** si apuntan exactamente en la misma dirección.

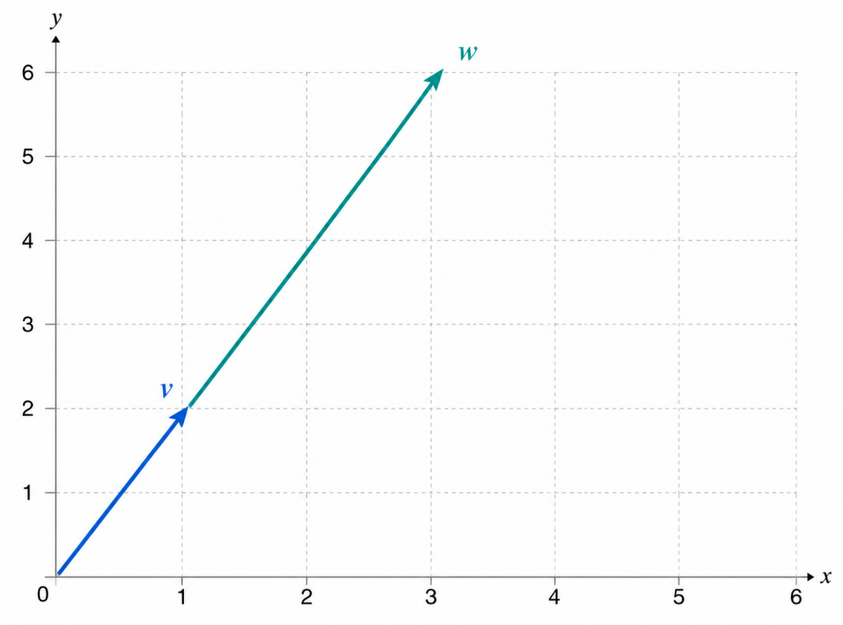

$$v = (1,2)$$

$$w = (3,6) = 3 \cdot v$$

$$\cos_{sim}(\mathbf{v} \,.\, \mathbf{w}) = 1$$

$$d_2(\mathbf{v}, \mathbf{w}) = \sqrt{20} = 4{,}7$$

Euclídea detecta separación. Coseno detecta orientación.

Normalización, producto escalar y coseno

EBIS Business Techschool

Cuando dos vectores están normalizados con norma L2 igual a 1, la similitud del coseno se reduce directamente a su **producto escalar**.

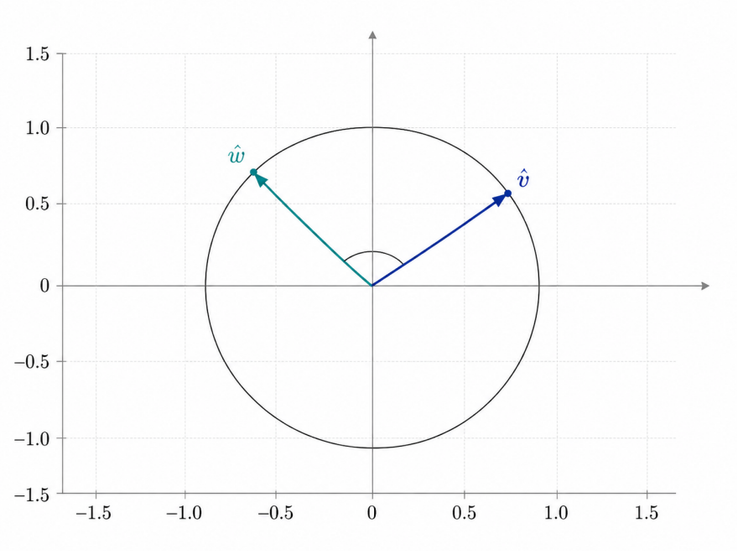

$$||\hat{\mathbf{v}}|| = ||\hat{\mathbf{w}}|| = 1$$

$$\cos_{sim}(\hat{\mathbf{v}}, \hat{\mathbf{w}}) = \hat{\mathbf{v}} \cdot \hat{\mathbf{w}}$$

$$||\hat{\mathbf{v}} - \hat{\mathbf{w}}||_2^2 = 2 - 2\cos_{sim}(\hat{\mathbf{v}}, \hat{\mathbf{w}})$$

Sobre vectores normalizados, **maximizar similitud coseno y minimizar distancia euclídea producen el mismo orden de vecinos.**

De la geometría a la recuperación de información

EBIS Business Techschool

De una consulta a un ranking de resultados

Si una consulta y los elementos de una colección se encuentran representados dentro de un **espacio común**, podemos comparar la consulta con cada candidato y asignarle una puntuación.

Calculando el score de los candidatos

Para recuperar información necesitamos comparar la consulta ***q*** con cada elemento de la colección mediante el mismo criterio.

$$q = (0.8, 0.6)$$

Candidato	Vector	Similitud Coseno
A	(0.3, 0.9)	0.79
B	(-0.2, 0.8)	0.51
C	(0.7, 0.7)	0.99
D	(0.9, 0.3)	0.95
E	(-0.8, -0.4)	-0.96

Aplicamos la **misma función de comparación** entre la consulta y todos los candidatos.

El score convierte una relación geométrica en un valor que podemos **ordenar computacionalmente**.

Del score al top-k

Una vez calculadas las puntuaciones, el problema de recuperación se transforma en un problema de **ordenación**.

$$q = (0.8, 0.6)$$

Candidato	Vector	Similitud Coseno
A	(0.3, 0.9)	0.79
B	(-0.2, 0.8)	0.51
C	(0.7, 0.7)	0.99
D	(0.9, 0.3)	0.95
E	(-0.8, -0.4)	-0.96

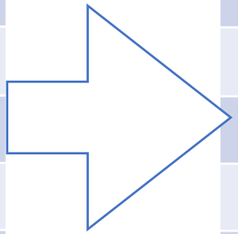

Ranking	Vector	Similitud Coseno
C	(0.7, 0.7)	0.99
D	(0.9, 0.3)	0.95
A	(0.3, 0.9)	0.79
B	(-0.2, 0.8)	0.51
E	(-0.8, -0.4)	-0.96

Top-k retrieval consiste en recuperar los k elementos con mejor puntuación según nuestro criterio de comparación.

Si ***k=3***, entonces los resultados que devolveríamos serían **C, D,** y **A**.

Nuestro primer sistema de recuperación

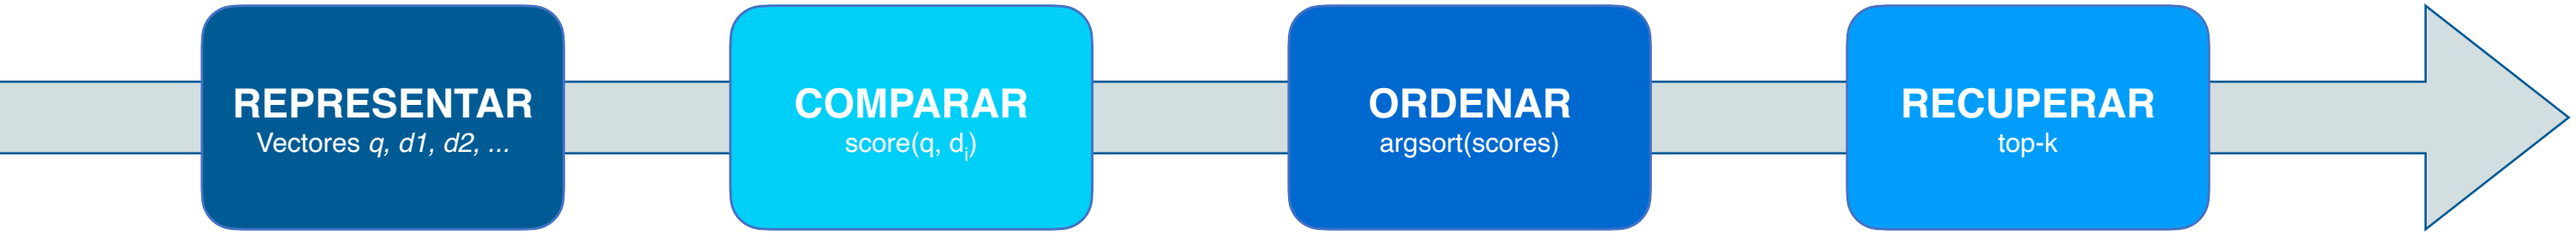

El principio es sencillo. El verdadero reto estará en decidir **cómo representar la información, cómo comparar los vectores y cómo hacerlo eficientemente a gran escala**.

Todo depende de la representación

Una función de distancia o similitud únicamente puede trabajar con la información que esté **codificada dentro de los vectores**.

Producto = (precio, peso)

Producto = (categoría, estilo, uso, características, ...)

Los objetos son los mismos. **Lo que cambia es el espacio vectorial en el que estamos comparando.**

La geometría de un sistema de recuperación está determinada por su representación.

¡Gracias y hasta la próxima!

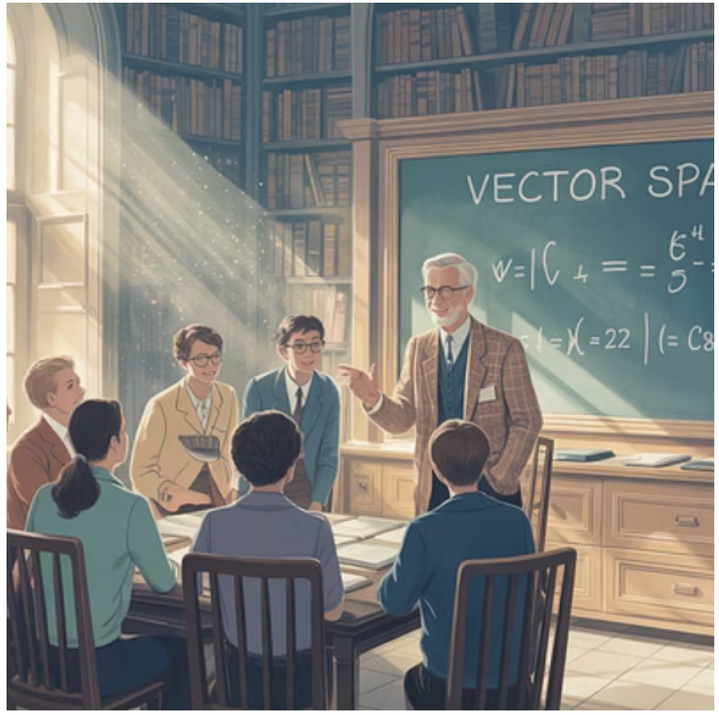

No dudéis en contactarme si tenéis dudas adicionales o necesitáis aclaraciones sobre cualquier aspecto del curso. Podéis encontrarme a través de:

Correo electrónico

albertoragmat@gmail.com

LinkedIn

Alberto Ruiz-Arteaga González

Tutorías

Todos los viernes de 1**7:30 a 18:30 (hora de Madrid)** en el **Metacampus**.

EBIS Business Techschool

www.ebiseducation.com