Tema 5: Sistemas de recuperación de la información, RAG y Langchain

EBIS Business Techschool

Contenidos

- Fundamentos matemáticos de la recuperación de información
- Representación de la información I: Sparse vs Dense
- Representación de la información II: Métodos modernos de retrieval
- Indexación y búsqueda eficiente
- Sistemas de almacenamiento y recuperación
- Construcción y evaluación de sistemas de recuperación
- Retrieval Augmented Generation

www.ebiseducation.com

Agenda de la sesión

EBIS Business Techschool

El problema de representar información

Retomaremos la idea de la sesión anterior: para recuperar información necesitamos transformarla en una representación matemática. Analizaremos qué propiedades puede preservar una representación y cómo esa elección condiciona las relaciones que podremos detectar posteriormente.

BM25 y búsqueda basada en términos

Estudiaremos BM25 como uno de los métodos de recuperación léxica más utilizados en la práctica, entendiendo cómo mejora la ponderación de términos y por qué sigue siendo relevante en buscadores y sistemas de recuperación modernos

Sparse vs dense: dos formas de entender la relevancia

Compararemos ambos paradigmas mediante ejemplos reales de retrieval, trabajando con modelos modernos de proveedores y modelos open source para entender sus fortalezas, limitaciones y los escenarios en los que cada enfoque resulta más adecuado

Representaciones sparse y recuperación léxica

Introduciremos las representaciones basadas en vocabulario, utilizando Bag of Words y TF-IDF para comprender conceptos como frecuencia, ponderación de términos, alta dimensionalidad y sparsity.

Representaciones dense y embeddings

Veremos cómo los modelos de embeddings permiten representar la información mediante vectores densos aprendidos, capaces de capturar relaciones que no dependen exclusivamente de coincidencias literales entre términos.

Recap & Q&A

Resumen de conceptos clave y resolución de dudas.

El problema de representar la información

EBIS Business Techschool

Representar es elegir qué conservar

EBIS Business Techschool

Una representación transforma un objeto complejo en una estructura matemática sobre la que podemos operar. Pero esa transformación **no conserva necesariamente toda la información original**.

Seleccionar

Decidimos qué propiedades del objeto formarán parte de la representación.

Codificar

Esas propiedades se transforman en valores que un sistema puede procesar matemáticamente.

Descartar

La información que no queda reflejada en la representación deja de estar disponible para las operaciones posteriores.

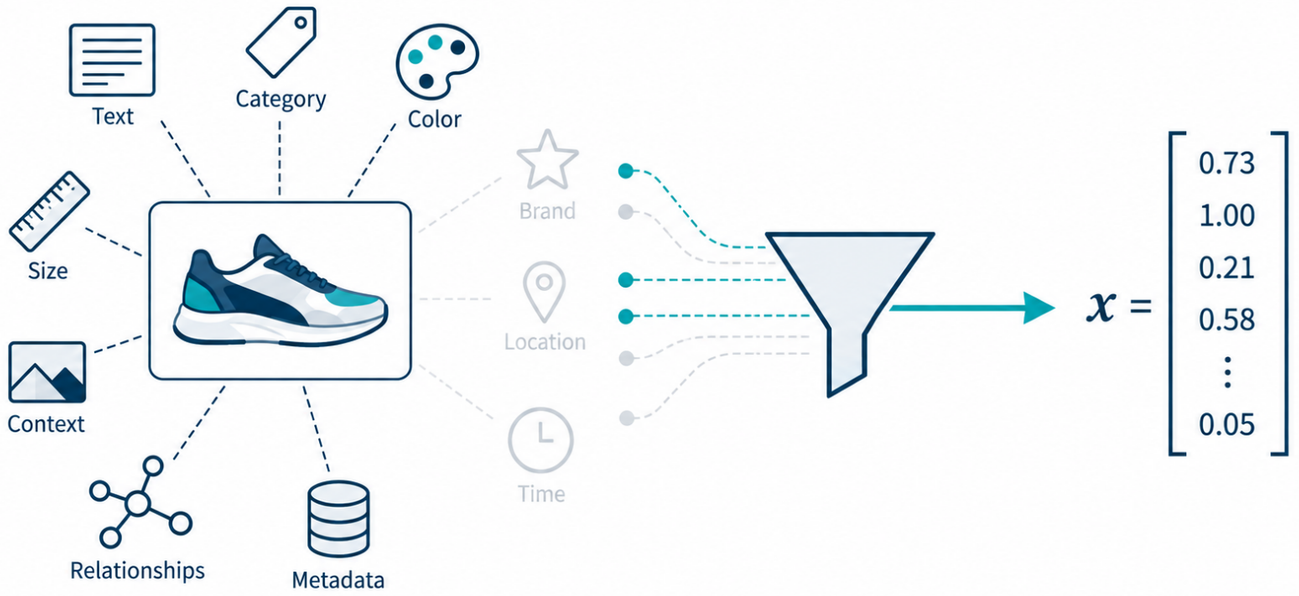

Toda representación es una simplificación del objeto original.
Su utilidad depende de que preserve precisamente la información relevante para nuestro problema.

El mismo objeto puede tener muchas representaciones

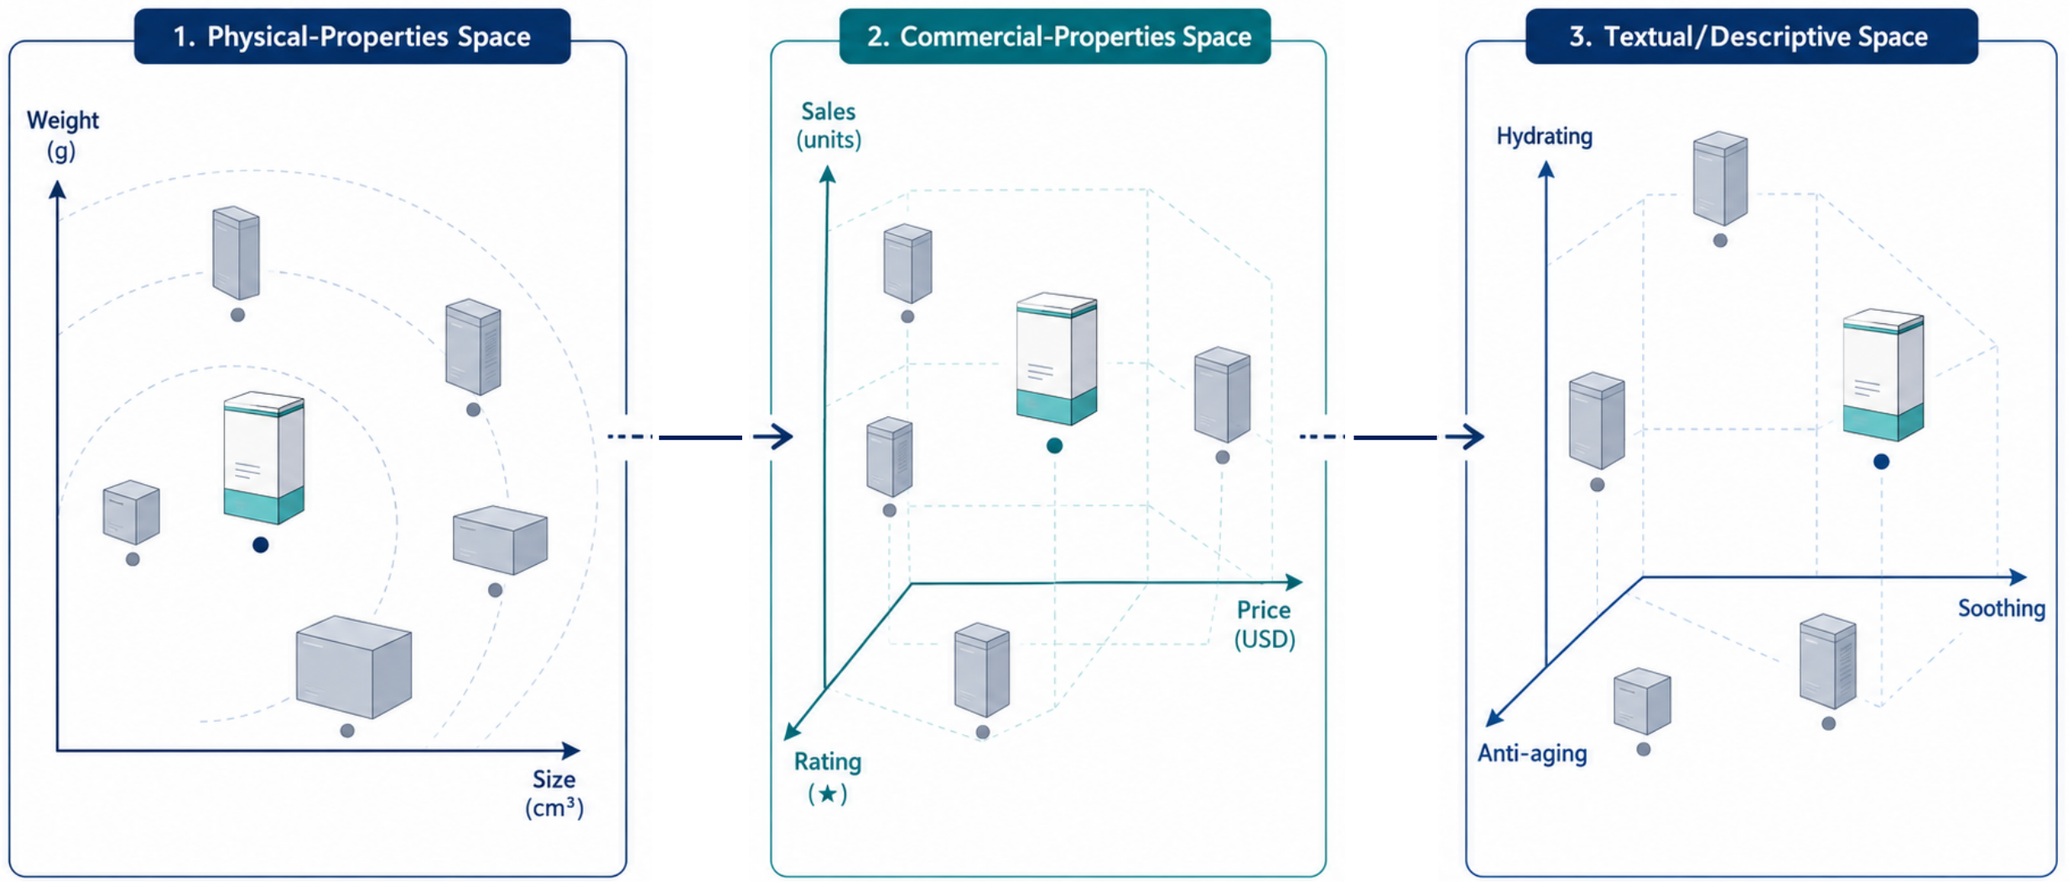

Representación A - Propiedades Físicas

Variables como *peso, altura, anchura, volumen, ...*

Representación A - Propiedades Comerciales

Variables como *precio, descuento, ventas, valoración, ...*

Representación A - Contenido Textual

Información extraída de su nombre y descripción

¿Qué debería preservar una buena representación?

EBIS Business Techschool

Una representación es útil cuando hace que las relaciones importantes para nuestro problema sean **fáciles de identificar matemáticamente**.

Señal relevante

Debe conservar la información necesaria para resolver la tarea.

Separación

Elementos diferentes para nuestro problema deberían poder distinguirse.

Proximidad

Elementos relacionados deberían presentar representaciones compatibles con esa relación

Comparabilidad

Consulta y candidatos deben encontrarse en un espacio sobre el que podamos aplicar un criterio común.

No existe una representación universalmente óptima: su calidad depende del **objetivo de recuperación**.

Una buena geometría es consecuencia de una buena representación.

Dos estrategias para representar texto

Para representar información textual podemos seguir enfoques muy diferentes. Dos grandes familias organizan buena parte de los sistemas modernos de recuperación.

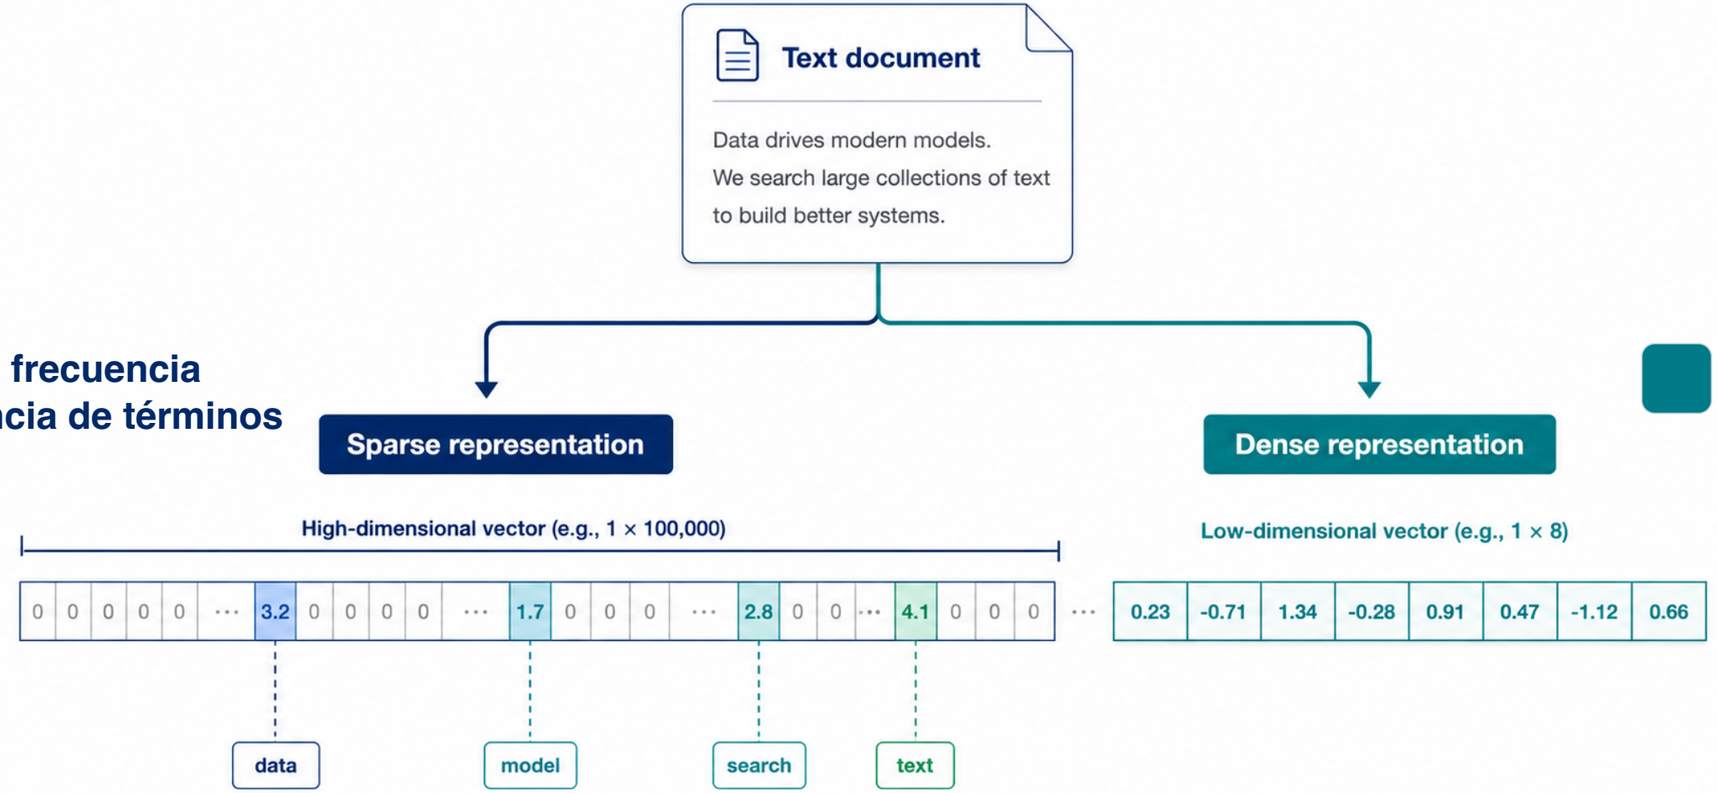

Presencia, frecuencia e importancia de términos

- Las dimensiones están ligadas explícitamente al **vocabulario o a características identificables del texto**.
- Los vectores suelen tener una **dimensionalidad elevada**, pero únicamente una pequeña parte de sus valores son distintos de cero.

Relaciones aprendidas entre textos y su contenido

- La información se codifica mediante un número mucho menor de **dimensiones densas aprendidas por un modelo**.
- Sus componentes no suelen corresponder directamente con palabras o características interpretables.

Representaciones sparse y recuperación léxica

EBIS Business Techschool

El vocabulario como sistema de coordenadas

EBIS Business Techschool

Una forma directa de representar texto consiste en asociar **una dimensión del espacio a cada término del vocabulario**.

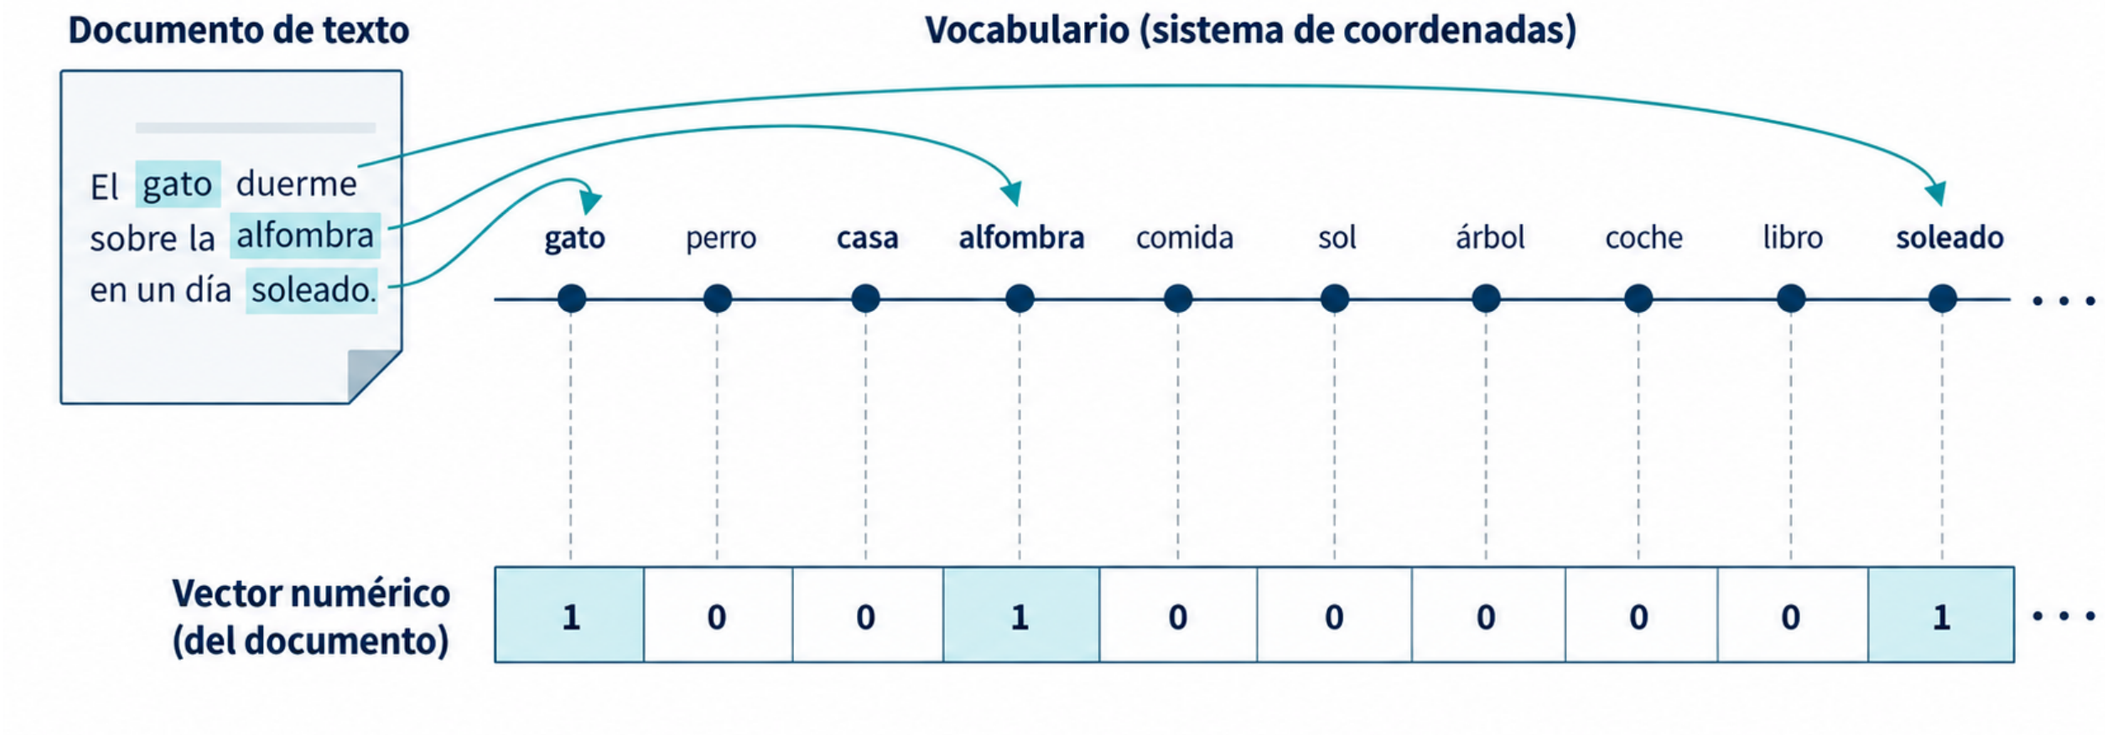

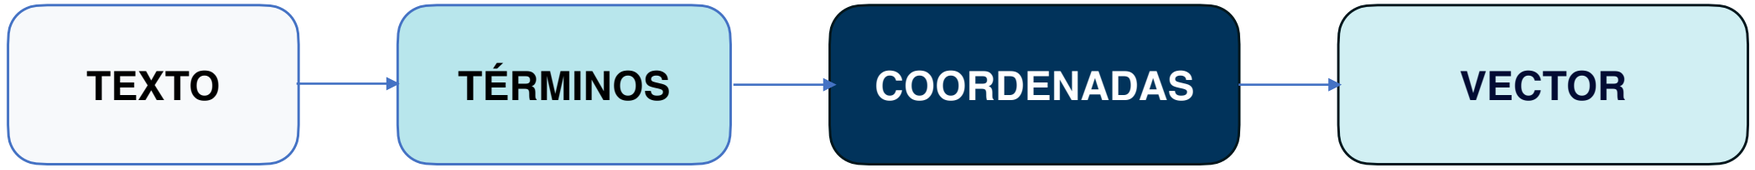

Bag of Words: convertir palabras en números

EBIS Business Techschool

Bag of Words (BoW) representa un documento mediante el número de veces que aparece cada término del vocabulario.

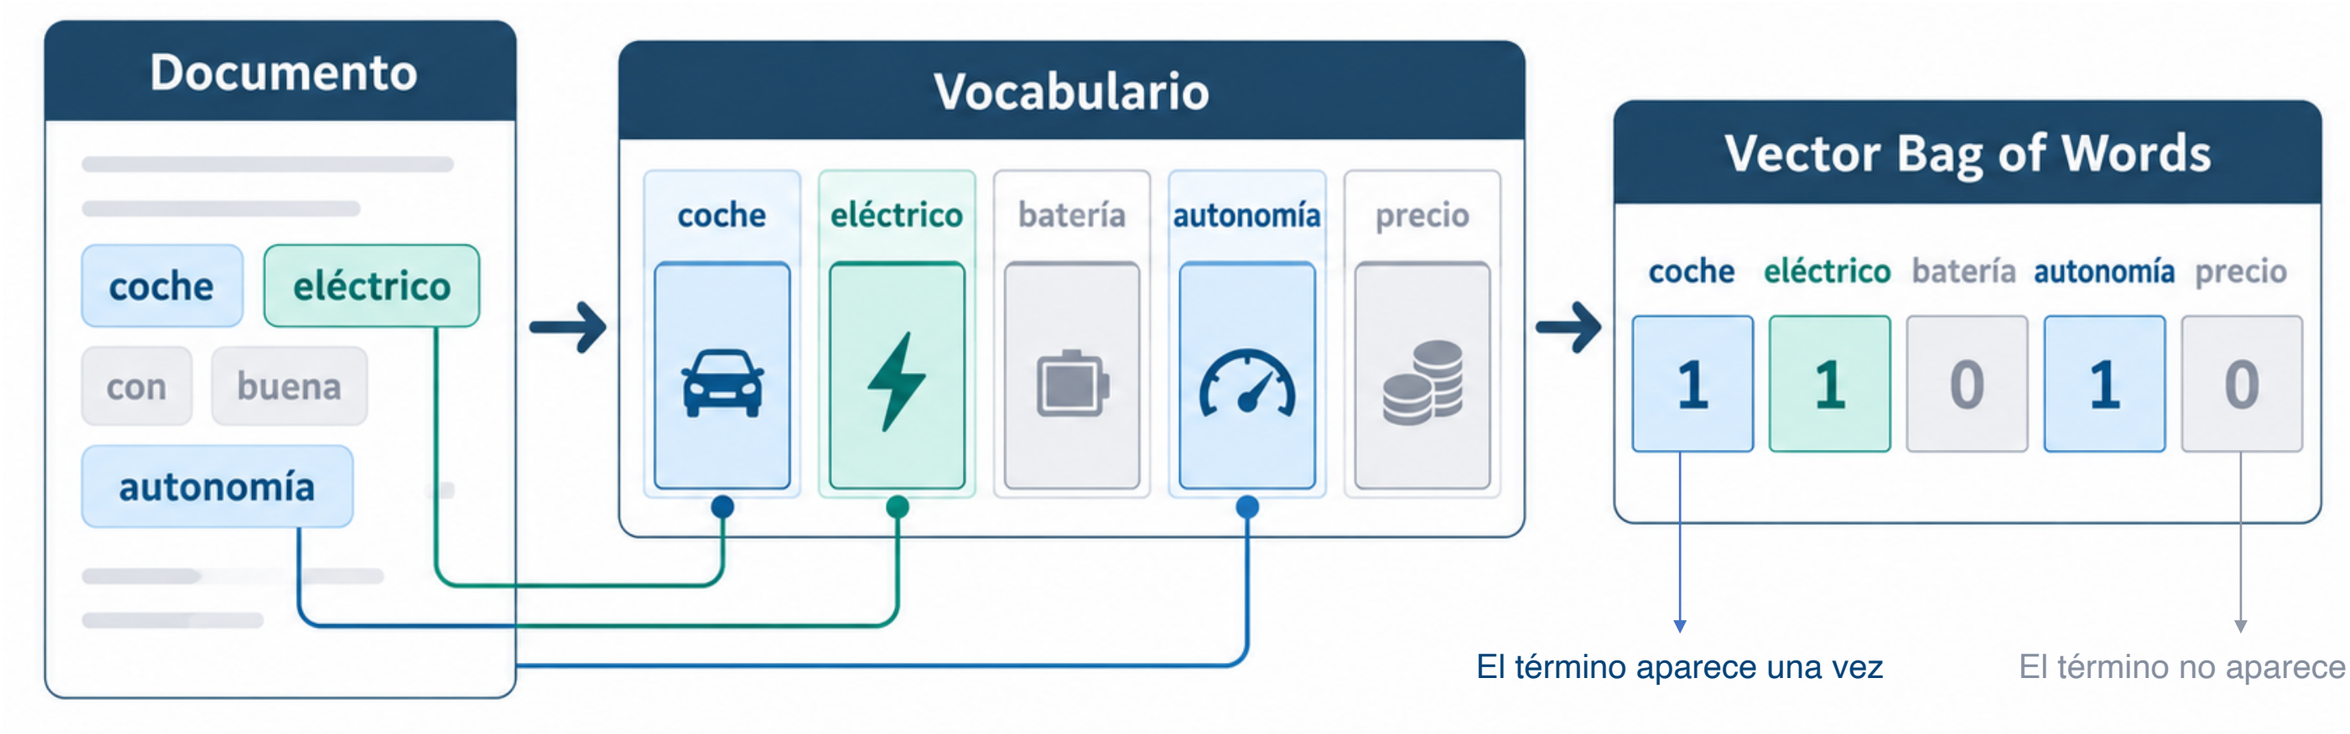

El documento deja de ser una secuencia de palabras y pasa a ser un **vector numérico**.

Una colección completa se convierte en una matriz

Si aplicamos la misma representación a todos los documentos de una colección, podemos organizarlos dentro de una **matriz documento-término**.

VOCABULARIO

DOCUMENTOS	coche	eléctrico	batería	autonomía	precio	...
Doc. A	1	1	0	1	0	...
Doc. B	1	0	0	0	2	...
Doc. C	0	1	2	1	0	...
Doc. D	0	0	0	0	1	...
...	...	...	...	...	...	...

Todos los documentos quedan representados dentro del **mismo espacio vectorial**.

¿Por qué se llaman representaciones dispersas?

EBIS Business Techschool

En colecciones reales, el vocabulario puede contener **decenas o cientos de miles de términos**, mientras que cada documento utiliza únicamente una pequeña parte de ellos.

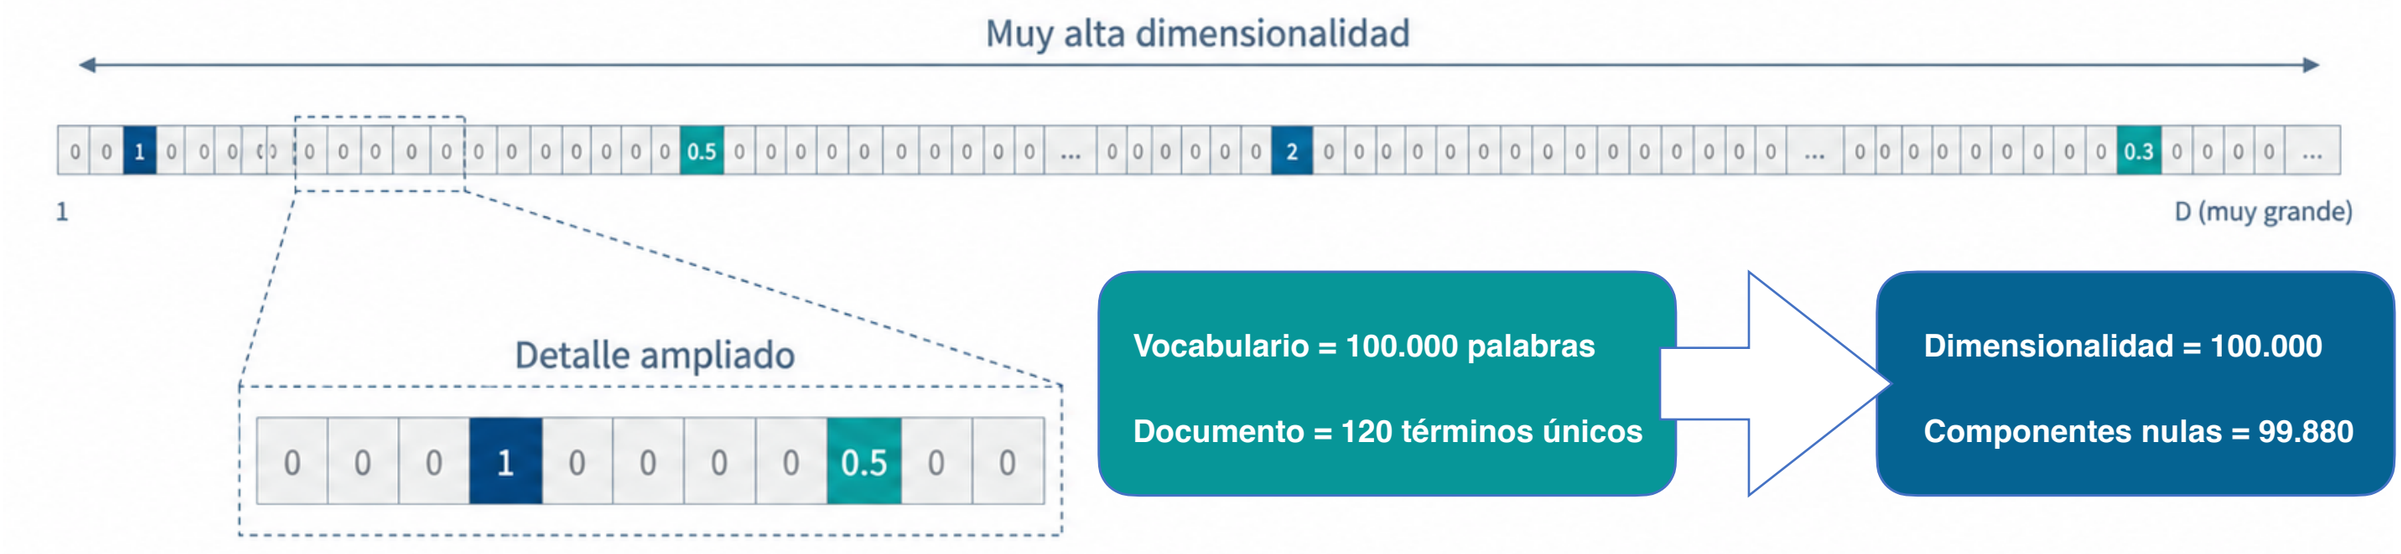

Alta dimensionalidad

Una dimensión por término del vocabulario.

Pocos valores activos

Cada documento utiliza solo una fracción de esas dimensiones.

Estructura explotable

No necesitamos almacenar ni procesar explícitamente todos los ceros.

Sparse ≠ Ineficiente por definición. Su estructura dispersa puede aprovecharse mediante representaciones e índices especializados.

Lo que BoW conserva... y lo que destruye

EBIS Business Techschool

Conserva:

qué términos aparecen

Pierde:

el orden de las palabras

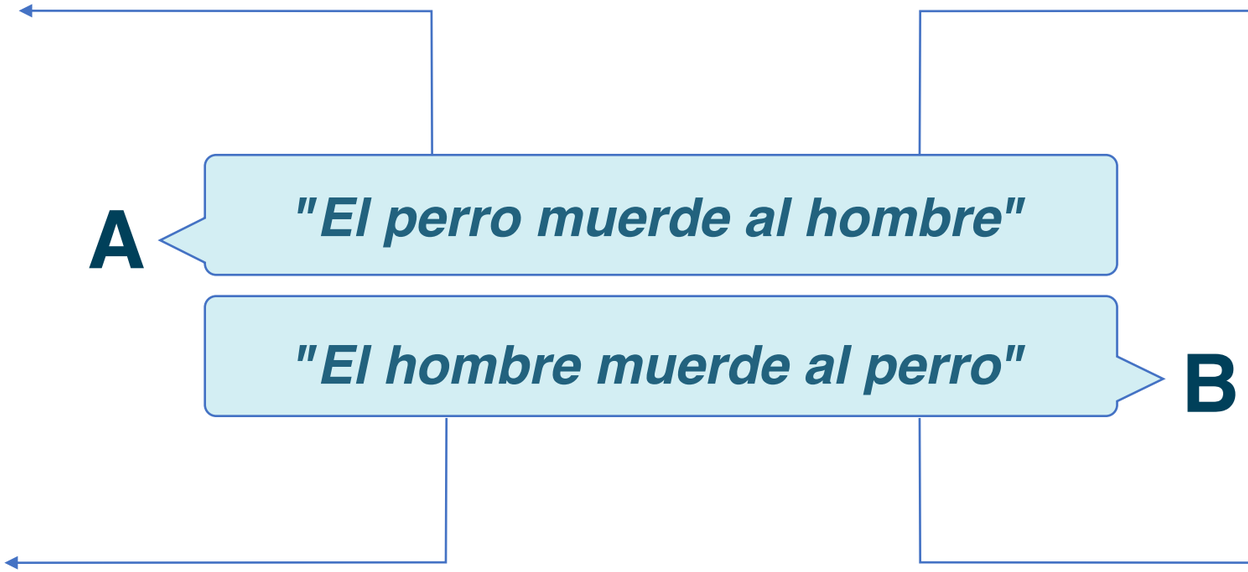

Conserva:

cuántas veces aparecen

Pierde:

gran parte de la estructura y del contexto

BoW(A) = BoW(B)

Bag of Words modela principalmente **contenido léxico**, no significado composicional.

No todas las palabras informan por igual

El simple conteo de términos presupone que todas las palabras aportan el mismo valor para distinguir documentos. En una colección real, esto rara vez es cierto.

"comparativa batería coche eléctrico"

- ***coche*** aparece en 9.500 documentos
- ***eléctrico*** aparece en 6.800 documentos
- ***batería*** aparece en 1.200 documentos
- ***comparativa*** aparece en 180 documentos

Un término que aparece en prácticamente toda la colección aporta **menos información discriminativa** que uno relativamente poco frecuente.

Necesitamos ponderar cada término considerando **dos niveles de información: el documento individual + la colección completa**.

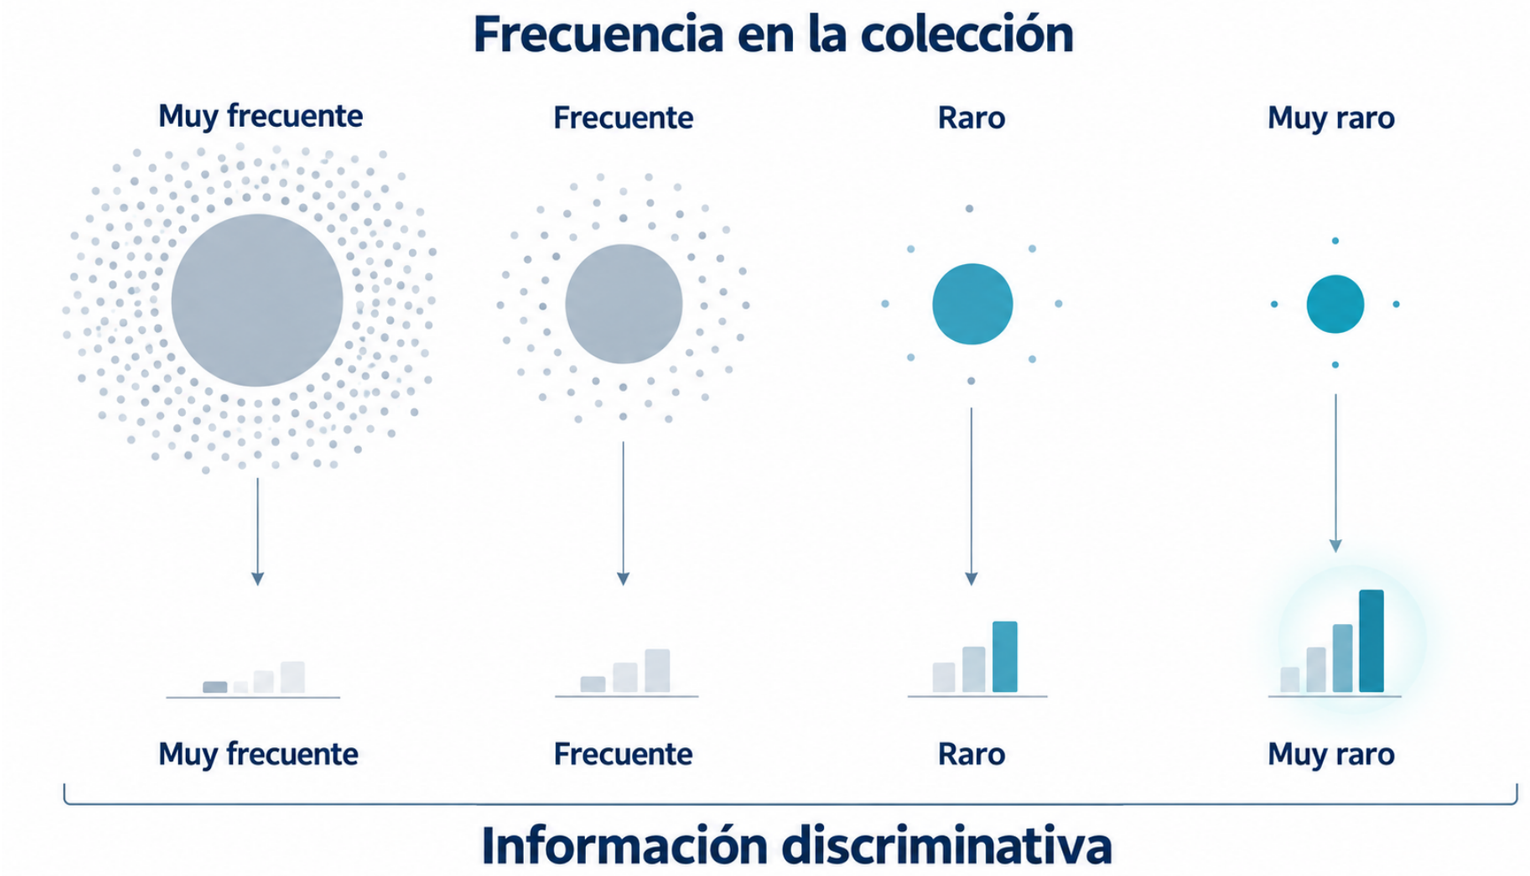

Frecuencia dentro del documento ≠ Importancia dentro de la colección

TF-IDF: frecuencia local, importancia global

EBIS Business Techschool

TF-IDF pondera cada término combinando cuánto aparece dentro de un documento con lo excepcional que resulta dentro de la colección.

$$TF - IDF(t, d) = TF(t, d) \cdot IDF(t)$$

Term-Frequency - TF

¿Cuánto aparece el término en este documento?

$$TF(t, d) = \textbf{frecuencia de } t \textbf{ en } d$$

Inverse Document Frequency - IDF

¿En cuántos documentos de la colección aparece el término?

$$IDF(t) = \log\left(\frac{N + 1}{DF(t) + 1}\right) + 1$$

Término frecuente en el documento + poco frecuente en la colección → peso elevado

TF-IDF convierte el vector de conteos en un vector de **términos ponderados por su capacidad discriminativa**.

BM25 y búsqueda basada en términos

EBIS Business Techschool

De TF-IDF a BM25: ¿qué nos falta?

EBIS Business Techschool

TF-IDF introduce una idea fundamental: **no todos los términos deben pesar igual**. Sin embargo, utilizar directamente la frecuencia de aparición sigue introduciendo comportamientos poco realistas para recuperación.

La frecuencia no debería crecer indefinidamente

Que una palabra aparezca 20 veces no implica que un documento sea 20 veces más relevante que otro donde aparece una vez.

La longitud del documento importa

Los documentos largos tienen más oportunidades de contener un término simplemente porque contienen más palabras.

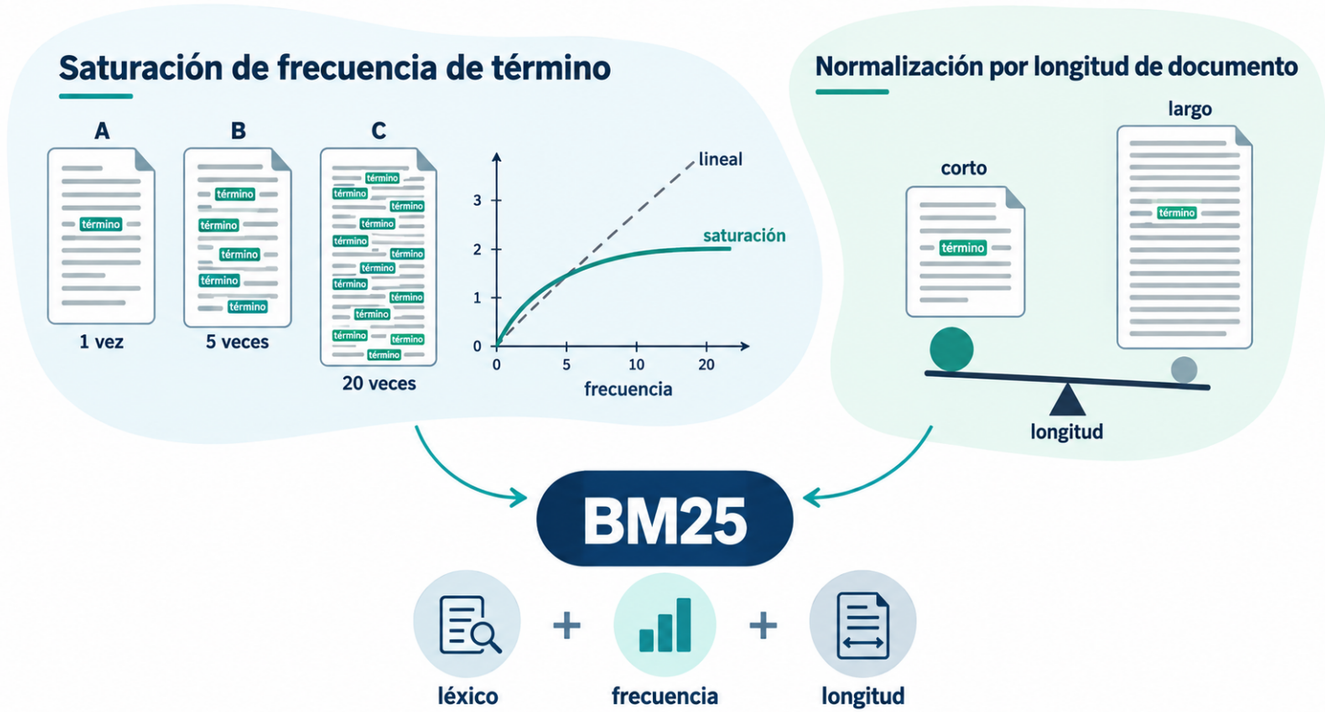

BM25 conserva la lógica léxica de TF-IDF, pero introduce **saturación de frecuencia y normalización por longitud**.

La intuición de BM25

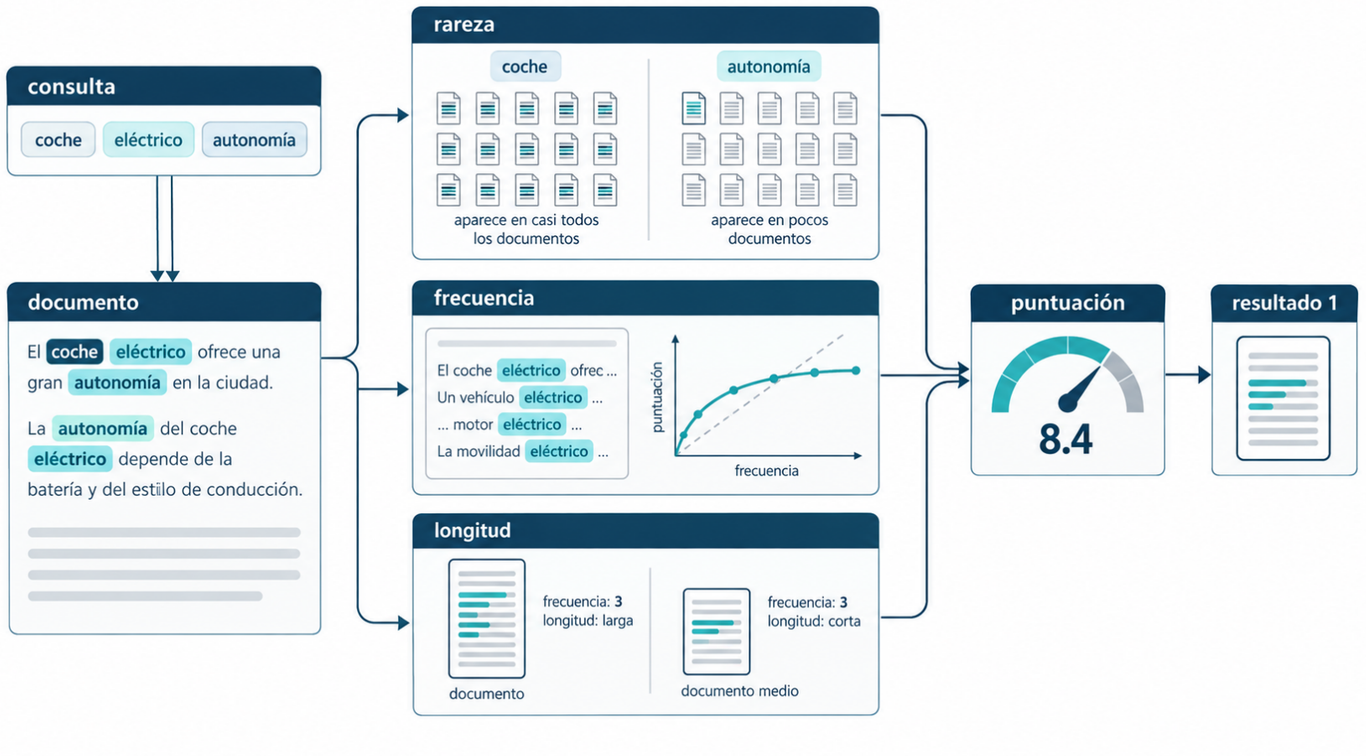

BM25 asigna un score entre una consulta y un documento combinando tres señales fundamentales.

1 Rareza del término

Los términos poco frecuentes en la colección aportan más información.

2 Frecuencia con saturación

Repetir un término aumenta su contribución, pero cada repetición adicional aporta menos.

3 Longitud del documento

La frecuencia observada se interpreta teniendo en cuenta el tamaño del documento.

BM25 no busca representar el significado del texto: busca estimar muy bien su relevancia léxica para una consulta.

BM25, pieza a pieza

EBIS Business Techschool

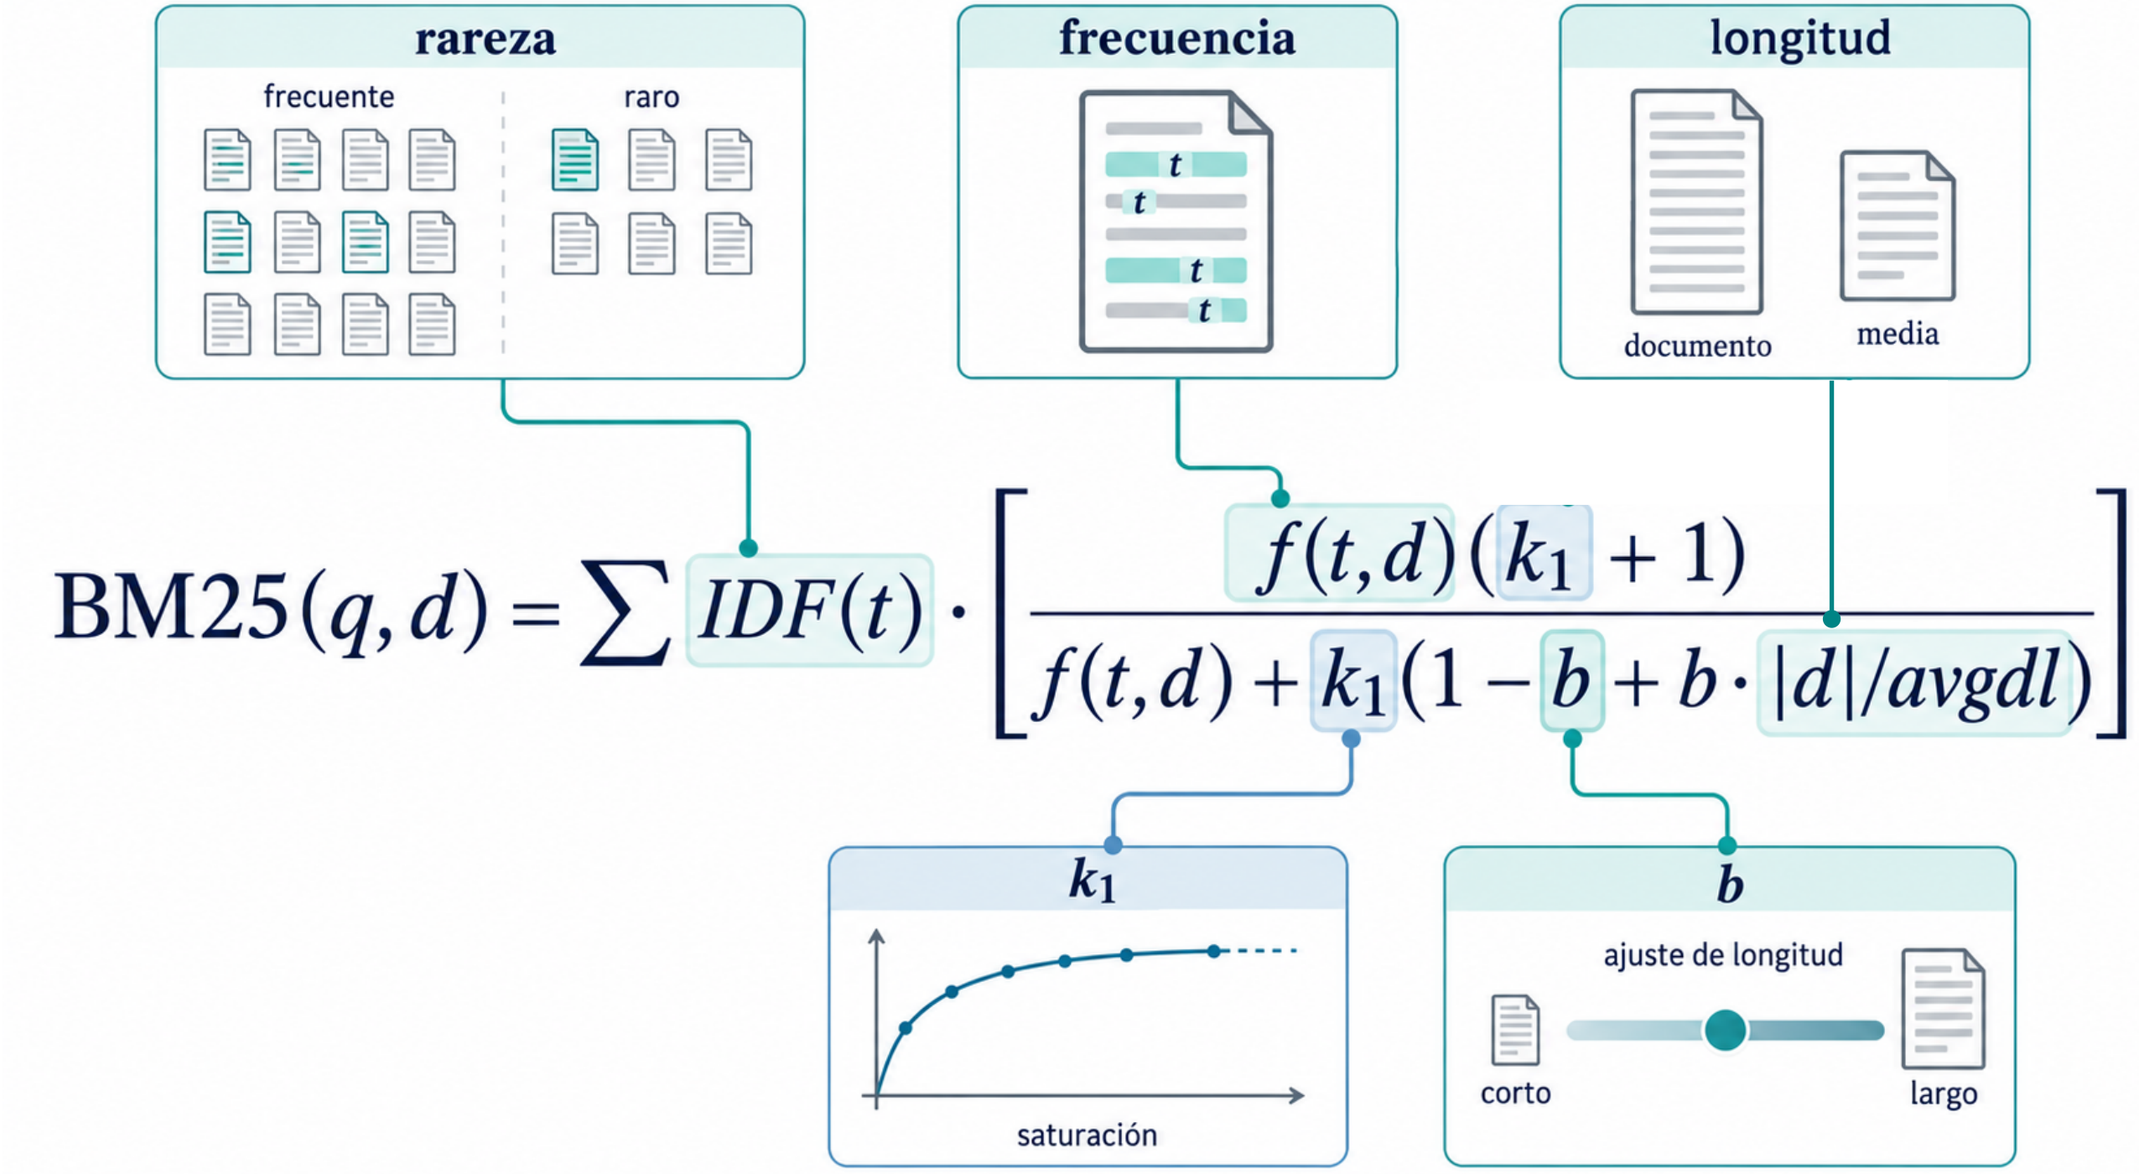

Saturación: diez apariciones no valen diez veces más

EBIS Business Techschool

BM25 aplica **rendimientos decrecientes** a la frecuencia de un término.

- Primera aparición → gran incremento de evidencia
- Apariciones adicionales → incrementos progresivamente menores

k_1 controla la velocidad con la que se produce esta saturación

La frecuencia importa, pero **deja de dominar el score cuando el término ya está suficientemente representado**.

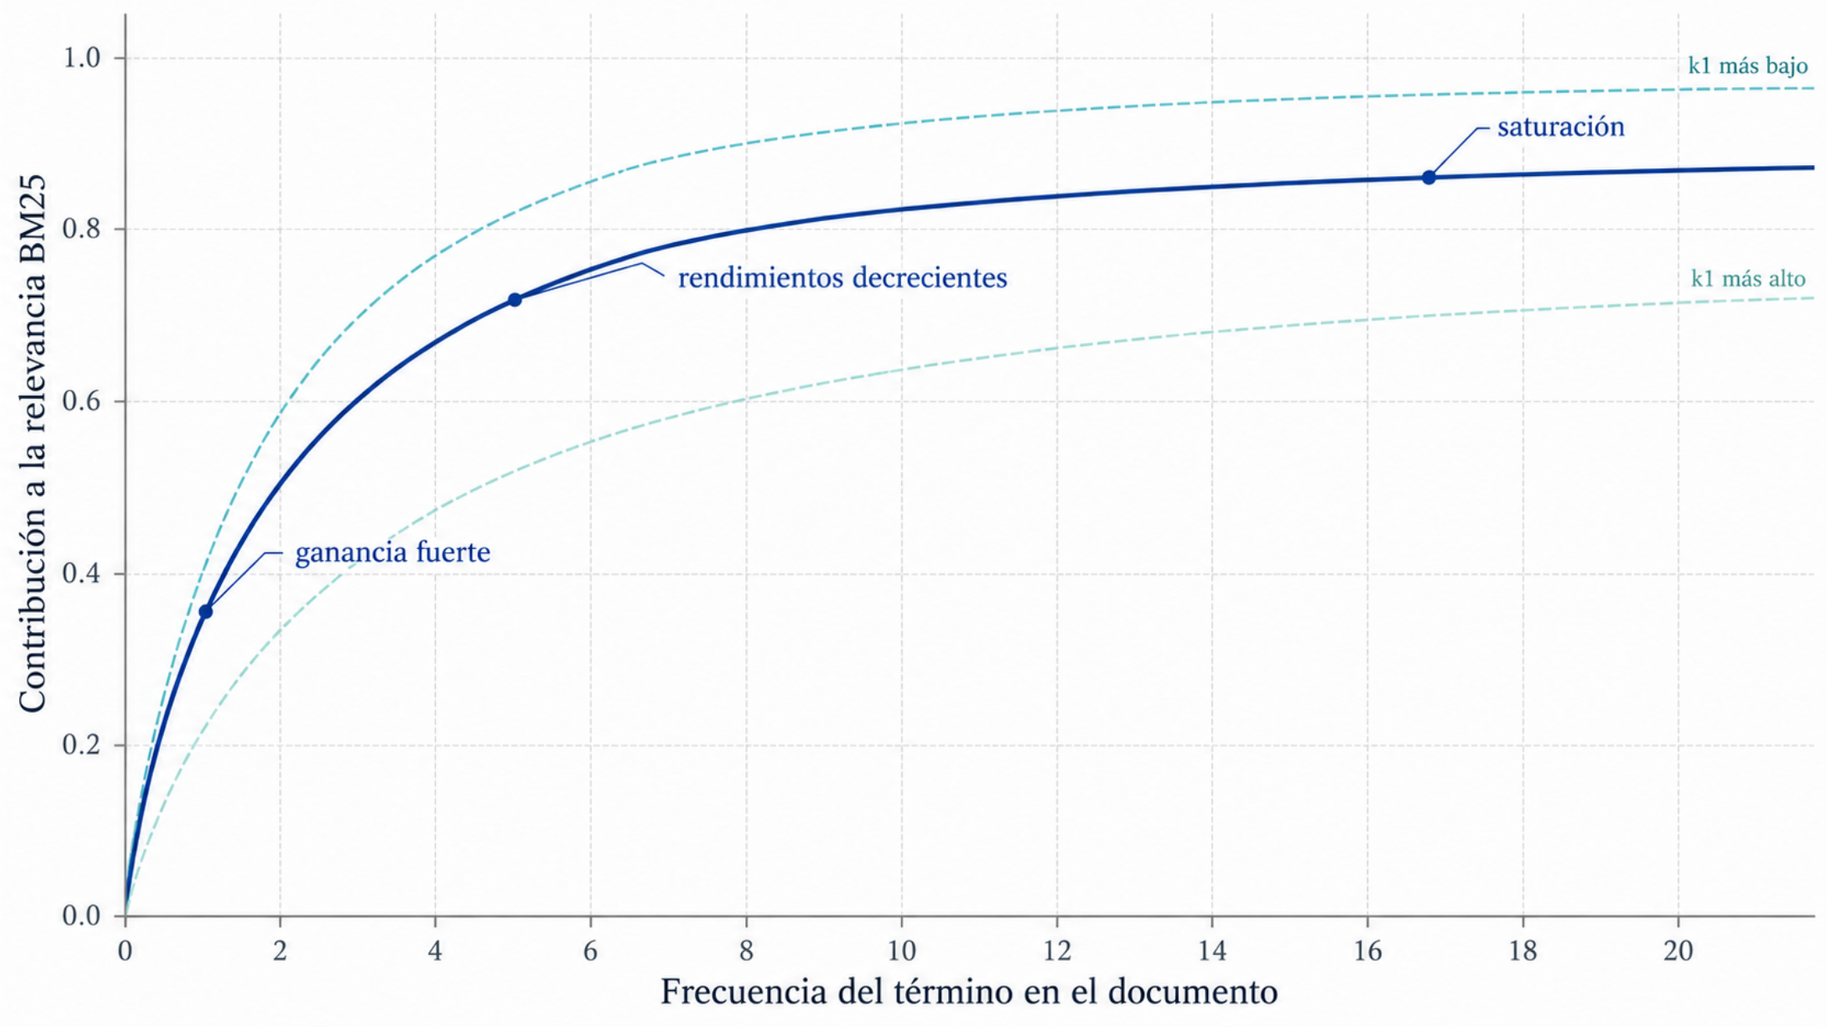

Normalización por longitud: el contexto de la frecuencia

EBIS Business Techschool

BM25 interpreta la frecuencia de un término **en relación con la longitud del documento**.

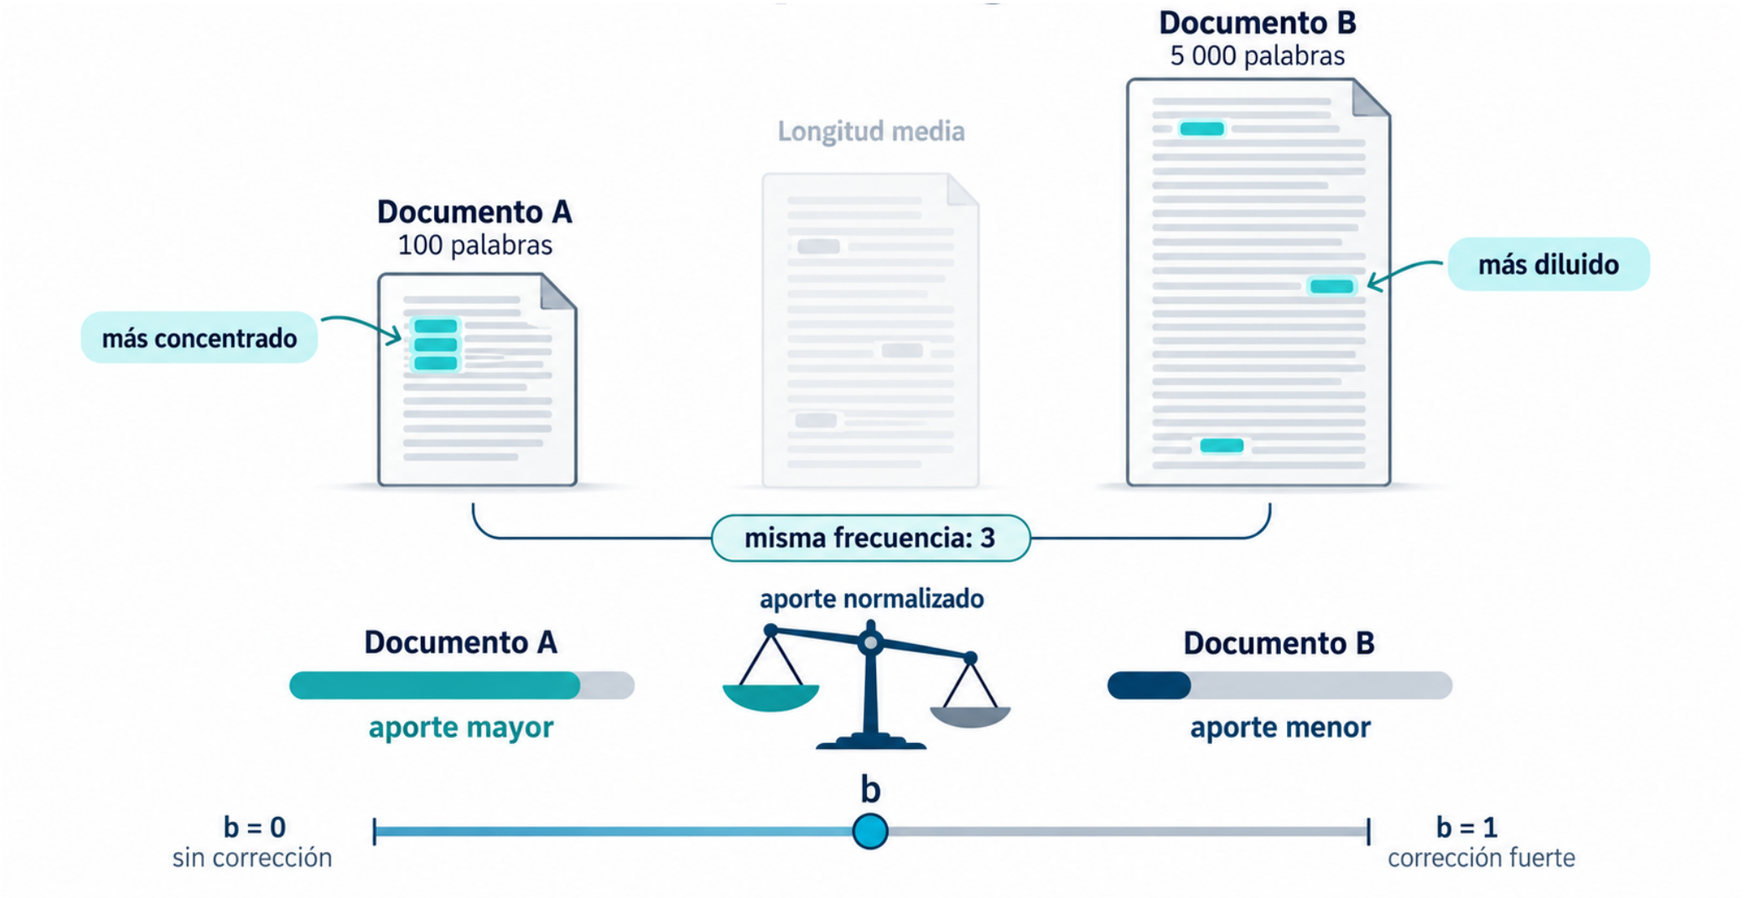

BM25 sigue importando

EBIS Business Techschool

BM25 es un método **léxico**: recupera información a partir de la coincidencia y relevancia de términos. Esa propiedad sigue siendo extraordinariamente útil.

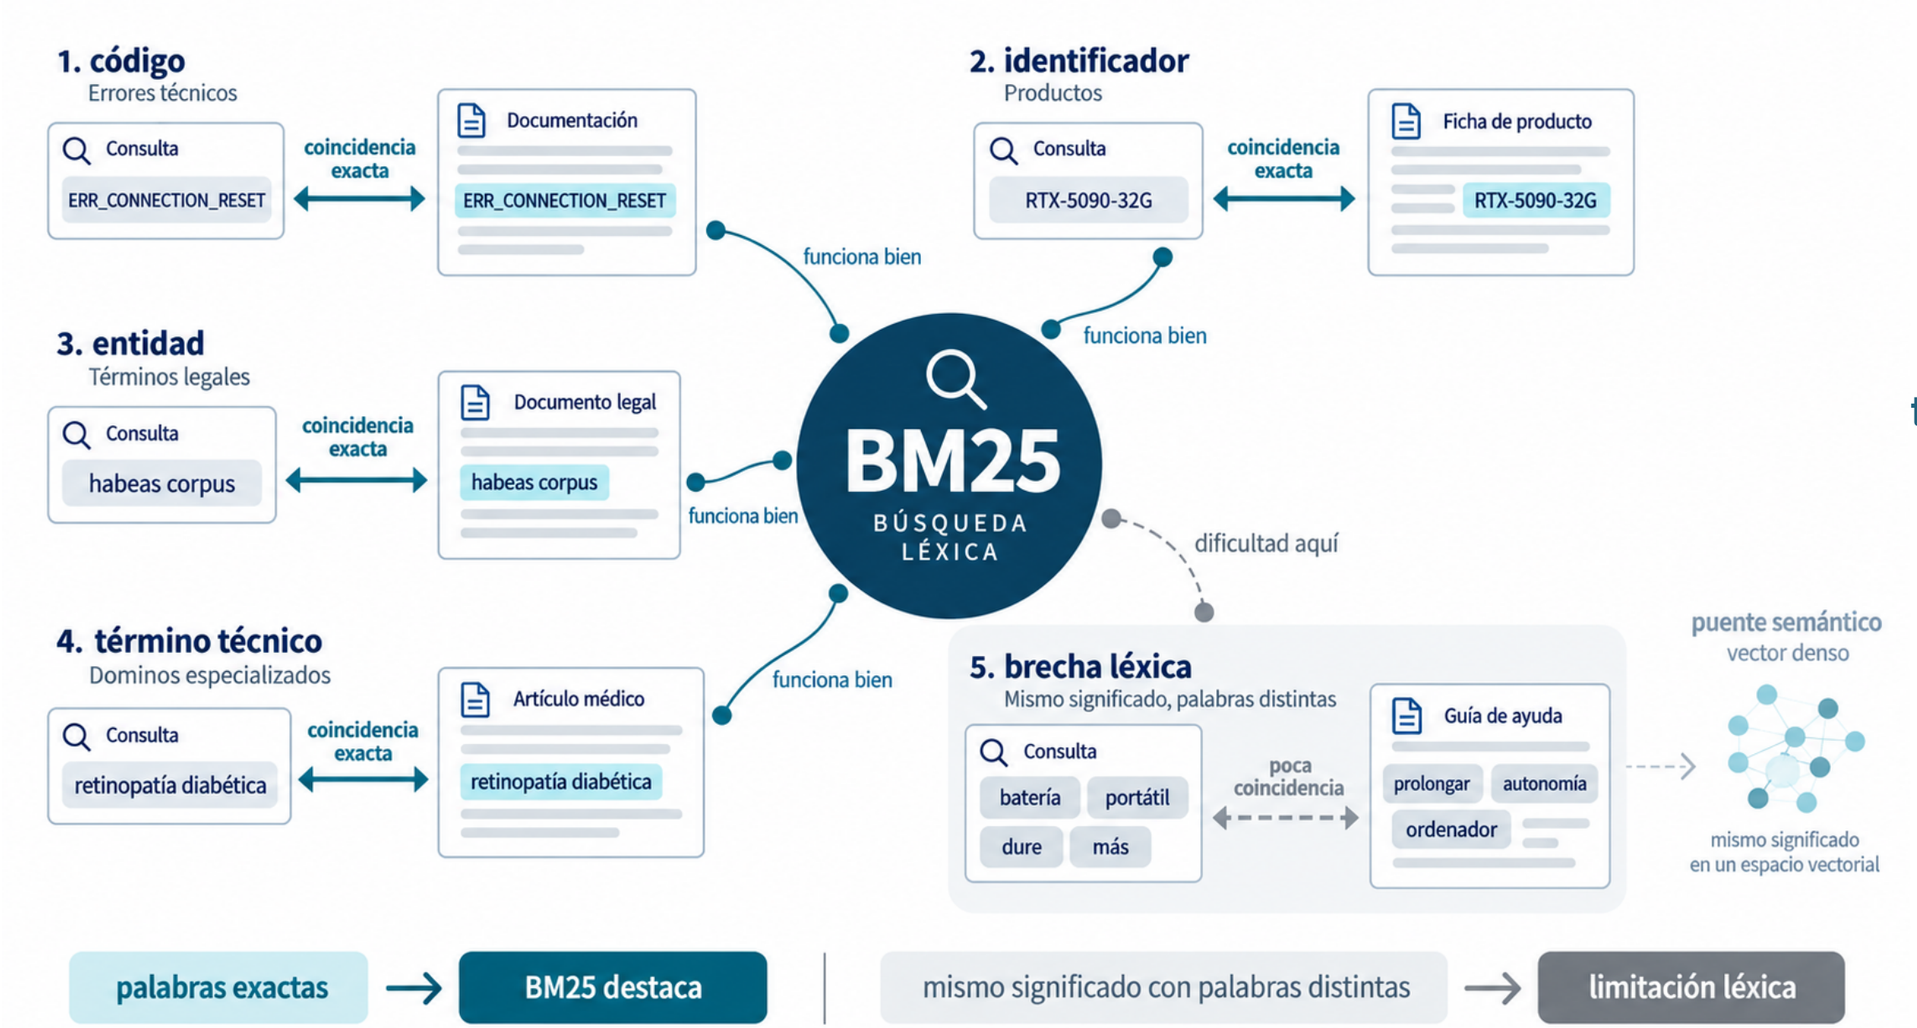

¿Qué ocurre cuando dos textos expresan la misma idea utilizando palabras diferentes?

Representaciones dense y embeddings

EBIS Business Techschool

Cuando las palabras no coinciden

Los sistemas léxicos funcionan especialmente bien cuando consulta y documento comparten términos relevantes. Pero pueden tener dificultades cuando **la misma idea se expresa con palabras diferentes**.

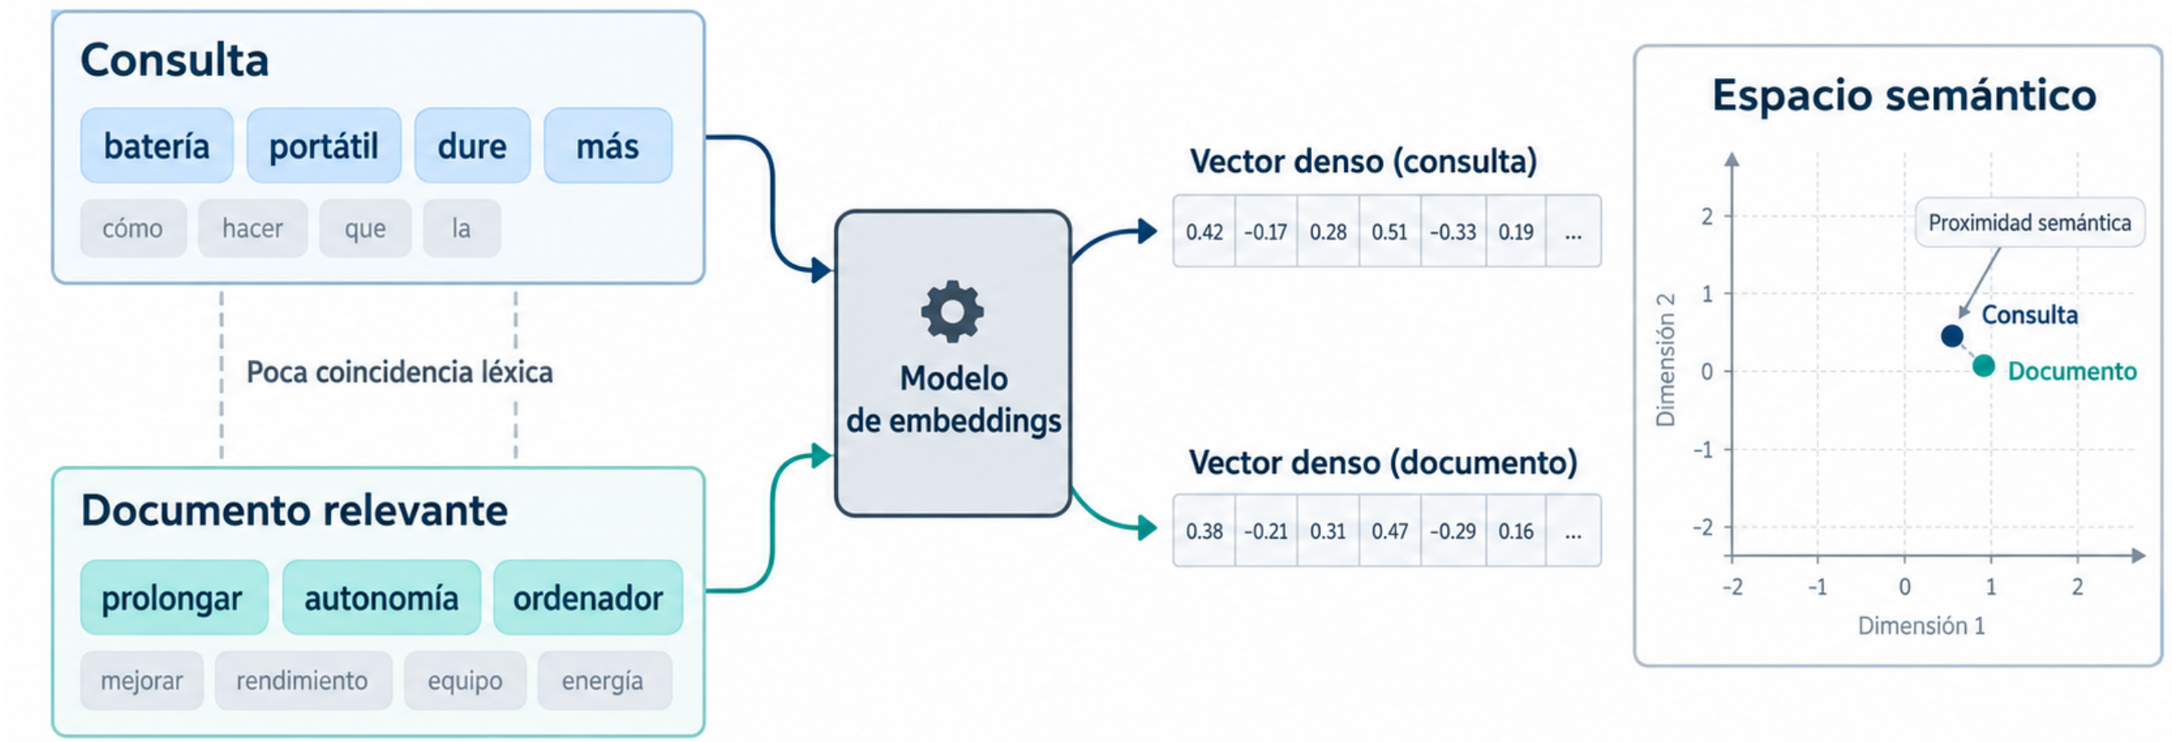

Necesitamos una representación capaz de hacer visibles relaciones que **no dependan exclusivamente de compartir vocabulario**.

¿Qué es un embedding?

EBIS Business Techschool

Un embedding es una **representación vectorial densa aprendida por un modelo**, diseñada para codificar determinadas propiedades y relaciones de la información de entrada.

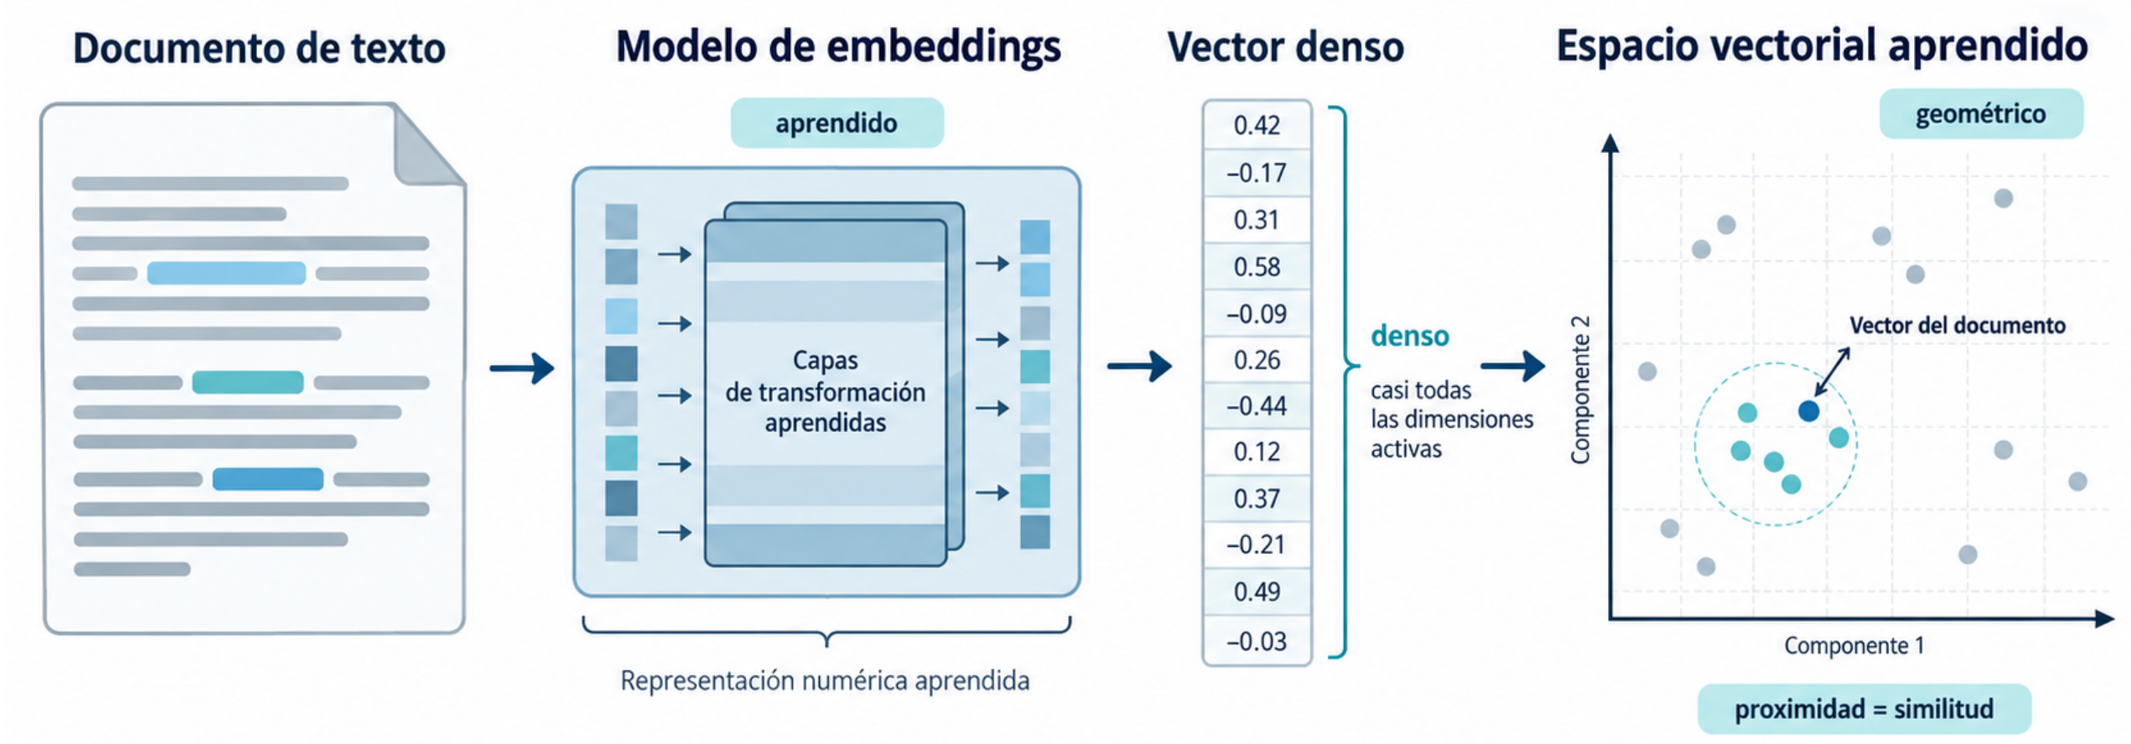

Vectores densos

La mayoría de sus componentes contienen valores distintos de cero.

Representación aprendida

Las dimensiones no se definen manualmente: emergen del entrenamiento del modelo.

Geometría

Las relaciones aprendidas se manifiestan mediante posiciones, direcciones y proximidades dentro del espacio

Aprender una geometría útil para retrieval

EBIS Business Techschool

Un modelo de embeddings para recuperación se entrena para que determinadas parejas de textos ocupen **posiciones compatibles dentro del mismo espacio vectorial**.

queremos aumentar similitud

Query ⟷ **Documento relevante**

queremos reducir similitud

Query ⟷ **Documento no relevante**

El modelo aprende una función:

$$f(\text{texto}) \longrightarrow \mathbb{R}^d$$

cuya geometría favorece las relaciones utilizadas durante el entrenamiento.

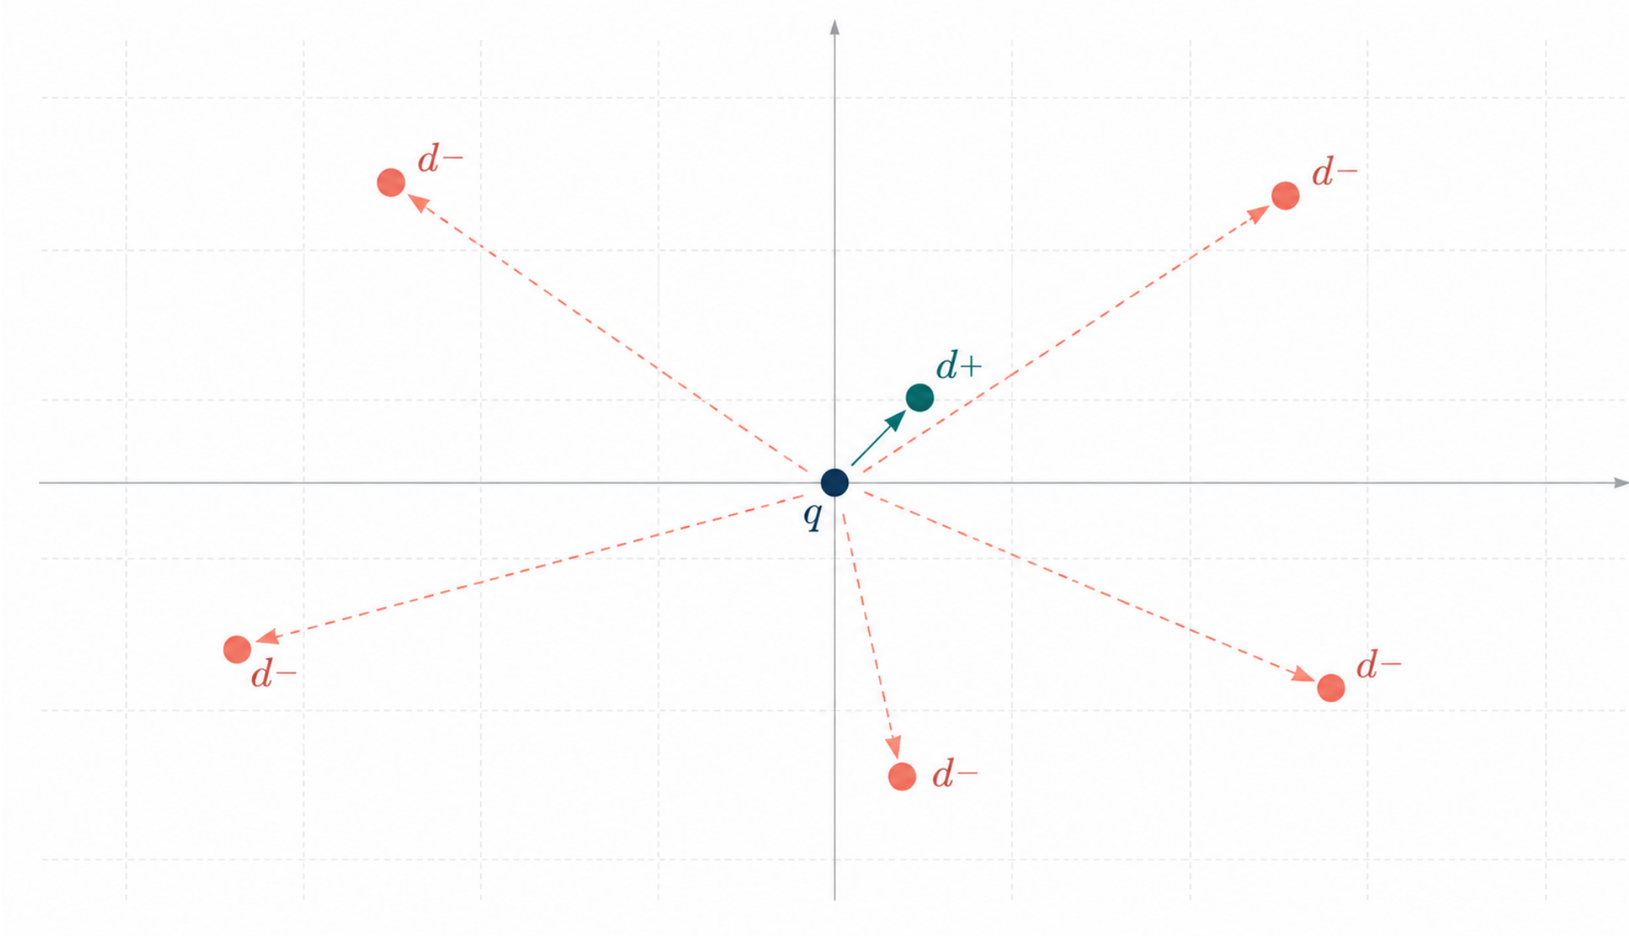

No aprendemos la "posición correcta" de cada texto: aprendemos qué relaciones debe preservar el espacio.

Query y documento: mismo espacio, diferentes roles

En retrieval necesitamos que consultas y documentos puedan compararse dentro de un **espacio compatible**. Sin embargo, algunos modelos reciben información adicional sobre el papel que desempeña cada texto.

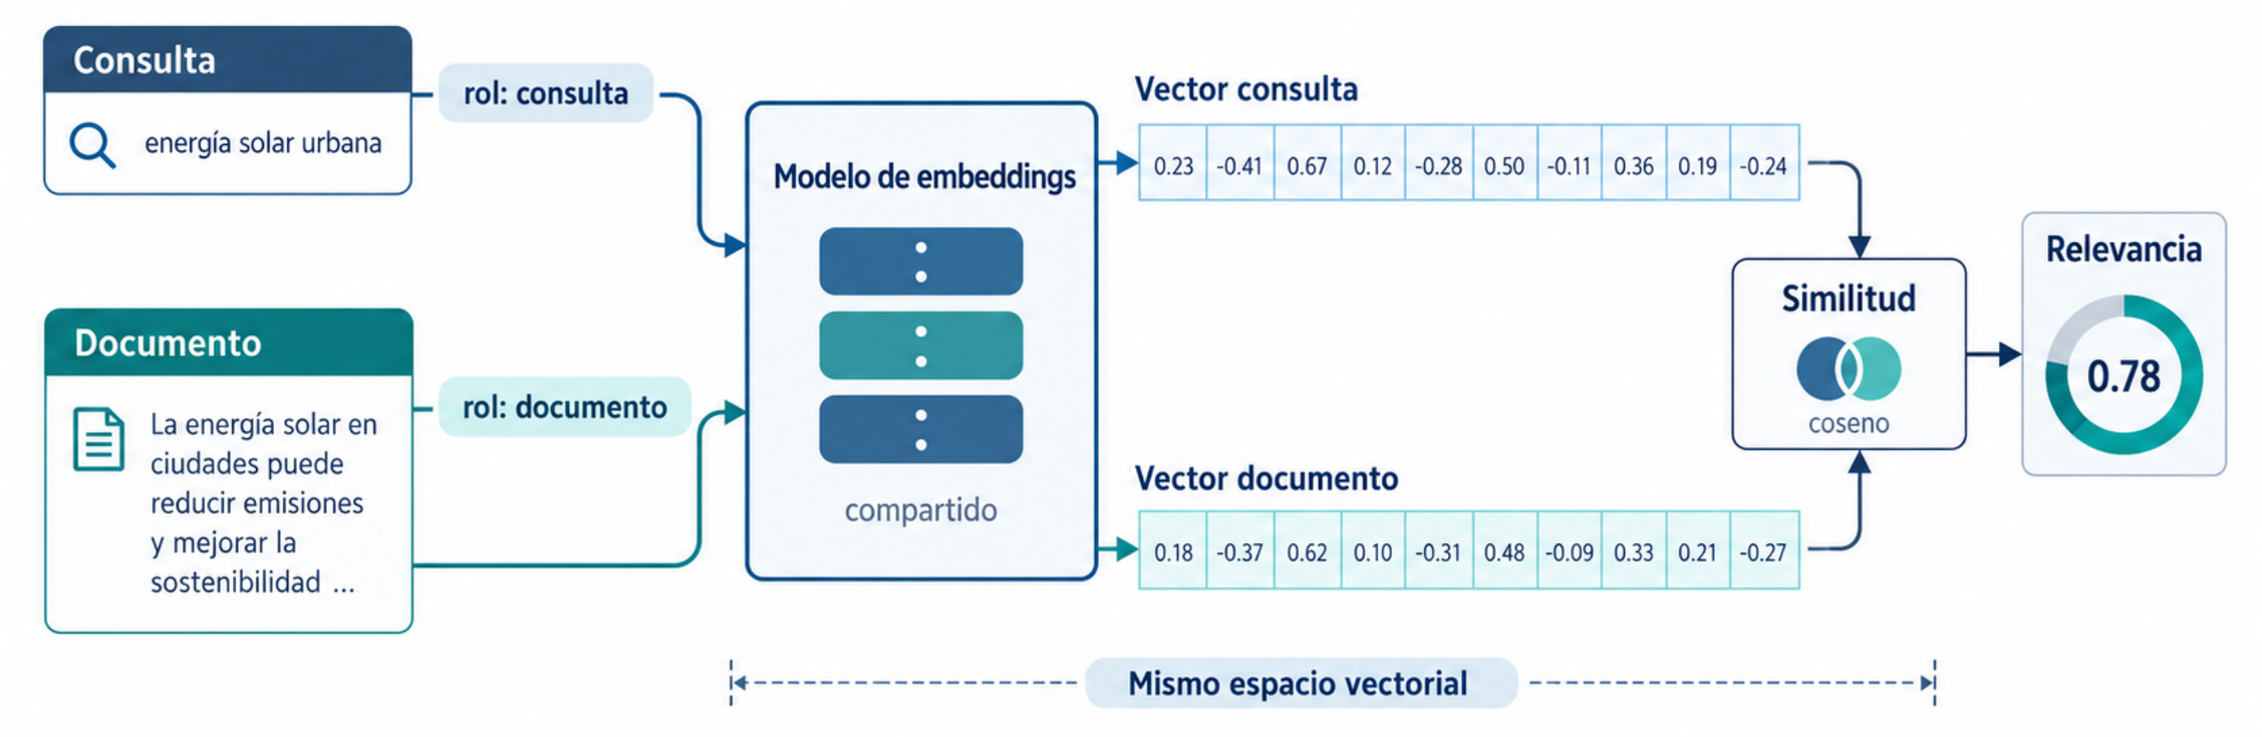

El objetivo no es que ambos textos sean idénticos, sino que el modelo aprenda cuándo un documento **responde adecuadamente a una consulta**.

Algunos modelos utilizan **instrucciones, prefijos o tipos de entrada** específicos para retrieval.

¿Qué modelos de embeddings usamos hoy?

EBIS Business Techschool

En la práctica podemos obtener embeddings mediante **servicios gestionados** o ejecutar modelos abiertos bajo nuestra propia infraestructura.

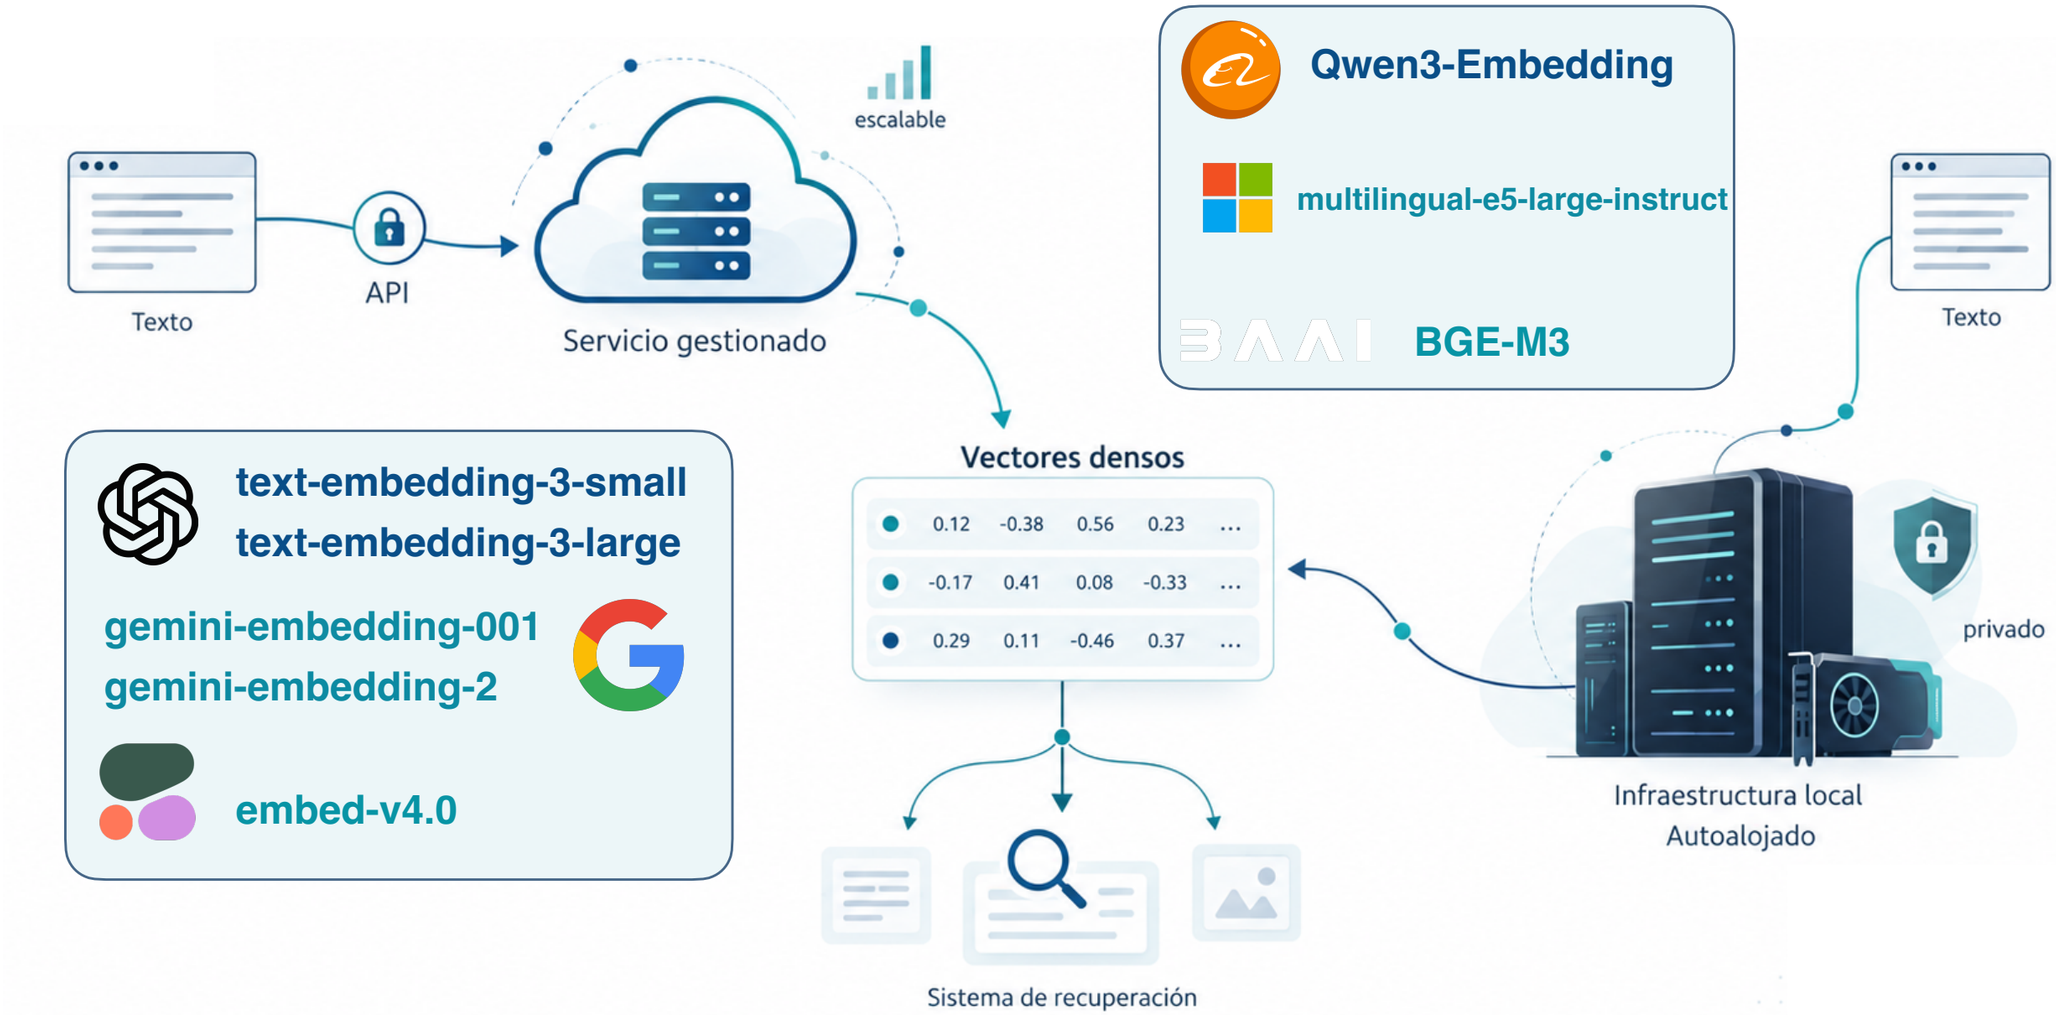

Dense retrieval tampoco es magia

Los embeddings permiten capturar relaciones más allá de la coincidencia literal, pero introducen **sus propios supuestos y limitaciones**.

Precisión léxica

Una representación semántica puede diluir diferencias que para nuestra aplicación son críticas.

Dependencia del modelo

Cada modelo construye su propio espacio y puede priorizar relaciones diferentes.

Opacidad

Las dimensiones no suelen ser directamente interpretables.

Coste e infraestructura

Generar, almacenar y consultar embeddings introduce nuevos requisitos operativos.

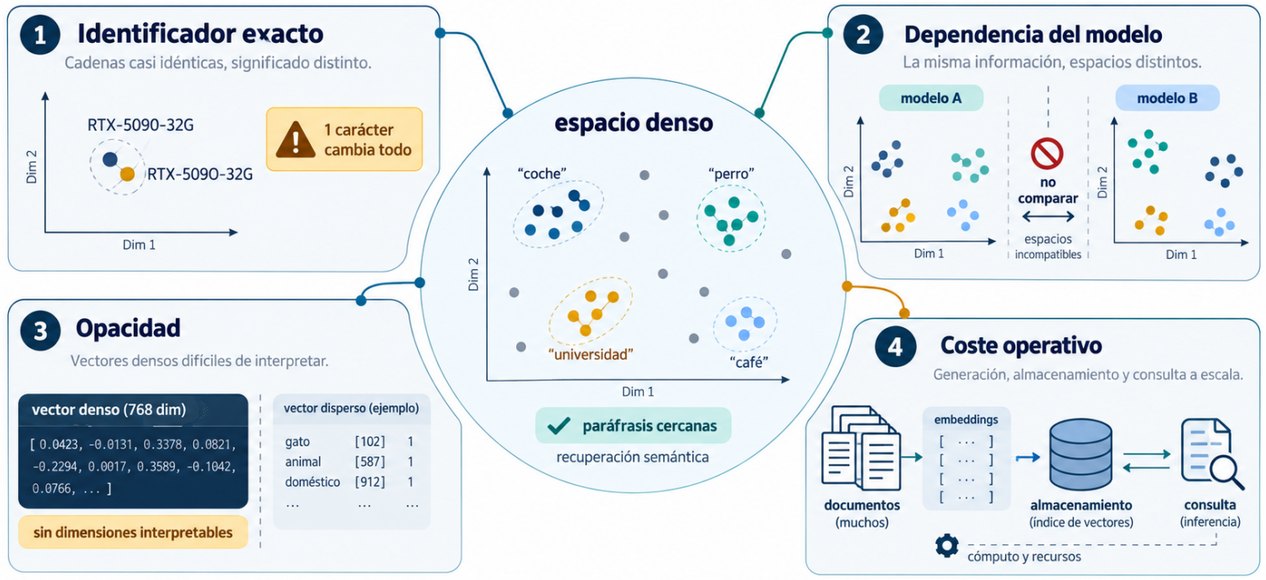

Nunca debemos comparar directamente embeddings generados por modelos o espacios incompatibles.

Sparse vs Dense: Dos formas de entender la relevancia

EBIS Business Techschool

Sparse vs Dense: el mismo corpus, dos rankings

EBIS Business Techschool

La misma consulta puede producir resultados diferentes dependiendo de la representación y de la señal utilizada para estimar relevancia.

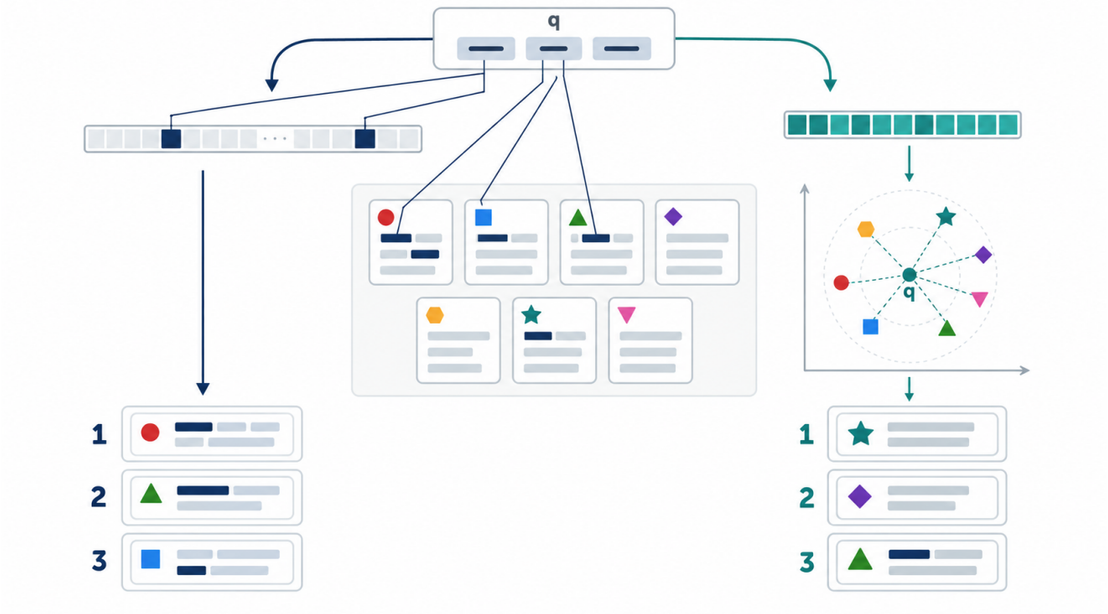

SPARSE
Prioriza principalmente coincidencia y relevancia **léxica**.

DENSE
Prioriza relaciones aprendidas dentro del espacio de embeddings.

No están intentando responder exactamente a la misma pregunta.

Dos señales complementarias

Para recuperar información necesitamos comparar la consulta ***q*** con cada elemento de la colección mediante el mismo criterio.

Sparse

- Coincidencia exacta
- Terminología específica
- Identificadores y entidades
- Alta interpretabilidad

Dense

- Paráfrasis
- Sinonimia
- Variabilidad lingüística
- Relaciones aprendidas

La elección adecuada **depende de qué tipo de relevancia necesitamos detectar**.

¿Y si no elegimos uno solo?

En muchos sistemas reales, la recuperación no se limita a elegir entre Sparse o Dense.

Relevancia léxica + Relevancia semántica

Podemos combinar distintas señales de recuperación y utilizar etapas posteriores para **refinar el ranking de candidatos**.

Esto nos lleva al siguiente paso: **Hybrid Retrieval, Reranking y métodos modernos de recuperación**.

¡Gracias y hasta la próxima!

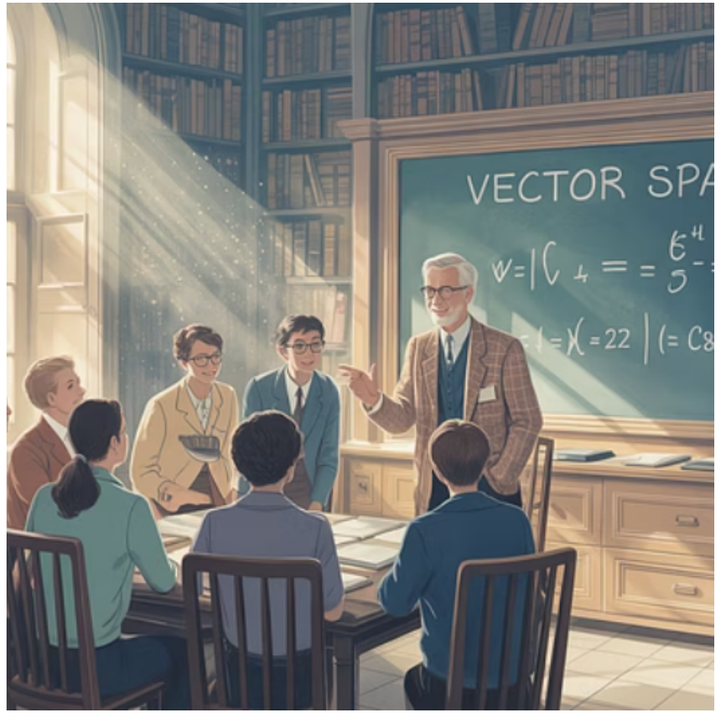

No dudéis en contactarme si tenéis dudas adicionales o necesitáis aclaraciones sobre cualquier aspecto del curso. Podéis encontrarme a través de:

Correo electrónico

albertoragmat@gmail.com

LinkedIn

Alberto Ruiz-Arteaga González

Tutorías

Todos los viernes de **17:30 a 18:30 (hora de Madrid)** en el **Metacampus**.

EBIS Business Techschool

www.ebiseducation.com