Tema 5: Sistemas de recuperación de la información, RAG y Langchain

EBIS Business Techschool

Contenidos

- Fundamentos matemáticos de la recuperación de información
- Representación de la información I: Sparse vs Dense
- Representación de la información II: Métodos modernos de retrieval
- Indexación y búsqueda eficiente
- Sistemas de almacenamiento y recuperación
- Construcción y evaluación de sistemas de recuperación
- Retrieval Augmented Generation

www.ebiseducation.com

Agenda de la sesión

EBIS Business Techschool

Más allá de Sparse vs Dense

Retomaremos las fortalezas y limitaciones de ambas representaciones para entender por qué los sistemas modernos de recuperación suelen combinar distintas señales en lugar de depender de un único método.

Hybrid Retrieval: combinar relevancia léxica y semántica

Estudiaremos cómo recuperar candidatos mediante Sparse y Dense de forma simultánea y cómo combinar rankings utilizando estrategias como ponderación de scores y **Reciprocal Rank Fusion (RRF)**.

Reranking: recuperar primero, ordenar mejor después

Introduciremos las arquitecturas de **Cross-Encoders** y el paradigma retrieve-then-rerank, entendiendo por qué podemos sacrificar eficiencia sobre un conjunto pequeño de candidatos para mejorar la precisión del ranking final.

Late Interaction y representaciones Multi-Vector

eremos alternativas intermedias entre los embeddings de un único vector y los Cross-Encoders, utilizando **ColBERT** como referencia para entender la interacción tardía y la representación de un documento mediante múltiples vectores.

Más allá del texto: representaciones multimodales

Cerraremos ampliando el concepto de embedding hacia modelos capaces de representar **texto, imágenes y otros tipos de información dentro de espacios compatibles**, analizando cómo cambia el problema de recuperación cuando aparecen varias modalidades.

Recap & Q&A

Resumen de conceptos clave y resolución de dudas.

Más allá de Sparse vs Dense

EBIS Business Techschool

Ningún retriever ve toda la relevancia

Sparse y Dense detectan **señales diferentes** dentro de una misma colección. Esto significa que también pueden recuperar candidatos distintos para una misma consulta.

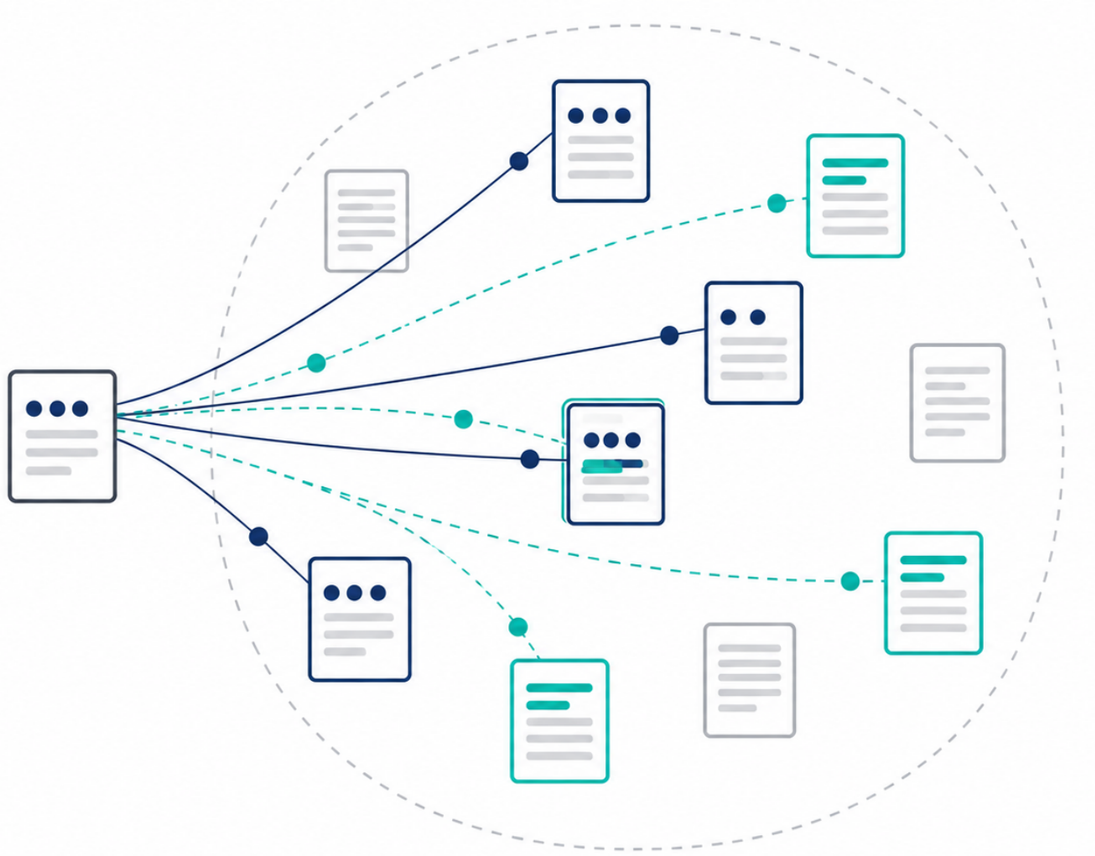

Sparse

Favorece coincidencias léxicas precisas y términos discriminativos.

Dense

Favorece relaciones aprendidas aunque consulta y documento utilicen palabras diferentes.

Cada método puede encontrar información relevante que el otro pasa por alto.

Los errores tampoco son los mismos

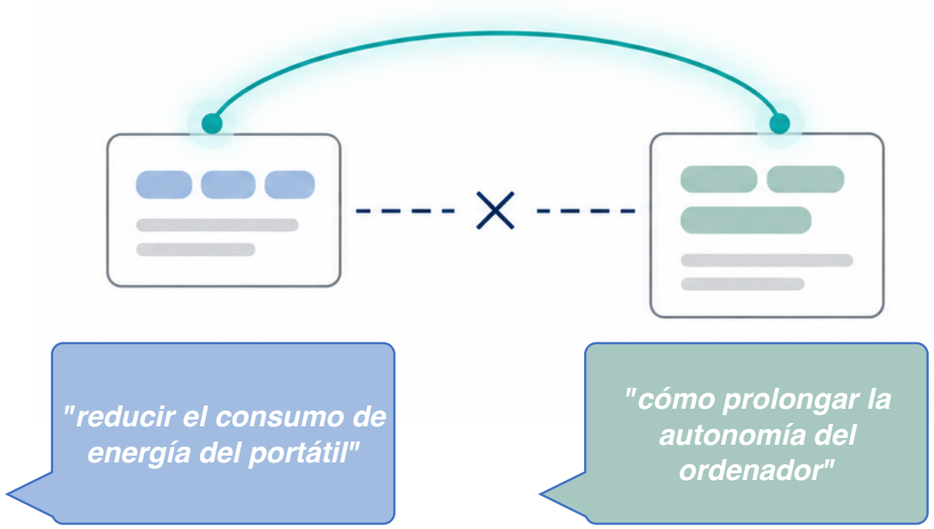

Sparse puede perder...

Poco solapamiento léxico

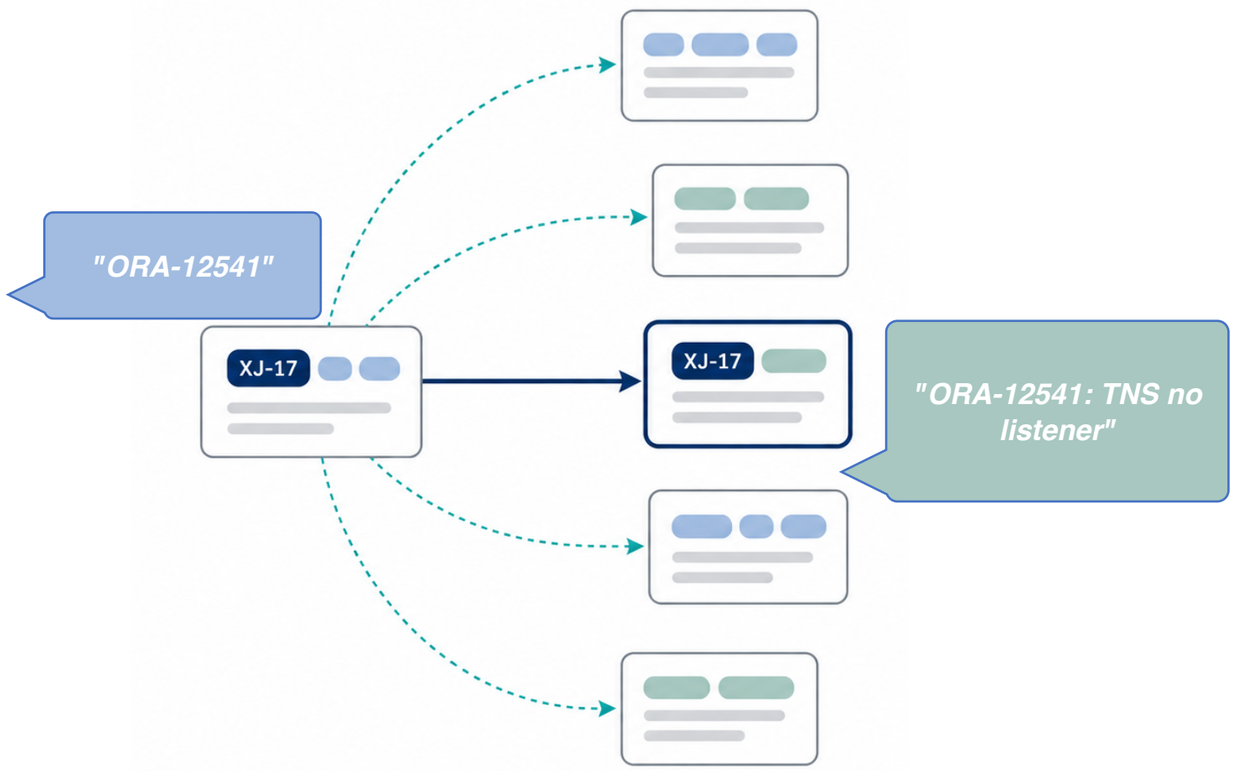

Dense puede perder...

Una coincidencia exacta que sea más útil que una aproximación semántica

De elegir un retriever a combinar señales

Si Sparse y Dense aportan evidencia complementaria, el problema deja de ser necesariamente: **¿cuál utilizamos?**

Y pasa a ser: **¿Cómo combinamos sus resultados?**

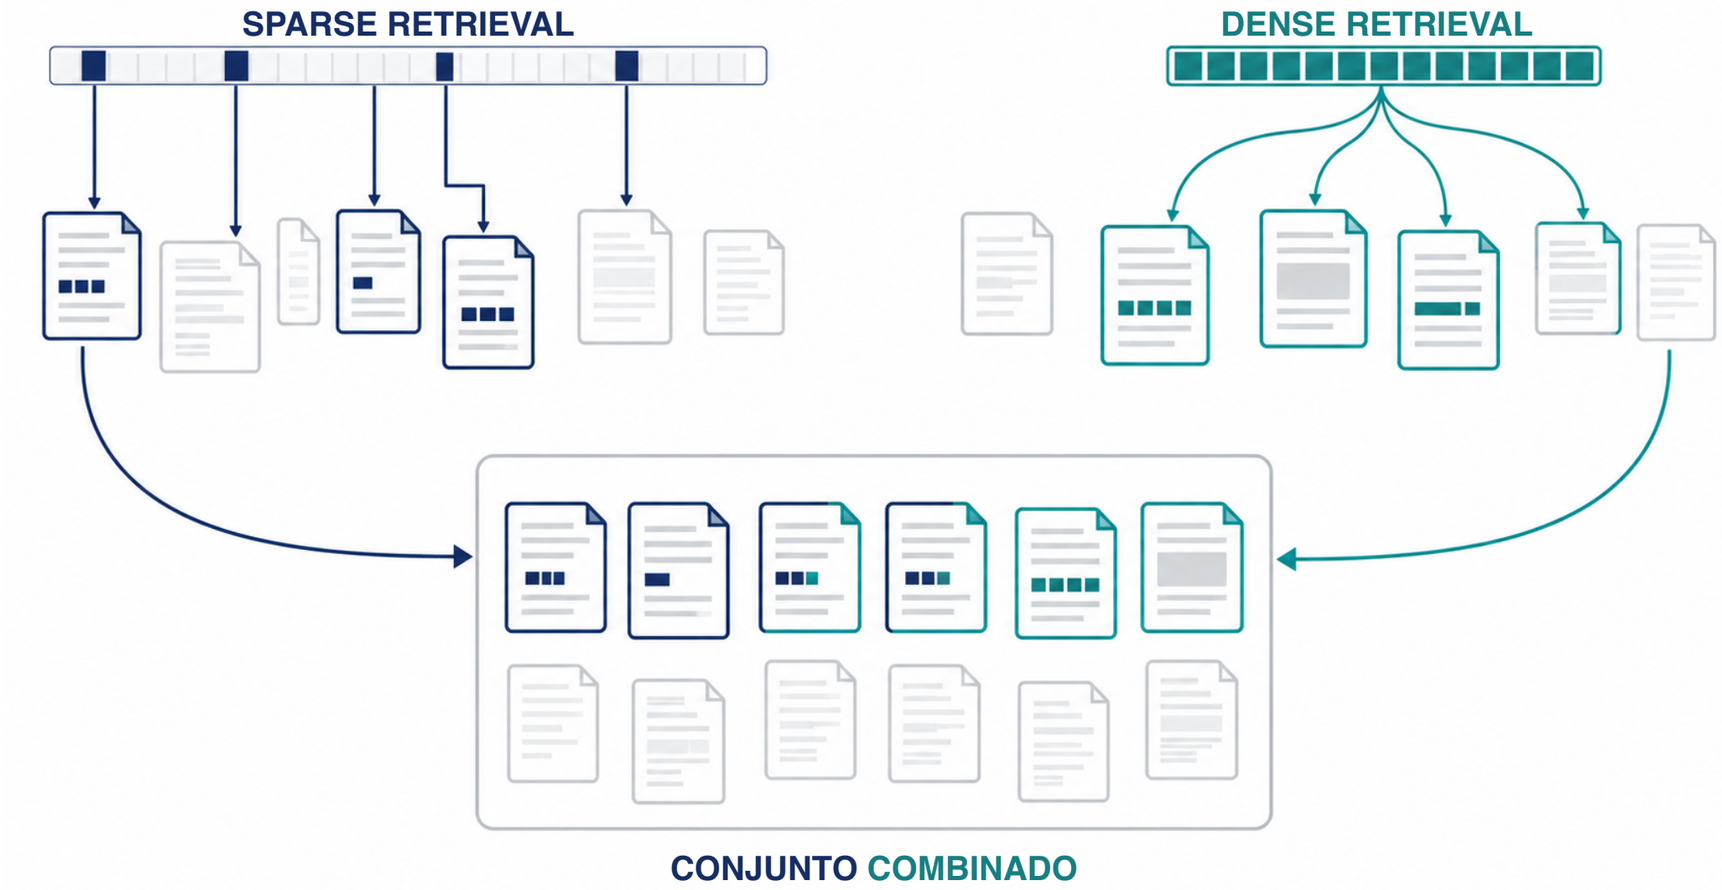

Hybrid Retrieval:
Combinar relevancia léxica y semántica

EBIS Business Techschool

Hybrid Retrieval: dos señales, una recuperación

EBIS Business Techschool

Un sistema híbrido utiliza **más de una estrategia de recuperación** sobre la misma consulta y combina posteriormente la evidencia obtenida.

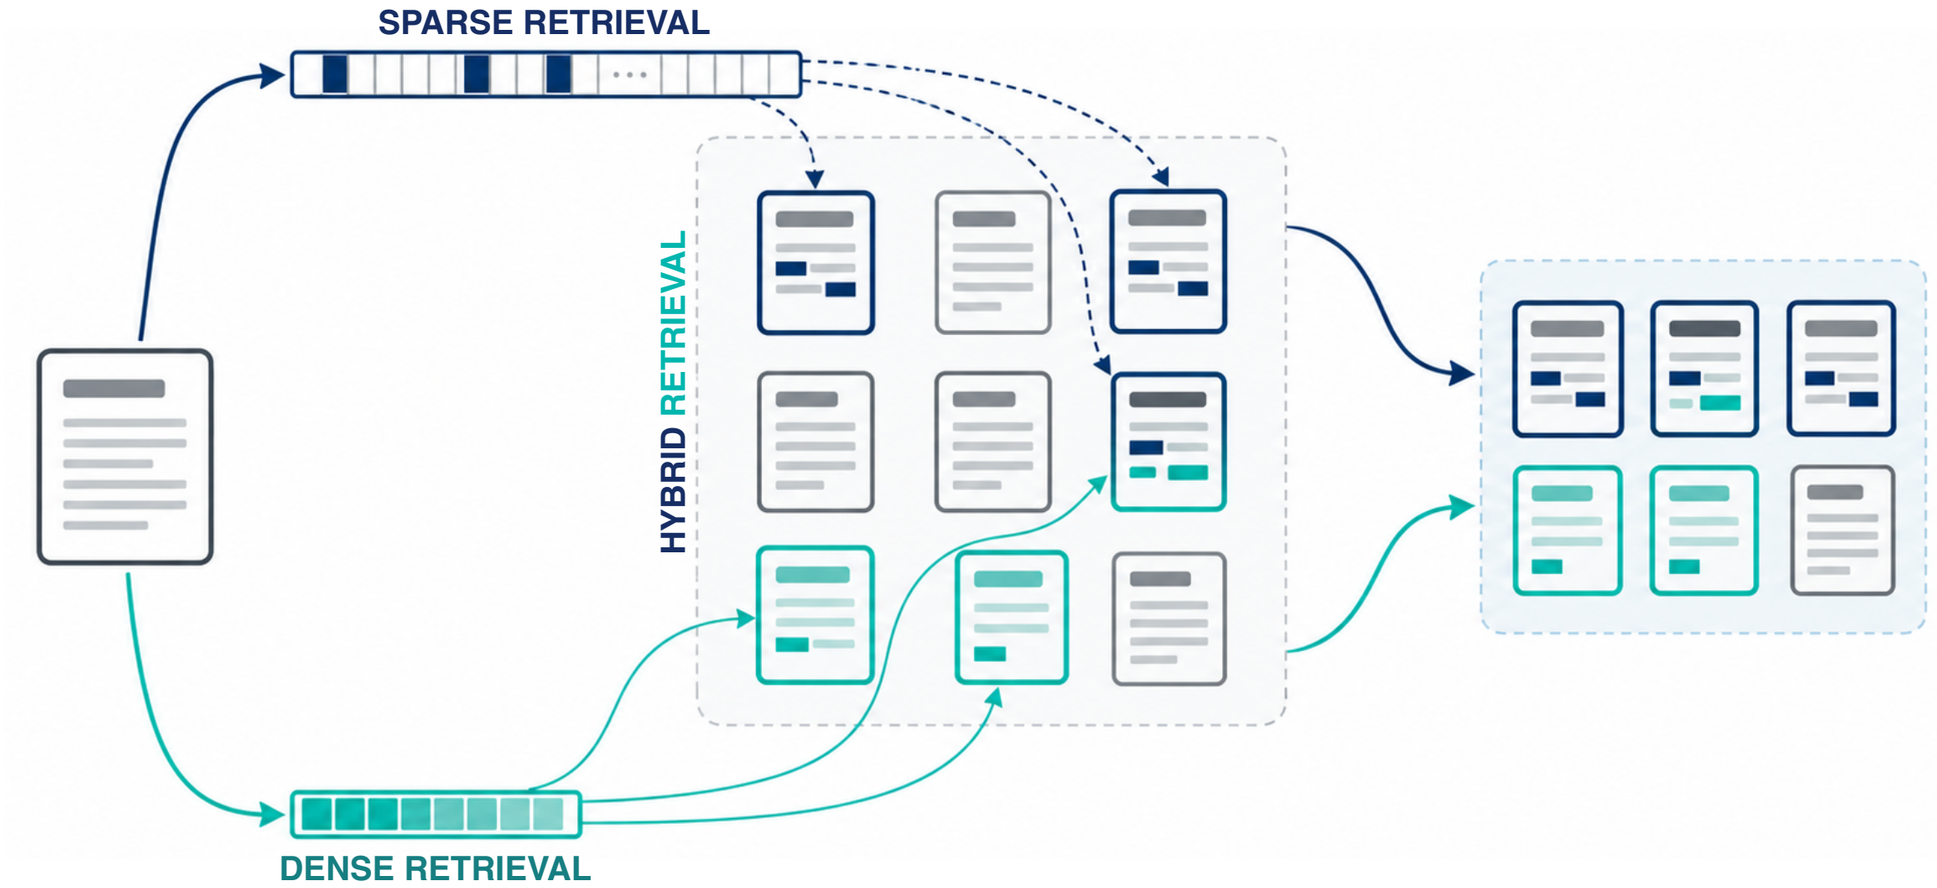

El objetivo no es que ambos retrievers estén de acuerdo, sino **aprovechar información relevante aportada por cualquiera de ellos**.

Los scores no hablan necesariamente el mismo idioma

EBIS Business Techschool

Combinar dos rankings no consiste simplemente en sumar sus puntuaciones. Cada retriever puede generar scores con **escalas, distribuciones e interpretaciones diferentes**.

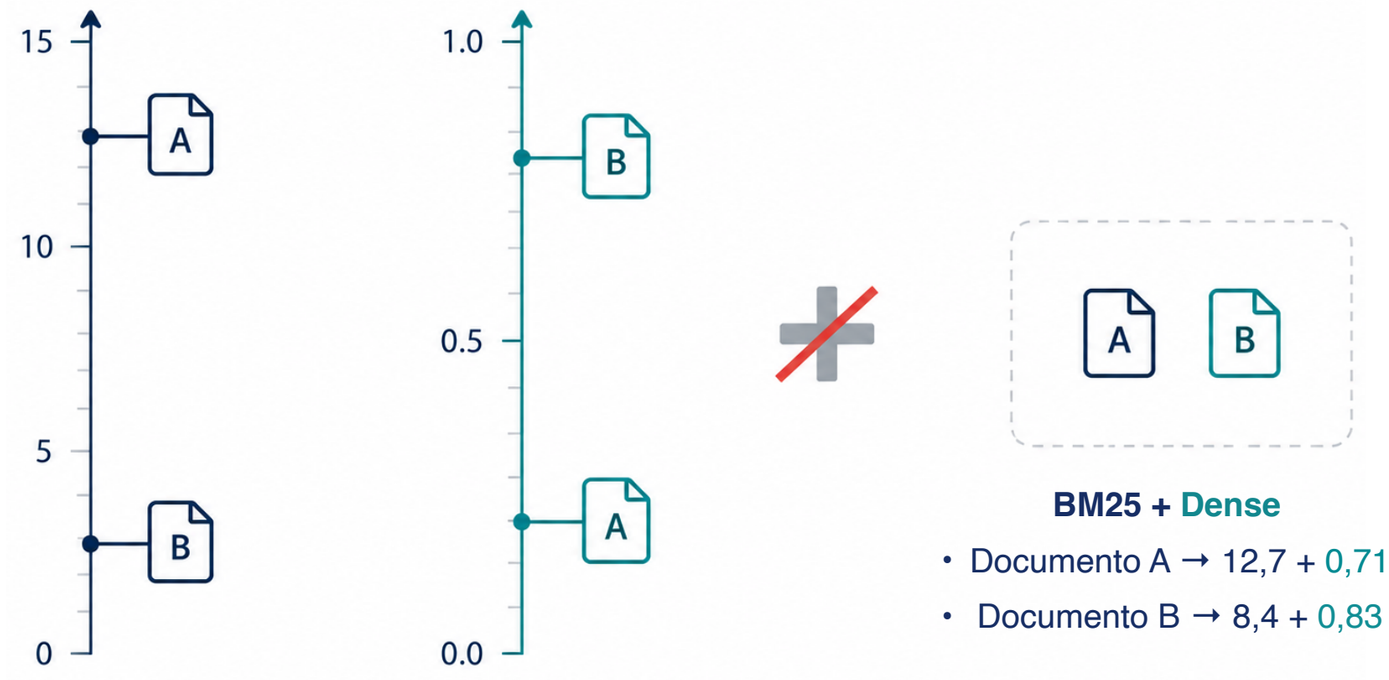

BM25

- Documento A → 12,7
- Documento B → 8,4

Dense

- Documento A → 0,71
- Documento B → 0,83

BM25 + Dense

- Documento A → 12,7 + 0,71
- Documento B → 8,4 + 0,83

No tiene una interpretación útil en sí misma

DOS ALTERNATIVAS

- **Score-Based Fusion:** Normalizar y ponderar las puntuaciones.
- **Rank-Based Fusion:** Combinar la posición que ocupa cada candidato en los rankings.

Score-based fusion: combinar señales normalizadas

Si queremos combinar directamente los scores de distintos retrievers, primero debemos llevarlos a una **escala comparable**.

Documento A

Sparse → #1

Dense → #4

Documento B

Sparse → #8

Dense → #1

Los valores originales no son directamente comparables porque proceden de **funciones de scoring diferentes**.

$$s_{hybrid}(d) = \alpha \cdot s^{norm}_{sparse}(d) + (1 - \alpha) \cdot s^{norm}_{dense}(d)$$

Normalización

Transformamos los scores de cada retriever a una escala común antes de combinarlos.

Ponderación

El parámetro α controla cuánto peso damos a la señal léxica frente a la señal dense.

Score-based fusion conserva información sobre la intensidad de cada señal, pero exige que los scores sean comparables.

Reciprocal Rank Fusion: combinar posiciones

Reciprocal Rank Fusion (RRF) evita comparar directamente los scores originales y utiliza únicamente la **posición de cada documento dentro de cada ranking**.

$$RRF(d) = \sum_{r \in R} \frac{1}{k + \text{rank}_r(d)}$$

$\text{rank}_r(d) \rightarrow$ posición del documento d en el ranking r

$k \rightarrow$ constante que suaviza la diferencia entre posiciones

Ejemplo con *k = 60*:

Documento A

Sparse → #1
Dense → #4

$$RRF(A) = \frac{1}{60+1} + \frac{1}{60+4} = 0{,}032$$

Documento B

Sparse → #8
Dense → #1

$$RRF(B) = \frac{1}{60+8} + \frac{1}{60+1} = 0{,}031$$

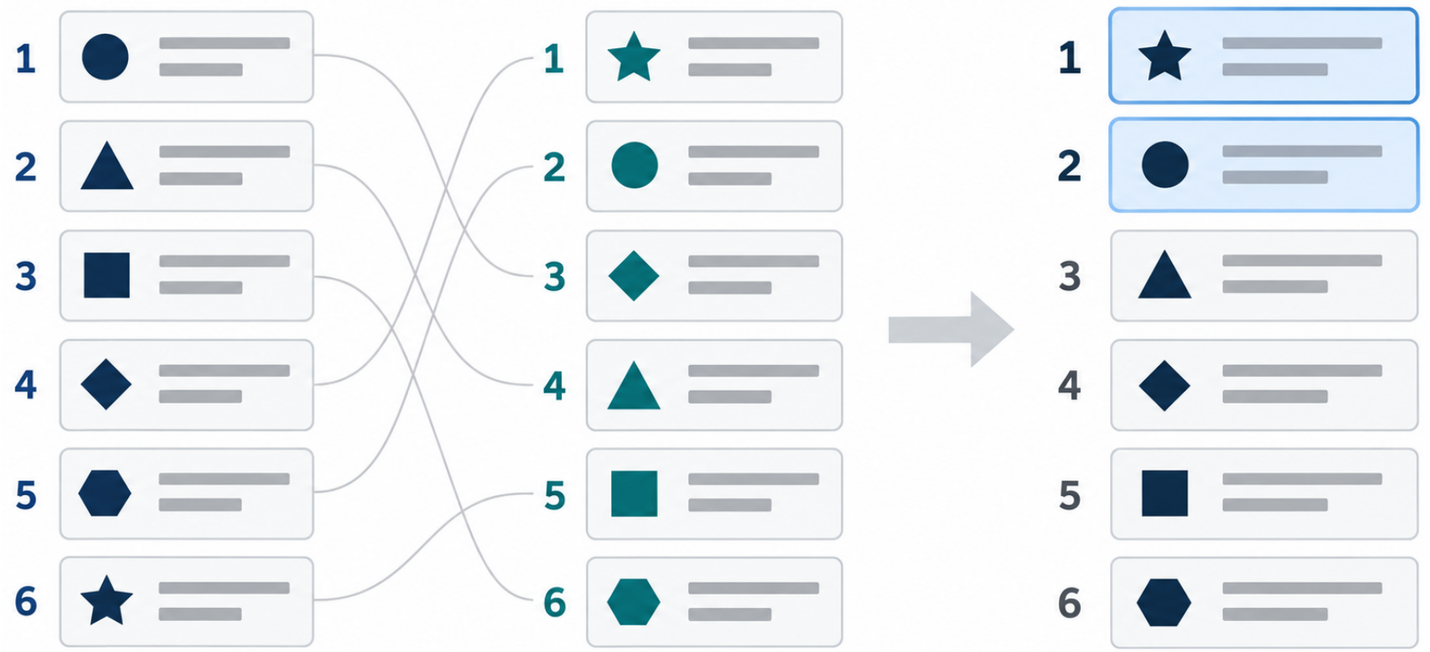

Reranking: recuperar primero, ordenar mejor después

EBIS Business Techschool

Recuperar candidatos no significa ordenar perfectamente

EBIS Business Techschool

Los retrievers de primera etapa están diseñados para encontrar buenos candidatos de forma **rápida y escalable**. Su objetivo principal es no dejar fuera información relevante.

1 Corpus completo → Top *k* candidatos

Aquí priorizamos **recall y eficiencia**.

2 Top *k* candidatos → Ranking refinado

Podemos permitirnos utilizar un método **más preciso y costoso**.

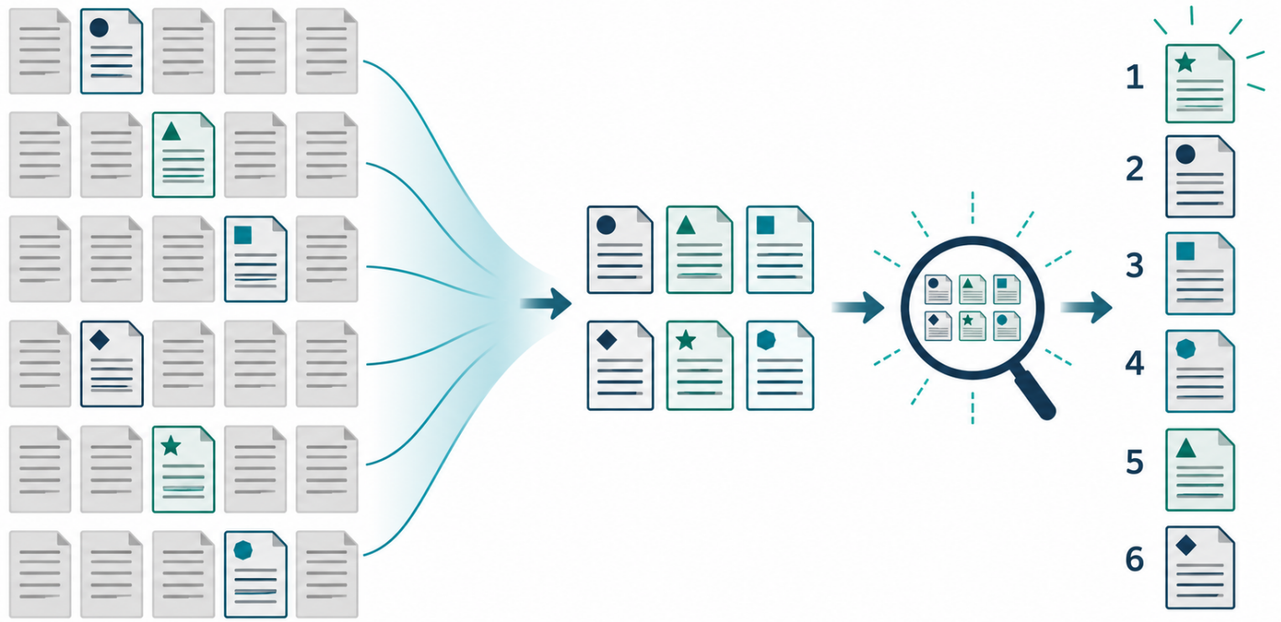

Si reducimos millones de documentos a unas pocas decenas, podemos gastar mucho más cómputo en decidir **qué candidato debe ir primero**.

Bi-Encoder vs Cross-Encoder

EBIS Business Techschool

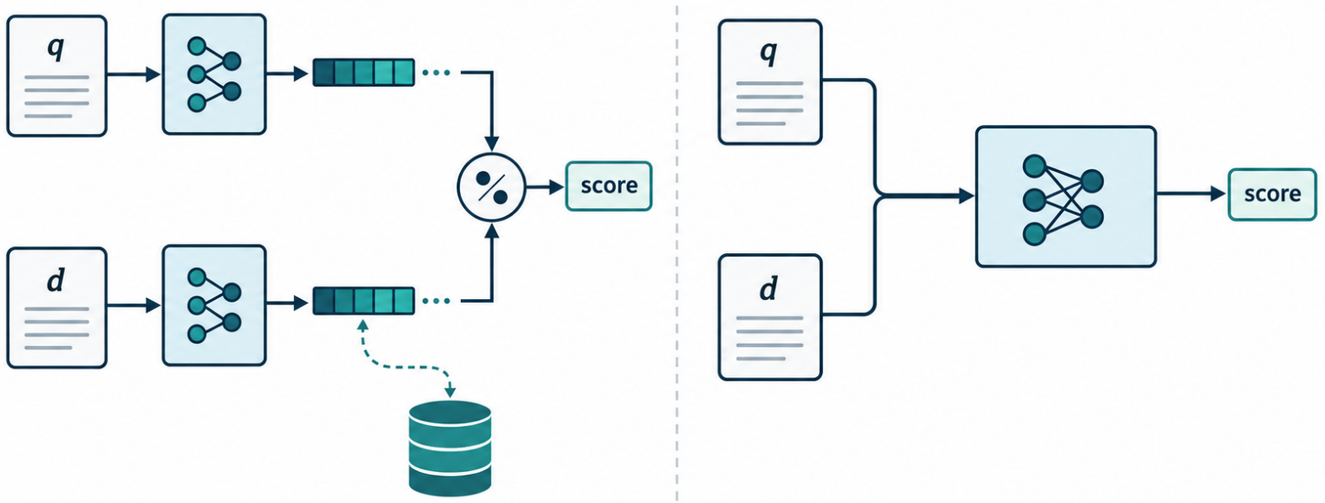

La diferencia fundamental está en c**uándo permitimos que query y documento interactúen.**

1 Bi-Encoder

Query y documento se codifican **por separado**.

$$q \rightarrow \mathrm{e}_q \qquad d \rightarrow \mathrm{e}_d \qquad \Rightarrow \qquad score(q,d) = sim(\mathrm{e}_q, \mathrm{e}_d)$$

2 Cross-Encoder

Query y documento se procesan **conjuntamente**.

$$[q,d] \rightarrow Model \rightarrow score$$

El modelo puede analizar directamente las interacciones entre ambos textos.

¿Por qué un Cross-Encoder puede ordenar mejor?

Un embedding comprime cada texto en una única representación antes de conocer el otro elemento de la comparación. Un Cross-Encoder, en cambio, puede analizar **query y documento conjuntamente**.

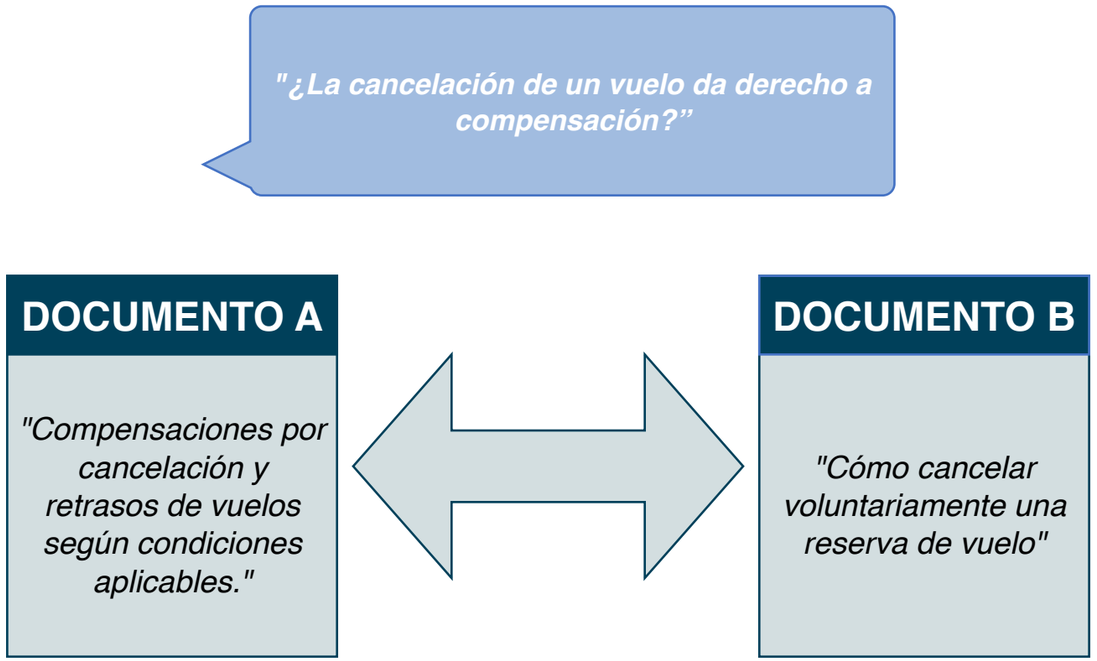

Ambos documentos comparten vocabulario relevante a la query, **pero solo uno responde realmente a la intención de la consulta**.

El Cross-Encoder nos ofrece...

Interacción término a término

El modelo puede relacionar partes concretas de query y documento.

Contexto conjunto

Una palabra se interpreta teniendo en cuenta el contenido del otro texto

Score directo

El modelo aprende específicamente a estimar relevancia entre la pareja completa.

Retrieve first, Rerank second

La arquitectura habitual combina la **eficiencia del retriever** con la **precisión del reranker**.

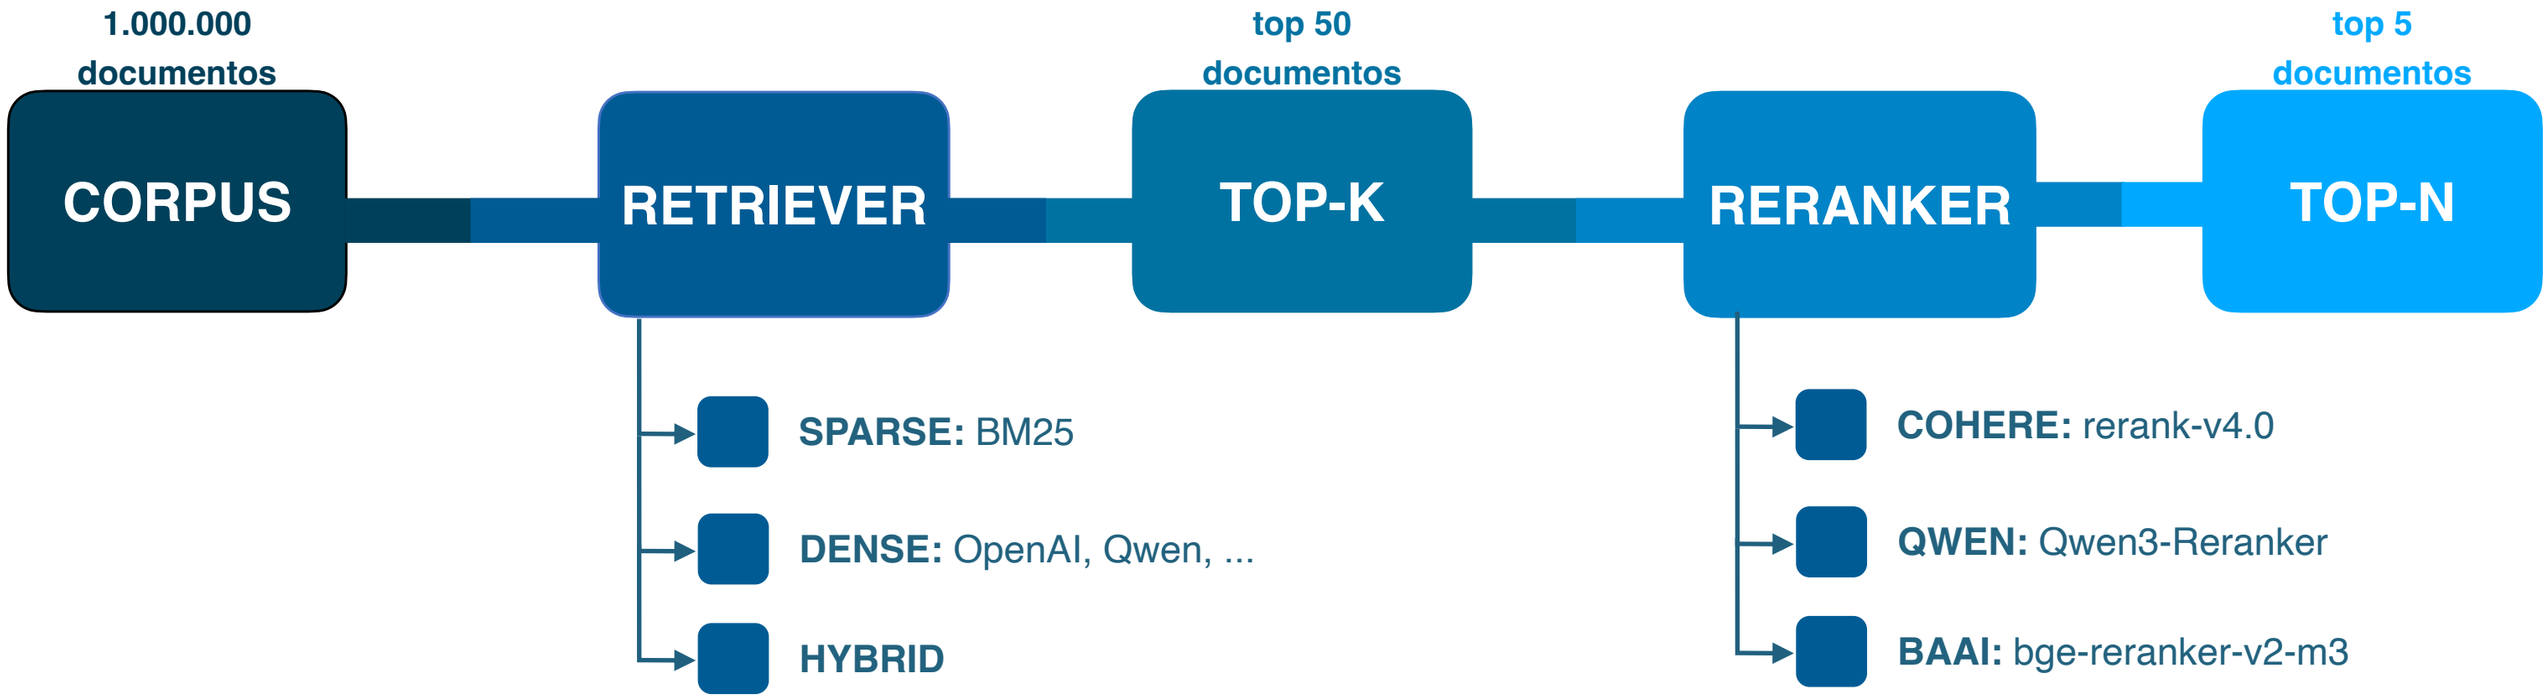

Late Interaction y representaciones Multi-Vector

EBIS Business Techschool

¿Qué perdemos al comprimir un texto en un solo vector?

En Dense Retrieval tradicional, todo el contenido de una query o un documento termina condensado en **una única representación vectorial**.

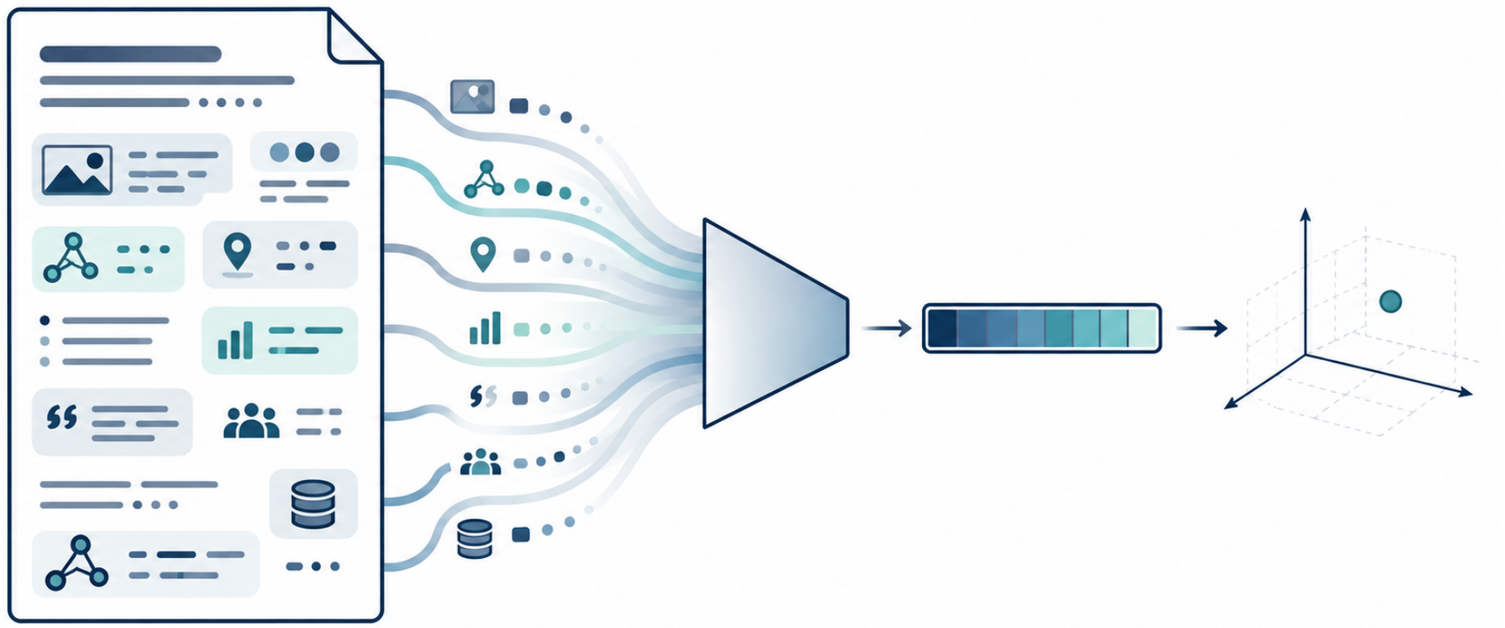

Esta compresión permite una recuperación extremadamente eficiente, pero obliga al modelo a condensar en un único punto información sobre:

términos · entidades · temas · relaciones · matices

Dos textos pueden ser globalmente parecidos y, aun así, diferir en **qué partes concretas resultan relevantes para la consulta**.

¿Y si conservamos varias representaciones por texto en lugar de una sola?

Multi-Vector: Conservar más detalle

EBIS Business Techschool

En una representación Multi-Vector, un documento no tiene por qué reducirse a un único embedding. Podemos conservar **múltiples vectores asociados a diferentes partes de su contenido**.

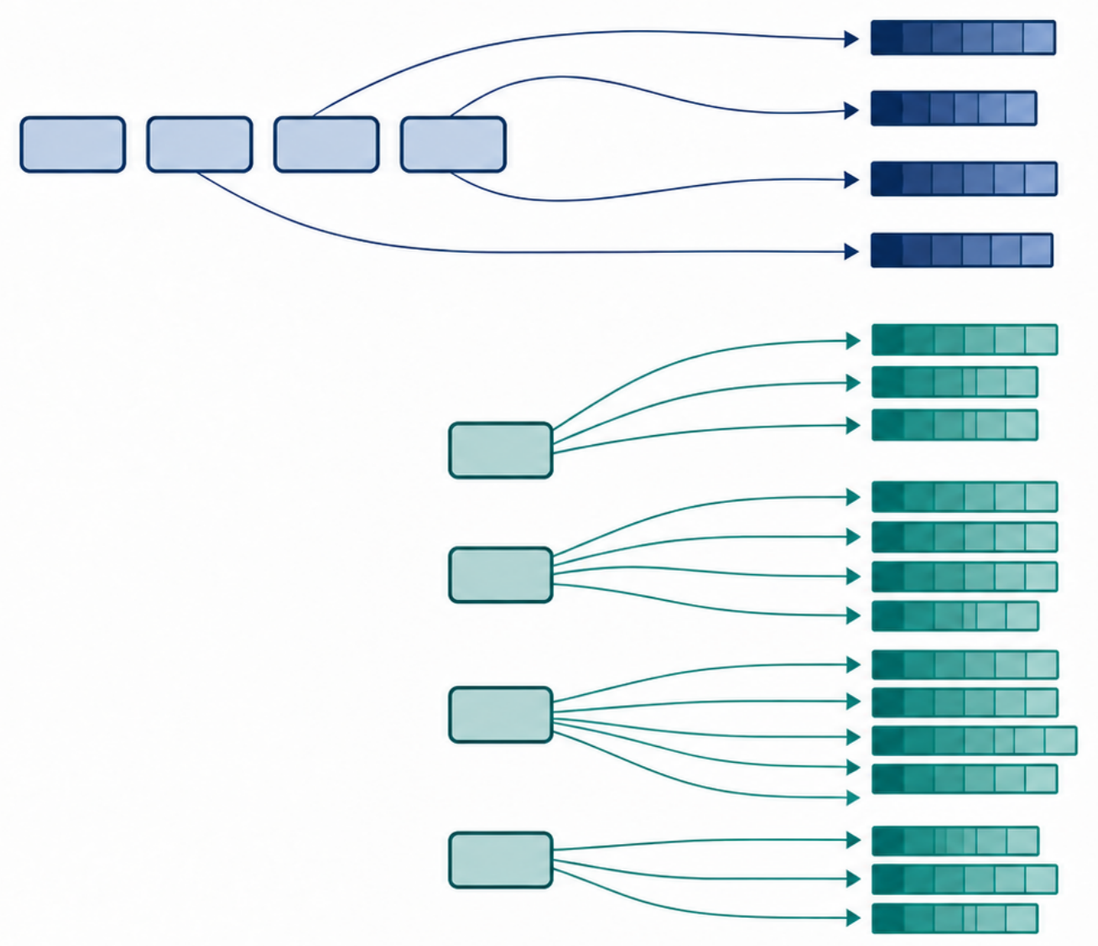

Single-Vector

Documento $d \rightarrow \mathrm{e}_d$

Query $q \rightarrow \mathrm{e}_q$

Multi-Vector

Documento $d \rightarrow \{\mathrm{e}_{1,d}, e_{2,d}, \ldots, e_{m,d}\}$

Query $q \rightarrow \{\mathrm{e}_{1,q}, e_{2,q}, \ldots, e_{m,q}\}$

Esto permite comparar **partes concretas de la query con partes concretas del documento** sin procesarlos conjuntamente desde el principio.

Late-Interaction: interactuar después de representar

Late Interaction mantiene la eficiencia de **codificar query y documentos por separado**, pero retrasa la interacción hasta disponer de sus representaciones locales.

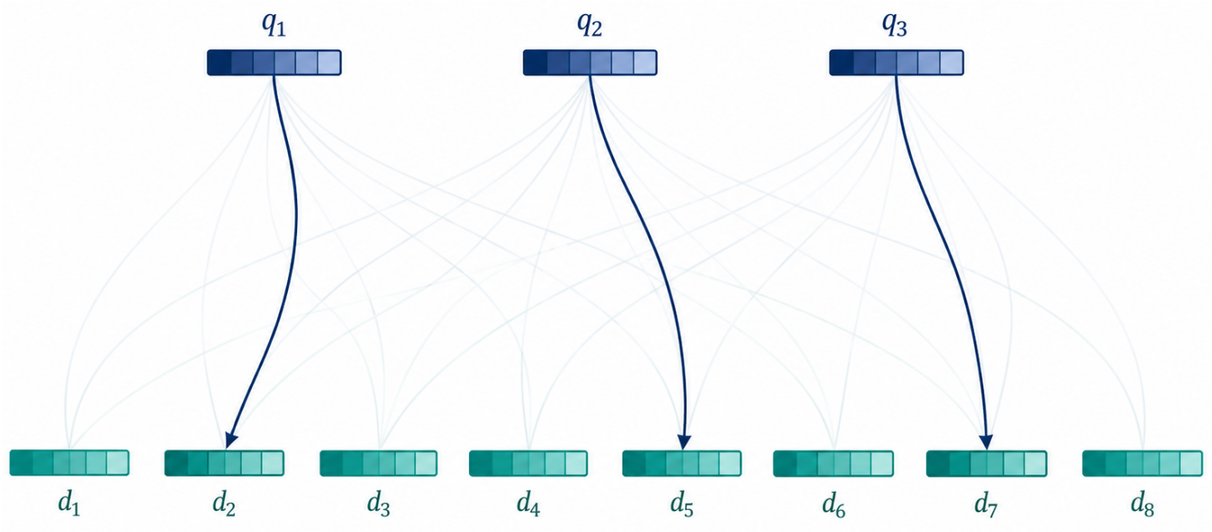

$$score(q,d) = \sum_i \max_j sim(q_i, d_j)$$

Para cada sub-vector de la query:

1. Buscamos la parte del documento más similar.
2. Conservamos esa mejor coincidencia.
3. Agregamos las coincidencias obtenidas.

Cada término de la query puede encontrar su mejor correspondencia dentro del documento.

ColBERT: entre Bi-Encoder y Cross-Encoder

ColBERT es el ejemplo clásico de Late Interaction: conserva representaciones a nivel de token y permite interacción detallada sin procesar cada pareja query-documento conjuntamente mediante un Cross-Encoder.

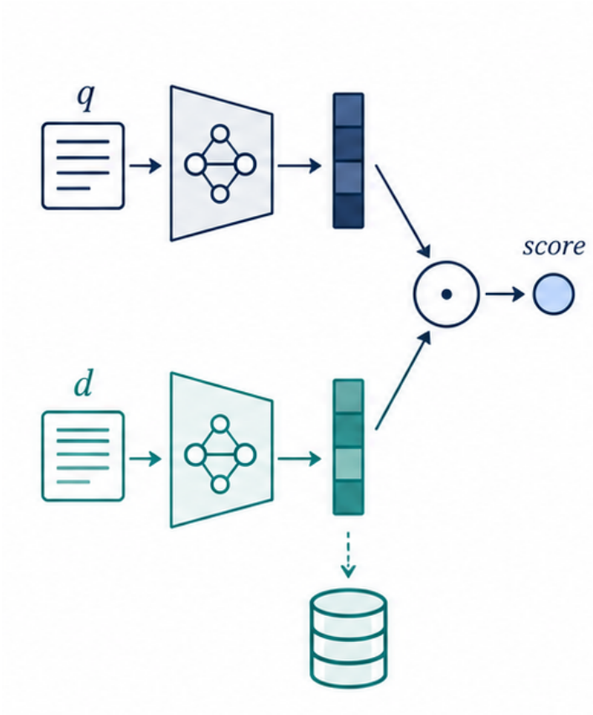

Bi-Encoder - 1 vector por texto

Muy eficiente

Interacción limitada

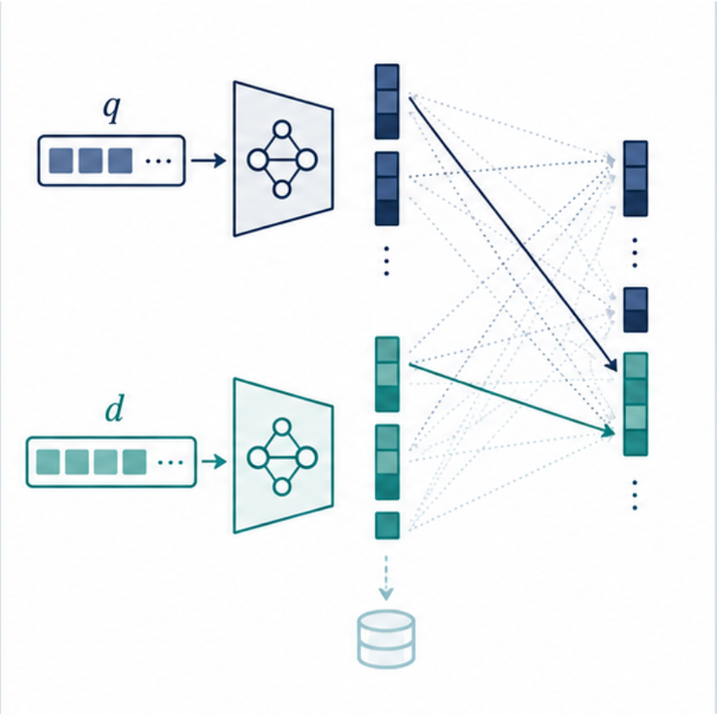

ColBERT / Late Int. - Varios vectores por texto

Interacción local posterior

Equilibrio entre detalle y eficiencia

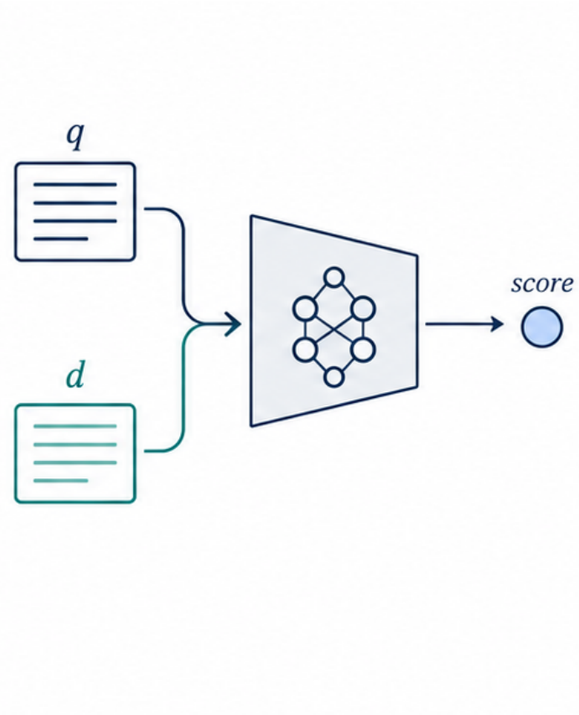

Cross-Encoder - Query + Documento juntos

Máxima interacción

Coste computacional elevado

Más interacción → Mayor capacidad de modelar relevancia

Más independencia → Mayor capacidad de precomputación e indexación

Más allá del texto: representaciones multimodales

EBIS Business Techschool

Un mismo espacio para distintas modalidades

Una representación multimodal busca proyectar diferentes tipos de información dentro de un **espacio compatible**, de forma que podamos comparar elementos aunque procedan de modalidades distintas.

$$\text{texto} \rightarrow e_{txt}$$

$$\text{imagen} \rightarrow e_{im}$$

$$\text{audio} \rightarrow e_{au}$$

$$\text{vídeo} \rightarrow e_{vid}$$

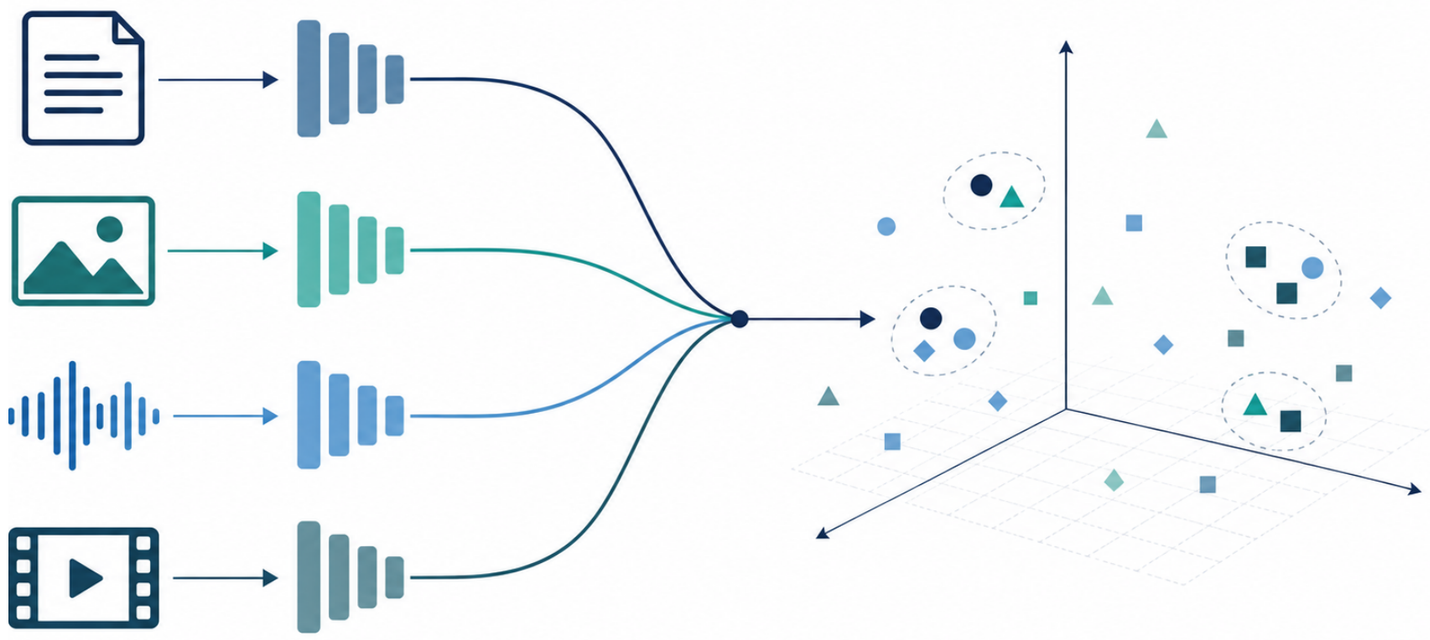

Si las representaciones son compatibles, podemos utilizar **la misma lógica geométrica de recuperación** independientemente de la modalidad original.

Cross-modal retrieval

EBIS Business Techschool

Cuando distintas modalidades comparten un espacio compatible, la consulta y los candidatos **no necesitan tener el mismo formato**.

"perro corriendo por la playa"

Texto → Recuperar imágenes

fotografía de un producto → Recuperar ficha técnica

Imagen → Recuperar texto

fragmento sonoro → vídeos o documentos asociados

Audio → Recuperar contenido relacionado

La comparación deja de ser texto contra texto y pasa a ser significado representado contra significado representado.

La idea general no cambia

Aunque cambien los modelos y las modalidades, el problema fundamental de recuperación sigue siendo el mismo:

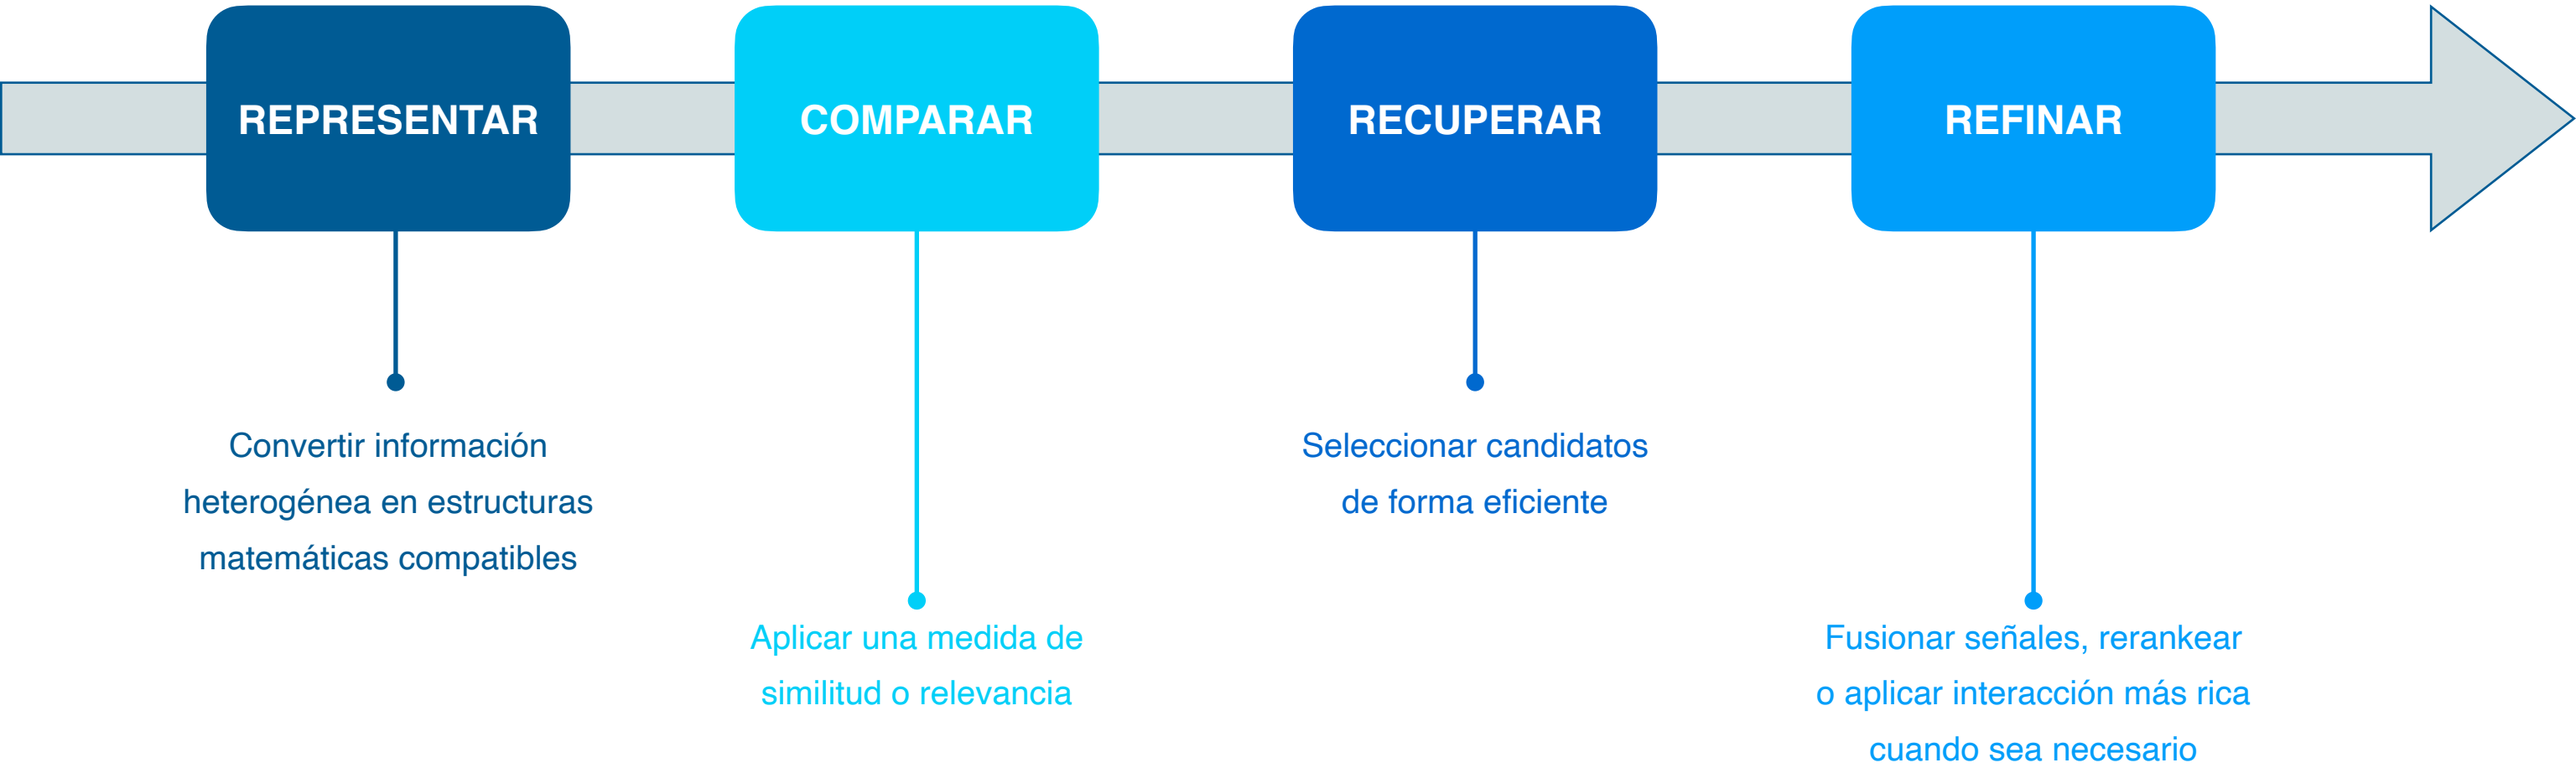

La arquitectura cambia, pero el principio permanece: **la calidad del retrieval depende de qué información conserva la representación y de cómo la utilizamos para comparar candidatos.**

¡Gracias y hasta la próxima!

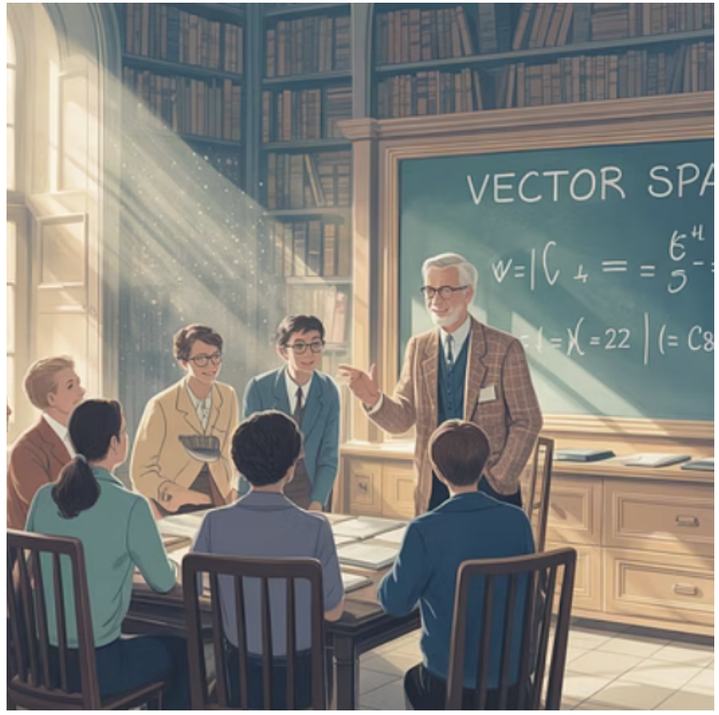

No dudéis en contactarme si tenéis dudas adicionales o necesitáis aclaraciones sobre cualquier aspecto del curso. Podéis encontrarme a través de:

Correo electrónico

albertoragmat@gmail.com

LinkedIn

Alberto Ruiz-Arteaga González

Tutorías

Todos los viernes de **17:30 a 18:30 (hora de Madrid)** en el **Metacampus**.

EBIS Business Techschool

www.ebiseducation.com