

Tema 5: Sistemas de recuperación de la información, RAG y Langchain

EBIS Business Techschool

Contenidos

- Fundamentos matemáticos de la recuperación de información
- Representación de la información I: Sparse vs Dense
- Representación de la información II: Métodos modernos de retrieval
- Indexación y búsqueda eficiente
- **Sistemas de almacenamiento y recuperación**
- Construcción y evaluación de sistemas de recuperación
- Retrieval Augmented Generation



Agenda de la sesión

EBIS Business Techschool

1

Del índice vectorial a un sistema de almacenamiento

Del motor ANN al sistema que persiste, actualiza y sirve datos.

2

Datos, metadatos y búsqueda filtrada

Cómo combinar similitud semántica con restricciones estructuradas.

3

Persistencia, actualización y operación del sistema

Versionado, frescura, disponibilidad y ciclo de vida.

4

Vector databases, PostgreSQL + pgvector y despliegue

Opciones especializadas, relacionales, self-hosted y managed.

5

Diseño y elección de una arquitectura de recuperación

Decidir desde patrones de consulta, escala y requisitos.

6

Recap & Q&A

Resumen de conceptos clave y resolución de dudas.

Del índice vectorial a un sistema de almacenamiento

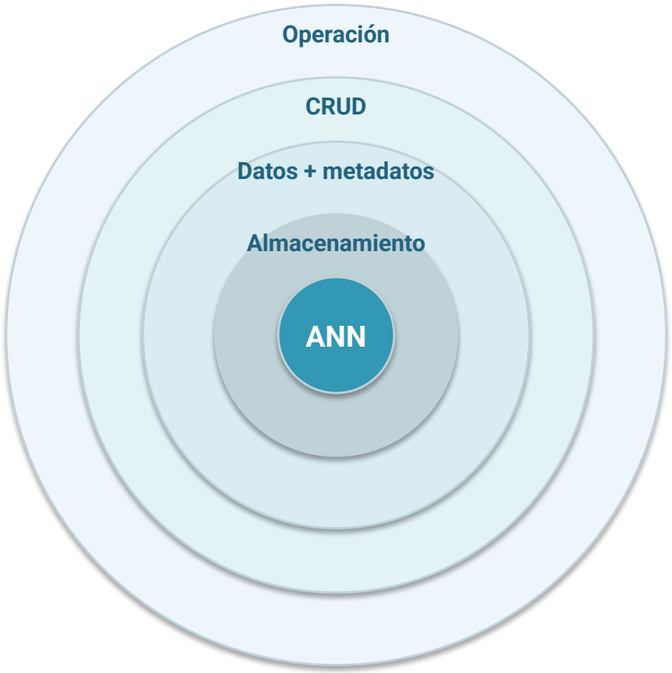


EBIS Business Techschool

Un índice vectorial resuelve solo una parte del problema

HNSW, IVF o cualquier otro índice ANN resuelven una pregunta muy concreta:

¿Cómo encontrar rápidamente los vectores más próximos a una query?



1. **¿Dónde viven los datos?**

   Los vectores y documentos deben sobrevivir al proceso que ejecuta la búsqueda.

2. **¿Cómo cambian?**

   Necesitamos insertar, actualizar y eliminar información.

3. **¿Cómo describimos cada vector?**

   IDs, metadatos, permisos, fechas, categorías, versiones…

4. **¿Cómo operamos el sistema?**

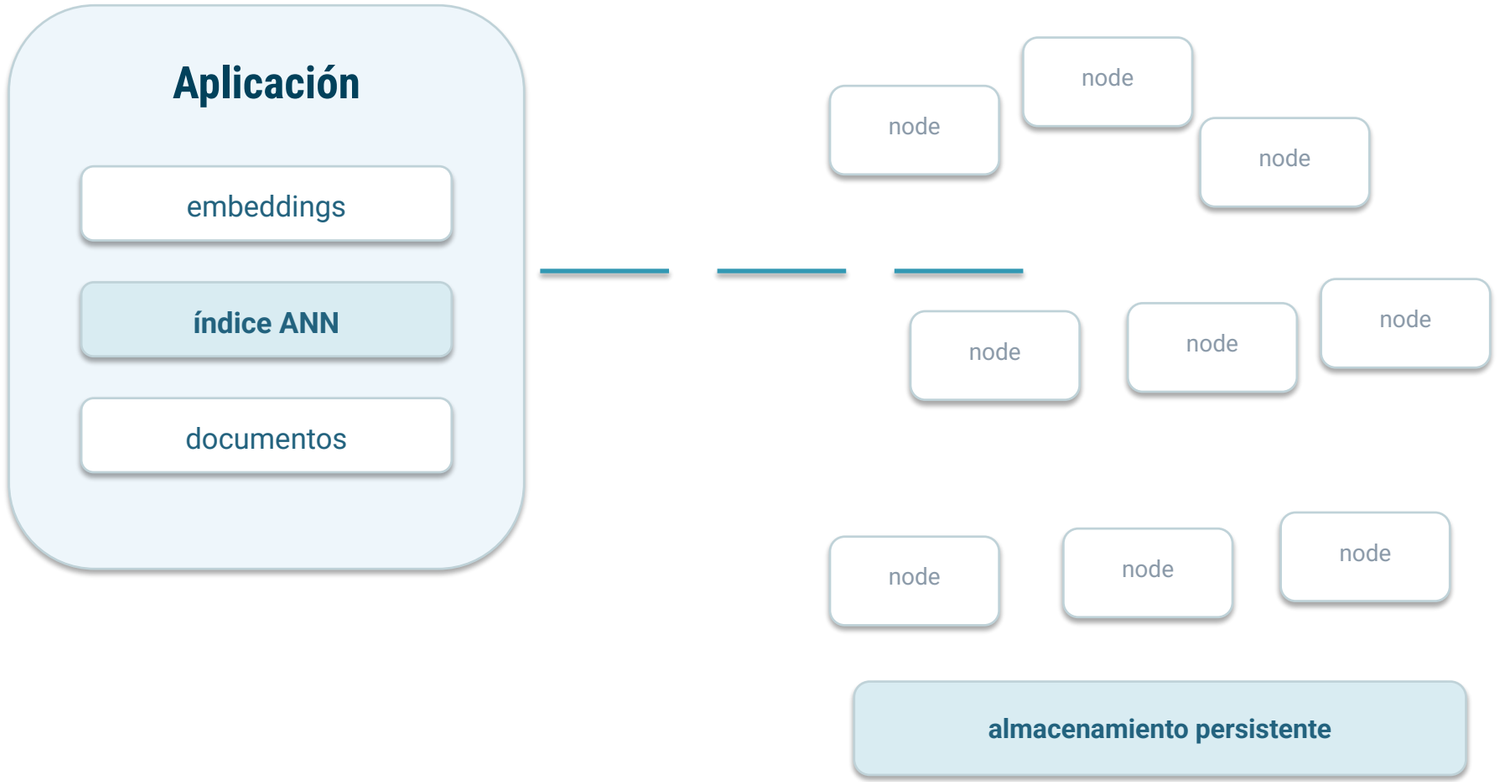
   Concurrencia, escalado, backups, disponibilidad, monitorización…

El índice optimiza la búsqueda. La base de datos gestiona el ciclo de vida de la información.

¿Por qué no quedarnos simplemente con un índice local?

EBIS Business Techschool

Para prototipos y colecciones pequeñas, una aplicación puede mantener embeddings e índice directamente en el mismo proceso.



1 Capacidad

Vectores, índice y estructuras auxiliares pueden requerir decenas o cientos de GB.

2 Persistencia

Reiniciar un proceso no debería implicar reconstruir todo el estado.

3 Concurrencia

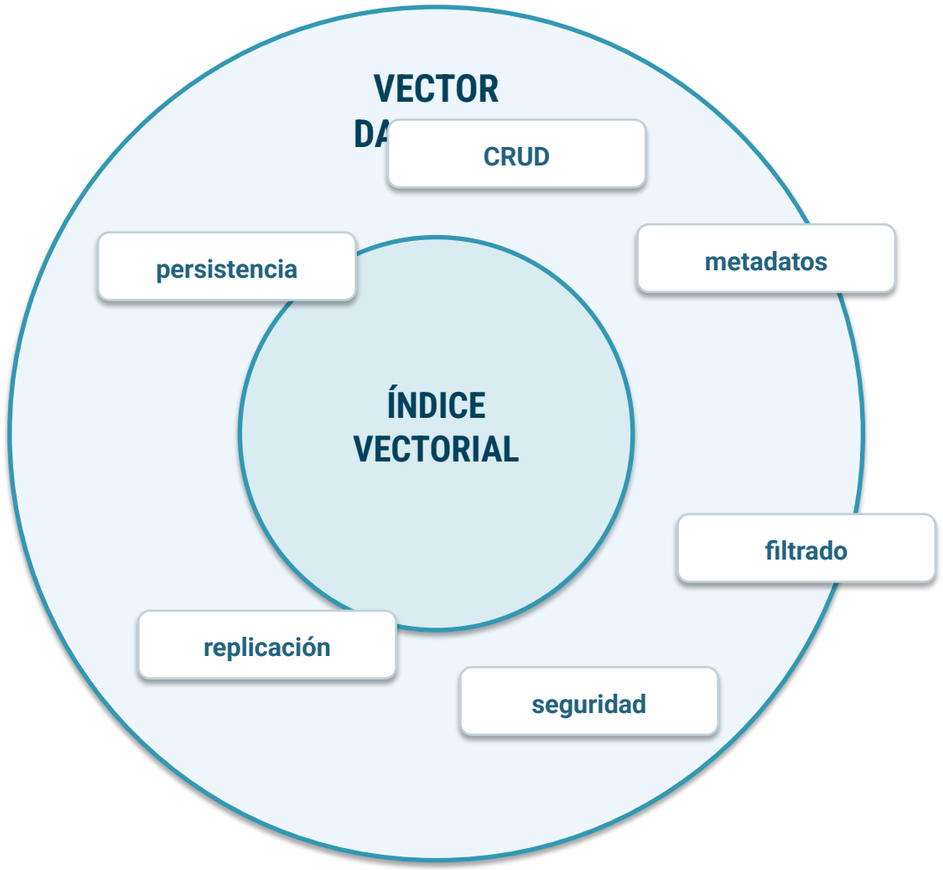
Múltiples aplicaciones y usuarios necesitan consultar y modificar los mismos datos.

4 Escalabilidad

Almacenamiento y procesamiento pueden necesitar distribuirse entre varias máquinas.

El problema deja de ser solamente algorítmico y pasa a ser también un problema de sistemas.

Índice vectorial vs Vector Database



1 Índice vectorial

Estructura especializada para acelerar nearest-neighbor search.

vectores · estructura ANN · parámetros de búsqueda

2 Vector Database

Sistema de almacenamiento y recuperación que incorpora uno o varios índices como parte de una infraestructura mayor.

persistencia · CRUD · metadatos · filtrado · concurrencia · seguridad · replicación · backups

Una Vector Database utiliza índices vectoriales; no los sustituye conceptualmente.

Un vector rara vez viaja solo

En una aplicación real no almacenamos únicamente una coordenada en R^d.



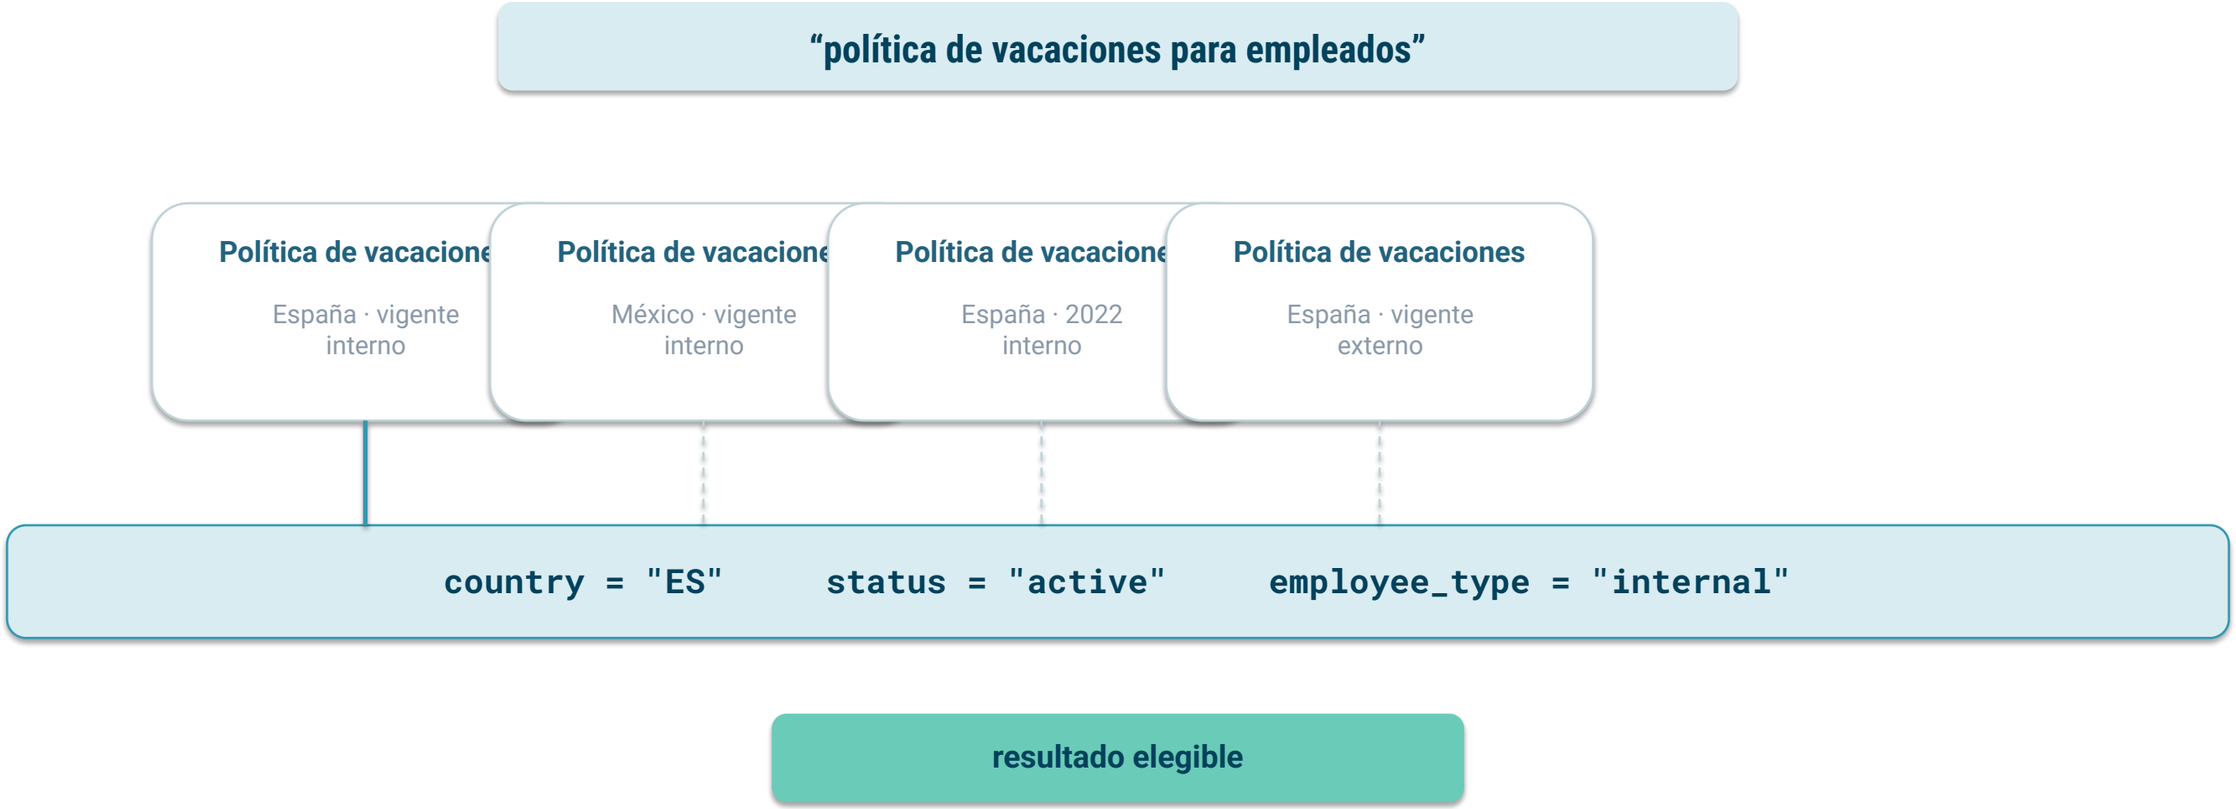
El embedding permite buscar por similitud. Los demás campos permiten decidir qué información puede o debe recuperarse.

Datos, metadatos y búsqueda filtrada

EBIS Business Techschool

La relevancia semántica no es suficiente

Un documento puede ser extremadamente similar a una query y, aun así, no ser un resultado válido.



La similitud determina relevancia. Los filtros determinan elegibilidad.

Metadata filtering: combinar estructura y similitud

Una búsqueda vectorial puede incorporar condiciones estructuradas junto con la similitud semántica.

```
similar_to(query_embedding)


AND language = "es"

AND category = "legal"

AND date >= "2026-01-01"

AND access_level IN ["public", "internal"]
```

Propiedades del contenido

idioma · categoría · autor · fecha · producto

Contexto operacional

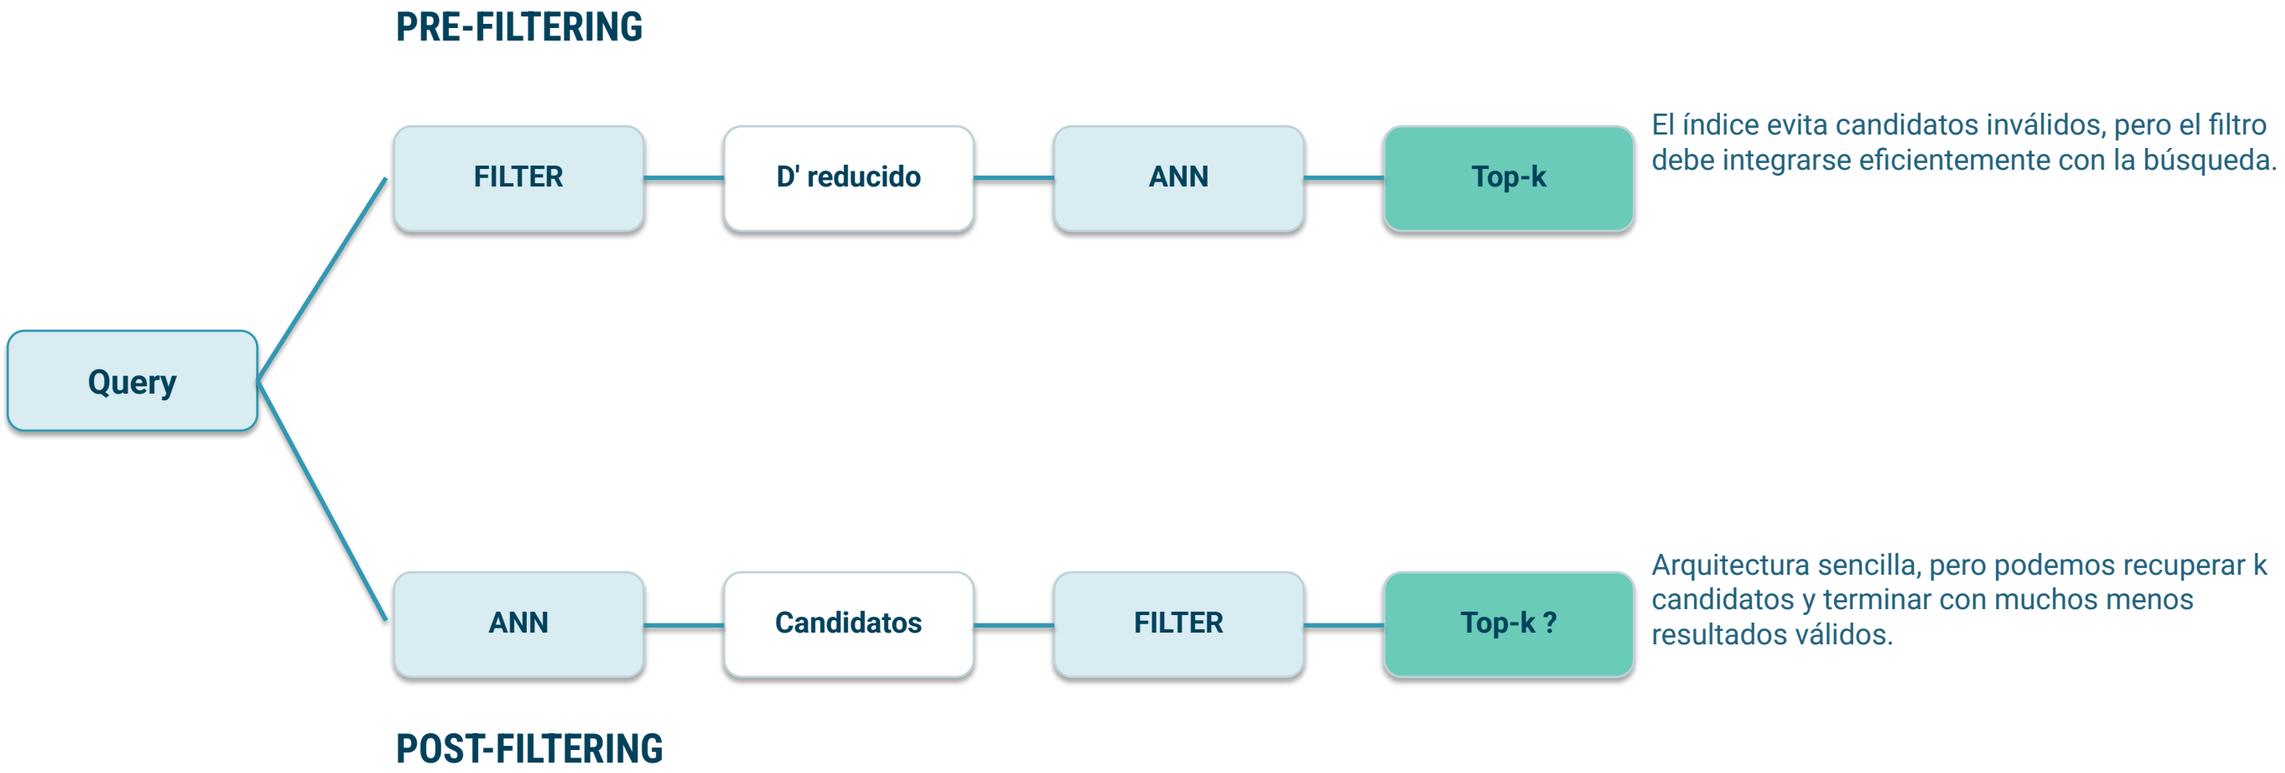
tenant · región · versión · fuente

Reglas de negocio

disponibilidad · estado · precio · permisos

Los metadatos convierten una búsqueda genérica por similitud en una consulta adaptada al dominio.

¿Filtrar antes o después de buscar?



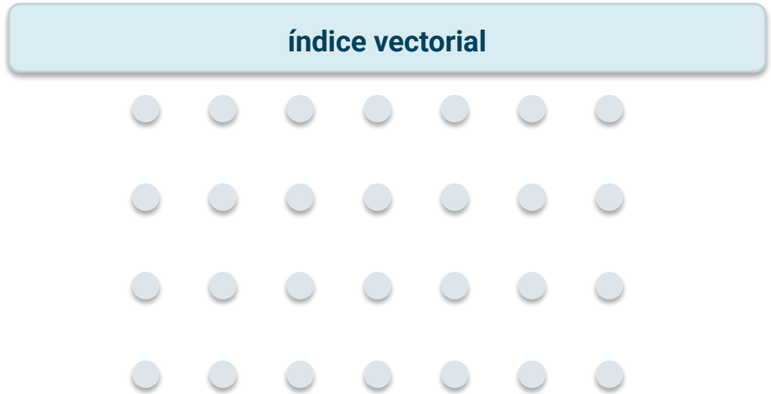
En sistemas reales pueden utilizarse estrategias pre-filter, post-filter o híbridas/iterativas.

Los metadatos también necesitan ser buscables

Añadir metadatos no garantiza que filtrarlos sea eficiente.

100 millones de vectores

```
country = "ES"
category = "support"
  Top-10 semántico
```



`country` `category` `status`

1 ¿Qué elementos cumplen el filtro?

Resolverlo rápido puede requerir índices específicos sobre atributos estructurados.

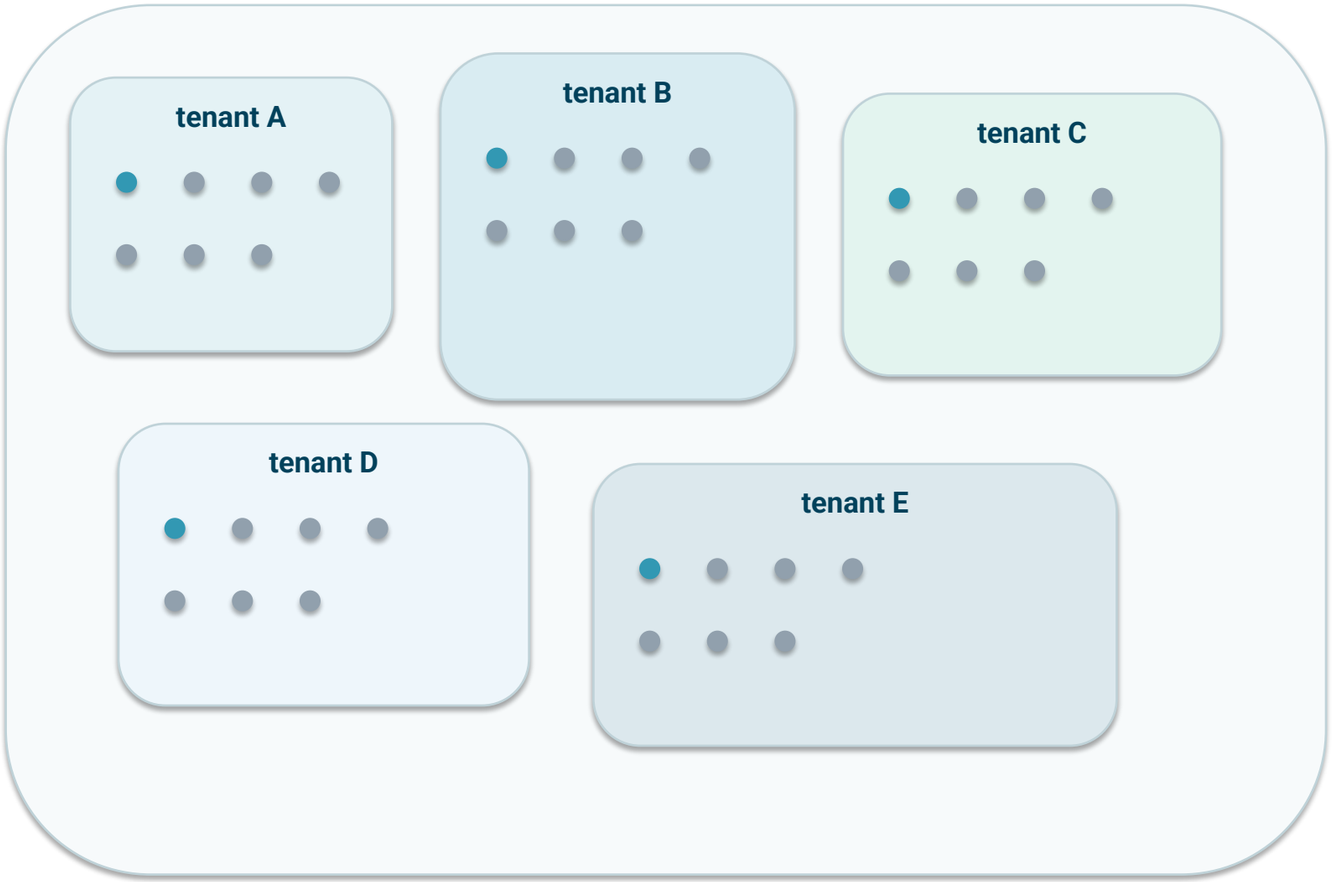
2 ¿Cuáles son los más próximos?

El índice vectorial resuelve la similitud; ambos mecanismos deben cooperar.

Un sistema moderno puede mantener simultáneamente índices vectoriales e índices sobre atributos estructurados.

Separar datos lógicamente también importa

Muchos sistemas mantienen información de múltiples clientes, aplicaciones, versiones o dominios dentro de una misma infraestructura.



1 Colección / índice

Gran unidad física o lógica de almacenamiento.

2 Namespace / partición / tenant

Segmentación de conjuntos de datos dentro del sistema.

3 Metadata

Restricciones más finas aplicadas sobre registros individuales.

```
company_42 → notion → legal → internal
```

Una buena estrategia de segmentación puede mejorar aislamiento, seguridad, mantenimiento y rendimiento.

Persistencia, actualización y operación del sistema

EBIS Business Techschool

Persistir significa poder continuar donde lo dejamos

Generar embeddings y construir un índice puede requerir una cantidad considerable de tiempo y recursos.



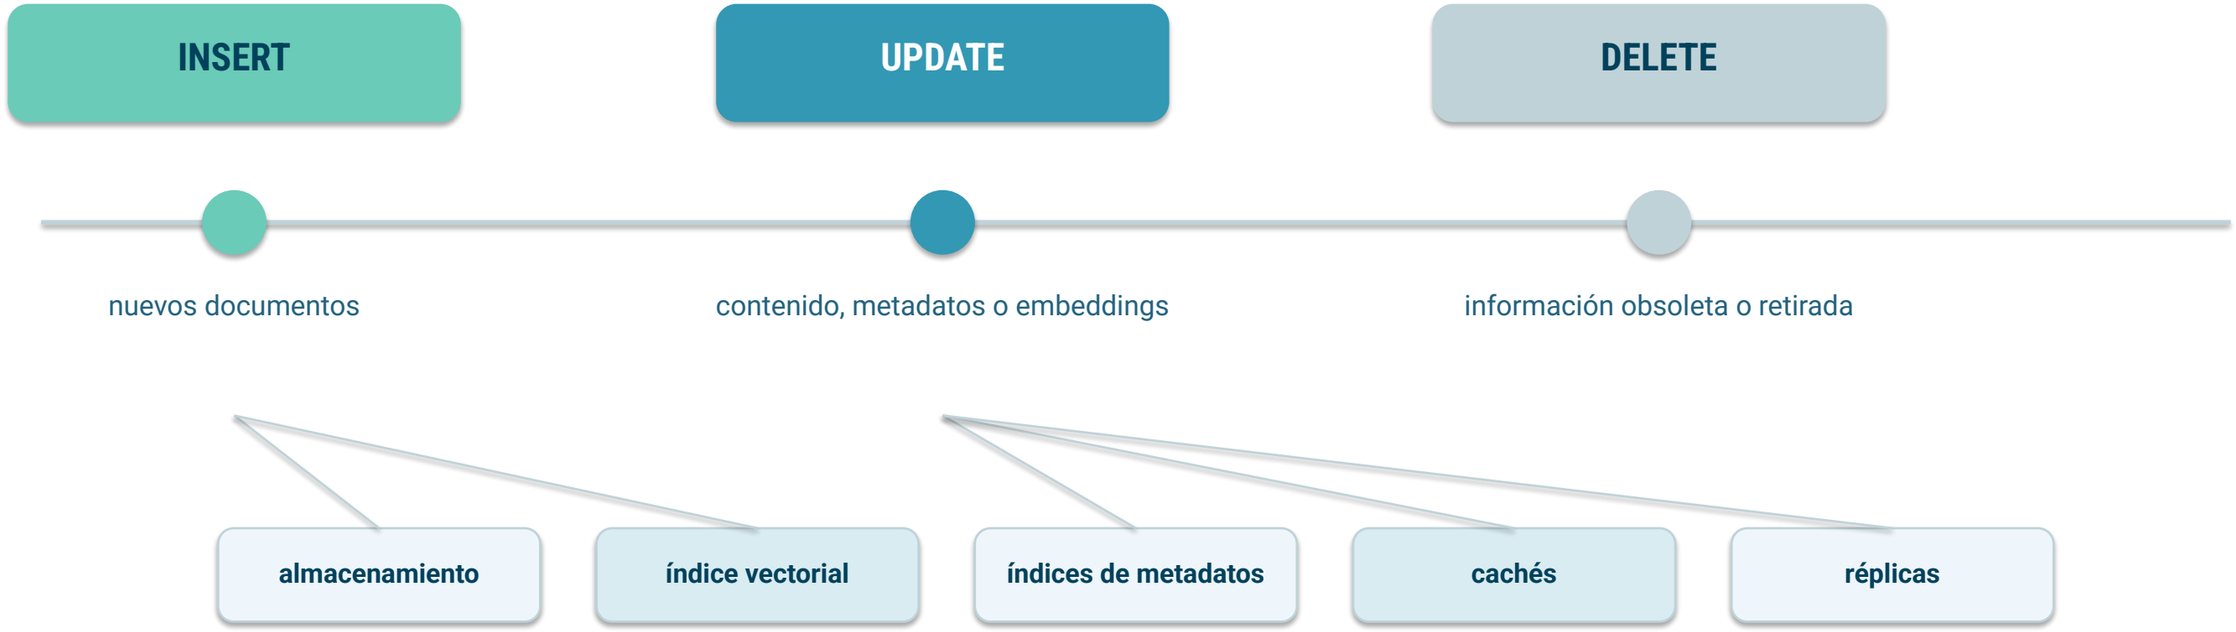
- **vectores**
- **contenido y metadatos**
- **estructuras de indexación**
- **configuración y estado**

Reiniciar una aplicación, sustituir un nodo o desplegar una nueva versión no debería obligarnos a reconstruir toda la colección desde cero.

El índice deja de ser un objeto temporal del proceso y pasa a formar parte del estado del sistema.

Un sistema de retrieval no es necesariamente estático

En producción aparecen continuamente nuevas operaciones sobre la colección.

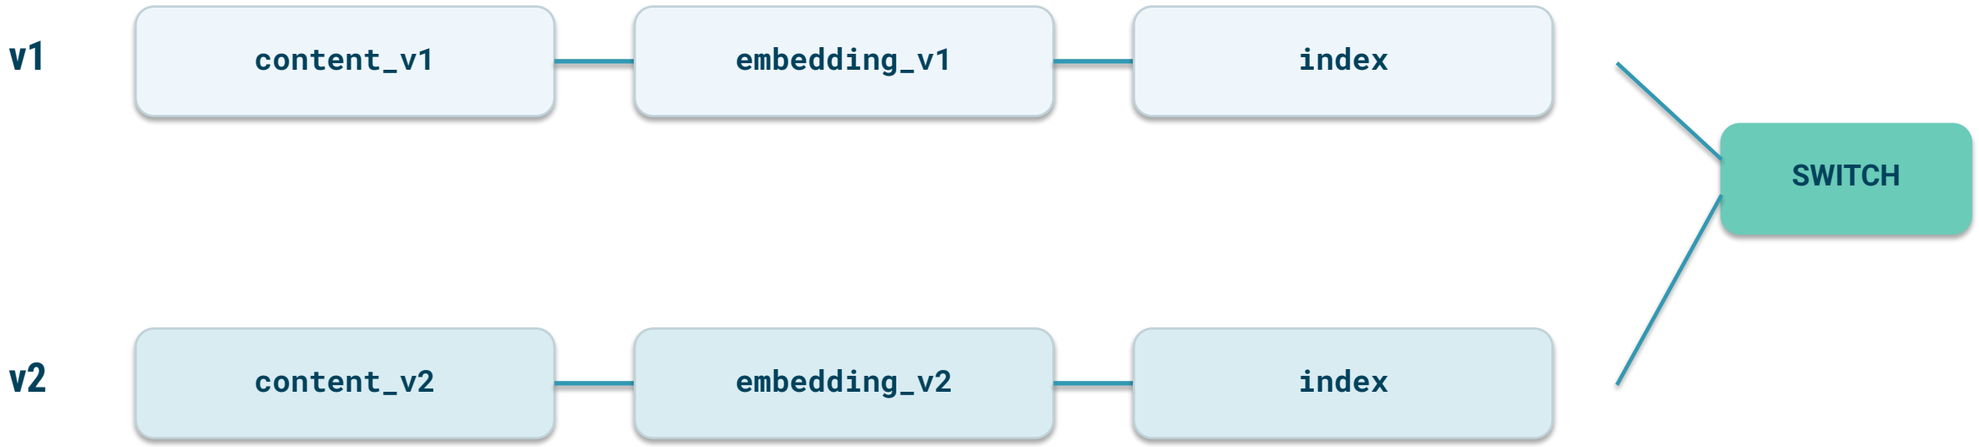


La frescura del retrieval depende de cuánto tarda una modificación en convertirse en searchable.

Documento, embedding e índice evolucionan juntos

EBIS Business Techschool

Si cambia el contenido utilizado para construir un embedding, su representación vectorial puede dejar de describir correctamente el documento.



¿qué ocurre durante la reindexación?

¿cómo evitamos mezclar versiones?

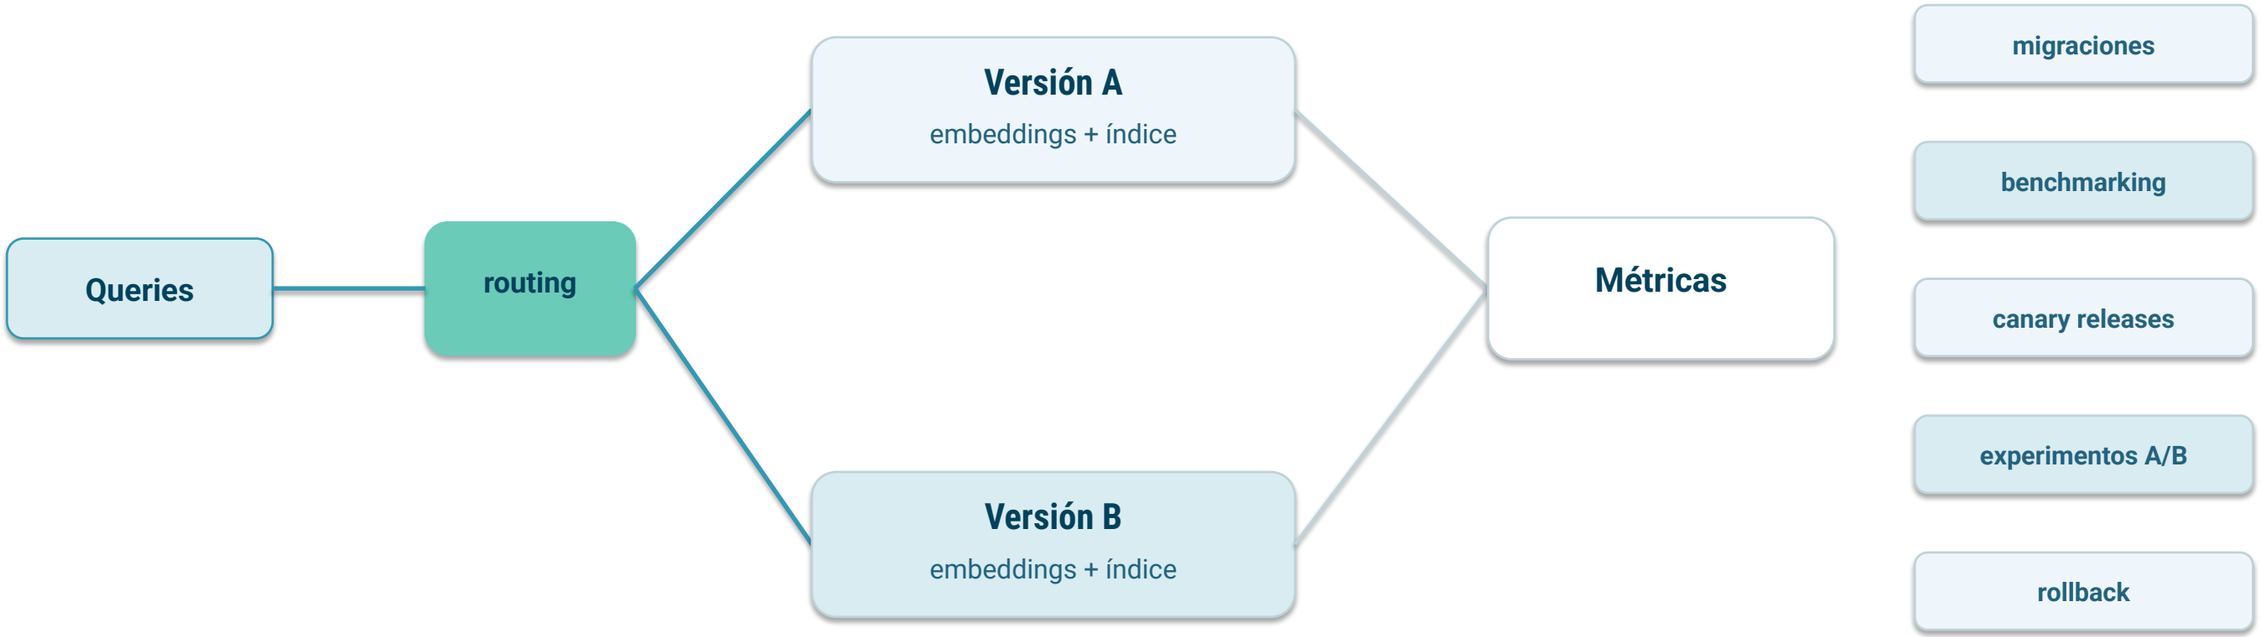
¿podemos reconstruir sin interrumpir búsquedas?

¿cómo migramos a un nuevo embedding model?

Cambiar de embedding model es también una migración de datos.

Versionar permite separar construcción y serving

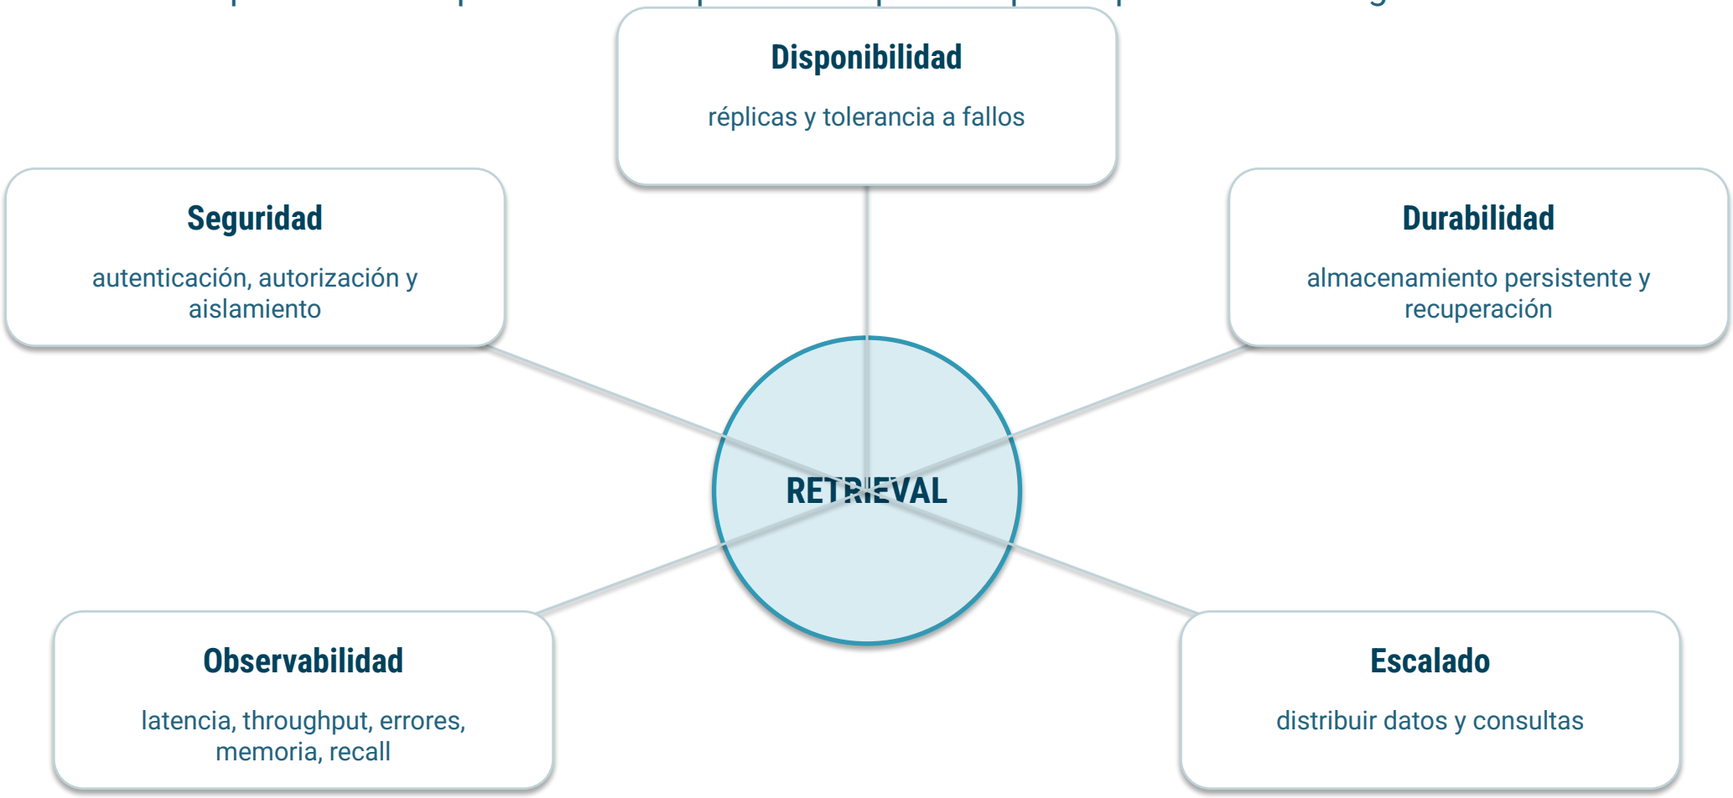
Un nuevo embedding model, estrategia de chunking o configuración de índice puede requerir reconstruir una parte importante del sistema.



Una base vectorial facilita estas operaciones, pero el experimento A/B sigue siendo una decisión de arquitectura de la aplicación.

La búsqueda rápida no sirve si el sistema no está disponible

Cuando retrieval forma parte de una aplicación real aparecen requisitos que no pertenecen al algoritmo ANN.



Producción exige optimizar algo más que Recall@k y latencia.

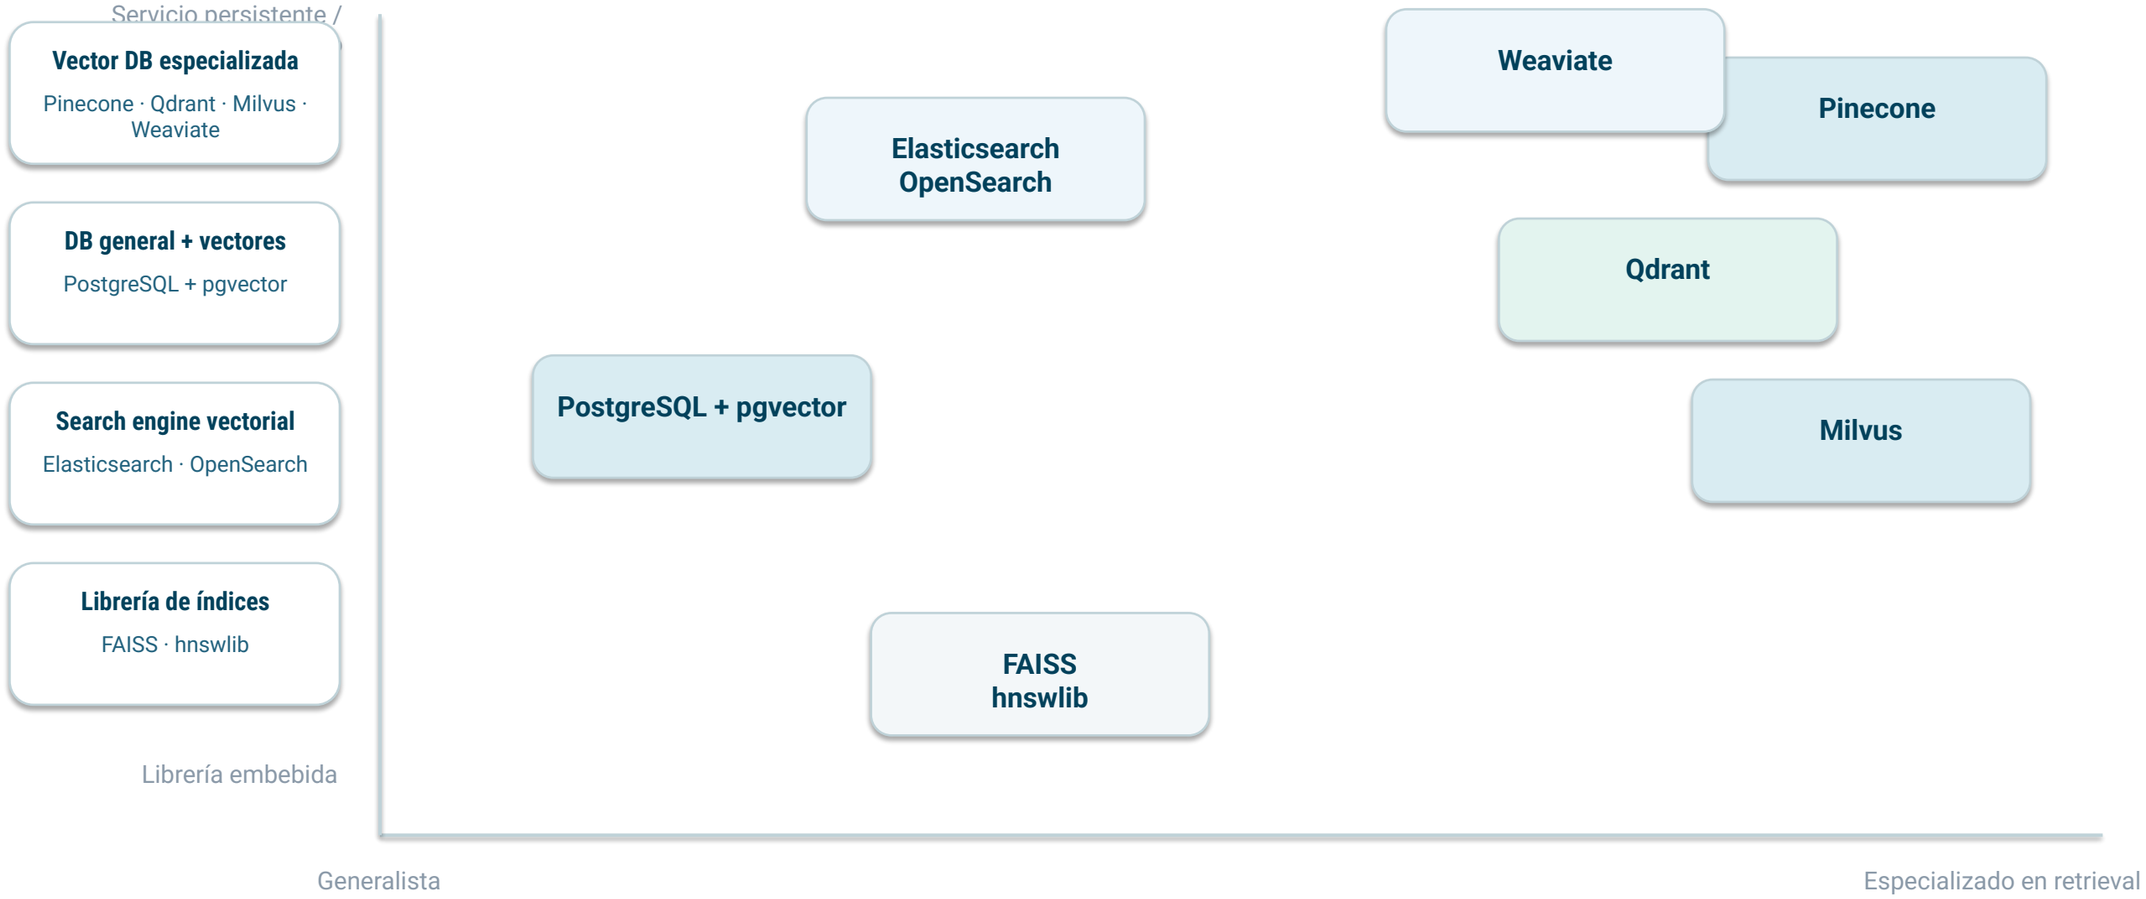
Vector databases, PostgreSQL + pgvector y modelos de despliegue



EBIS Business Techschool

El ecosistema tiene varias formas de almacenar vectores

Todas pueden resolver nearest-neighbor search; no todas resuelven el mismo problema operacional.



PostgreSQL + pgvector: cuando los vectores son parte del dato

EBIS Business Techschool

pgvector añade tipos y operaciones de similitud vectorial dentro de PostgreSQL.

documents

id	content	embedding	category_id	user_id	created_at
101	...	[0.17, …]	12	42	2026-09
102	...	[…]	12	42	2026-09
103	...	[…]	12	42	2026-09
104	...	[…]	12	42	2026-09

SQL: JOIN · WHERE · transacciones

Vector similarity

Exact Search · HNSW · IVFFlat

La búsqueda vectorial se integra dentro del modelo relacional existente, en lugar de introducir necesariamente un sistema independiente.

¿Cuándo tiene mucho sentido PostgreSQL + pgvector?

EBIS Business Techschool

Datos ya en PostgreSQL

Evitamos duplicar información y añadir otra infraestructura.

Retrieval ligado al modelo relacional

joins, permisos, usuarios, productos, relaciones, transacciones…



Escala vectorial manejable

Latencia y throughput caben dentro de la arquitectura PostgreSQL.

Consistencia especialmente importante

Datos estructurados y embeddings pueden gestionarse en el mismo sistema transaccional.

Aplicación centrada en datos relacionales + vector search como capacidad

Introducir una Vector Database independiente puede añadir complejidad antes de aportar beneficio.

¿Cuándo cobra ventaja una Vector Database especializada?

EBIS Business Techschool



Separar el workload vectorial tiene sentido cuando las ventajas operacionales o de escala justifican otro sistema.

Especializada vs relacional: depende del centro de gravedad

EBIS Business Techschool

Atributo	PostgreSQL + pgvector	Vector Database especializada
Modelo principal	Relacional	Retrieval / vectorial
SQL / joins	Nativo	Limitado o diferente
Transacciones complejas	Fortaleza natural	No suele ser el objetivo principal
Vector search	Integrada	Función central
Escalado del retrieval	Unido a la arquitectura DB	Puede escalarse independientemente
Operación	Aprovecha PostgreSQL existente	Nueva infraestructura o servicio
Mejor encaje	Vector como parte del dominio	Retrieval como workload principal

La frontera no es absoluta. La elección debe partir del workload, no de la etiqueta “Vector Database”.

¿Quién opera la infraestructura?

Self-hosted y managed forman un continuo: cambia quién asume la complejidad operacional.

SELF-HOSTED

infraestructura · versiones · red · escalado · seguridad · backups · monitorización

MANAGED

provisioning · mantenimiento · disponibilidad · escalado · actualizaciones

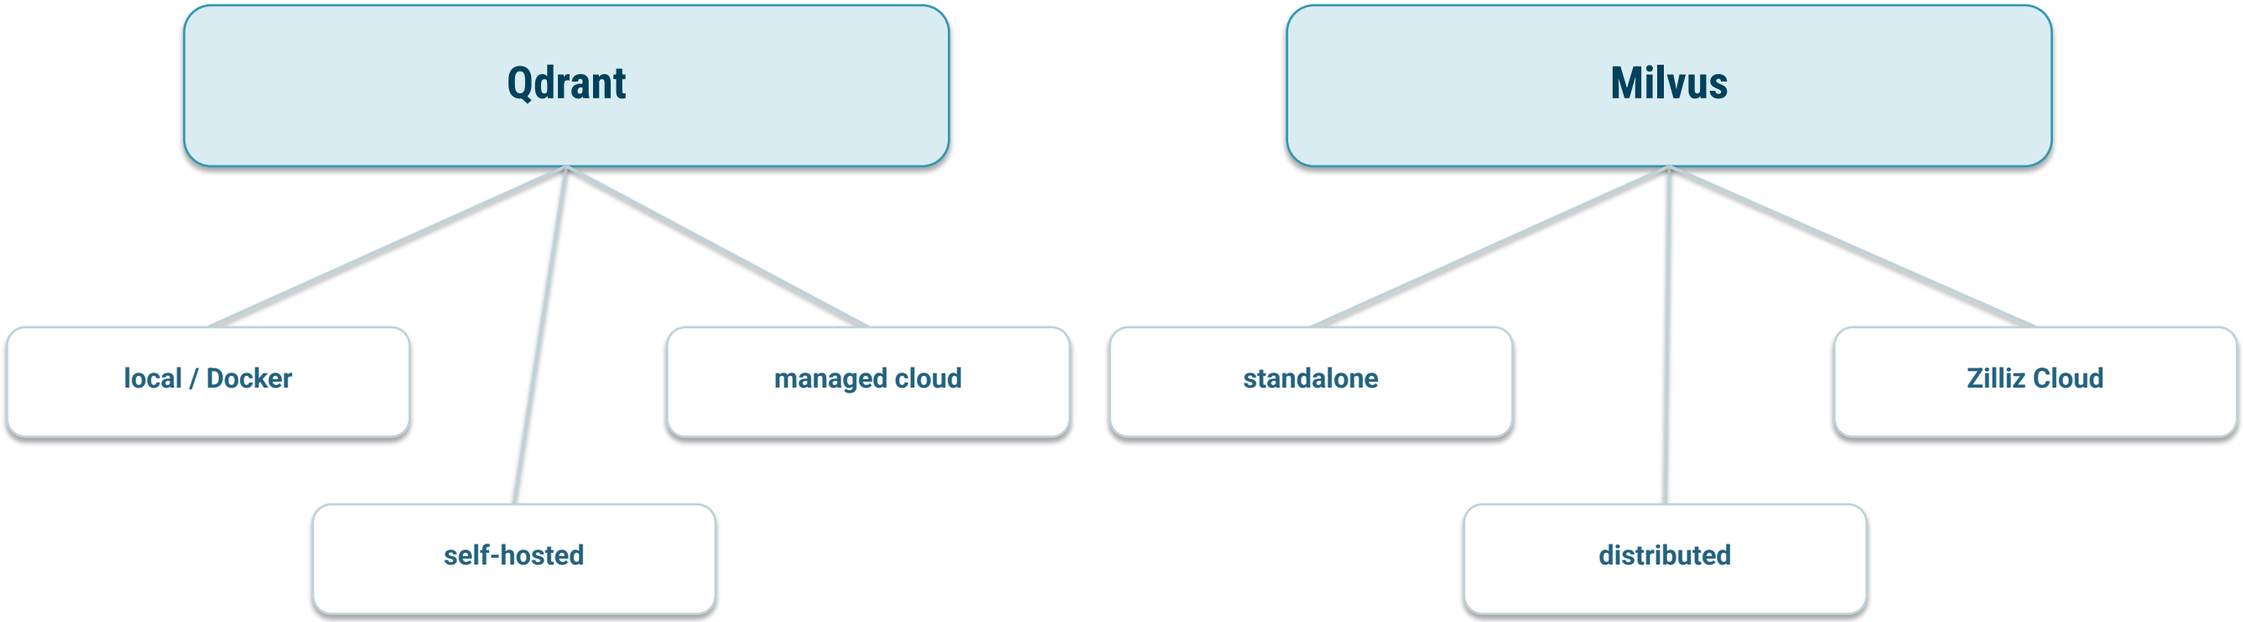


Local / Docker — VM propia — Kubernetes propio — Managed cloud — Fully managed

Milvus / Qdrant self-hosted	**Qdrant Cloud / Zilliz Cloud**	**Pinecone**

La tecnología de búsqueda puede ser similar; lo que cambia es quién asume la complejidad operacional.

Tecnología y operación son decisiones diferentes



¿quién lo mantiene?

¿dónde se almacenan los datos?

¿cómo escala?

¿qué SLA necesitamos?

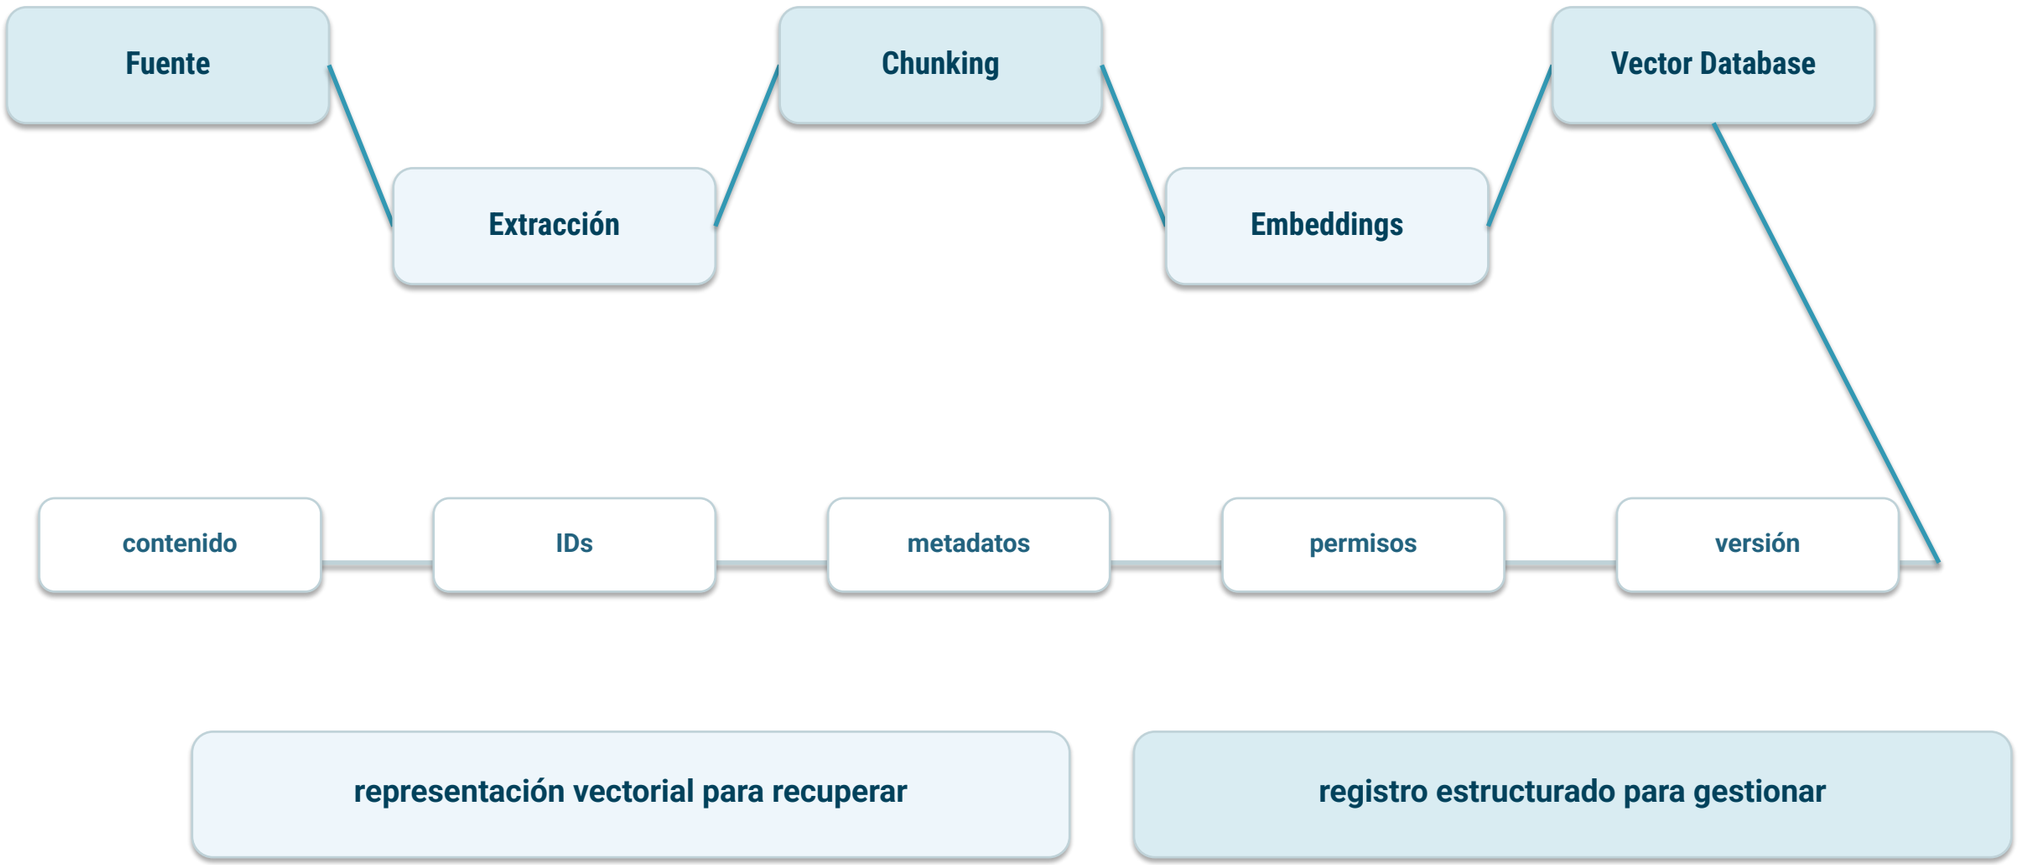
¿qué restricciones de red o compliance existen?

“¿Qué base de datos utilizamos?” y “¿cómo la desplegamos?” son dos preguntas distintas.

Diseño y elección de una arquitectura de recuperación

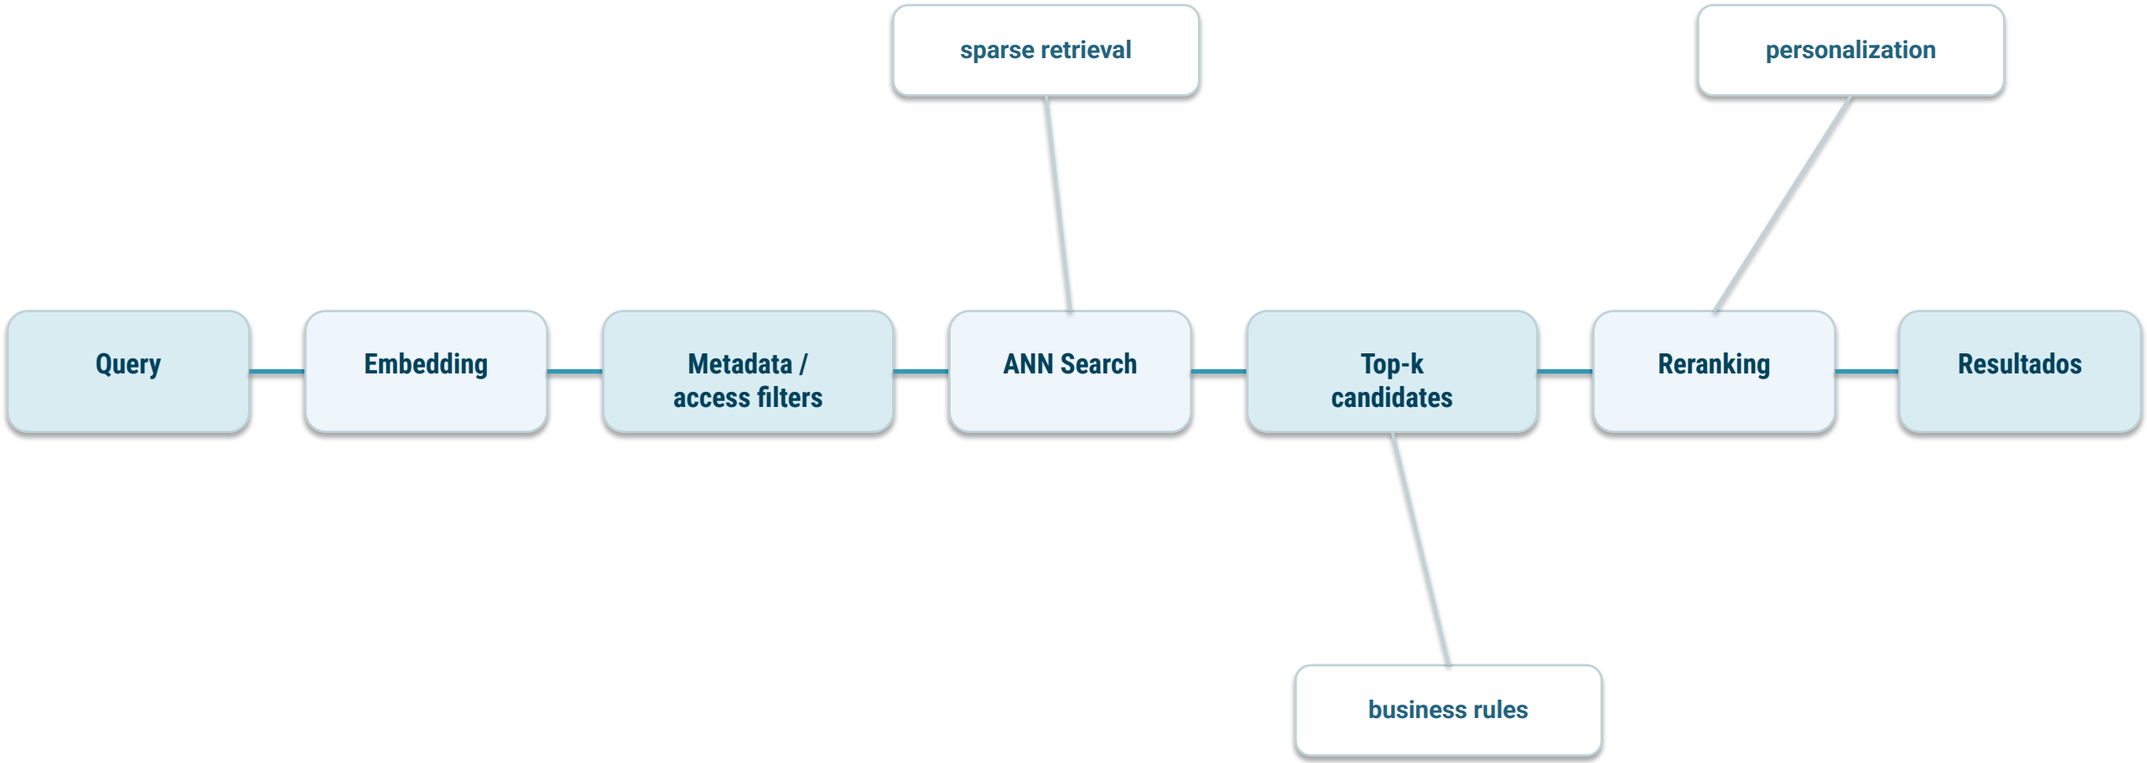


De un documento a una colección searchable



La calidad del sistema empieza mucho antes de ejecutar la primera query.

De una query a un resultado recuperado

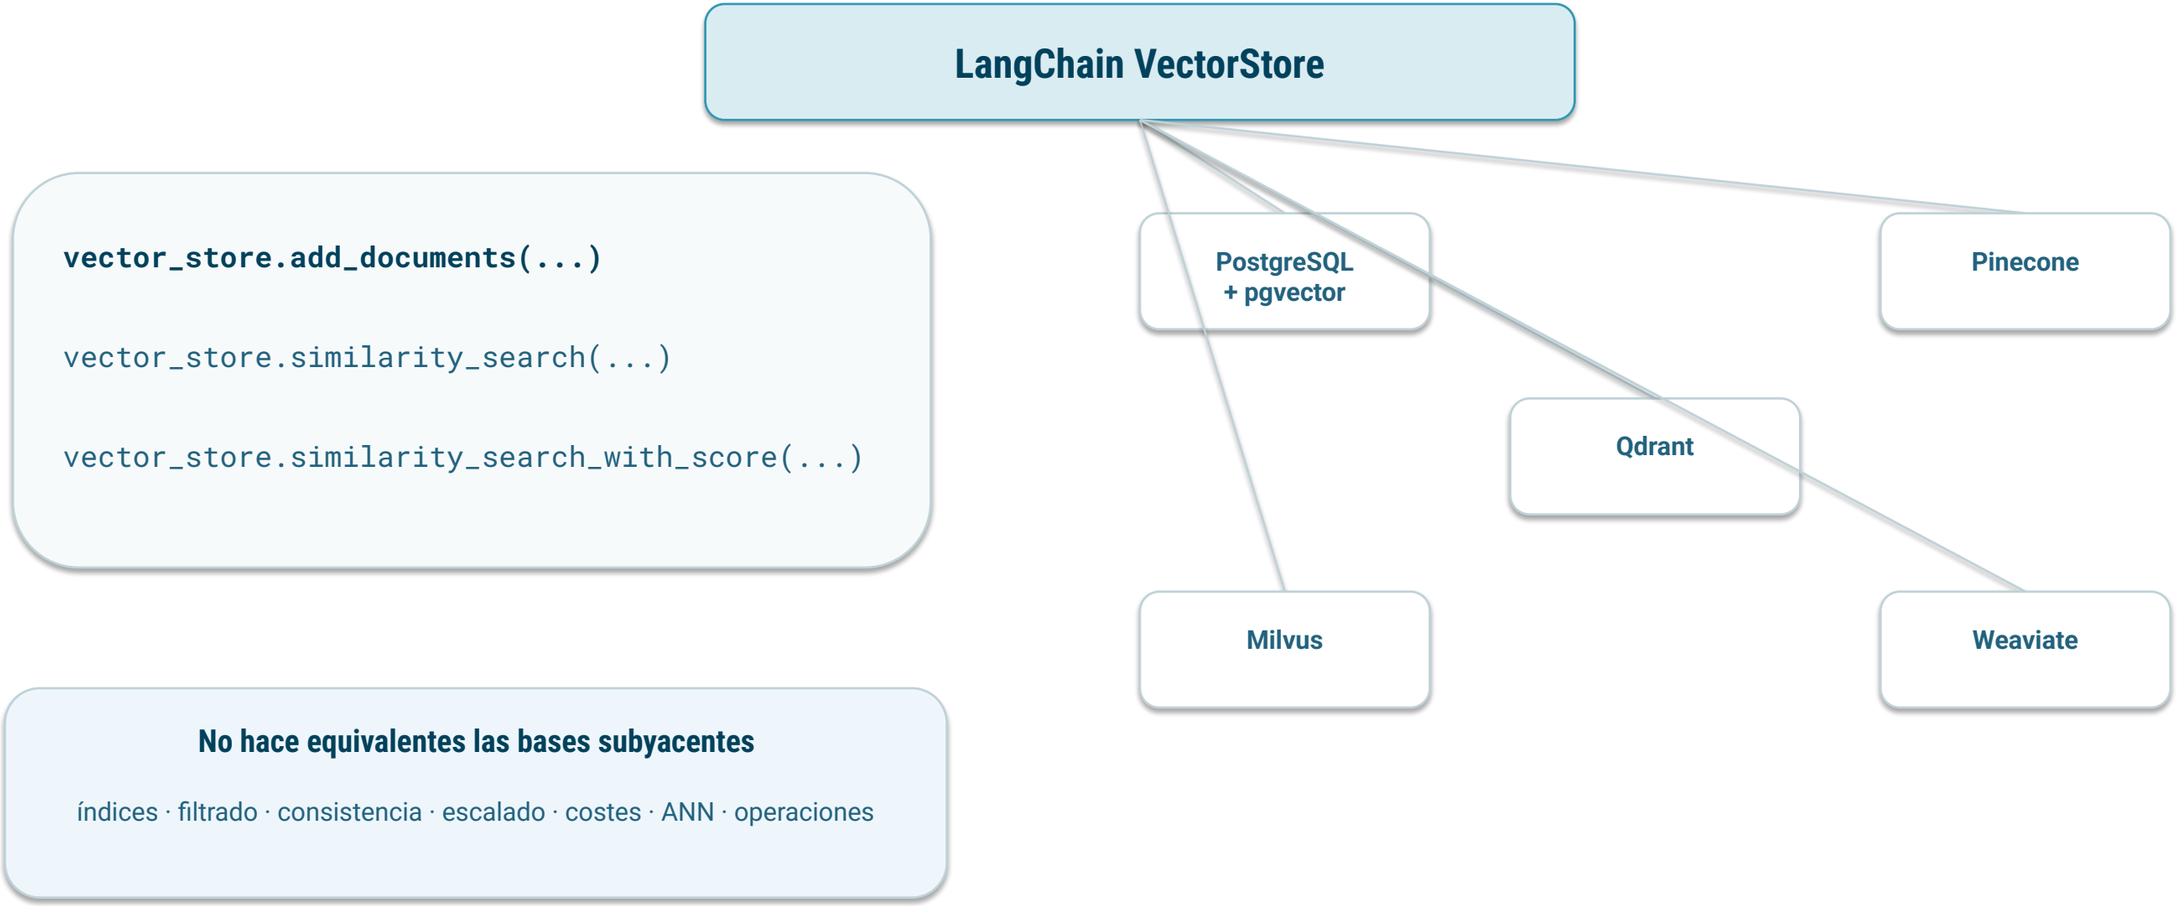


La Vector Database ocupa una posición central, pero retrieval sigue siendo un pipeline, no una única llamada a similarity_search().

VectorStore: una interfaz común sobre sistemas diferentes

EBIS Business Techschool

LangChain proporciona abstracciones para trabajar con distintos almacenes vectoriales mediante una interfaz relativamente homogénea.



No hace equivalentes las bases subyacentes

índices · filtrado · consistencia · escalado · costes · ANN · operaciones

Una abstracción simplifica el código cliente; no elimina la arquitectura del sistema.

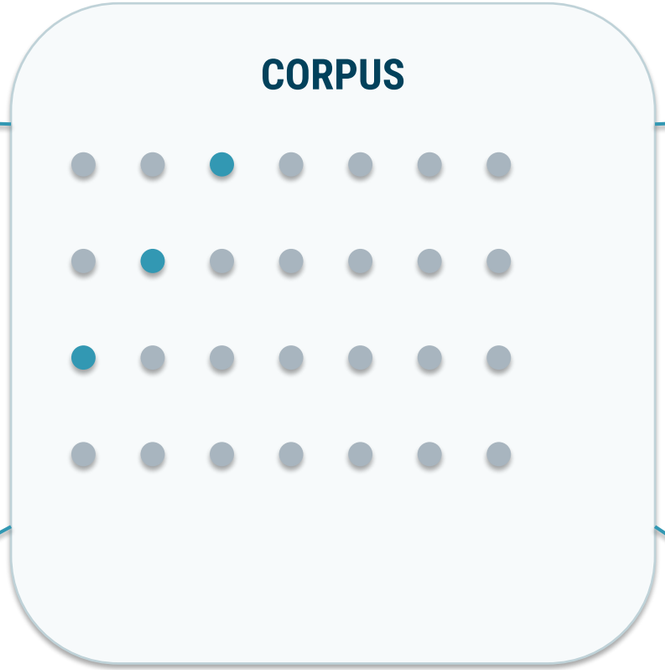
El patrón de consulta debe influir en el diseño

“cualquier documento parecido”

vector search domina

“documentos parecidos del usuario X”

filtro altamente selectivo



“productos parecidos en España, categoría Y, precio < 100 €”

varios filtros estructurados

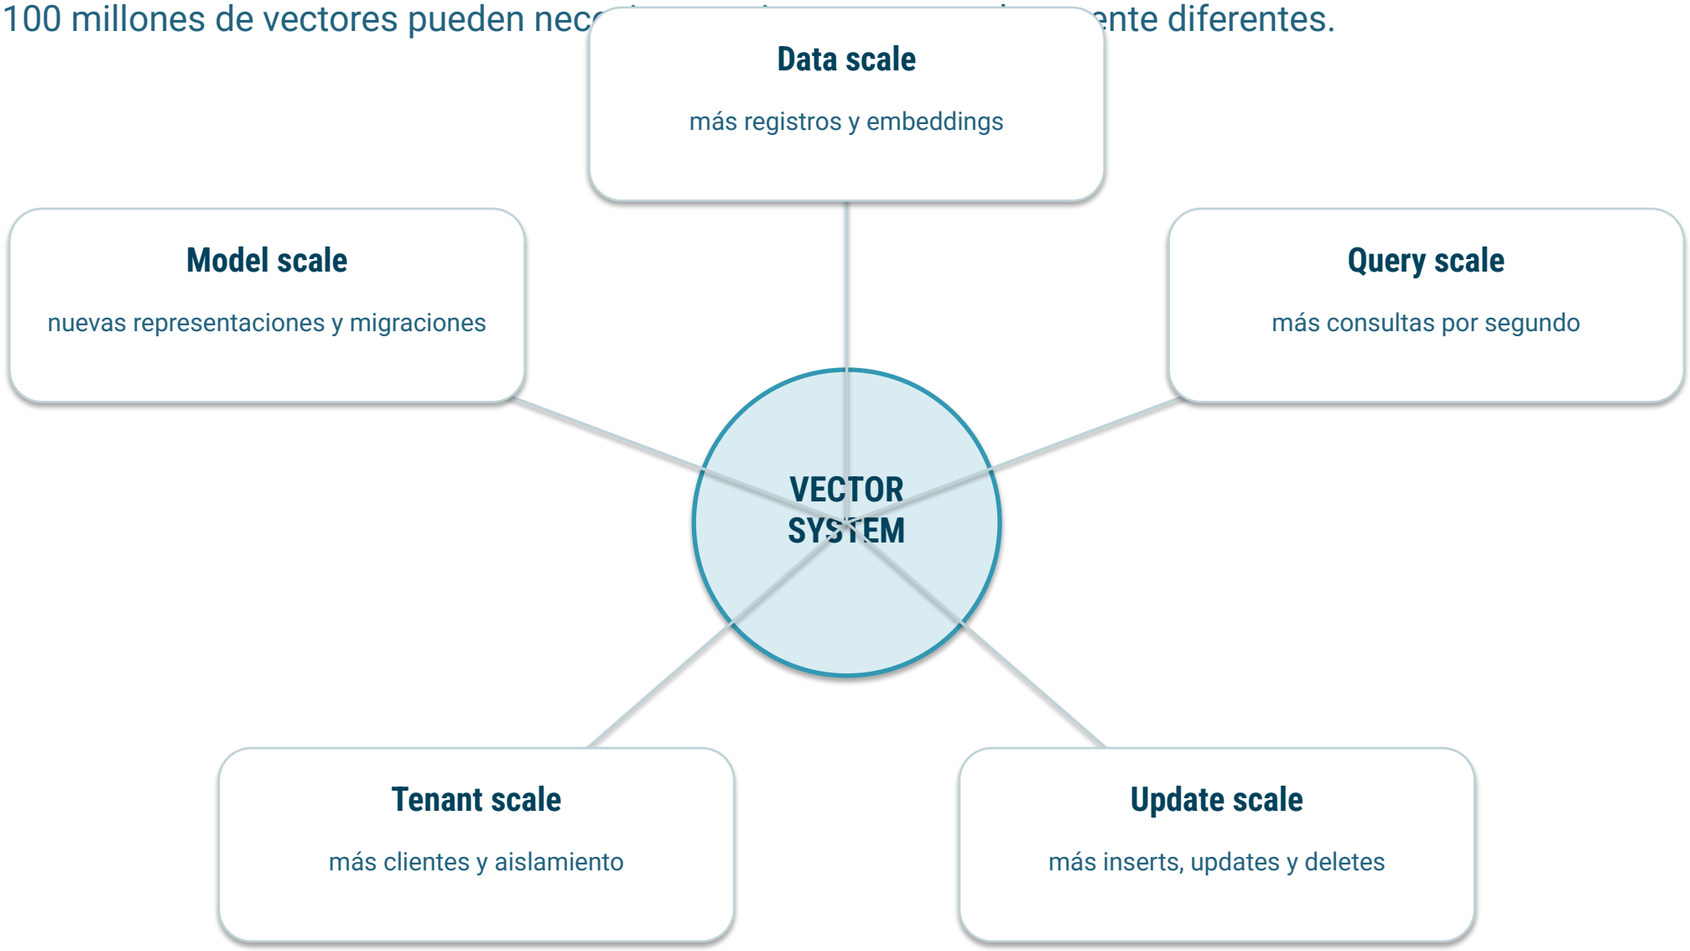
“corpus global con permisos por documento”

filtering forma parte de la seguridad

No basta con preguntar cuántos vectores tendremos. También debemos saber cómo serán las queries.

Escalar no significa solamente añadir más vectores

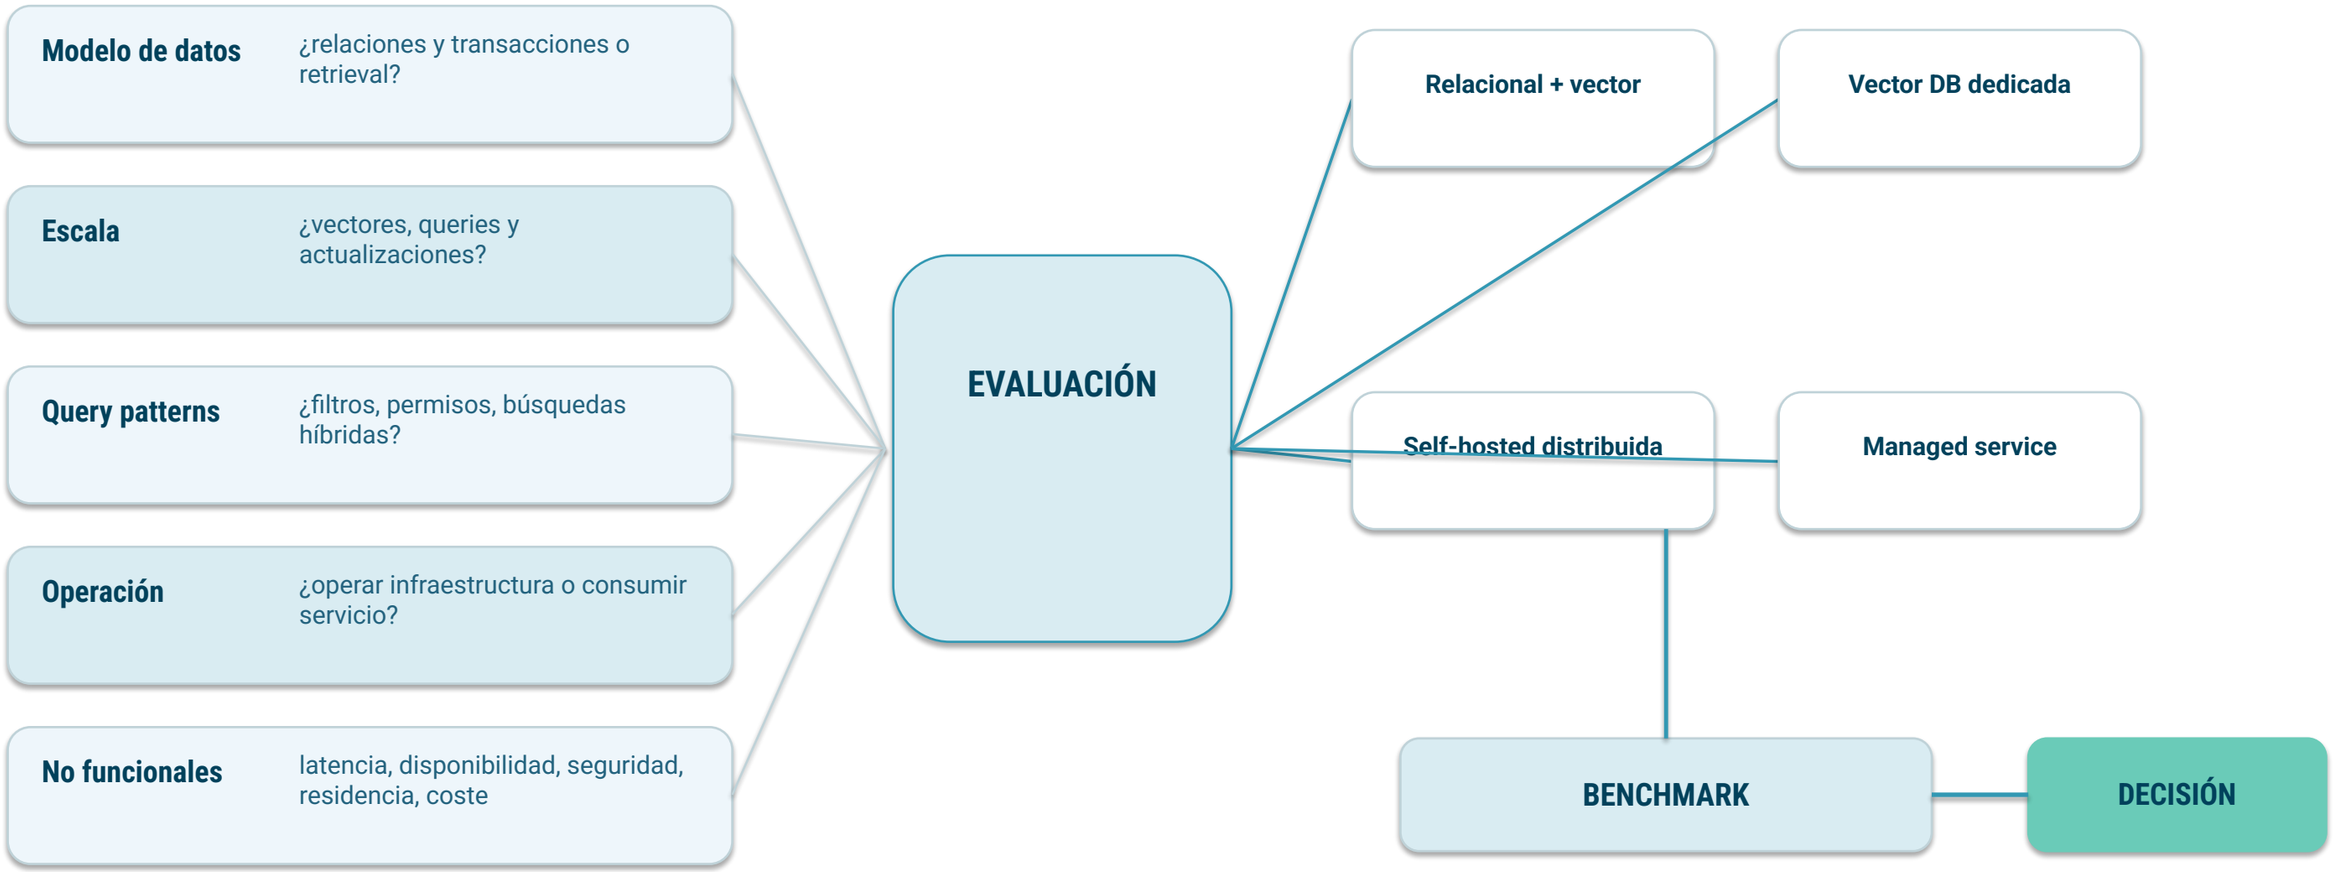
Dos sistemas con 100 millones de vectores pueden nec ente diferentes.



La escala tiene varias dimensiones.

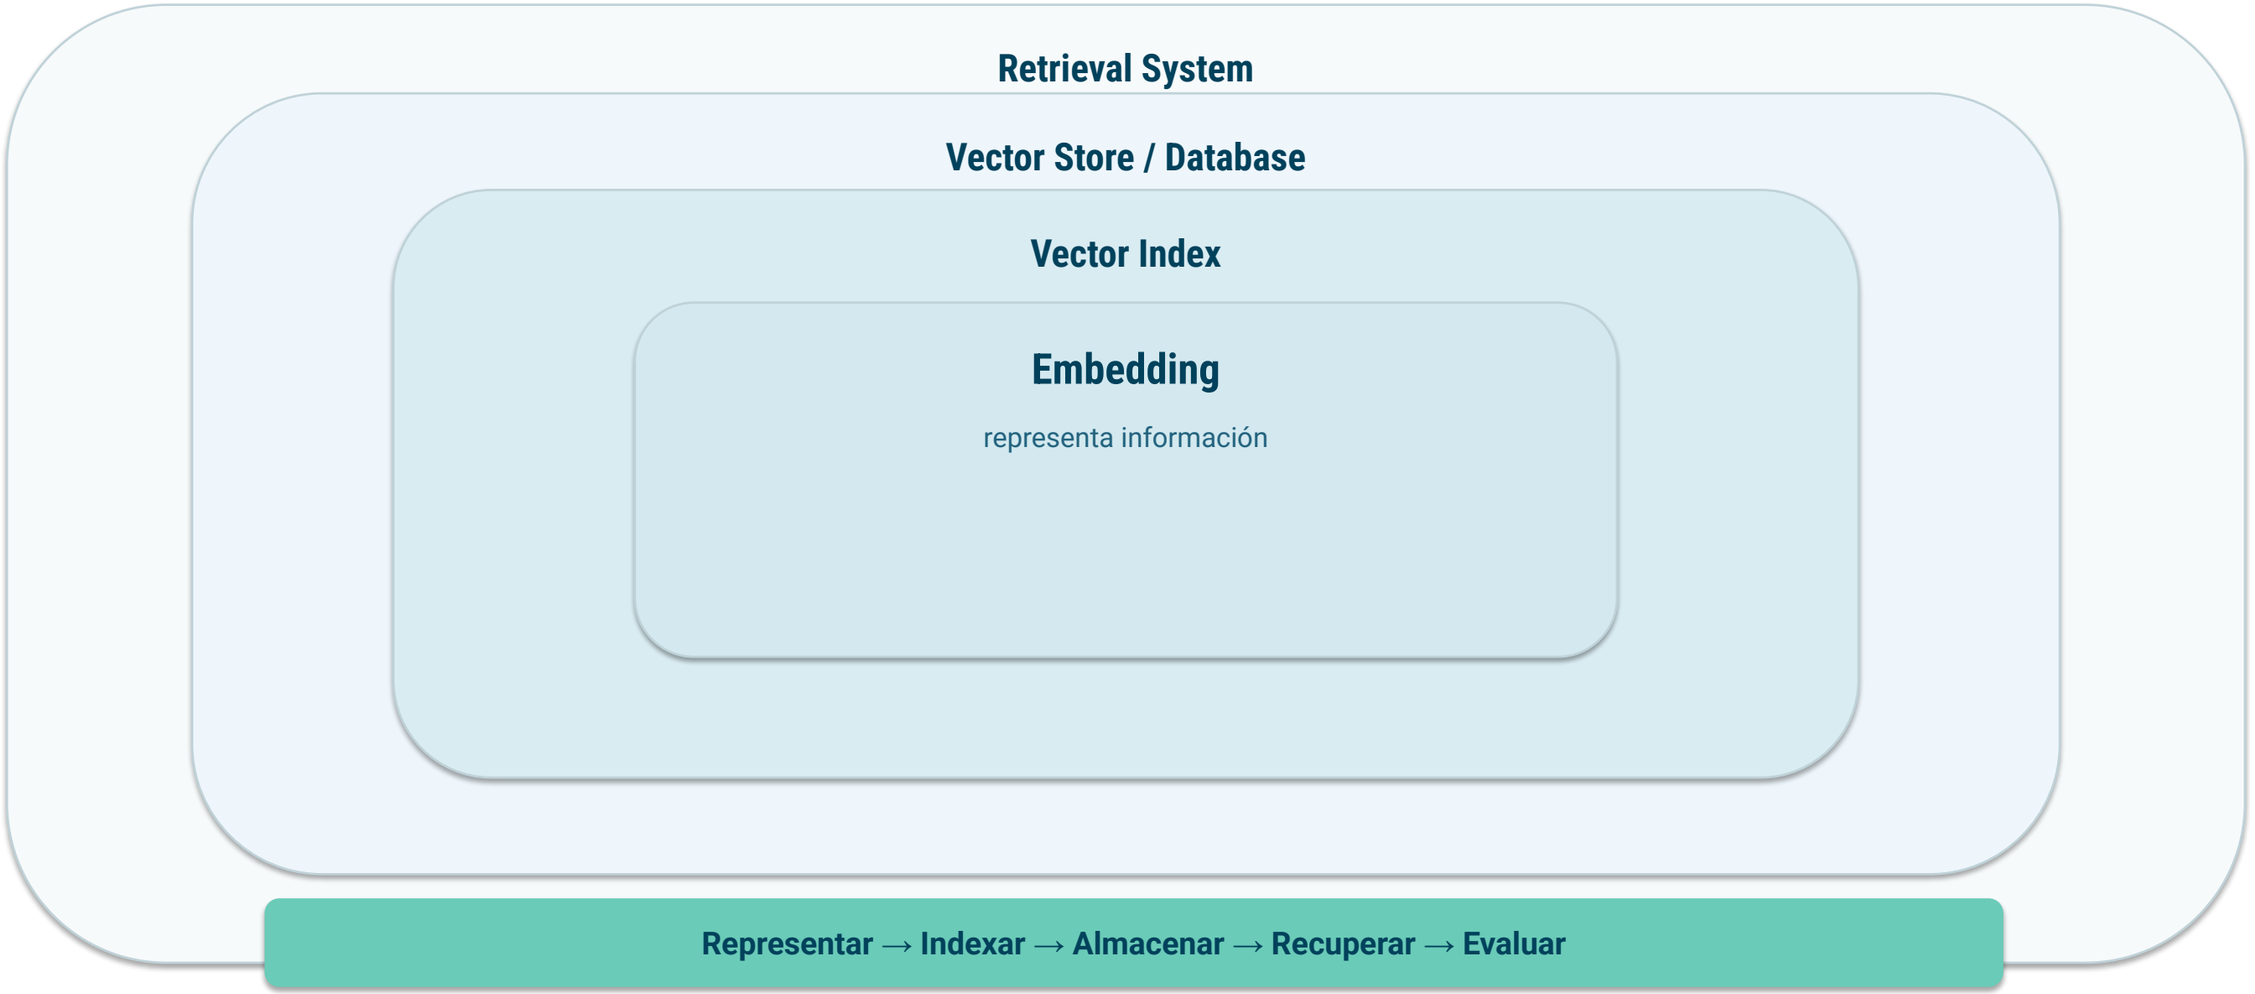
La arquitectura nace de las restricciones

EBIS Business Techschool



Elegir una Vector Database no debería ser el punto de partida. Debería ser una consecuencia del diseño.

Del índice al sistema de recuperación



Un sistema de retrieval se diseña para encontrar la información correcta, para el usuario correcto, bajo las restricciones correctas y con un coste operacional aceptable.

Recap & Q&A

EBIS Business Techschool

1. El índice vectorial es una estructura de búsqueda, no un sistema completo de datos.
2. Metadatos y filtros forman parte del retrieval real.
3. Persistencia, actualización, versiones y disponibilidad condicionan producción.
4. pgvector y Vector Databases especializadas responden a centros de gravedad distintos.
5. **La arquitectura debe elegirse desde requisitos y benchmarks.**

¿Preguntas?