

Tema 5: Sistemas de recuperación de la información, RAG y Langchain

EBIS Business Techschool

Contenidos

- Fundamentos matemáticos de la recuperación de información
- Representación de la información I: Sparse vs Dense
- Representación de la información II: Métodos modernos de retrieval
- Indexación y búsqueda eficiente
- Sistemas de almacenamiento y recuperación
- Construcción y evaluación de sistemas de recuperación
- Retrieval Augmented Generation



www.ebiseducation.com

Agenda de la sesión

EBIS Business Techschool

Un problema real, un sistema real

Trabajaremos sobre un corpus real de literatura científica y construiremos un sistema de retrieval evaluable de extremo a extremo.

Decisiones de representación y recuperación

Compararemos distintas formas de representar, indexar y recuperar la información.

Evaluar antes de optimizar

Definiremos un ground truth y utilizaremos métricas adecuadas para cada etapa del pipeline.

Experimentar y diagnosticar

Compararemos configuraciones, cuantificaremos incertidumbre y analizaremos dónde y por qué falla el sistema.

Recap & Q&A

Resumen de conceptos clave y resolución de dudas.

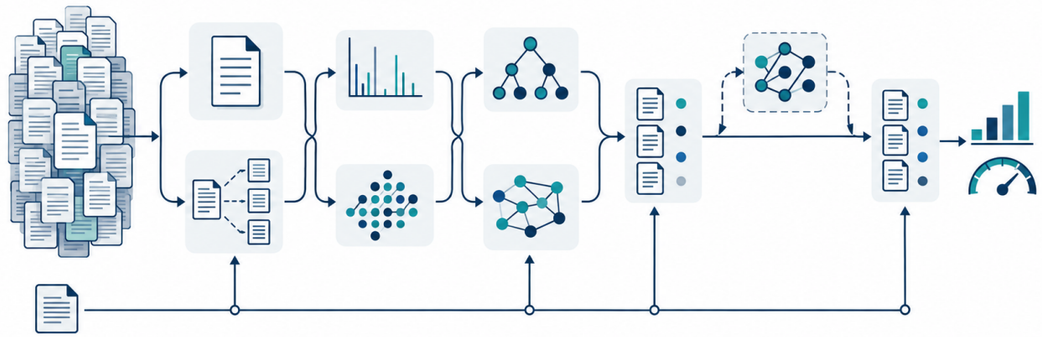
Un problema real, un sistema real



EBIS Business Techschool

Del prototipo al sistema real

Hasta ahora hemos estudiado por separado las piezas fundamentales de un sistema de recuperación.



1 Representación

¿Qué modelo de embeddings utilizamos? ¿Qué dimensionalidad? ¿Documento completo o chunks?

2 Retrieval

¿Sparse, Dense o Hybrid? ¿Exact Search o ANN? ¿Necesitamos reranking?

3 Arquitectura

¿Índice local o Vector Database? ¿Qué coste de memoria y latencia podemos asumir?

4 Evaluación

¿Qué significa que el sistema sea mejor? ¿Con qué datos y métricas lo demostramos?

Ahora todas esas decisiones están conectadas y vamos a tener que tomarlas sobre un caso real.

Un buscador real sobre literatura científica

Utilizaremos **TREC-COVID**, un benchmark de *Information Retrieval* construido sobre literatura científica biomédica.

Corpus

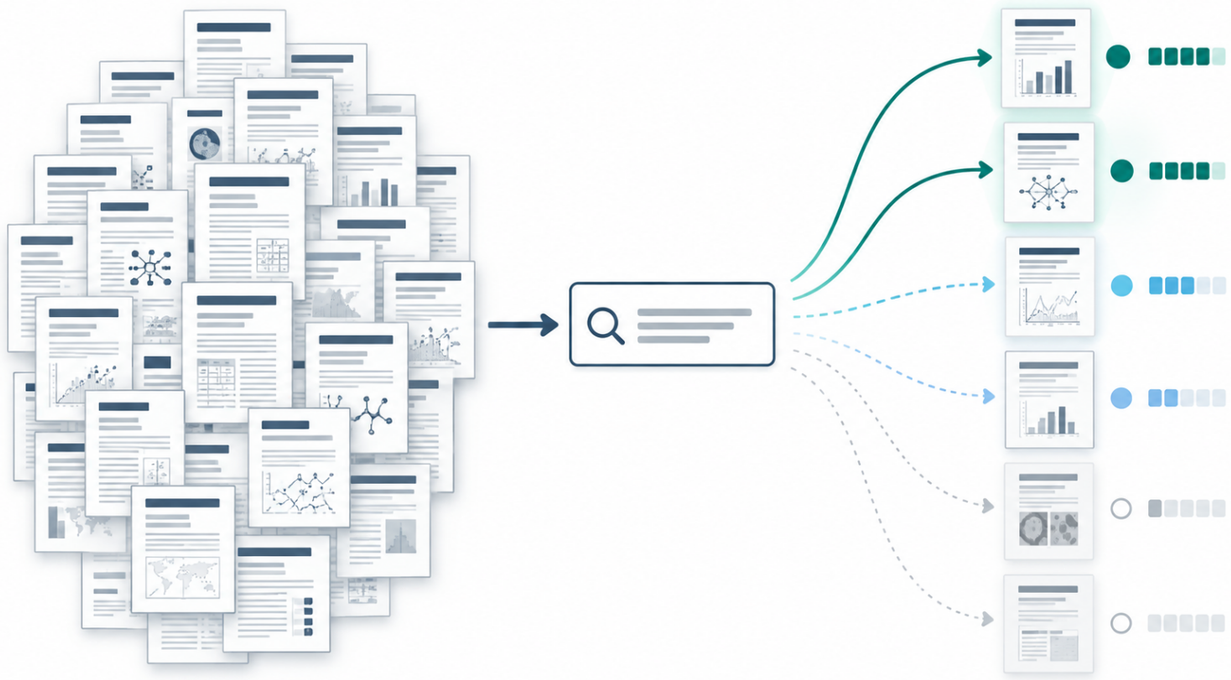
Aproximadamente, 171.000 artículos científicos con título y contenido textual.

Queries

Necesidades de información expresadas como consultas reales.

Qrels

Para cada query conocemos qué documentos fueron juzgados relevantes y con qué grado de relevancia.



Ya no tenemos que decidir "a ojo" si un resultado parece bueno. Tenemos ground truth.

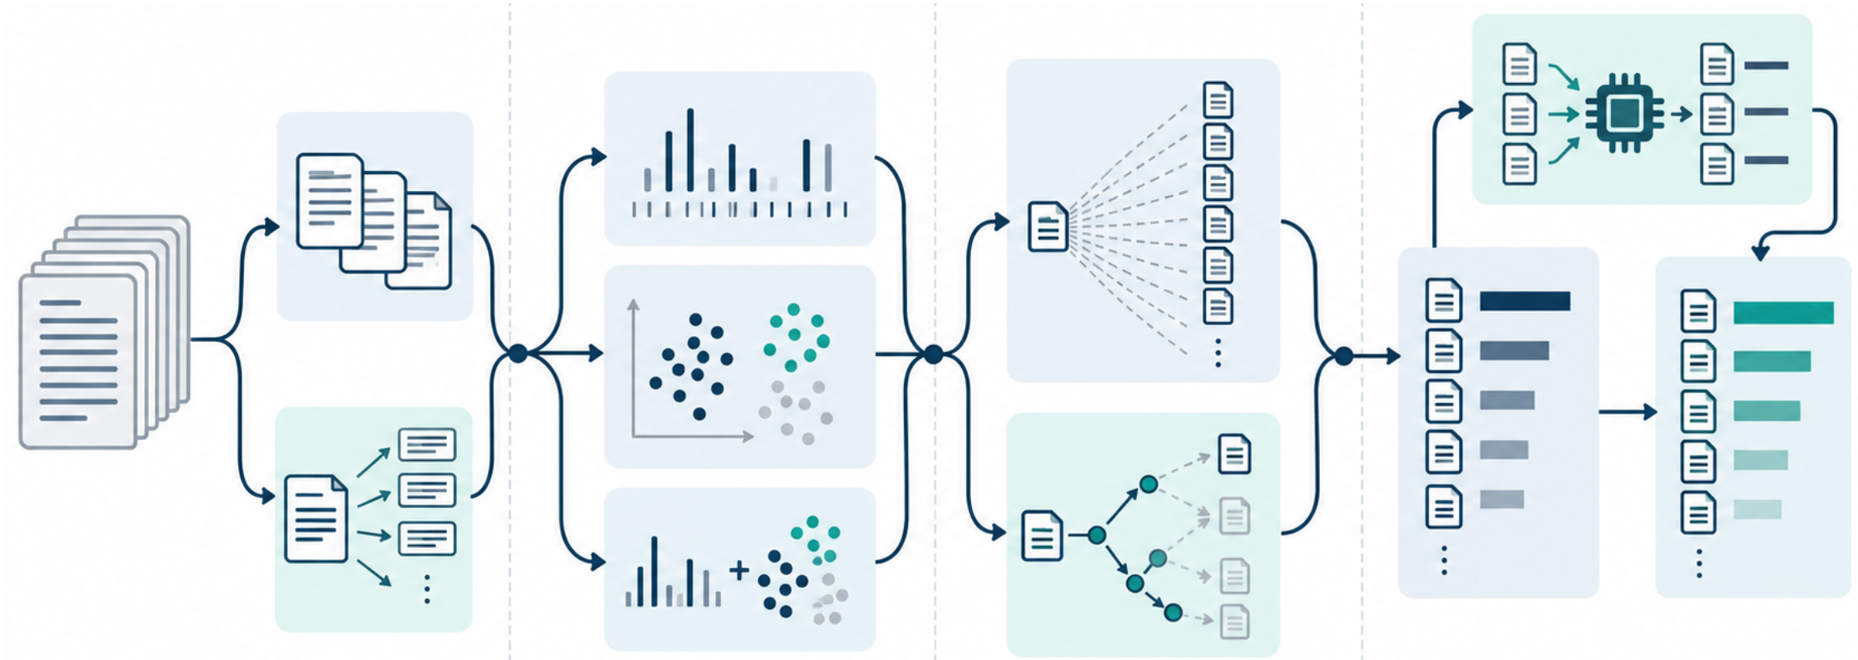
Decisiones de representación y recuperación



EBIS Business Techschool

Diseñar el pipeline significa tomar decisiones

EBIS Business Techschool



Representación
- Modelo de embeddings
- Dimensionalidad
- Documento completo vs chunks
- Chunk size y overlap

Candidate Retrieval
- Sparse
- Dense
- Hybrid

Search
- Exact Search
- ANN
- HNSW + parámetros

Ranking
- Retriever Only
- Cross-Encoder Reranking

Representar mejor también cuesta más

Elegir una representación no consiste únicamente en buscar la mayor calidad semántica.



Modelo

Diferentes modelos producen geometrías y señales de relevancia diferentes

Dimensionalidad

Más dimensiones implican mayor almacenamiento y mayor coste de comparación

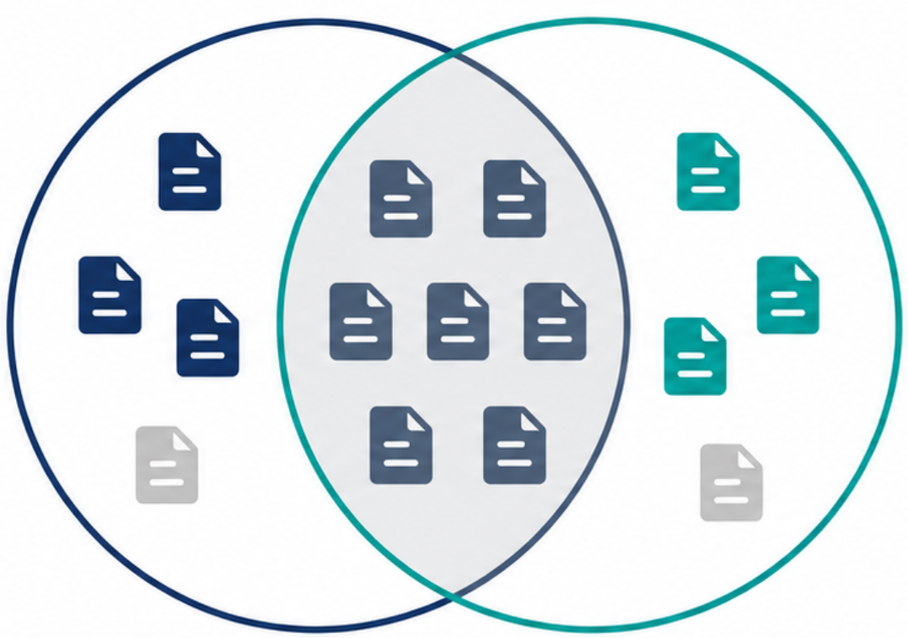
Granularidad

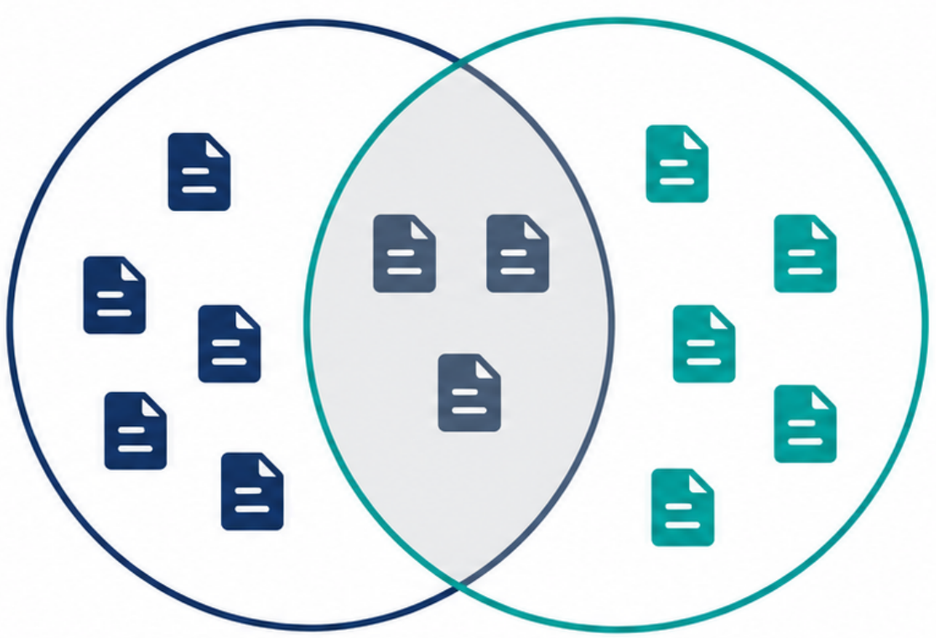
Documento completo vs múltiples chunks

Número de vectores

El chunking puede multiplicar considerablemente el tamaño del índice

ANN Recall no es Retrieval Recall





ANN Recall@k

Da una idea de cuánto perdemos al movernos de una búsqueda exacta a un algoritmo de búsqueda aproximada.

Responde a la pregunta: **¿Cuántos de los vecinos exactos consigue recuperar el índice ANN?**

Retrieved Recall@k

En este caso, comparamos los resultados recuperados con respecto a los grados de relevancia proporcionados por los **Qrels**.

Responde a la pregunta: **¿Cuántos de los documentos realmente relevantes consigue recuperar el sistema?**

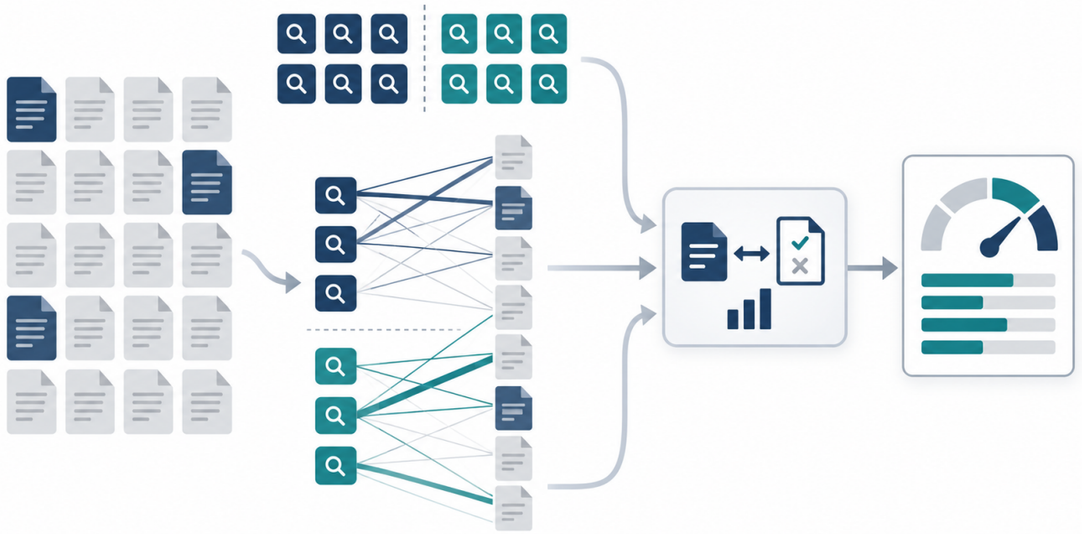
Evaluar antes de optimizar



EBIS Business Techschool

Evaluar un retrieval requiere un ground truth

Un sistema de recuperación solo puede optimizarse si podemos comparar sus resultados contra una referencia.



$$Corpus + Queries + Qrels \longrightarrow Evaluation$$

En cuanto a los datos a usar, diferenciaremos...

Development Set

Utilizado para comparar configuraciones y ajustar decisiones

Evaluation Set

Reservado para estima el rendimiento final

En cuanto a evaluar si conseguimos fragmentos relevantes, podríamos definir la relevancia como...

Relevancia binaria

Relevante / No relevante

Relevancia graduada

Distintos niveles de utilidad para una misma query

No existe una única métrica de retrieval

En producción aparecen continuamente nuevas operaciones sobre la colección.

Precision@k

De los resultados recuperados, ¿cuántos son relevantes?

$$Precision_k = \frac{\#relevantes_{recuperados}}{k}$$

Recall@k

De todos los resultados relevantes, ¿cuántos hemos encontrado?

$$Recall_k = \frac{\#relevantes_{recuperados}}{\#relevantes_{totales}}$$

MRR

¿En qué posición aparece el primer resultado relevante?

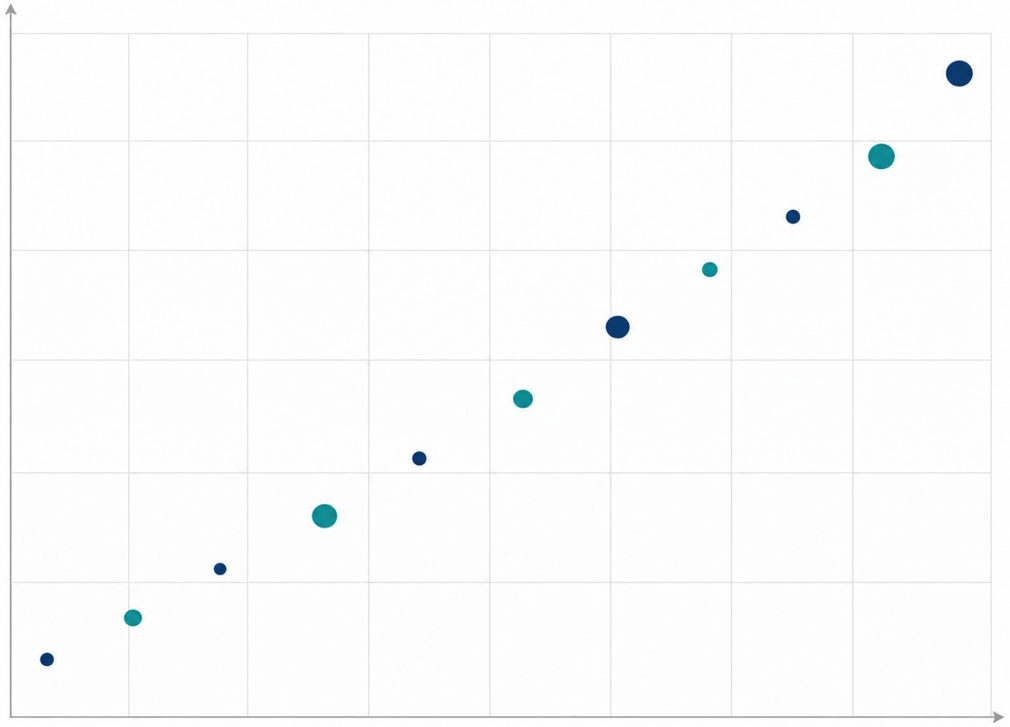
nDCG@k

¿Estamos colocando los documentos más relevantes en las primeras posiciones?

Retrieval es una optimización multiobjetivo

EBIS Business Techschool

Mejorar el sistema implica optimizar varias propiedades que compiten entre sí.



Calidad

Recall@100 nDCG@10 ...

Rendimiento

p50 / p95 latency

Recursos

memoria tamaño del índice ...

Complejidad

número de componentes operación y mantenimiento ...

El mayor nDCG no implica automáticamente la mejor arquitectura. La mejor configuración es la que satisface las restricciones del sistema.

Experimentar y diagnosticar



EBIS Business Techschool

Cada cambio debe convertirse en un experimento medible

EBIS Business Techschool

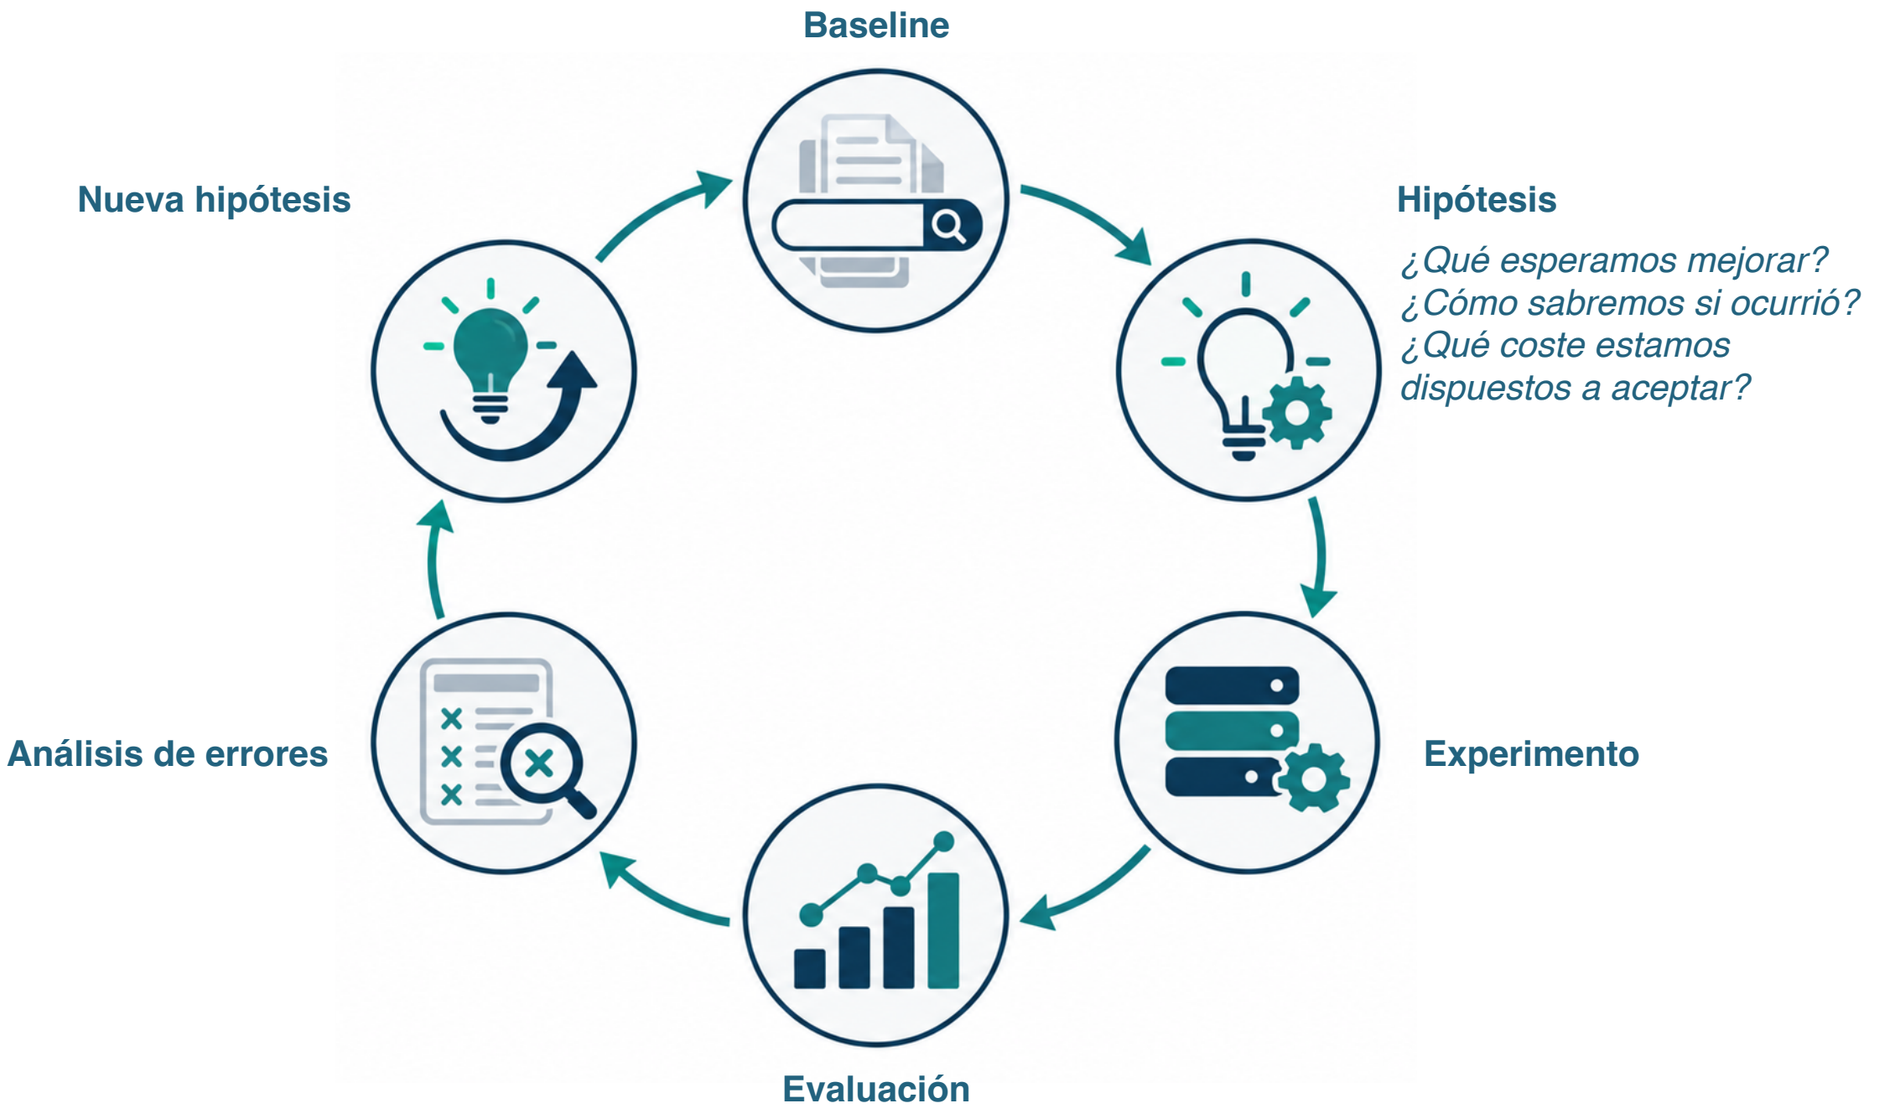
Run	Representación	Retrieval	Índice	Reranker
001	-	BM25	-	-
002	E5	Dense	Exact	-
003	E5	Dense	HNSW	-
004	E5	Hybrid	HNSW	-
005	E5	Hybrid	HNSW	Cross-Encoder

Sobre cada configuración definida para cada experimento, mediremos las distintas métricas de interés:

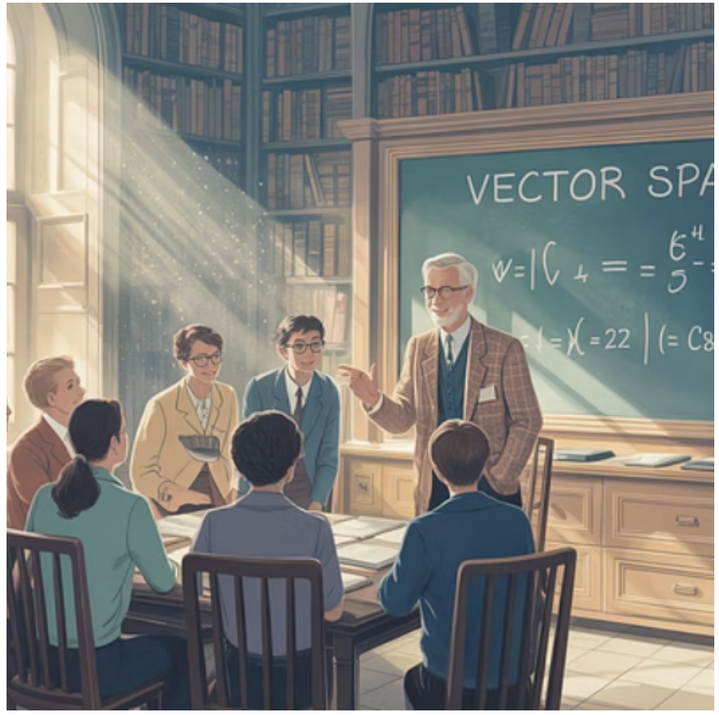
- **Recall@100**
- **nDCG@10**
- **p95 latency**
- **Memory / Index size**
- **...**

Cada experimento modifica una decisión y mide sus consecuencias. Y llevaremos un registro de todos los experimentos realizados.

El ciclo de mejora



¡Gracias y hasta la próxima!







No dudéis en contactarme si tenéis dudas adicionales o necesitáis aclaraciones sobre cualquier aspecto del curso. Podéis encontrarme a través de:

Correo electrónico

albertoragmat@gmail.com

LinkedIn

Alberto Ruiz-Arteaga González

Tutorías

Todos los viernes de **17:30 a 18:30 (hora de Madrid)** en el **Metacampus**.



EBIS Business Techschool

www.ebiseducation.com