

Sesión 7: Retrieval-Augmented Generation (RAG)

EBIS Business Techschool

Agenda de la sesión

1. **RAG estándar**
   Recuperación, contexto y respuesta con fuentes.
2. **Búsqueda como herramienta**
   El LLM formula la consulta y la aplicación la ejecuta.
3. **Evaluación y práctica**
   Comparación en el notebook y aplicación UMBRA.
4. **Otras arquitecturas RAG**
   GraphRAG y RAPTOR como contenido adicional.

Continuamos el caso TREC-COVID de la sesión anterior. Seguiremos la pregunta del usuario hasta la respuesta y comprobaremos qué evidencia la sostiene.

RAG estándar



EBIS Business Techschool

El punto de partida: TREC-COVID

EBIS Business Techschool

Lo que ya tenemos

171.332 documentos y un recuperador híbrido en Pinecone. Combinamos resultados semánticos y léxicos mediante RRF.

La configuración elegida

text-embedding-3-large, 256 dimensiones y 100 candidatos por rama. Reutilizamos los índices sin volver a embeber el corpus.

La nueva necesidad

El usuario quiere una explicación apoyada en los artículos, además de una lista ordenada de resultados.

La elección previa sirve como punto de partida, no como garantía de la calidad de la respuesta.



Qué aporta RAG

EBIS Business Techschool

Generación aumentada por recuperación

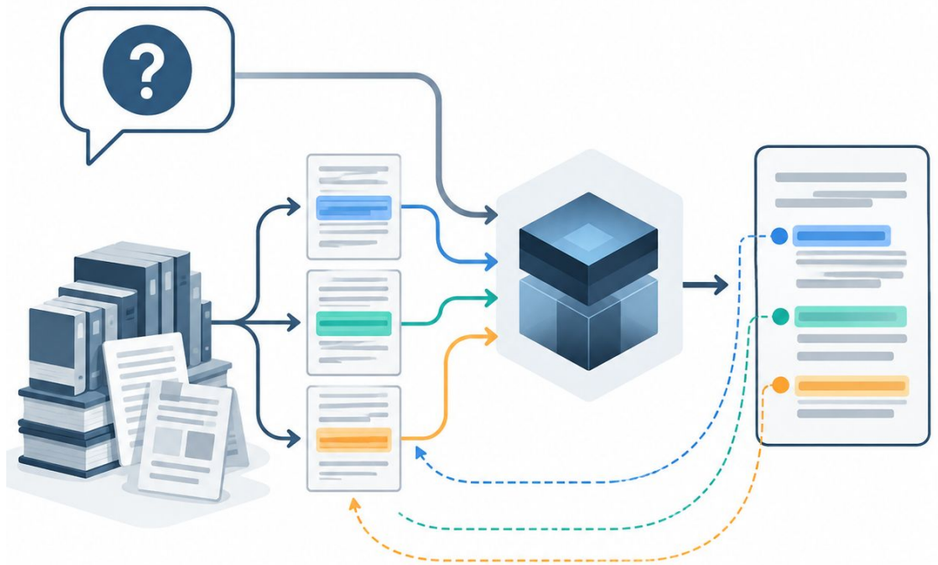
RAG incorpora información recuperada de una colección al contexto con el que un modelo de lenguaje redacta una respuesta.

Dos modelos con tareas diferentes

El modelo de embeddings representa la consulta para buscar. El LLM recibe textos y genera la explicación.

Conocimiento disponible en cada consulta

Podemos aportar documentos externos sin volver a entrenar el LLM. La calidad depende de lo recuperado y de cómo lo utiliza.



El LLM trabaja con los pasajes que le enviamos. No consulta la base de datos vectorial por sí solo.

El recorrido de una pregunta

EBIS Business Techschool

1. Buscar con la pregunta del usuario

Generamos su embedding y su representación léxica. Consultamos las dos ramas de Pinecone y fusionamos el ranking.

2. Preparar el contexto

Leemos los textos, eliminamos duplicados y seleccionamos pasajes dentro del presupuesto de documentos y tokens.

3. Generar y revisar

El LLM recibe instrucciones, pregunta y fuentes etiquetadas. Devuelve una respuesta con referencias como [D1] y [D2].



En el modo estándar, la aplicación fija la búsqueda antes de llamar al LLM.

Candidatos y contexto tienen límites distintos

EBIS Business Techschool

Búsqueda: amplitud de candidatos

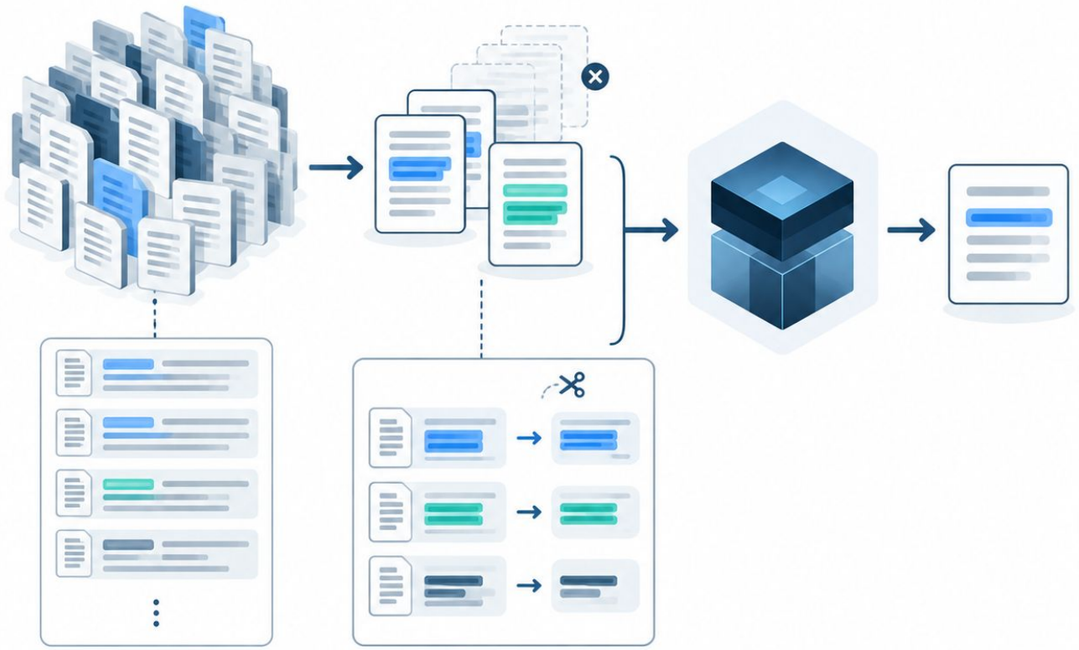
Pedimos hasta 100 resultados por rama. RRF produce un ranking fusionado de hasta 100 documentos.

Contexto: evidencia que verá el LLM

Seleccionamos hasta 6 documentos y 6.500 tokens de fuentes por búsqueda, con hasta 1.200 tokens de texto por documento.

Respuesta: presupuesto de salida

El generador dispone de hasta 1.200 tokens de salida. Las instrucciones, la pregunta y el historial también ocupan contexto.



Los 100 candidatos no implican enviar 100 documentos al modelo.

Instrucciones, evidencia y citas

EBIS Business Techschool

Un contrato de respuesta explícito

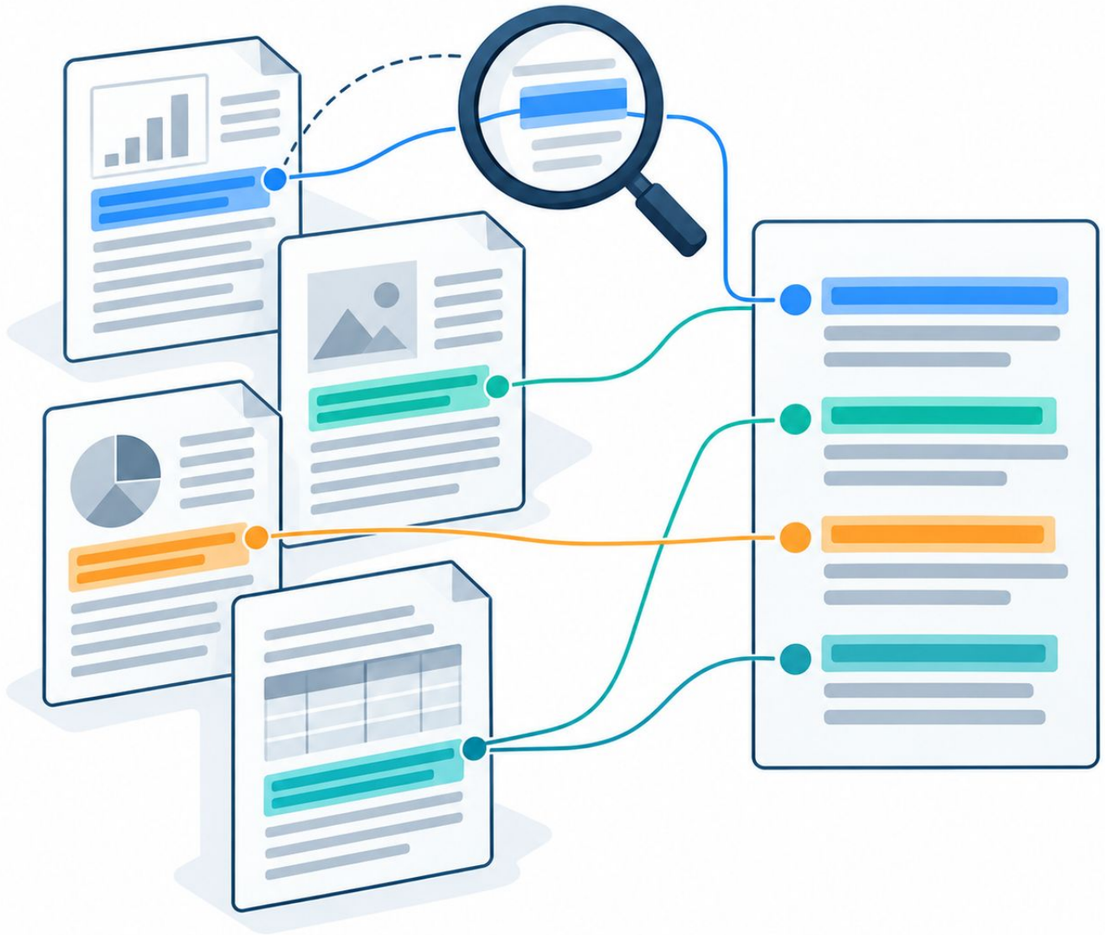
Pedimos que responda con la evidencia disponible, cite las fuentes y reconozca cuándo falta información.

Documentos identificables

Cada pasaje incluye una etiqueta, un ID y un título. La etiqueta conecta la afirmación con el documento que podemos abrir.

Una comprobación necesaria

Una cita válida identifica una fuente existente. Para comprobar fidelidad hay que leer si ese pasaje respalda la afirmación.



La colección es histórica. La respuesta debe conservar sus límites y su incertidumbre.

Búsqueda como herramienta



EBIS Business Techschool

Qué significa dar una herramienta al LLM

EBIS Business Techschool

La aplicación describe una función

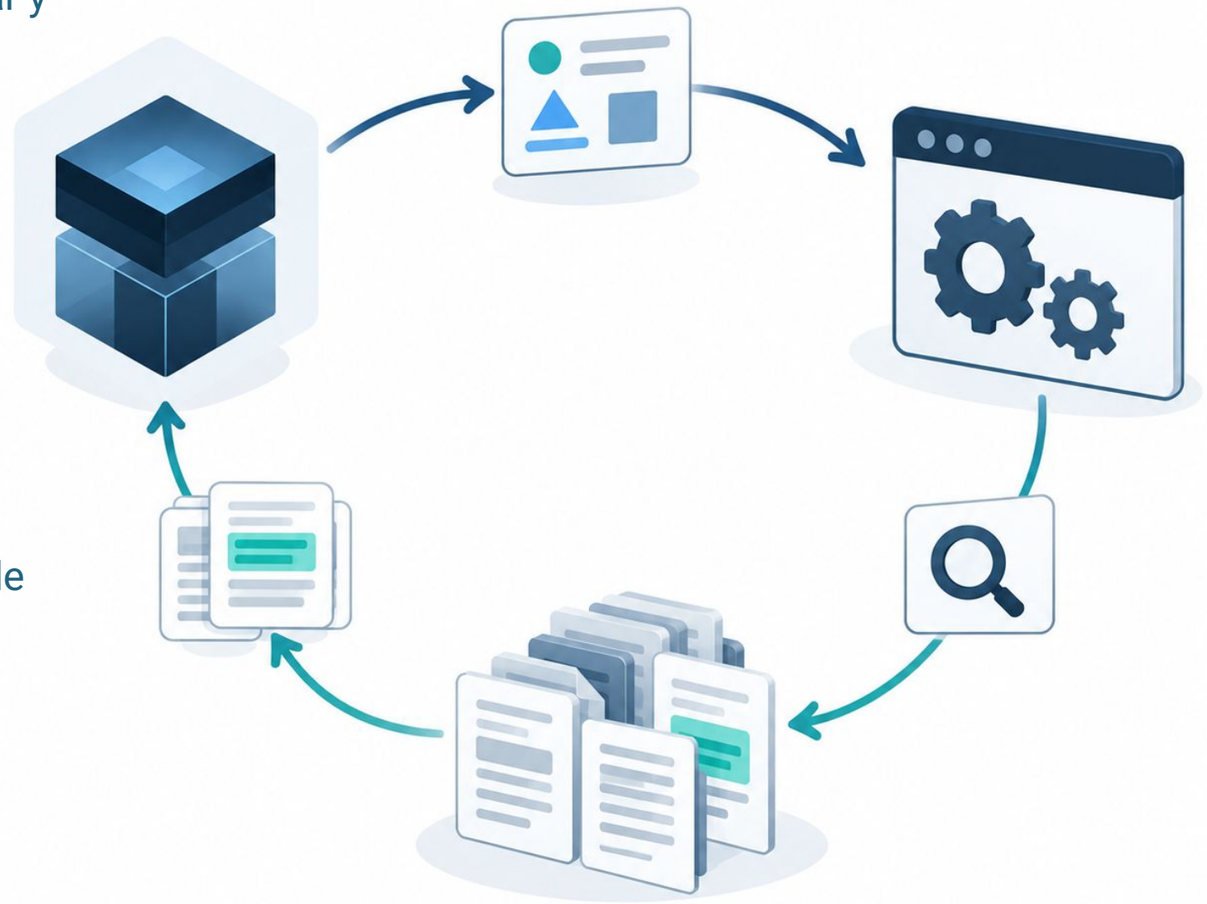
search_library recibe una query. Su contrato explica cuándo buscar y qué argumentos acepta.

El modelo solicita una llamada

El LLM propone una consulta estructurada. Python valida los argumentos y ejecuta la búsqueda con el recuperador existente.

El modelo recibe el resultado

La aplicación devuelve las fuentes a la conversación. El LLM puede responder o solicitar otra búsqueda dentro de los límites.



Las credenciales y la ejecución permanecen en el backend.

La reformulación de la consulta

EBIS Business Techschool

Pregunta del usuario

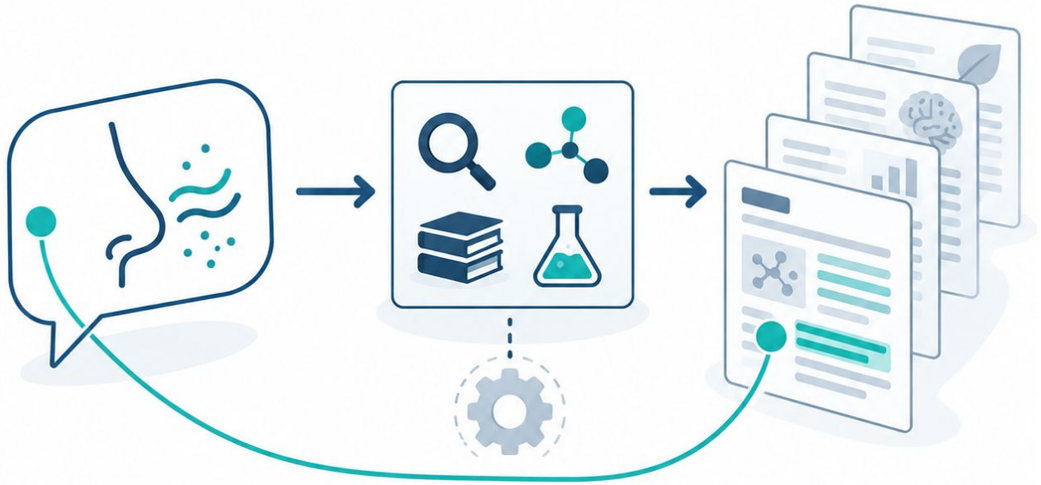
«¿Qué se sabe sobre perder el olfato con COVID?»

Posible consulta del modelo

«COVID-19 anosmia olfactory dysfunction». Puede aportar terminología técnica e inglés para buscar en la colección.

Lo que debemos comprobar

La reformulación debe conservar la intención. Añadir una población, un tratamiento o una relación causal cambiaría la pregunta.



Este ejemplo es ilustrativo. La mejora se comprueba en las fuentes recuperadas.

Control del diálogo y del consumo

EBIS Business Techschool

Un flujo acotado

La primera búsqueda es obligatoria. Permitimos hasta 2 búsquedas y hasta 3 llamadas al LLM, incluida la respuesta final.

Contexto acumulado

Cada búsqueda puede aportar hasta 6 fuentes. Dos búsquedas pueden acumular hasta 12 documentos distintos.

Historial y seguimiento

El modelo recibe hasta 8 mensajes previos. En el modo estándar, una pregunta ambigua sigue llegando literalmente al buscador.



Más llamadas y más contexto pueden aumentar el consumo sin mejorar la respuesta.

Evaluación y práctica



EBIS Business Techschool

La calidad se revisa por etapas

EBIS Business Techschool

Recuperación

¿Los resultados contienen documentos relevantes? Podemos seguir usando los juicios de relevancia y las métricas de la sesión anterior.

Contexto

¿El pasaje necesario llega al prompt? La selección y el recorte pueden excluir evidencia presente en el ranking.

Generación

¿La respuesta atiende la pregunta y cada afirmación se sostiene en las fuentes? ¿Reconoce información ausente o contradictoria?



Los qrels de TREC-COVID evalúan relevancia documental, no la corrección de una respuesta generada.

Comparación de los dos enfoques

EBIS Business Techschool

Condiciones que mantenemos

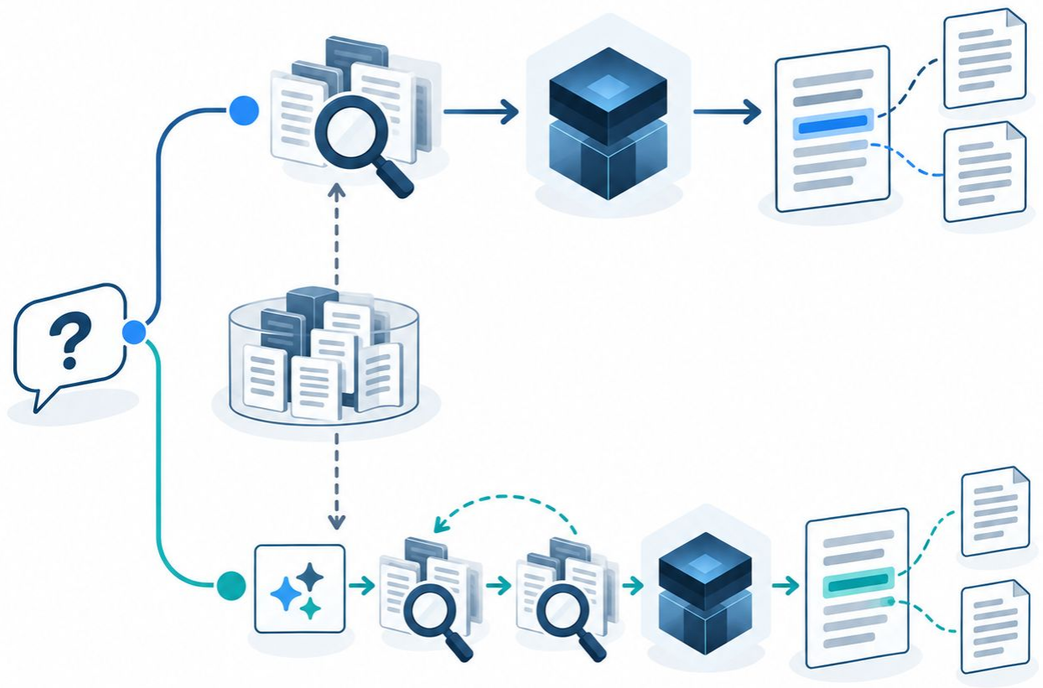
Mismas preguntas, corpus, recuperador y modelo generativo. Guardamos la consulta efectiva y las fuentes de cada ejecución.

Resultados que revisamos

Calidad de la respuesta y soporte de las citas. Registramos también tokens, llamadas y latencia.

Diferencias que declaramos

El flujo con herramientas puede buscar dos veces y acumular más contexto. La comparación actual evalúa ambos sistemas completos.



Para aislar el efecto de reformular, habría que igualar también búsquedas y presupuesto de contexto.

Otras arquitecturas RAG



EBIS Business Techschool

GraphRAG: relaciones y visión global

EBIS Business Techschool

La idea

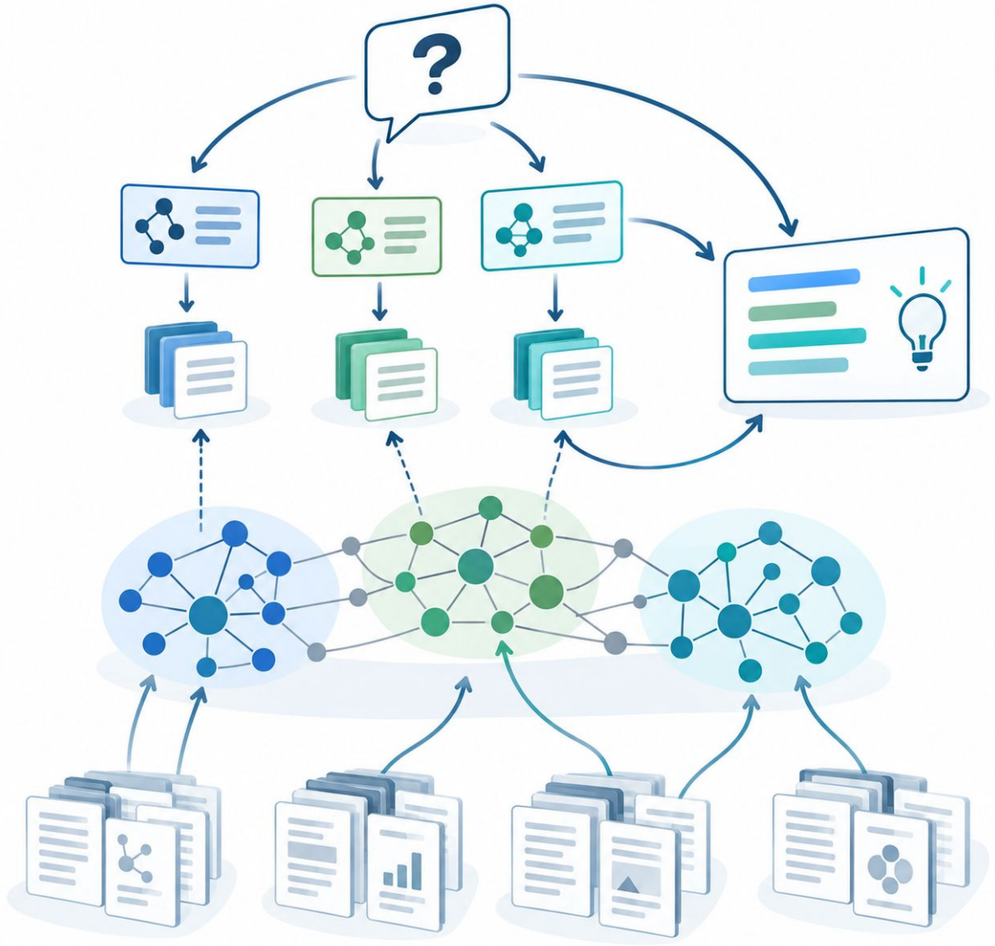
Un grafo representa entidades y relaciones extraídas de los documentos. Algunas arquitecturas añaden resúmenes de comunidades.

La pregunta que motiva el cambio

Para explorar relaciones o temas globales puede hacer falta conectar información repartida por la colección.

El extra del notebook

Construimos un grafo local de hasta 8 documentos con citas literales. El ejemplo no implementa comunidades ni búsqueda global.



Extraer un grafo introduce coste y posibles errores. Cada relación necesita procedencia.

RAPTOR: recuperación a varios niveles

EBIS Business Techschool

La idea

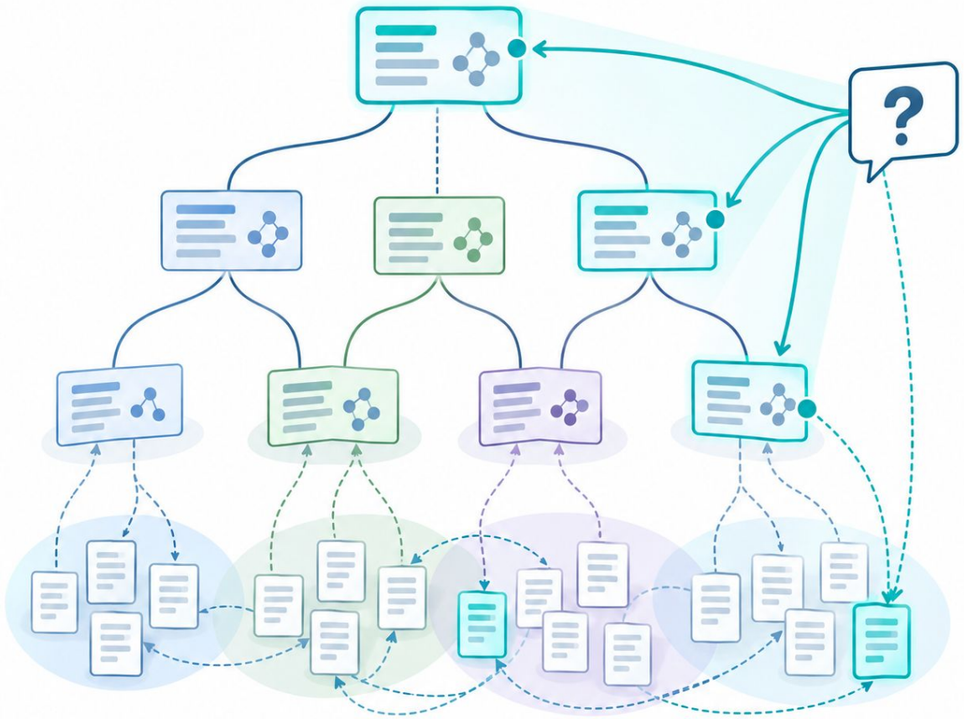
Agrupar fragmentos y resumirlos de forma recursiva produce una jerarquía. Podemos buscar detalles y síntesis de distinto alcance.

La pregunta que motiva el cambio

Una consulta amplia puede requerir información distribuida entre varios documentos, más allá de un pasaje aislado.

El extra del notebook

Usamos de 2 a 16 documentos, TF-IDF y K-Means. Los resúmenes ayudan a localizar los documentos originales.



Es una adaptación didáctica. Un resumen puede omitir matices o introducir errores.