Enlaces útiles · Sesión 2

Modelos de IA generativa open source

Aquí tenéis los enlaces que os van a hacer falta para los deberes, ordenados por ejercicio, y unos cuantos más para ir más allá. No hace falta leerlos enteros: tirad de ellos cuando os atasquéis. Casi todos son documentación oficial y gratuita; los artículos científicos están marcados.

Revisados el 13 de octubre de 2026. Si alguno cambia, buscad la página equivalente en la misma web.

Para el ejercicio 1 (datos con garantías)

1 · Vistas y comentarios en DuckDB

https://duckdb.org/docs/stable/sql/statements/create_view

https://duckdb.org/docs/stable/sql/statements/comment_on

Para qué sirve: Nuestra capa semántica son vistas de DuckDB con un comentario en cada vista y en cada columna. Esos comentarios son lo que el esquema automático le enseña al modelo.

Qué debéis saber hacer: Leer una vista del script 02 y escribir vosotros una nueva, con su comentario.

2 · DuckDB desde Python

https://duckdb.org/docs/stable/clients/python/dbapi

Para qué sirve: Cómo ejecutan SQL nuestros scripts, y cómo pasar valores como parámetros en lugar de pegarlos en el texto de la consulta.

Qué debéis saber hacer: Ejecutar vuestra propia consulta y leer el resultado.

3 · Qué es una capa semántica en la industria

https://docs.getdbt.com/docs/use-dbt-semantic-layer/dbt-sl

Para qué sirve: La capa semántica de dbt, una de las más usadas: las métricas («ventas netas») se definen una vez y todos las consultan igual. Es la misma idea que nuestras vistas, a escala de empresa.

Qué debéis saber hacer: Explicar por qué es mejor definir una métrica una vez en código que explicarla en cada prompt.

4 · Modelos de expertos (MoE)

https://huggingface.co/blog/moe

https://huggingface.co/Qwen/Qwen3-30B-A3B-Instruct-2507

Para qué sirve: Por qué el 30B de clase escribe casi tan rápido como el 4B: de sus 30.000 millones de parámetros, en cada token solo trabajan unos 3.000 millones. El segundo enlace es la ficha del modelo.

Qué debéis saber hacer: Distinguir parámetros totales y activos, y qué cuesta memoria y qué cuesta tiempo.

Para el ejercicio 2 (la voz)

5 · Whisper

https://github.com/openai/whisper

Para qué sirve: El repositorio oficial: cómo se instala, qué modelos hay (de tiny a large-v3 y turbo), cuánta memoria necesita cada uno y cómo se usa desde Python. Licencia MIT.

Qué debéis saber hacer: Instalarlo y elegir un modelo que vuestro equipo pueda mover.

6 · Instalar PyTorch

https://pytorch.org/get-started/locally/

Para qué sirve: El selector que os da la orden exacta para vuestro sistema. Si no tenéis GPU NVIDIA, elegid la versión para CPU: es mucho más ligera.

Qué debéis saber hacer: Instalar la versión adecuada antes que Whisper.

7 · El audio, para una máquina

https://huggingface.co/learn/audio-course/chapter1/audio_data

Para qué sirve: Del curso de audio de Hugging Face: muestreo, amplitud, espectrograma y espectrograma mel, lo mismo que vimos con el script 06.

Qué debéis saber hacer: Explicar qué recibe Whisper: no el sonido, sino números.

Para el ejercicio 3 (RAG)

8 · Embeddings con Ollama y bge-m3

https://docs.ollama.com/capabilities/embeddings

https://ollama.com/library/bge-m3

https://huggingface.co/BAAI/bge-m3

Para qué sirve: Cómo pedirle un vector a Ollama y la ficha del modelo que usamos: multilingüe y con textos de hasta 8.192 tokens. La ficha habla de tres tipos de vectores; con Ollama usamos solo el denso.

Qué debéis saber hacer: Descargar el modelo, pedir el vector de un texto y saber cuántos números tiene.

9 · Similitud coseno en DuckDB

https://duckdb.org/docs/stable/sql/functions/list

Para qué sirve: La función list_cosine_similarity, con la que comparamos la pregunta con los 51 vectores sin necesitar una base de datos vectorial.

Qué debéis saber hacer: Encontrar la función y entender qué devuelve.

10 · Leer PDF con PyMuPDF

https://pymupdf.readthedocs.io/en/latest/

Para qué sirve: La librería que saca el texto de los PDF en el script 10. Si un PDF es escaneado no hay texto que sacar: haría falta OCR.

Qué debéis saber hacer: Sacar el texto de una página y ver por qué hay que limpiarlo.

Internal

11 · BM25 y la fusión RRF

https://en.wikipedia.org/wiki/Okapi_BM25

https://cormack.uwaterloo.ca/cormacksigir09-rrf.pdf

Para qué sirve: La búsqueda por palabras de toda la vida y el artículo original de Reciprocal Rank Fusion (2009, en inglés, cuatro páginas), la forma en que combinamos las dos listas.

Qué debéis saber hacer: Explicar por qué RRF usa la posición en cada lista y no la puntuación.

Para ir más allá (opcional)

12 · El artículo que bautizó el RAG

https://arxiv.org/abs/2005.11401

Para qué sirve: Lewis y otros, 2020 (artículo científico, en inglés). Nuestro RAG es más sencillo, pero la idea es la misma: buscar primero y generar después.

Qué debéis saber hacer: Situar de dónde viene el término.

13 · Recuperación contextual

https://www.anthropic.com/engineering/contextual-retrieval

Para qué sirve: Una técnica parecida a nuestra cabecera de contexto: añadir a cada fragmento una frase que lo sitúe en su documento antes de indexarlo (allí la escribe un LLM; nosotros la construimos con la ficha). Combina embeddings y BM25, como nosotros.

Qué debéis saber hacer: Relacionarlo con el experimento (a) del ejercicio 3.

14 · Comparar modelos de embeddings

https://huggingface.co/spaces/mteb/leaderboard

Para qué sirve: La clasificación MTEB: modelos de embeddings comparados en muchas tareas e idiomas. Una buena nota general no garantiza que sea el mejor para vuestros documentos: por eso hicimos nuestro examen.

Qué debéis saber hacer: Filtrar por idioma y tamaño y encontrar alternativas a bge-m3.

15 · Cómo se entrenó Whisper

https://arxiv.org/abs/2212.04356

Para qué sirve: El artículo de Whisper (Radford y otros, 2022; artículo científico, en inglés): 680.000 horas de audio con transcripciones de internet. Explica por qué funciona sin ajustarlo y por qué alucina.

Qué debéis saber hacer: Contar en dos frases cómo se entrenó.

16 · Ajustar Whisper con datos propios y LoRA

https://huggingface.co/blog/fine-tune-whisper

https://huggingface.co/docs/peft/index

https://arxiv.org/abs/2106.09685

Para qué sirve: Lo que contamos de las 1.000 llamadas: una guía paso a paso para ajustar Whisper, la librería PEFT y el artículo original de LoRA (artículo científico, en inglés).

Qué debéis saber hacer: Explicar qué hace falta antes de ajustar: transcripciones revisadas, separar por llamada y medir el WER.