Ejercicios propuestos - Sesión 2

Preguntad a los datos, usad el audio y los documentos, y comprobad cada respuesta

En la sesión 2 hemos pasado de preguntarle cosas al modelo a construir algo en lo que se pueda confiar: una **capa semántica** para que el SQL no caiga en las trampas del caso, **Whisper** para convertir la llamada en texto y un **RAG** que responde citando sus fuentes. Ahora os toca montarlo en vuestro ordenador y, sobre todo, buscar dónde falla. Son cuatro ejercicios y unas **dos horas y media** en total.

Igual que en la sesión 1, no os voy a dar todos los comandos. Os digo **qué quiero conseguir** y vosotros os buscáis la vida.

Una pista que vale para todo: cada script explica al principio del archivo para qué sirve y cómo se usa, y todos tienen --help. Leedlo antes de ejecutar. Si os atascáis más de media hora con lo mismo, escribidme.

Antes de empezar: descomprimid DropLab_sesion_2.zip en la misma carpeta de la sesión 1 (los scripts nuevos usan los de la sesión 1). Trae los documentos nuevos, la llamada, los scripts de clase (practica/sesion_2) y las transcripciones que hicimos en el Jetson.

Sobre el modelo: en clase usamos qwen3:30b-a3b-instruct, que cargado ocupa unos 18 GB. En un portátil **no cabe** (seguramente, si alguien tiene algo super potente, tirad millas) : usad qwen3:4b-instruct o el que elegisteis en la sesión 1. Todos los scripts permiten cambiar de modelo (mirad el --help). Que vuestro modelo saque peor nota que el del Jetson no es un fallo vuestro: es justo lo que quiero que midáis.

Ejercicio 1 · El SQL libre, con y sin capa semántica (**unos 40 minutos**)

En clase vimos que el mismo modelo pasaba de 2 a 5 aciertos sobre 5 en el examen rápido solo cambiando lo que ve: las tablas crudas o unas vistas con el negocio ya resuelto. Quiero que lo comprobéis con vuestro modelo y que busquéis vosotros los fallos. Lo que quiero que consigáis:

- **Comprobar la capa antes de usarla.** El script 02 tiene una opción que compara las vistas con las cifras del script 03 de la sesión 1. Si algo no sale en verde, no sigáis: avisadme.
- **Ver lo que ve el modelo.** Sacad el prompt de sistema que recibe el modelo con la capa y buscad tres avisos de negocio que van dentro de los comentarios de las vistas (por ejemplo, qué columna no descuenta abonos o qué no es un cliente).
- **La misma pregunta, dos modos.** Preguntad por las ventas netas de Malasaña en los periodos A y B con el script 01, en modo clase (tablas crudas) y con la capa. Copiad el SQL de cada uno. Si no salen 40.000 y
  26.000 €, encontrad la línea del SQL que lo explica.
- **El examen rápido.** Pasad el examen rápido del script 04 en los dos modos con vuestro modelo. Tarda unos minutos.
- **Tres preguntas vuestras.** Escribid tres preguntas nuevas que no estén en ningún examen (el script 04 os deja verlos sin llamar al modelo). Una tiene que ser imposible con estos datos: pensad en lo que no existe. Antes de preguntar al modelo, calculad vosotros la respuesta correcta con vuestro propio SQL sobre las vistas (el script 02 os deja ejecutarlo con las mismas barreras). Después, preguntad al modelo con la capa y comparad.

Qué queremos conseguir:

- Vuestro modelo y el tiempo medio por pregunta.
- El examen rápido en los dos modos: aciertos y qué pregunta falla en cada uno, comparado con el Jetson (lo tenéis en el anexo).
- El SQL de la pregunta de Malasaña en los dos modos y, si falla, la línea culpable explicada.
- Vuestras tres preguntas: la respuesta correcta con vuestro SQL, lo que respondió el modelo y, si falla, el tipo de error con la clasificación de la sesión 1 (cifra inventada, cifra real con significado falso…). ¿Lo habría cazado el verificador? Pensad qué comprueba exactamente.
- Una mejora de la capa: una vista, una columna o un comentario que añadiríais para que vuestro modelo no repita el fallo. No hace falta programarla; si os animáis, mejor.

Ejercicio 2 · Transcribid la llamada y auditadla (**unos 40 minutos**)

Whisper no funciona con Ollama: se instala aparte, con PyTorch. En el Jetson usamos la GPU; en vuestro portátil irá por CPU, más lento, pero funciona. Si en media hora no conseguís instalarlo, usad las transcripciones del Jetson que vienen en el zip y decídmelo en la entrega. Lo que quiero que consigáis:

- **Escuchadla primero.** Antes de transcribir nada, escuchad la versión mono de la llamada (dura menos de dos minutos) y apuntad: hasta qué día dice Álex que duró el Pack 4, qué pasó el día 6 y a qué horas, y qué dice Dani de las visitas. Esa es vuestra referencia humana.
- **Instalad Whisper** (el paquete openai-whisper) en vuestro entorno virtual. En el Jetson hizo falta un PyTorch especial de NVIDIA; en un portátil vale el normal, pero mirad en la web de PyTorch cómo instalar la versión para vuestro sistema: la que viene por defecto puede descargar varios GB que no necesitáis.
- **Transcribid por canales** con el modelo small, y con turbo si vuestro equipo aguanta (en CPU puede tardar varios minutos). Apuntad cuánto tarda frente a lo que dura el audio.
- **Las palabras dudosas.** El script marca las palabras con probabilidad baja. Elegid cinco, id a ese segundo exacto (el visor del script 08 os deja hacer clic en cada frase) y escuchad: ¿acertó Whisper? Buscad también algún error con probabilidad alta, si lo hay.
- **Comparad dos transcripciones:** la vuestra con la del Jetson, small con turbo, o con y sin la opción de solo voz. Elegid una frase que cambie y explicad qué cambió en la entrada. Cuidado con sacar conclusiones de un solo ejemplo: en clase vimos «**ya nos**» frente a «**ya no se**», y eso no demostraba que separar los canales fuera la causa.
- **Del audio al dato.** Coged tres cosas que se dicen en la llamada y comprobad cada una en otra fuente: en los datos (con vuestro SQL sobre las vistas) o en los documentos. Por ejemplo, lo que dice Dani del día 6 frente al registro de disponibilidad.

Qué queremos conseguir:

- Vuestro equipo, el modelo de Whisper y los tiempos (o «usé las transcripciones del Jetson», y por qué).
- Una tabla con las cinco palabras dudosas: la palabra, su probabilidad, lo que se oye y si acertó.
- La comparación de dos transcripciones, con una explicación prudente.
- Las tres comprobaciones: qué se dice, dónde lo habéis comprobado y si coincide.
- Una frase: si esta transcripción entrara en un informe para dirección, ¿cómo la presentaríais? (No es un acta revisada por nadie.)

Ejercicio 3 · Montad el RAG y cambiad una decisión (**unos 50 minutos**)

En clase os dije que cómo se trocea, qué ficha lleva cada fragmento y cómo se busca son decisiones del científico de datos, no del modelo. Ahora vais a cambiar una y a medir qué pasa. Sin medir, es solo una opinión. Lo que quiero que consigáis:

- **El RAG funcionando:** el modelo de embeddings bge-m3 descargado en Ollama, el corpus preparado (con la transcripción del Jetson salen 51 fragmentos) y el índice creado. Son los scripts 10 y 11, y el orden importa.
- **Mirad cómo se trocea** un PDF y la llamada: el script 10 os enseña una fuente antes y después de cortarla. Elegid un fragmento del expediente y explicad de dónde sale cada dato de su ficha: ¿lo pone el documento o lo deduce el código?
- **La línea base.** Pasad el examen de recuperación del script 14 con k = 3 y con k = 1, y apuntad los aciertos y el MRR de las tres búsquedas. Es rápido porque no usa el LLM. (El MRR es la media de 1/posición de la
  primera fuente correcta: 1 si sale la primera, 0,5 si sale la segunda…)
- **Cambiad una decisión, solo una,** y repetid el examen. Elegid entre: (a) quitar la cabecera de contexto del texto que se indexa; (b) trocear mucho más pequeño, bajando el límite de palabras por fragmento; (c) otro modelo de embeddings, por ejemplo nomic-embed-text. Para (a) y (b) hay que tocar el script 10: buscad dónde se construye el texto que se indexa y dónde está el límite. Después, volved a crear el corpus y el índice.
- **Preguntad a los documentos** con vuestro modelo (script 13): la pregunta del Pack 4, una vuestra y una imposible. Abrid las fuentes citadas y leedlas: ¿dicen lo mismo que la respuesta?
- **Deshaced el cambio** y volved a crear el corpus y el índice antes del ejercicio 4.

Qué queremos conseguir:

- La ficha del fragmento que elegisteis, explicada.
- Una tabla antes y después: aciertos y MRR de cada búsqueda, con k = 3 y k = 1, y qué preguntas cambian.
- Vuestra conclusión en dos o tres frases. Ojo: puede que vuestro cambio no lo empeore todo. Si mejora una cosa y empeora otra, contadlo tal cual: eso es lo interesante.
- Las tres respuestas con sus citas y, para cada una, si la fuente dice exactamente lo mismo. Si encontráis una cita real con un significado distinto, señaladmela.

Ejercicio 4 · Cinco frases para dirección (**unos 20 minutos**)

Para terminar, juntamos los tres bloques. Al final de este documento tenéis la respuesta que escribió el analista (script 15) en el Jetson. Pasó la verificación del código: todas sus cifras salen de una consulta y todas sus citas existen. Lo que quiero que hagáis:

- **Auditadla frase a frase:** ¿qué es un hecho, qué es testimonio y qué es hipótesis? ¿Hay alguna afirmación que no respalde ninguna fuente? ¿Qué dato importante no consultó?
- **Escribid vuestras cinco frases para dirección:** la hipótesis que priorizáis, las cifras con la consulta que las da, las fuentes (documento y página o sección; la llamada, como testimonio) y el dato que pediríais para confirmarla. Sin afirmar causas que los datos no prueban.
- **Opcional:** ejecutad el analista con vuestro modelo y comparad su respuesta con la del Jetson.