Test - Sesión 2

Test de la sesión 2

1. **En la sesión 2 pusimos una capa semántica entre los CSV de DropLab y el modelo. ¿Qué es exactamente?**

a) Un modelo más grande que entiende mejor el negocio de la empresa.

b) Unas vistas escritas en código que ya resuelven periodos, abonos y tiendas, para que el modelo solo traduzca la pregunta.

c) Un prompt más largo con todas las reglas de cálculo del caso.

d) Una copia de los CSV en formato JSON para que el modelo los lea directamente.

2. **Con las tablas crudas, el 30B dio unas ventas netas de Malasaña de 39.817,63 € (A) y 26.212,37 € (B), en lugar de 40.000 y 26.000 €. El SQL se ejecutó sin ningún error. ¿Qué pasó?**

a) El modelo redondeó mal los decimales al escribir la respuesta final.

b) DuckDB perdió algunas filas al leer los CSV.

c) Asignó cada abono al periodo de su venta, no al de la fecha en que se reconoció el abono.

d) Cogió como periodo A todo el mes de marzo, incluidos el 30 y el 31.

3. **El verificador del bloque I revisa la respuesta final del modelo. ¿Qué error NO puede detectar?**

a) Una cifra calculada de cabeza que no sale de ninguna consulta.

b) Un ticket medio de «25 858 €» cuando la consulta devolvió 258,33.

c) Una respuesta con cifras escrita sin haber hecho ninguna consulta.

d) «307 líneas», cuando 307 es la suma de unidades que devolvió el SQL.

4. **¿Por qué medimos la capa semántica con tres exámenes (batería, validación y prueba final) y no solo con la batería?**

a) Porque la capa se diseñó mirando la batería: hacían falta preguntas nuevas para ver si la habíamos ajustado a ella.

b) Porque cada examen se hace con un modelo distinto y así se comparan.

c) Porque la batería tenía preguntas imposibles y había que sustituirlas.

d) Porque con más preguntas el modelo va aprendiendo y su nota mejora.

5. **En el Jetson, qwen3:30b-a3b ocupa unos 18 GB y escribe a 8,5 tokens/s; qwen3:4b ocupa 3,2 GB y escribe a 7,3 tokens/s. ¿Cómo puede el 30B ir casi igual de rápido?**

a) Porque Ollama lo comprime al cargarlo hasta dejarlo del tamaño del 4B.

b) Es un modelo de expertos: en cada token solo trabajan unos 3.000 millones de parámetros, aunque todos tienen que estar en memoria.

c) Porque solo carga la mitad de sus pesos y el resto lo consulta en internet.

d) Porque el 30B se ejecuta en la GPU y el 4B, en la CPU.

6. **¿Qué afirmación sobre Whisper es correcta?**

a) Se ejecuta con Ollama, igual que cualquier otro LLM.

b) Reconoce sonidos uno a uno y, por eso, no puede inventarse texto.

c) Convierte trozos de 30 s en una representación log-mel; un codificador la procesa y un decodificador escribe el texto token a token, como un LLM.

d) Separa por sí solo a los interlocutores, aunque estén grabados en el mismo canal.

7. **En un tramo casi en silencio, large-v3 escribió «¿Qué pasa?», y nadie lo había dicho. ¿Cuál es la explicación más razonable?**

a) El decodificador es un modelo de lenguaje y, con poca señal, puede completar una frase plausible: una alucinación.

b) El micrófono captó una tercera voz que no se oye al escuchar la llamada.

c) Whisper convierte los silencios largos en preguntas para marcarlos.

d) Es imposible: Whisper nunca escribe nada en tramos sin voz.

8. **Whisper escribe «ya nos entregaba» y la palabra dudosa tiene probabilidad 0,626. ¿Cómo usamos esa probabilidad?**

a) Es la probabilidad de que lo que se dice sea cierto para el negocio.

b) Sirve para decidir qué tramos escuchar primero; no garantiza el acierto, y hay errores con probabilidad alta.

c) Si supera 0,5, la palabra es correcta y no hace falta revisarla.

d) Indica el volumen de la voz en ese momento de la llamada.

9. **En la transcripción de la llamada sabemos quién dice cada frase. ¿Por qué?**

a) Porque Whisper reconoce la voz de Álex y la de Dani.

b) Porque el espectrograma es una huella biométrica de cada persona.

c) Porque el LLM deduce quién habla por el contenido de cada frase.

d) Porque cada interlocutor se grabó en un canal distinto y transcribimos cada canal por separado.

10. **Queremos adaptar Whisper con 1.000 llamadas reales de la empresa. ¿Qué plan es el correcto?**

a) Transcribir las 1.000 con Whisper y usar esas salidas como etiquetas, sin revisarlas, para ganar tiempo.

b) Revisar las transcripciones, mezclar todos los fragmentos y repartirlos al azar entre entrenamiento y prueba.

c) Pasar las 1.000 llamadas por 07_transcribir.py: el modelo va aprendiendo cada vez que transcribe.

d) Revisarlas a mano, separar entrenamiento y prueba por llamada completa y medir el WER antes y después del ajuste.

11. **En nuestro RAG, cada fragmento se indexa con una cabecera: título, código, estado, fecha y sección. ¿Para qué?**

a) Para que el fragmento se entienda aunque llegue solo: sin ella, una sección como «Pack 4: ejecución» no diría de qué documento ni de qué versión viene.

b) Para que el modelo de embeddings ocupe menos memoria al calcular los vectores.

c) Porque bge-m3 no acepta textos que no empiecen por un título.

d) Para que el LLM se entrene con los documentos de la empresa.

12. **¿Quién decide en nuestro RAG que el borrador del Pack 4 está sustituido?**

a) El modelo de embeddings, porque los vectores del borrador y del aprobado quedan lejos.

b) El LLM, cuando lee los dos documentos al responder.

c) Una regla del código: el calendario aprobado dice «sustituye a CAM-2026-03-DRAFT» y el código marca ese documento.

d) BM25, porque el borrador tiene menos palabras que el documento aprobado.

13. **Buscamos «HIST-JOIN-001» en los documentos. ¿Qué afirmación es correcta?**

a) La búsqueda por palabras (BM25) clava los códigos exactos; la semántica entiende sinónimos. La híbrida (RRF) combina las dos listas según la posición en cada una.

b) La semántica lo encuentra siempre, porque entiende cualquier código; BM25 solo funciona en inglés.

c) Ninguna búsqueda lo encuentra: los códigos no se pueden buscar en un RAG.

d) La híbrida suma las similitudes coseno de las dos listas y las convierte en probabilidades.

14. **La fuente esperada sale entre los 3 primeros fragmentos, pero el modelo responde «el inicio efectivo de las obras fue el 1 de abril [F2]», y la fuente dice «inicio programado». El verificador no avisa. ¿Qué concluimos?**

a) Que el RAG está bien: si la cita existe, la frase es verdad.

b) La cita y la fecha existen, pero el significado no: la búsqueda funcionó y el fallo está en la redacción. Hay que leer la fuente.

c) Que hay que cambiar el modelo de embeddings, porque la recuperación falla.

d) Que el verificador está roto, porque debería comprobar que la frase dice lo mismo que la fuente.

15. **La primera vez que probamos el analista (script 15) respondió sin usar ninguna herramienta, con cifras y citas [S1] y [D1]. ¿Qué lo detectó y qué cambiamos?**

a) Nada: las citas tenían el formato correcto y la respuesta se aceptó.

b) El propio modelo se dio cuenta en el segundo intento y se corrigió solo.

c) Bajamos la temperatura del modelo y el problema desapareció.

d) El código: ninguna fuente consultada y seis cifras sin respaldo. Ahora no acepta una respuesta sin haber consultado antes.