

Tema 8: IA Agéntica y automatización basada en agentes

Sesión 4 · Memoria, contexto y estado

EBIS Business Techschool

Contenidos

- Del LLM al agente: anatomía y arquitectura
- Razonar y actuar: ReAct y patrones de planificación
- Herramientas desde la perspectiva del agente
- **Memoria, contexto y estado**
- Sistemas multiagente
- Agentes en producción e integración empresarial



Agenda de la sesión

EBIS Business Techschool

18:30–18:40	Repaso de los deberes
18:40–18:55	El contexto es finito
18:55–19:25	Demo: memoria a largo plazo
19:25–19:40	Actividad: recordar u olvidar
19:40–19:55	Memoria y estado
19:55–20:25	Demo: checkpointing
20:25–20:35	Actividad: diseña la memoria
20:35–20:50	Caso real: memoria visible
20:50–21:00	Cierre: deberes

Repaso de los deberes



EBIS Business Techschool

Nivel base: herramientas que ahorran pasos

EBIS Business Techschool

Antes

- buscar_cliente → solo IDs de pedido
- Una llamada más por cada pedido
- «serum» no encuentra nada

Después

- buscar_cliente_con_pedidos → resumen de cada pedido
- Una sola llamada
- Nombres parciales y opciones si hay varias

Menos pasos: menos tokens y menos errores ($0{,}95^{10} \approx 0{,}60$)

Reto: un recurso MCP

soluciones/sesion3/deber_reto_servidor_mcp.py

```python
@servidor.resource("lumen://politica-devoluciones")
def politica_devoluciones() -> str:
    """Política de devoluciones de Lumen Shop."""
    return ("Devoluciones gratuitas en 30 días..."
            "Más de 50 € requiere supervisor.")
```

1. Las herramientas actúan; los recursos aportan contexto
2. El cliente MCP decide cuándo leerlos
3. Buen puente con el tema de hoy: qué contexto damos al agente

El contexto es finito



EBIS Business Techschool

Más contexto no es mejor contexto

EBIS Business Techschool



Se pierde en el medio

Los modelos atienden peor a lo que queda enterrado en mitad de un contexto largo



Cuesta dinero

Cada vuelta del bucle reenvía todo el historial



Añade latencia

Más tokens de entrada, respuestas más lentas

Referencia: «Lost in the Middle» (Liu et al., 2023)

Context engineering: cuatro estrategias

EBIS Business Techschool

Decidir qué entra en cada llamada al modelo



Escribir

Guardar fuera del contexto: notas, archivos, memoria



Seleccionar

Recuperar solo lo relevante para este paso



Comprimir

Resumir el historial o recortar resultados largos



Aislar

Repartir el trabajo entre subagentes con su propio contexto

Dónde se va el contexto de un agente

EBIS Business Techschool

× N

el historial se reenvía completo en cada una de las N vueltas del bucle

Lo que ocupa espacio

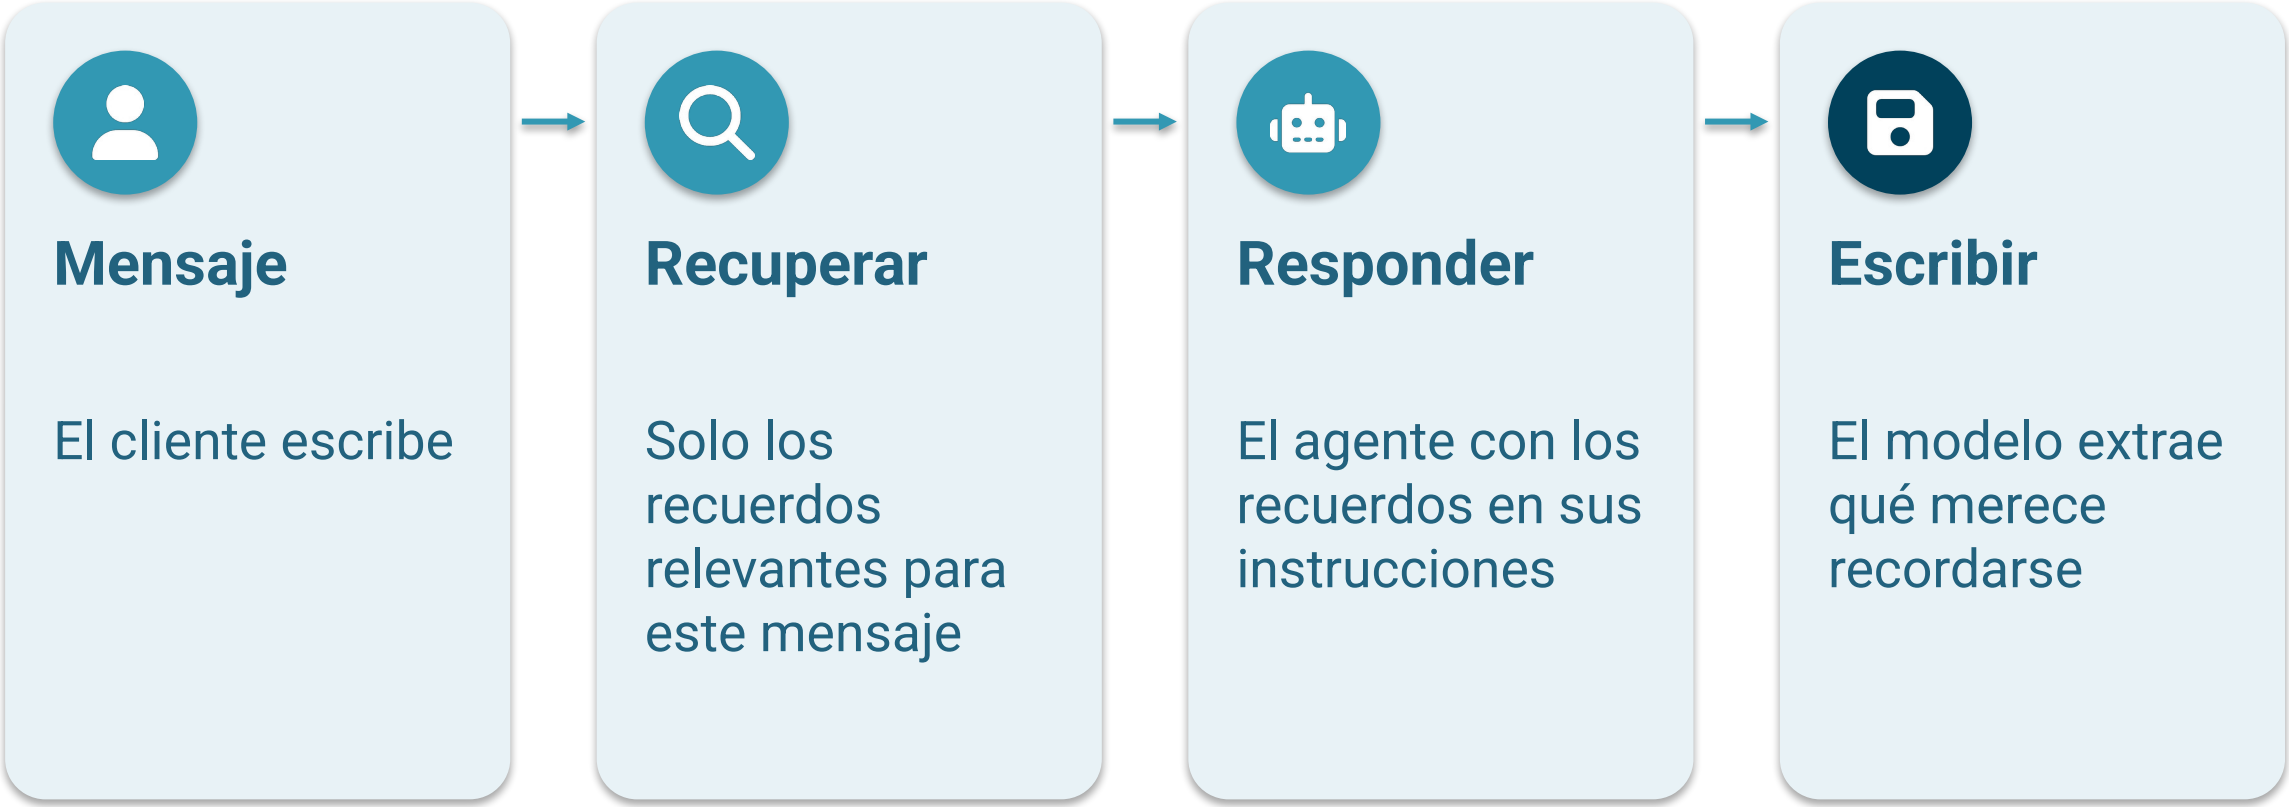
- Instrucciones y descripciones de herramientas
- Cada llamada a herramienta y su resultado
- Resultados largos (JSON, documentos)
- El historial de la conversación

Demo: memoria a largo plazo



EBIS Business Techschool

Leer, responder, escribir



Puntuación de recuperación = similitud con la consulta + recencia

En directo: el agente recuerda

EBIS Business Techschool

EN DIRECTO `sesion4/agente_con_memoria.py`

```
$ python -m sesion4.agente_con_memoria
marta.lopez@email.com "Tengo la piel muy sensible y me
salen rojeces. ¿Qué tal es el sérum?"

$ python -m sesion4.agente_con_memoria
marta.lopez@email.com "¿Qué me recomendáis para el
sol?"

$ python -m sesion4.agente_con_memoria
marta.lopez@email.com --olvidar
```

Qué observar

- Qué memorias se guardan tras la primera conversación
- Qué recuerdos se recuperan en la segunda
- Derecho de supresión en una línea

La puntuación de un recuerdo

sesion4/memoria.py

```
def puntuar(memoria, vector_consulta, ahora):
    dias = (ahora - memoria["fecha"]).days
    recencia = 0.5 ** (dias / vida_media)
    similitud = coseno(vector_consulta,
                       memoria["vector"])
    return 0.7 * similitud + 0.3 * recencia
```

1. La recencia decae a la mitad cada 30 días
2. La similitud viene de los embeddings (Tema 5)
3. El peso de cada factor es una decisión de diseño

Actividad: recordar u olvidar



EBIS Business Techschool

¿Lo guardarías en memoria?

EBIS Business Techschool

ACTIVIDAD · 10 MIN

¿Recordar, no recordar o recordar con condiciones? ¿Por qué?

1. «Prefiero que me enviéis a la oficina»
2. «Mi número de tarjeta es…»
3. «Tengo la piel atópica»
4. «Estoy muy enfadado con vosotros»
5. «Es un regalo para mi madre, que cumple 60»
6. «Compré el sérum en 2024»



Descanso · 5 minutos

Retomamos a las 19:40

Memoria y estado



EBIS Business Techschool

Cuatro tipos de memoria

EBIS Business Techschool



De trabajo

El contexto de la conversación actual



Episódica

Qué pasó en interacciones anteriores



Semántica

Hechos y preferencias del cliente o del dominio



Procedimental

Cómo hacer las cosas: instrucciones y habilidades

Clasificación del marco CoALA, inspirada en la psicología cognitiva

Tres decisiones de diseño

EBIS Business Techschool

Qué guardar

Hechos útiles en el futuro, nunca datos sensibles innecesarios

Cuándo escribir

Durante la conversación o en segundo plano al terminar

Cómo recuperar

Similitud, recencia, importancia

Estado frente a memoria

EBIS Business Techschool

Estado (checkpointing)

- La foto de una ejecución concreta
- Permite pausar y reanudar
- Vive en un hilo (thread)
- Ejemplo: ticket-42 a medio resolver

Memoria a largo plazo

- Lo aprendido entre ejecuciones
- Permite personalizar
- Vive por cliente o por usuario
- Ejemplo: Marta tiene la piel sensible

La memoria también es un dato personal



Si vuestro agente recuerda, tiene que poder olvidar

RGPD: minimización de datos, transparencia sobre qué se guarda y derecho de supresión. Diseñadlo desde el principio.

Demo: checkpointing



EBIS Business Techschool

En directo: retomar, revisar, volver atrás

EBIS Business Techschool

EN DIRECTO `sesion4/checkpointing.py`

```
$ python -m sesion4.checkpointing --hilo ticket-42 "Soy
jorge.ruiz@email.com, ¿cómo va mi pedido?"

$ python -m sesion4.checkpointing --hilo ticket-42 "¿Y
qué producto era?"

$ python -m sesion4.checkpointing --hilo ticket-42 --
historial

$ python -m sesion4.checkpointing --hilo ticket-42 --
volver 2 "Perdona, soy marta.lopez@email.com"
```

Qué observar

- El segundo mensaje recuerda el primero aunque el proceso se cerró
- Cada paso del grafo es un estado guardado
- Desde un estado anterior la conversación se bifurca

Time travel: bifurcar desde un estado anterior



Para qué sirve

- Depurar: reproducir desde el paso que falló
- Corregir un dato sin empezar de cero
- Probar alternativas

Actividad: diseña la memoria



EBIS Business Techschool

La memoria de vuestro agente

EBIS Business Techschool

ACTIVIDAD · 10 MIN



Pensad en un agente de vuestra empresa. Respondemos en voz alta:

1. ¿Qué debería recordar entre conversaciones?
2. ¿Qué no debería recordar nunca?
3. ¿Memoria por usuario, por cliente o compartida?
4. ¿Durante cuánto tiempo?

Caso real: memoria visible



EBIS Business Techschool

Los asistentes de consumo ya recuerdan

EBIS Business Techschool



Visible

El usuario puede consultar qué se recuerda de él



Editable

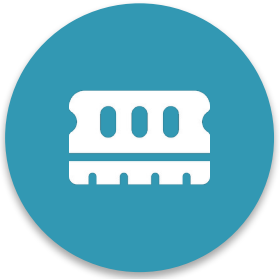
Puede corregir o borrar recuerdos concretos



Desactivable

Puede desactivar la memoria o usar chats sin ella

La memoria se diseña junto con sus controles



La memoria es una función de producto, no solo técnica

Qué se recuerda, cuánto tiempo y quién lo controla son decisiones que afectan a la confianza del cliente.

Cierre: deberes



EBIS Business Techschool

Deberes para la sesión 5

EBIS Business Techschool

NIVEL BASE

Comprime el historial

Cuando la conversación supere un número de tokens (caracteres / 4), sustituye los mensajes antiguos por un resumen y conserva los últimos. Cuidado: no separes una llamada a herramienta de su resultado.

RETO

Memoria con importancia

Haz que el modelo puntúe de 1 a 10 la importancia de cada memoria al guardarla y que la recuperación combine similitud, recencia e importancia.

No evaluables · Los comentamos al inicio de la próxima sesión



EBIS Business Techschool

www.ebiseducation.com