Máster en Ingeniería de Automatización con IA Agéntica

Tema 9. Evaluación y control de la fiabilidad y seguridad en sistemas de agentes

Trabajo previo a clase

Este documento recoge lo que debes preparar antes de cada sesión del tema. Las tareas de deberes no son evaluables: las comentaremos y resolveremos al inicio de la sesión siguiente. Todas se pueden hacer de forma autónoma, también si sigues el máster en modalidad online flexible.

Importante: en clase no se dedica tiempo a instalaciones. Llega a la primera sesión con el entorno comprobado. Si conservas el entorno del Tema 8 (Python y Ollama con qwen2.5:7b), te bastan unos 10 minutos.

Antes de…	Qué hay que preparar	Tiempo
Sesión 1	Preparar el entorno y lectura	≈ 40 min
Sesión 2	Deberes de la sesión 1	≈ 45 min + reto
Sesión 3	Deberes de la sesión 2 y lectura	≈ 1 h + reto

Antes de la sesión 1 · Medir al agente

Tiempo estimado: unos 40 minutos

Obligatorio

- **Prepara el entorno del tema** siguiendo GUIA_INSTALACION.md del repositorio tema9-fiabilidad: entorno virtual nuevo, dependencias y el mismo modelo del Tema 8 (qwen2.5:7b en Ollama). Si tu ordenador no puede ejecutar el modelo local, la guía explica cómo usar un proveedor en la nube.
- **Comprueba que todo funciona** con python comprobar_entorno.py. Debe terminar con «Todo listo para el Tema 9». Si algo falla, revisa la tabla de problemas frecuentes de la guía; si no lo resuelves, consúltalo con tu tutor antes de la clase.
- **Lee la introducción de «τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains»** (Yao, Shinn, Razavi y Narasimhan, 2024). Fíjate en la métrica pass^k: la veremos en la primera hora.

Opcional

- Si montaste la demo tema8-mlflow del Tema 8, puedes conservarla: en la sesión 3 los tickets del agente también se pueden ver en MLflow, aunque no es necesario.

Dónde está el material: repositorio tema9-fiabilidad en el campus y enlace a la lectura en el documento de deberes y lecturas.

Antes de la sesión 2 · Fallos, guardarraíles y seguridad

Tiempo estimado: unos 45 minutos, más el reto si lo haces

Obligatorio

- **Deber base: amplía el conjunto de pruebas.** Añade cuatro casos a sesion1/casos.json, al menos uno de cada categoría, y la métrica coste por caso resuelto. Compárala con el coste por caso.

- **Piensa la respuesta a esta pregunta:** si el agente acierta el 80 % de los casos en un intento, ¿lo pondrías ya en producción? ¿Qué más necesitas saber?

Opcional

- **Reto: calibra el juez** con las diez respuestas de sesion1/etiquetas_humanas.json: acuerdo con la persona y respuestas malas aprobadas.

Dónde está el material: enunciados completos en sesion1/README.md.

Antes de la sesión 3 · Observabilidad, supervisión y mejora continua

Tiempo estimado: alrededor de 1 hora, más el reto si lo haces

Obligatorio

- **Deber base: guardarraíl antiinvención.** Convierte el detector de alucinaciones en un guardarraíl de salida que, ante un dato sin respaldo, sustituya la respuesta por una segura.
- **Lee el OWASP Top 10 para aplicaciones LLM 2025** (al menos LLM01, LLM02, LLM06 y LLM07) y piensa qué riesgo no cubre todavía nuestro agente.

Opcional

- **Reto: sigue la procedencia.** En cuanto el agente lea contenido de terceros, bloquea las herramientas irreversibles en esa conversación.

Dónde está el material: enunciados completos en sesion2/README.md; enlace a la lectura en el documento de deberes y lecturas.

Después de la última sesión

Los deberes finales del tema están en sesion3/README.md: un nivel base (alertas), un reto (cerrar el ciclo de mejora continua) y un proyecto opcional (el informe de fiabilidad de tu propio agente), que es una buena base para el Trabajo Fin de Máster. Las soluciones se publican en el campus.

El cuestionario tipo test del tema estará disponible en el campus.